DOI：10.13334/j.0258-8013.pcsee.213110 文章编号：0258-8013 (2022) 14-5034-11 中图分类号：TM 73 文献标识码：A

多时间尺度的配电网深度强化学习无功优化策略

胡丹尔[1]，彭勇刚[1*]，韦巍[1]，肖婷婷[1]，蔡田田[2]，习伟[2]

(1. 浙江大学，浙江省 杭州市 310027；2. 南方电网数字电网研究院有限公司，广东省 广州市 510663)

Multi-timescale Deep Reinforcement Learning for Reactive Power Optimization of Distribution Network

HU Daner[1], PENG Yonggang[1*], WEI Wei[1], XIAO Tingting[1], CAI Tiantian[2], XI Wei[2]

(1. Zhejiang University, Hangzhou 310027, Zhejiang Province, China;

2. Digital Grid Research Institute, China Southern Power Grid, Guangzhou 510663, Guangdong Province, China)

ABSTRACT: With the access of high proportion distributed generation, distributed network faces tremendous challenges in dealing with uncertainty and coordinating a variety of reactive power compensation equipment. This paper presented a multi-timescale voltage regulation strategy based on a mathematical optimization model and data-driven method. First, for the online tap changer and switching capacitor with slow-timescale regulation, Aiming to minimize active power loss, the day ahead reactive power and voltage optimization model were proposed based on mixed-integer second-order cone programming. Second, to meet the real-time requirements on the fast timescale stage, an intraday real-time scheduling method based on multi-agent reinforcement learning was proposed, transforming the real-time reactive power optimization problem into a Markov game process and adopting a centralized training and decentralized execution framework. Compared with traditional methods, this method has low communication cost, better real-time performance, and does not rely on an accurate power flow model. Finally, the effectiveness of the proposed strategy is verified by an IEEE 33-bus example.

KEY WORDS: voltage control; deep reinforcement learning; multi-agent; Markov process; data-driven

摘要：随着高比例分布式电源的接入，配电网在应对源荷不确定性和协调多种无功补偿设备等方面面临较大挑战。该文提出一种基于优化数学模型与数据驱动方法相结合的配电网多时间尺度电压调节策略。该策略首先针对长时间尺度调节的有载调压变压器和电容器组，以最小化有功功率损耗为目标，建立基于混合整数二阶锥规划的日前无功电压优化模型。其次，为满足短时间尺度调度对于实时性的要求，提出一种基于多智能体强化学习的日内实时调度方法，将实时无功优化问题转化为马尔科夫博弈过程，并采用集中训练、分散执行框架。与传统方法相比，该方法通信开销低、实时性强并且不依赖于精确的潮流模型。最后，通过 IEEE 33 节点算例验证所提策略的有效性。

关键词：电压控制；深度强化学习；多智能体；马尔科夫过程；数据驱动

0 引言

近年来，为应对日益加剧的能源危机、环境问题以及充分响应国家“双碳”目标，配电网中以风光等可再生能源为主的分布式电源(distributed generation，DG)的渗透率逐渐提高，源荷的不确定性以及可调控资源的多样性使得配电网呈现出状态多样、结构灵活和运行控制复杂的特点,为配电网经济安全可靠运行带来巨大的挑战[1-3]。传统配电网无功电压优化通过控制配电网中无功调节设备如有载调压变压器(on-line tap changer，OLTC)、分组投切电容器(switching capacitor，SC)、静止无功补偿装置(static var compensator，SVC)等，达到稳定系统节点电压、减小运行网损的目标，是保证配电网电能质量以及运行经济性的重要手段。风光等 DG 的大规模接入给电网运行带来巨大挑战的同时，其基于逆变器的并网特点也赋予 DG 参与无功调节的潜力，并且具有快速响应、连续调节的优势。因此，将风机、光伏等 DG 与传统的无功调节设备相结合共同参与无功优化，对配电网安全经济运行、降低配电网无功补偿设备投资具有重要意义[4]。

大多数配电网无功优化模型包含大量的不同

基金项目：国家重点研发计划项目(2020YFB0906000，2020YFB0906002)。

National Key R&D Program of China (2020YFB0906000, 2020YFB0906002).

结构变量和非线性约束，属于复杂非线性规划问题。目前，基于模型的无功优化方法严重依赖于精确的电力系统潮流模型与预测数据。根据通信方式的不同，优化方式通常可分为集中式、分布式和分散式 3 种方式。集中控制下的无功优化问题使用的常用算法包括混合整数线性规划[5]、锥松弛规划[6]和进化算法[7]。分布式无功优化算法允许相邻节点共享信息并通过协作以实现全局目标，如交替方向乘子法[8]和对偶分解法[9]。分散式无功优化方法能够加快控制速度，具体包括准实时无功优化等[10]。这些基于物理模型的优化方法大多高度依赖于电力系统的模型，并且算法的计算复杂度会随着配电网拓扑规模和可控设备数量的增加呈指数级增长。同时配电网具有的不确定性和 DG 逆变器、投切电容器组等多种无功设备时间尺度和调控方式等方面的差异使得无功优化面临维数高、建模困难和求解缓慢的问题，如何提高实时性和最优性成为配电网无功优化研究的热点。

因此，国内外学者开始尝试依靠无模型和数据驱动的相关技术来解决以上问题。其中基于人工智能技术的优化方法在配电网无功优化中得到了广泛应用。数据驱动的方法能够用于解决模型不完整的问题，并利用可测量数据训练神经网络模型并学习最优调度结果[11-12]。有大量研究在无功优化领域使用了强化学习(reinforcement learning，RL)算法。在这些研究中，基于深度强化学习的无功优化方法在改进学习性能方面表现出了优越性。文献[13]利用表格 Q–学习算法在满足操作约束的同时学习一组控制动作进行无功优化，但该算法在处理具有大规模数据空间任务时十分低效。文献[14]使用深度 Q 网络(deep Q learning，DQN)优化电容器投切，并在短时间尺度下调节电压偏差，但该算法只能用于处理离散动作控制问题。文献[15]提出一种深度确定性策略梯度(deep deterministic policy gradient，DDPG)算法，以缓解由电力系统中不确定性引起的电压越限问题。以上强化学习算法都是将无功调节装置统一视为单一智能体来解决无功优化问题，然而单一智能体难以直接应用于更大规模的配电网系统中。因此，采用基于多智能体深度强化学习(multi-agent deep reinforcement learning，MADRL)能够赋予多种调节设备独立决策的能力，从集中式转为分散式决策，从而可以更高效协调多种无功调节设备，以提高配电系统的灵活性和可靠性。文献[16]利用多智能体 DQN 框架进行无功优化，该框架将电容器和智能逆变器的状态/比率视为动作变量，有效减小了配电网网损。文献[17]同时考虑离散和连续调节设备，在部分可观测配电网中提出一种在线无功优化运行策略，但该文提出的方法仅把其他智能体当作环境的一部分，而未考虑多智能体相互协调优化作用。

综上所述，为充分发挥分布式电源的无功调节能力，针对传统无功优化难以同时快速处理不同时间尺度和调节速度设备的不足，本文将具有实时连续调节能力的风光、SVC 与较长时间尺度的 OLTC、SC 等离散设备结合，提出了一种多时间尺度配电网无功优化策略。首先，在第一阶段日前集中式优化框架下，以小时为调度动作周期，利用混合整数二阶锥规划(mixed-integer second-order cone programming，MISOCP)最小化网络有功损耗。第二阶段以分钟级调度周期，基于多智能体深度确定性策略梯度(multi-agent deep deterministic policy gradient，MADDPG)算法训练具有连续调节功能的设备。训练过程中通过多个智能体之间协调优化实现在线无功优化。与基于模型的优化算法相比，该方法不需要精确完整的配电网物理模型，具有更好的可扩展性；基于离线集中训练和在线分散执行的框架，智能体只需通过观测本地状态给出决策，无需复杂的通信设备，并且具有更好的实时性能。最后，利用 IEEE 33 节点算例仿真验证了所提多时间尺度优化策略的可行性。

1　多时间配电网尺度无功电压控制策略

传统集中式模型预测控制优化方法高度依赖于通信和计算性能，缺乏快速解决电压越限问题的能力[18]。相比之下，本文提出一种结合数据驱动的多时间尺度电压控制策略，在减轻电压越限的同时，最大限度地减少实时的线路损耗。所提出的多时间尺度无功优化框架如图 1 所示。

在多种调节设备协同参与无功优化的情景中，需要考虑不同设备调节和响应速度不同的问题[19-20]。OLTC 和 SC 等离散调节设备属于慢动作设备，投切指令的时间间隔不宜过短；光伏、风机逆变器和 SVC 等属于快速连续调节设备，调节的时间可以短到分钟级甚至秒级[21]。

第一阶段在中央控制器中计算最优潮流结果，结合小时级(1h)的光伏和负荷预测数据获取 OLTC

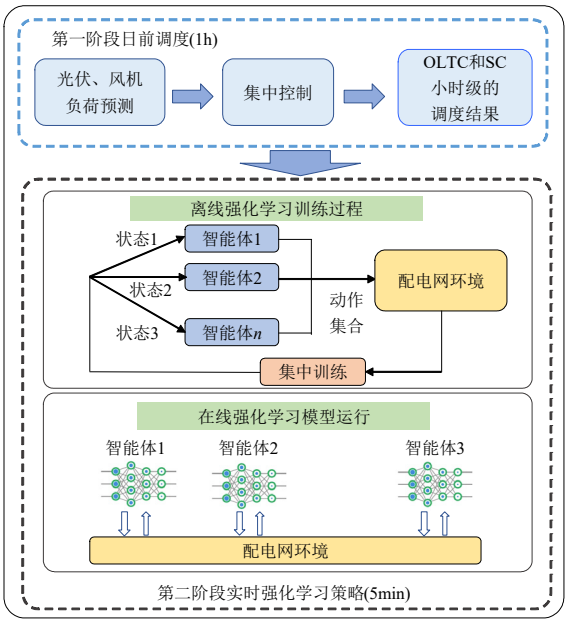


图 1 多时间尺度配电网无功电压控制策略示意图

Fig. 1 Diagram of two timescale volt/var optimization of distribution

和 SCs 的调度结果。该结果将被发送给日内优化的强化学习智能体，并视为智能体控制器的输入。在短时间尺度中以 5min 为调度周期，首先基于多智能体 MADDPG 深度强化学习方法对智能体进行离线训练学习获得最优电压控制策略。之后将训练完成的策略部署于各智能体中，智能体在实时调节时根据本地量测的观测值进行光伏、风机、SVC 的无功功率调节，以缓解配电网中的电压越限问题并降低网损。

2 第一阶段集中优化

日前的集中优化在第一阶段进行，按一小时的时间间隔调度 OLTC 和 SCs。以配电网中的总功率损耗最小为目标，建立如下的优化模型：

$$\min \sum_{t\in T}\sum_{ij\in L} l_{ij,t} r_{ij} \tag{1}$$

$$\begin{cases} P_{\mathrm{PV}j,t}+P_{\mathrm{WT}j,t}-P_{\mathrm{L}j,t}=\sum\limits_{v\in j}(P_{jv,t}+l_{jv,t}r_{jv})-\sum\limits_{i\in j}P_{ij,t} \\ Q_{\mathrm{PV}j,t}+Q_{\mathrm{WT}j,t}+Q_{\mathrm{SC}j,t}-Q_{\mathrm{L}j,t}= \\ \quad \sum\limits_{v\in j}(Q_{jv,t}+l_{jv,t}x_{jv})-\sum\limits_{i\in j}Q_{ij,t} \end{cases} \tag{2}$$

$$u_{i,t}=u_{j,t}+2(P_{ij,t}r_{ij}+Q_{ij,t}x_{ij})+l_{ij,t}(r_{ij}^2+x_{ij}^2) \tag{3}$$

$$\left\| \begin{matrix} 2P_{ij,t} \\ 2Q_{ij,t} \\ l_{ij,t}-u_{j,t} \end{matrix} \right\|_2 \le l_{ij,t}+u_{j,t}, \forall ij\in L \tag{4}$$

$$\begin{cases} U_{\min}^2 \le u_{j,t} \le U_{\max}^2 \\ u_{1,t}=(U_0+\delta_{\mathrm{oltc},t}\cdot\Delta U)^2 \end{cases} \tag{5}$$

$$\begin{cases} \sum\limits_{t=1}^{T}\left|s_{iv,t+1}-s_{iv,t}\right| \le s_{iv,\max} \\ Q_{\mathrm{SC}i,t}=\sum\limits_{v} s_{iv,t}q_{i,t} \end{cases} \tag{6}$$

$$\sum_{t=1}^{T}\left|\delta_{\mathrm{oltc},t+1}-\delta_{\mathrm{oltc},t}\right| \le \delta_{\mathrm{oltc},\max} \tag{7}$$

$$\begin{cases} \left|Q_{\mathrm{PV}i,t}\right| \le \sqrt{S_{\mathrm{PV}i,t}^2-P_{\mathrm{PV}i,t}^2} \\ \left|Q_{\mathrm{WT}i,t}\right| \le \sqrt{S_{\mathrm{WT}i,t}^2-P_{\mathrm{WT}i,t}^2} \end{cases} \tag{8}$$

式(1)—(4)为基于二阶锥规划的潮流约束；T 为调度周期的集合；L 为配电网分支集合；$l_{ij,t}=|I_{ij,t}|^2$，其中 $I_{ij,t}$ 为支路 ij 在 t 时刻的电流；$P_{\mathrm{PV}j,t}$、$P_{\mathrm{WT}j,t}$、$P_{\mathrm{L}j,t}$ 分别为节点 j 在 t 小时内的光伏、风机、负荷有功功率值；$Q_{\mathrm{PV}j,t}$、$Q_{\mathrm{WT}j,t}$、$Q_{\mathrm{SC}j,t}$、$Q_{\mathrm{L}j,t}$ 分别为节点 j 在 t 小时内的光伏、风机、SC、负荷无功功率值；P_{ij}、Q_{ij} 即节点 i 流向节点 j 的有功功率和无功功率；式(5)中 $U_{\min}^2$ 和 $U_{\max}^2$ 表示节点电压平方的上下限；$\delta_{\mathrm{oltc},t}$ 表示抽头的位置，假定母线处变压器的一次电压 U_0 为 1.0pu，每次抽头调节补偿ΔU 为 0.01pu。式(6)和(7)表示 OLTC 和 SC 的运行约束，由于设备的机械特性和使用寿命限制，设备的日调节次数有限，$s_{iv,\max}$ 表示第 v 个电容器的最大动作次数，$q_{i,t}$ 表示电容器投切一次的无功功率输出。式(8)是光伏和风机的无功出力约束，$S_{\mathrm{PV}j,t}$ 和 $S_{\mathrm{WT}i,t}$ 分别表示光伏和风机逆变器的视在功率值。为了减少原始公式的非线性，约束条件式(5)—(7)将用线性化方法转化为式(9)—(11)。

$$\begin{cases} U_{\min}^2 \le u_{i,t} \le U_{\max}^2 \\ \delta_{\mathrm{oltc},t}=\sum\limits_{d=0}^{2\bar{\delta}}(d-\bar{\delta})\lambda_{d,t} \\ u_{1,t}=\sum\limits_{d=0}^{2\bar{\delta}}[(U_0+(d-\bar{\delta})\Delta U)^2\lambda_{d,t}] \\ \sum\limits_{d=0}^{2\bar{\delta}}\lambda_{u,t}=1 \end{cases} \tag{9}$$

$$\begin{cases} \delta_{\mathrm{oltc},t+1}-\delta_{\mathrm{oltc},t} \le \varphi_t \\ \delta_{\mathrm{oltc},t}-\delta_{\mathrm{oltc},t+1} \le \varphi_t \\ \sum\limits_{t=1}^{T}\varphi_t \le \delta_{\mathrm{oltc},\max} \end{cases} \tag{10}$$

$$\begin{cases} y_{iv,t}=c_{ia,t}+c_{ia,t+1}-2x_{ia,t} \\ x_{ia,t}\le c_{ia,t}, x_{ia,t}\le c_{ia,t+1}, x_{ia,t}\ge c_{ia,t}+c_{ia,t+1}-1 \\ \sum\limits_{t=1}^{T}y_{iv,t}\le c_{iv,\max} \\ Q_{\mathrm{SC}i,t}=\sum\limits_{v} c_{iv,t}q_{i,t} \end{cases} \tag{11}$$

式(9)中，$\bar{\delta}=5$是最大的抽头调节步长，其中$\delta_{\mathrm{oltc},t}$可以在[−5,5]区间变化，通过引入二进制变量$\lambda_{d,t}$来描述；式(10)中，φ_t是一个整数变量，表示在相邻两个调度时间间隔 OLTC 分接头的位置的不同，$y_{iv,t}$是二进制变量，表示在节点 i 处的第 v 个电容器在时间 t~t+1 是否产生变化。$x_{ia,t}=c_{ia,t}\cdot c_{ia,t+1}$为引入的二进制变量，重新整理后的式(1)—(4)和式(8)—(11)可以被看作一个 MISOCP 模型，用商业求解器 GUROBI 进行求解。

3　基于多智能体强化学习的电压控制策略

3.1　多智能体强化学习

多智能体强化学习是指多个具有自我控制能力、能够相互作用的智能体，在同一个环境中通过传感器感知状态，执行操作的过程，其算法框架如图 2 所示。智能体与外部环境之间交互以实现强化学习训练，首先智能体根据自己所感知的环境状态来选择动作以对环境做出响应，然后通过观测该动作所获得的结果进行策略调整，最后通过训练完成的智能体动作选择策略对环境做出最优的反应，来使其获得最大的奖励值。单智能体强化学习一般需要通过马尔科夫过程(markov decision process，MDP)来对其进行描述，而多智能体在强化学习中则需要用马尔可夫博弈过程(markov game process，MGP)来对其进行描述，也被称为随机函数博弈[22]。一个典型的多智能体马尔可夫博弈可以描述成元组〈N,S,a_1,a_2,…,a_N,P,γ,r_1,r_2,…,r_N〉，其中：N 为智能体的个数；S 为系统状态；[a_1,a_2,…,a_N]为智能体的动作集合；P 表示状态转移函数，P:$S\times a_1\times a_2,\ldots,a_N\times S\rightarrow[0,1]$，即根据当前系统状态 s 和联合动作 $\boldsymbol{a}$=[a_1, a_2,…,a_N]，给出下一个状态出现的概率；γ是折扣因子，保证越后面的奖励对奖励函数的影响越小，包含对未来奖励的不确定性。$r_m(s_\tau,a_1,\ldots,a_N,s_{\tau+1})$表示智能体 m 在状态 s_τ时，执行联合动作所得到的奖励 r_m，奖励函数一般根据具体的环境和学习目标设计。每个智能体都有一个核心目标，即最大化折扣回报。用期望的形式表示为

$$\max_{\pi_m} \underset{\substack{a_{m,\tau}\sim\pi_m \\ s_{\tau+1}\sim p(s_{\tau+1}|s_\tau,a_\tau)}}{E} [\sum_{\tau=0}^{T}\gamma_\tau r_{m,\tau}] \tag{12}$$

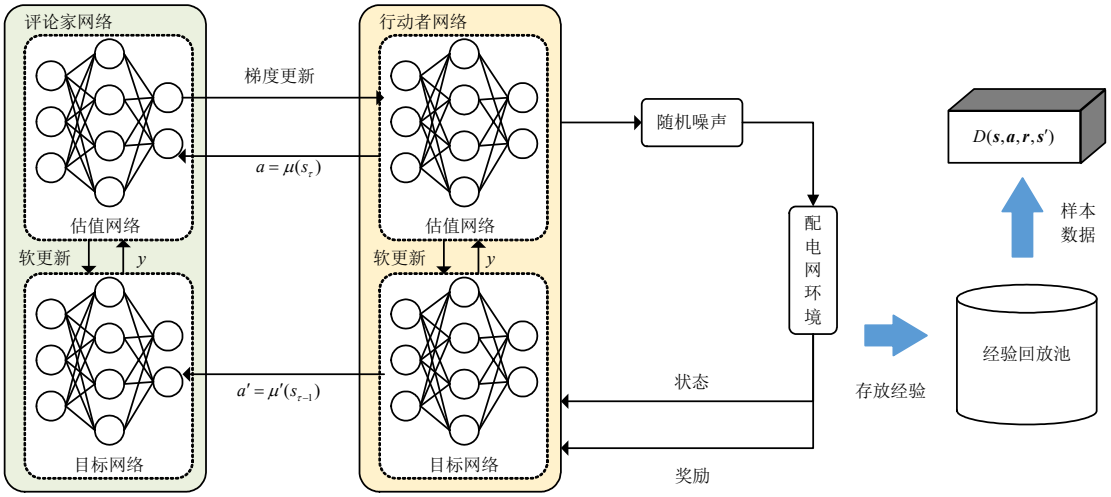


图 2　MADDPG 算法神经网络结构

Fig. 2　Neural network structure of MADDPG algorithm

Actor-Critic 框架下的 MADRL 需要同时学习一个策略和一个值函数，可以用于解决多个智能体交互的问题。在每次交互时，智能体将根据自己的策略网络选择一个动作。训练迭代步骤可以描述成以下过程：智能体根据观察到的状态 s 给出策略$\pi_\tau=(a_\tau|s_\tau)$。配电网在收到智能体的动作决策信息以后，将再次计算配电网潮流结果并向每个智能体返回更新的状态。Actor 网络可以指导智能体如何选择行动，而 Critic 网络则被用来评估这一行动的回报。Actor 网络的参数通常基于 Critic 给出的回报，并通过基于梯度下降的方法完成更新[23]。

3.2　深度确定性策略梯度算法

传统强化学习算法中存在一个共性的问题，即由于每个智能体的策略都会被更新和迭代，所以对于一个特定的智能体来说，环境是动态不稳定的。而在某种程度上，仅靠改变智能体自身的策略，不可能适应动态的不稳定环境。由于环境的不稳定，多智能体问题不能直接使用以往的经验回放等 DQN 技巧。为了应对上述情况，MADDPG 提出一个策略集的思想，它可以使每个智能体的策略集的

整体奖励最大化。

若 MADDPG 算法包含 N 个智能体，其包含 N 个策略网络 $\pi=\{\pi_1,\ldots,\pi_N\}$ 和 N 个 Critic 网络，其中策略网络参数为 $\theta=\{\theta_1,\ldots,\theta_N\}$。在深度神经网络训练过程中，第 m 个智能体的策略梯度可以表示为

$$\nabla_{\theta_m} J(\theta_m)=\underset{\substack{s\sim p\\ a_m\sim\pi_m}}{E}[\nabla_{\theta_m}\log\pi_m(a_m|s_m)Q_m^{\pi}(s,a_1,...,a_N)] \tag{13}$$

式中：s 为整个环境的信息；$Q_m^{\pi}(s,a_1,...,a_N)$ 为第 m 个中心化的价值函数，其输入是每个智能体基于策略网络 $\pi=\{\pi_1,\ldots,\pi_N\}$ 采取的动作 a_m 以及环境信息 s，其输出为第 m 个智能体的 Q 值。MADDPG 算法为了加快模型的收敛，提高算法的效率，采用深度确定性策略，即用 μ_m 表示成第 m 个智能体的策略，则智能体 m 的梯度可以描述成：

$$\nabla_{\theta_m} J(\mu_m)=\underset{s,a\sim D}{E}[\nabla_{\theta_m}\mu_m(a_m\mid s_m)Q_m^{\mu}(s,a_1,\cdots,a_N)\mid\cdot \\ a_m=\mu_m(s_m)] \tag{14}$$

式中 $D(s,a,r,s_{\tau+1})$ 表示经验回放池，智能体训练的样本将被存入经验回放池中，其中 $a=\{a_1,\ldots,a_N\}$，$r=\{r_1,\ldots,r_N\}$。智能体与环境交互过程中，Critic 网络的损失函数定义为：

$$L(\theta_m)=\underset{s,a,r,s_{\tau+1}}{E}\{[Q_m^{\mu}(s,a_1,\ldots,a_N)-y^2)]\} \tag{15}$$

$$y=r_m+\gamma Q_m'(s_m,a_1',\ldots,a_N')\mid_{a_m'=\mu_m'(s_m)} \tag{16}$$

MADDPG 采用了目标网络技术来稳定 Actor 网络和 Critic 网络训练过程，其中 $\mu'=\{\mu_{\theta_1'},...,\mu_{\theta_N'}\}$ 表示目标网络的 Actor 网络，第 m 个目标网络的 Actor 网络参数为 θ_k'，智能体目标网络的第 m 个 Critic 网络为 Q_m'。Critic 网络的参数随着训练不断调整更新，目标网络则不参与训练过程，其参数会根据估值网络的参数进行迭代更新直到结果收敛，整个训练的框图如图 2 所示。图中所示的深度神经网络结构主要有 3 个部分组成：1）卷积神经网络用来提取关键特征；2）Actor 网络可以拟合状态到动作的映射；3）Critic 网络可以拟合状态价值函数。

3.3 实时电压控制马尔科夫博弈过程设计

在实时无功优化问题中，可将配电网视为环境，同时风光设备的逆变器和 SVC 被自然定义为具备与环境交互能力的智能体。本问题中定义配电网的实时可量测信息为状态空间 S，第二阶段实时无功电压控制装置的调度指令集合为动作空间 A，从而将原本的无功优化问题转化为马尔科夫博弈过程。

定义智能体 m 在第 τ 时刻的状态观测为 $s_{m,\tau}\in S$，其中包括量测得到的节点电压向量 U_τ、OLTC 在 τ 时刻的档位 $\delta_{\mathrm{oltc},t}$ 和 SC 投切的无功功率值 $Q_{\mathrm{SC}v,\tau}$，记作 $s_{m,\tau}=[U_\tau,\ \delta_{\mathrm{oltc},t},\ U_{\mathrm{SC}v,\tau}]$。$N$ 个多智能体第 τ 时刻状态集合 $s_\tau=[s_{1,\tau},\ s_{2,\tau},\ldots,s_{m,\tau},\ldots,s_{N,\tau}]$。

短时间尺度下，要求无功设备具备实时连续可调能力，在目前以可再生能源为主的分布式发电广泛接入配电网的背景下，为充分挖掘逆变器快速灵活的无功功率支撑能力，本文将风光逆变器结合 SVC 设备纳入实时无功调节资源。因此，定义智能体 m 在 τ 时刻的动作为 $a_{m,\tau}\in A$，其中包括光伏和风机逆变器智能体、SVC 智能体的无功出力值：$a_{m,\tau}=[a_{\mathrm{PV},m}^{\tau},a_{\mathrm{WT},m}^{\tau},a_{\mathrm{SVC},m}^{\tau}]$。$N$ 个智能体第 τ 时刻动作集合 $a_\tau=[a_{1,\tau},\ a_{2,\tau},\ldots,a_{m,\tau},\ldots,a_{N,\tau}]$。

对于运行在节点 j 上的 DG，该 DG 逆变器在节点 j 处提供或吸收的无功功率可表示为以下约束：

$$\underline{Q}_{\mathrm{DG},j}^{\tau}\le Q_{\mathrm{DG},j}^{\tau}\le\overline{Q}_{\mathrm{DG},j}^{\tau} \tag{17}$$

$$\underline{Q}_{\mathrm{DG},j}^{\tau}=-\overline{Q}_{\mathrm{DG},j}^{\tau} \tag{18}$$

式中：$\overline{Q}_{\mathrm{DG},j}^{\tau}$ 为在 τ 时刻时，节点 j 上 DG 的最大无功功率，其值满足 $\overline{Q}_{\mathrm{DG},j}^{\tau}=\sqrt{(S_{\mathrm{DG},j}^{\tau})^2-(P_{\mathrm{DG},j}^{\tau})^2}$，其中 $P_{\mathrm{DG},j}^{\tau}$ 为 DG 的有功功率出力；$S_{\mathrm{DG},j}^{\tau}$ 为 DG 的视在功率。据此可定义 DG 智能体的无功出力值为 $Q_{\mathrm{DG},j}^{\tau}=a_{\mathrm{DG}}^{\tau}\overline{Q}_{\mathrm{DG},j}^{\tau}$，其中动作 $a_{\mathrm{DG}}^{\tau}\in[-1,1]$。

在学习过程中，多智能体将基于当前的状态 s 和最新动作 a 的共享观察结果来选择最优动作或者向环境提供新的控制动作，交互过程中电网运行约束将自然满足。配电网实时无功电压控制旨在通过合理规划配电网内无功调节资源，在日前调度的基础上进一步降低网损、提高电压质量，因此目标函数可定义为如下系统无功调度成本函数：

$$\mathrm{Min}\ F=\sum_{\tau}^{T}(C_{\mathrm{loss}}P_{\mathrm{Loss},\tau}+C_\beta V_{r,\tau}) \tag{19}$$

$$V_{r,\tau}=\sum_{(j\in\boldsymbol{L})}[\mathrm{ReLU}^2(\underline{U}-U_{j,\tau})+\mathrm{ReLU}^2(U_{j,\tau}-\overline{U})] \tag{20}$$

式中：P_{Loss} 为配电网中线路的损耗之和；C_{Loss} 为边际网损系数；C_β 为电压越限附加成本系数；$V_{r,\tau}$ 为节点电压越限量；$\overline{U}$ 和 $\underline{U}$ 为系统中电压安全运行的上、下限；ReLU 为线性整流函数，定义为 $\mathrm{ReLU}=\max(0,x)$。

定义智能体 m 在第 τ 时刻的观测奖励为 $r_{m,\tau}$，N 个智能体第 τ 时刻奖励集合 $r_\tau=[r_{1,\tau},\ r_{2,\tau},\ldots,r_{m,\tau},\ldots,$

$r_{N,\tau}$]，每个智能体通过共享合作的方式协调处理无功优化问题。强化学习算法以最大化奖励为目标，因此本文在将目标函数转化成强化学习马尔科夫决策过程中的单步奖励时，设计为目标函数的相反数，如式(21)所示：

$$r_{m,\tau} = -C_{\text{loss}} P_{\text{Loss},\tau} - C_{\beta} V_{r,\tau} \tag{21}$$

智能体在与环境交互时将最大化该奖励，即使得无功调度下系统运行成本最低。

4　算例分析

4.1　算例系统介绍

本文仿真测试基于硬件平台 NVIDIA GTX 2080Ti Intel(R) Core(TM) i7-7700K CPU 实现；软件系统为 ubuntu18.04(Linux)；强化学习算法均基于 Python 3.7.6 的 Pytorch 1.2.0 神经网络框架训练实现。

算例对 IEEE 33 节点配电网系统进行改动，且保证原有的系统的线路参数不变。在系统中节点 16、20、31 分别加装 SC。设每个 SC 每日动作次数上限是 5 次，具有 3 个档位，每档为 0.1MVar，总容量为 0.2MVar。OLTC 的可调节比例为 0.95pu~1.05pu，分接头共有 11 个调节挡位，设 OLTC 每天动作次数上限为 4 次。风电机组安装在节点 25 和 33，容量均为 0.5MW，光伏安装于节点 13、18 和 22，每个节点安装的容量均为 0.5MW。在系统中节点 11、29 分别加装 SVC，其可调容量范围均为 –0.4MVar~0.4MVar。边际网损系数 C_{Loss} 在强化学习训练过程中取值为 450$/(MW·h)，同时电压越限附加成本系数 C_{β}在本问题中取值为 1000$/pu^2。改进后的系统拓扑架构如图 3 所示，系统中各设备参数如表 1 所示。

选取浙江某地区半个月的分布式光伏、风机的实际数据用于验证本文所提策略的有效性。在实时强化学习策略中，数据被分为训练集和测试集，并随机挑选 10 天的数据作为强化学习的训练集，其余 5 天数据作为测试集，取调度周期为 24 h，决策

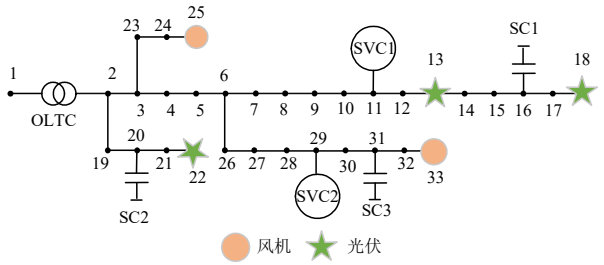


图 3　改进后的 IEEE-33 配电网算例系统

Fig. 3　Improved IEEE-33 distribution network system

表 1　IEEE 33 节点配电网电压调节装置参数

Table 1　Parameters of voltage regulation devices in IEEE 33-bus system

设备	参数	运行限制	安装节点
OLTC	±5×1%	4	1
SC	3×0.1MW	5	16、20、31
PV	0.5MW	—	13、18、22
WT	0.5MW	—	25、33
SVC	–0.4~0.4Mvar	—	11、29

间隔时长为 5min。测试集的光伏、风机日前预测曲线见附图 A1、A2。负荷预测曲线基于原始的 IEEE33 节点算例的空间负荷分布得到，负荷变化率见附图 A3。强化学习智能体通过离线学习的方式协作学习无功电压控制策略，将训练完成的 MADDPG 模型于测试集数据测试，以分析模型的性能和效果。设定 IEEE 33 配电网系统的根节点电压为 1.00pu，每个节点电压的安全运行范围应在 0.95pu 和 1.05pu 之间。每个训练的智能体的 Actor 和 Critic 网络结构相同，包括一个输入层、三个隐藏层和一个输出层。多智能体深度强化学习算法基于 Python 中的 Pytorch 框架搭建，训练通过算法程序与仿真环境的接口交互来完成。MADDPG 网络结构以及超参数详如表 2 所示。

表 2　Actor 和 Critic 网络结构以及超参数设定

Table 2　Structure and hyperparameters of Actor and Critic networks

参数	Critic 网络	Actor 网络
网络层数	5	5
学习率	0.01	0.001
折扣因子	0.99	0.99
隐藏层激活函数	ReLU 函数	ReLU 函数
输出层激活函数	双曲正切函数	双曲正切函数
每层神经元个数	256	256
训练最大回合数	288	288
训练总步长	100,000	100,000
经验回放池规模	10,000	10,000

4.2　第一阶段 SOCP 优化结果

在日前调度阶段，利用所提出的 SOCP 方法进行优化可得到 OLTC 和 SC 的调度的结果，如图 4 所示。可以看出，OLTC 分接头大多时间位于第 6 个档位，共动作 4 次，满足每日最大调节次数。由图 4 可得出，在多数时间内，SC3 比 SC1 和 SC2 提供更多的无功功率。这是由于节点 31 处的负荷无功高于节点 16 和 20 处的负荷无功，所以 SC3 将提供更多的无功功率补偿，以帮助最大限度地减少

网络有功功率损失，缓解电压越限。SC1、SC2 和 SC3 的动作次数在结果中显示分别为 5、1、4，都在本文设定的运行最大限制范围内。

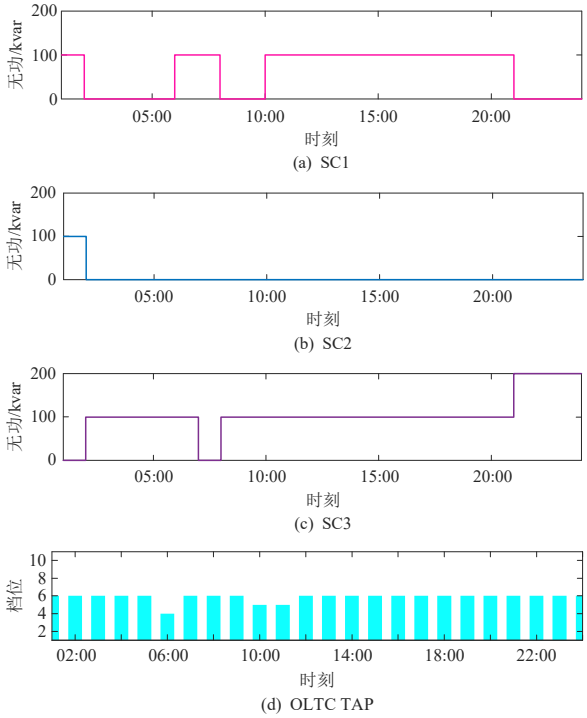


图 4 OLTC 和 SCs 日前调度优化结果

Fig. 4 Optimization results of OLTC and SCs in day-ahead dispatch

4.3 深度强化学习策略分析

4.3.1 训练过程

深度强化学习的过程需要在智能体与环境进行交互的情况下完成训练。在本算例中设计并搭建了 MATLAB 仿真环境来代替深度强化学习实际配电网的环境，通过计算潮流的方式来代替训练过程中的无功优化环境。多智能体强化学习训练对采集的数据进行采样和分析的整个过程中，所有动作都应该同时完成，训练和学习也应该统一进行。在训练开始时，每个回合需要初始化每个智能体的状态，仿真环境将根据网络给出的动作指令计算潮流，并完成动作集 a，根据每个智能体的奖励函数获得实时奖励 r。设定算法训练步长为 100,000 并将一天 24h 的时长设定为一个训练的回合，智能体的动作时间间隔为 5min。在修改后的 IEEE-33 配电网系统中根据式(21)计算累积奖励并进行更新。在训练学习过程中，通过观察当前状态 s 和最新动作 a，在智能体之间进行有效的通信以选择各自最优的动作。

4.3.2 算法有效性分析

为了验证本文所提强化学习算法的先进性和有效性，将 MADDPG 与以下 3 种方法进行对比。

方法 1：为了验证本文所提出的方法比传统的优化模型方法更具优越性，在短时间尺度下，选择粒子群(particle swarm optimization，PSO)优化算法[24]，通过连续调节设备进行无功优化。

方法 2：与离散动作策略强化学习的算法进行了性能比较，选择基于离散策略的单智能体集中式算法 DQN[25]作为对比基准算法。

方法 3：采用单智能体连续动作的深度确定策略梯度(deep deterministic policy gradient，DDPG) [26]作为对比基准算法，验证本文的多智能体协同策略更具优越性。

对于 DQN 以及 DDPG 的相关算法、原理以及网络结果等说明见附录 B。

在同样的 IEEE-33 节点配电网系统仿真环境下进行训练，训练的累计奖励结果如图 5 所示。实心曲线表示使用不同随机种子的 5 次实验的平均性能，浅色曲线表示误差范围。基于模型的方法采用了 PSO 方法，于图 5 中以红色虚线标记。

从训练的奖励曲线图 5 可以观察到，在训练开始时，智能体的行动策略无法在保证系统各节点的电压保持在 0.95 至 1.05pu 范围内的情况下同时减小系统的网损。然而，智能体性能在学习过程中逐渐增强，学习的奖励值会不断增加直到收敛。同时，图 5 表明，本文所提出的 MADDPG 算法训练结果累计奖励值明显优于单智能体强化学习算法 DDPG 以及 DQN。多智能体协同合作相较于单智能体连续和离散动作算法，具有更快的收敛速度和更好的训练效果。图 6 是使用了本文提出的 MADDPG 算法后配电网 IEEE 33 节点在一个小时内(12:00—13:00)的电压分布和变化情况。由图 6 可知，所有电压值在 12:00—13:00 时间段内均在 0.95~1.05pu

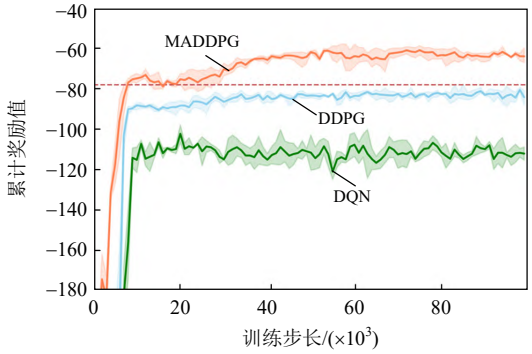


图 5 MADDPG 算法和基准算法的训练结果图

Fig. 5 Training performance of the proposed MADDPG and benchmarks

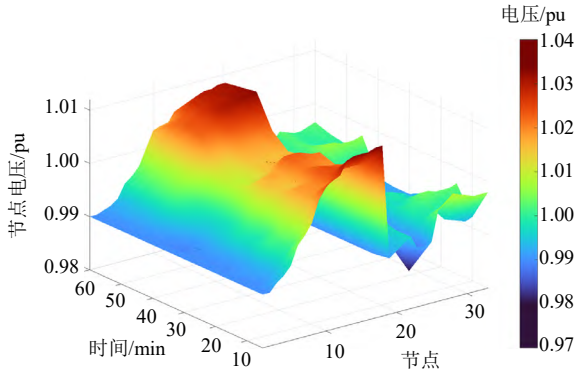


图 6　MADDPG 算法优化后的一小时内(12:00—13:00)电压分布

Fig. 6　Voltage profile after optimization of MADDPG algorithm in one hour (12:00—13:00)

的安全范围内。

基于测试集算例对比本文提出的 MADDPG 方法与基准方法 DDPG、DQN 以及基于模型的 PSO 优化算法，结果如表 3 所示。其中训练每回合的累计奖励 r 以及电压偏差指标 $V_{r,t}$的计算方式详见式(20)、(21)，结果以其平均值(Mean)、标准差(Std.)记录。可以看出与 DDPG、DQN 以及基于模型的 PSO 算法相比，本文所提出的 MADDPG 强化学习算法的累计奖励值 r 平均值分别提升了 27.80%，42.84%，21.78%，电压偏差指标 $V_{r,t}$分别下降了 96.25%，98.84%，63.53%，说明采用本文所提 MADDPG 算法进行无功电压优化可以更有效地降低配网的线路功率损耗，有效地减轻电压偏差。表 3 显示了 MADDPG、DDPG、DQN 和 PSO 每步的平均运行时间。证实 DRL 算法在速度上的优势，因为强化学习算法在线测试过程只需计算神经网络结果而不需要进行迭代。

表 3 不同无功优化策略下的结果对比

Table 3　Performance comparison of volt-var control algorithm

策略	平均运行时间/ms	累计奖励 r/\$		$V_{r,t}$	
		平均值	标准差	平均值	标准差
MADDPG	0.93	−61.59	5.58×10^{-1}	7.600×10^{-5}	5.523×10^{-5}
DDPG	0.96	−85.31	8.073×10^{-1}	2.032×10^{-3}	2.975×10^{-4}
DQN	0.99	−108.17	2.622	6.584×10^{-3}	2.169×10^{-3}
PSO	79	−78.14	0	2.084×10^{-4}	0

图 7 显示了在不同策略下 13:00—15:00 下的节点 18 的电压的变化值，从图中可以看出，DQN 策略下节点 18 的电压出现了电压越限，低于安全范围最低值 0.95pu，MADDPG 策略下的电压在该时间段均在安全范围内，具有相对平稳的电压值。图 8 对比了在不同策略下的日均网络损耗的值，本文提出的 MADDPG 在结果中比 DDPG、DQN、PSO 分别减小了 32.05%、41.89%和 24.64%，采用本文所提方法后的网损更低。此外，取不同无功优化策略下 12:00 时刻的电压结果如表 4 所示，结果表明 MADDPG 策略下的电压偏差最小，电压分布最稳定，波动性最小。

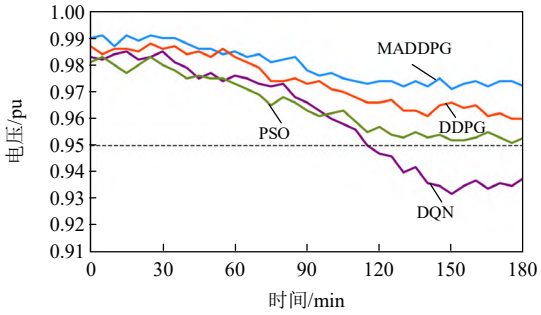


图 7　不同优化策略下 13:00—15:00 的电压对比(节点 18)

Fig. 7　Comparison of voltage profile (bus 18) during 13:00—15:00 with different control methods

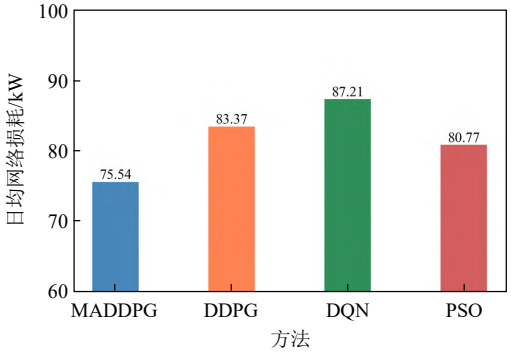


图 8　不同优化策略下日均网络损耗对比

Fig. 8　Comparison of daily average network loss with different control methods

表 4　不同无功优化策略下 12:00 时刻的电压结果

Table 4　Voltage performance comparison of volt-var control algorithm at 12:00

策略	电压偏差/pu	电压最大值/pu	电压最小值/pu
MADDPG	0.184	1.022	0.991
DDPG	0.223	1.048	1.003
DQN	0.381	1.057	1.010
PSO	0.208	1.038	0.991

5　结论

本文提出一种基于多时间尺度协调的配电网无功优化策略。在日前的小时级时间尺度下，采用 MISOCP 方法以最小化网损为目标进行优化，得到 SC 和 OLTC 的优化结果。第二个时间尺度以 5min 为调度周期，提出一种基于多智能体强化学习算法 MADDPG 来实现光伏和风机逆变器和 SVC 的实时协调电压控制。相较于传统的优化模型，本文所提

出的策略无需依赖于精确的潮流模型，同时MADDPG 算法采用集中学习、分散执行的框架，用神经网络近似 Actor 和 Critic 函数，解决传统强化学习算法中环境不稳定导致收敛困难的问题，显著提高在线实时决策的效率性能，达到更好的无功优化效果。

通过在 IEEE 33 节点的配电网系统算例中测试，对比验证 MADDPG、DDPG、DQN 和 PSO 的性能。仿真结果表明，经过训练后的 MADDPG 强化学习控制策略可以更好地协调光伏、风机和 SVC 等无功支撑设备，从而缓解节点电压越限并降低线路损耗，同时具有良好的实时性能。

参考文献

[1] 陈虹. 含分布式电源的配电网无功补偿优化研究[J]. 信息技术，2020，44(11)：132-136.
CHEN Hong. Reactive power compensation optimization of distribution network including distributed power supply [J]. Information Technology，2020，44(11)：132-136(in Chinese).

[2] 张宇精，乔颖，鲁宗相，等. 含高比例分布式电源接入的低感知度配电网电压控制方法[J]. 电网技术，2019，43(5)：1528-1535.
ZHANG Yujing，QIAO Ying，LU Zongxiang，et al. Voltage control for partially visible distribution networks with high DG penetration[J]. Power System Technology，2019，43(5)：1528-1535(in Chinese).

[3] 李培帅，吴在军，张错，等. 主动配电网分布式混合时间尺度无功/电压控制[J]. 电力系统自动化，2021，45(16)：160-168.
LI Peishuai，WU Zaijun，ZHANG Cuo，et al. Distributed hybrid-timescale voltage/var control in active distribution networks[J]. Automation of Electric Power Systems，2021，45(16)：160-168(in Chinese).

[4] 周玮，胡姝博，孙辉，等. 考虑大规模风电并网的电力系统区间非线性经济调度研究[J]. 中国电机工程学报，2017，37(2)：557-563.
ZHOU Wei，HU Shubo，SUN Hui，et al. Interval nonlinear economic dispatch in large scale wind power integrated system[J]. Proceedings of the CSEE，2017，37(2)：557-563(in Chinese).

[5] 郑能，丁晓群，管志成，等. 基于场景法的配电网有功－无功协调优化[J]. 电网技术，2019，43(5)：1640-1651.
ZHENG Neng，DING Xiaoqun，GUAN Zhicheng，et al. Coordinated optimization of active power and reactive power in distribution network based on scenario method [J]. Power System Technology，2019，43(5)：1640-1651(in Chinese).

[6] 郑能，丁晓群，郑程拓，等. 含高比例光伏的配电网有功－无功功率多目标协调优化[J]. 电力系统自动化，2018，42(6)：33-39，91.
ZHENG Neng，DING Xiaoqun，ZHENG Chengtuo，et al. Multi-objective coordinated optimization of active and reactive power for distribution network integrated with high proportion of photovoltaic generation[J]. Automation of Electric Power Systems，2018，42(6)：33-39，91(in Chinese).

[7] 于琳，孙莹，徐然，等. 改进粒子群优化算法及其在电网无功分区中的应用[J]. 电力系统自动化，2017，41(3)：89-95，128.
YU Lin，SUN Ying，XU Ran，et al. Improved particle swarm optimization algorithm and its application in reactive power partitioning of power grid[J]. Automation of Electric Power Systems，2017，41(3)：89-95，128(in Chinese).

[8] 高红均，刘俊勇，沈晓东，等. 主动配电网最优潮流研究及其应用实例[J]. 中国电机工程学报，2017，37(6)：1634-1644.
GAO Hongjun，LIU Junyong，SHEN Xiaodong，et al. Optimal power flow research in active distribution network and its application examples[J]. Proceedings of the CSEE，2017，37(6)：1634-1644(in Chinese).

[9] 方斯顿，程浩忠，徐国栋，等. 随机最优潮流及其应用的研究综述[J]. 电力自动化设备，2016，36(11)：1-10.
FANG Sidun，CHENG Haozhong，XU Guodong，et al. Reviews on stochastic optimal power flow and its application[J]. Electric Power Automation Equipment，2016，36(11)：1-10(in Chinese).

[10] 任佳依，顾伟，王勇，等. 基于模型预测控制的主动配电网多时间尺度有功无功协调调度[J]. 中国电机工程学报，2018，38(5)：1397-1407.
REN Jiayi，GU Wei，WANG Yong，et al. Multi-time scale active and reactive power coordinated optimal dispatch in active distribution network based on model predictive control[J]. Proceedings of the CSEE，2018，38(5)：1397-1407(in Chinese).

[11] LIU Haotian，WU Wenchuan. Two-stage deep reinforcement learning for inverter-based volt-var control in active distribution networks[J]. IEEE Transactions on Smart Grid，2021，12(3)：2037-2047.

[12] SHIN M，CHOI D H，KIM J. Cooperative management for PV/ESS-enabled electric vehicle charging stations：a multiagent deep reinforcement learning approach[J]. IEEE Transactions on Industrial Informatics，2020，16(5)：3493-3503.

[13] WANG Wei，YU Nanpeng，SHI Jie，et al. Volt-VAR control in power distribution systems with deep reinforcement learning[C]//2019 IEEE International

Conference on Communications，Control，and Computing Technologies for Smart Grids．Beijing：IEEE，2019：1-7．

[14] 李琦，乔颖，张宇精，等．配电网持续无功优化的深度强化学习方法[J]．电网技术，2020，44(4)：1473-1480．
LI Qi，QIAO Ying，ZHANG Yujing，et al．Continuous reactive power optimization of distribution network using deep reinforcement learning[J]．Power System Technology，2020，44(4)：1473-1480(in Chinese)．

[15] VLACHOGIANNIS J G，HATZIARGYRIOU N D. Reinforcement learning for reactive power control[J]．IEEE Transactions on Power System，2004，19(3)：1317-1325．

[16] ZHANG Ying，WANG Xinan，WANG Jianhui，et al. Deep reinforcement learning based volt-var optimization in smart distribution systems[J]. IEEE Transactions on Smart Grid，2021，12(1)：361-371．

[17] 倪爽，崔承刚，杨宁，等．基于深度强化学习的配电网多时间尺度在线无功优化[J]．电力系统自动化，2021，45(10)：77-85．
NI Shuang，CUI Chenggang，YANG Ning，et al．Multi-time-scale online optimization for reactive power of distribution network based on deep reinforcement learning [J]. Automation of Electric Power Systems，2021，45(10)：77-85(in Chinese)．

[18] CAO Di，HU Weihao，ZHAO Junbo，et al．A multi-agent deep reinforcement learning based voltage regulation using coordinated PV inverters[J]．IEEE Transactions on Power Systems，2020，35(5)：4120-4123．

[19] 周任军，段献忠，周晖．计及调控成本和次数的配电网无功优化策略[J]．中国电机工程学报，2005，25(9)：23-28，157．
ZHOU Renjun，DUAN Xianzhong，ZHOU Hui．A strategy of reactive power optimization for distribution system considering control action cost and times[J]．Proceedings of the CSEE，2005，25(9)：23-28，157(in Chinese)．

[20] 张璐，唐巍，丛鹏伟，等．含光伏发电的配电网有功无功资源综合优化配置[J]．中国电机工程学报，2014，34(31)：5525-5533．
ZHANG Lu，TANG Wei，CONG Pengwei，et al．Optimal configuration of active-reactive power sources in distribution network with photovoltaic generation [J]. Proceedings of the CSEE，2014，34(31)：5525-5533(in Chinese)．

[21] YANG Qiuling，WANG Gang，SADEGHI A，et al．Two-timescale voltage control in distribution grids using deep reinforcement learning[J]．IEEE Transactions on Smart Grid，2019，11(3)：2313-2323．

[22] LOWE R，WU Yi，TAMAR A，et al．Multi-agent actor-critic for mixed cooperative-competitive environments [C]//Proceedings of the 31st International Conference on Neural Information Processing Systems．Long Beach：Curran Associates Inc.，2017：6382-6393．

[23] BUŞONIU L，BABUŠKA R，DE SCHUTTER B. Multi-agent reinforcement learning：an overview[M]// SRINIVASAN D，JAIN L C．Innovations in Multi-agent Systems and Applications．Berlin：Springer，2010：183-221．

[24] 赵波，曹一家．电力系统无功优化的多智能体粒子群优化算法[J]．中国电机工程学报，2005，25(5)：1-7．
ZHAO Bo，CAO Yijia．A multi-agent particle swarm optimization algorithm for reactive power optimization [J]．Proceedings of the CSEE，2005，25(5)：1-7(in Chinese)．

[25] VAN HASSELT H，GUEZ A，SILVER D．Deep reinforcement learning with double q-learning[C]// Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence．Phoenix：AAAI Press，2016：2094-2100．

[26] QIU Chengrun，HU Yang，CHEN Yan，et al．Deep deterministic policy gradient(DDPG)-based energy harvesting wireless communications[J]．IEEE Internet of Things Journal，2019，6(5)：8577-8588．

附录 A　测试集数据

测试集的光伏、风机日前预测曲线见附图 A1、A2。负荷预测曲线基于原始的 IEEE33 节点算例的空间负荷分布得到，负荷变化率见附图 A1—A3。

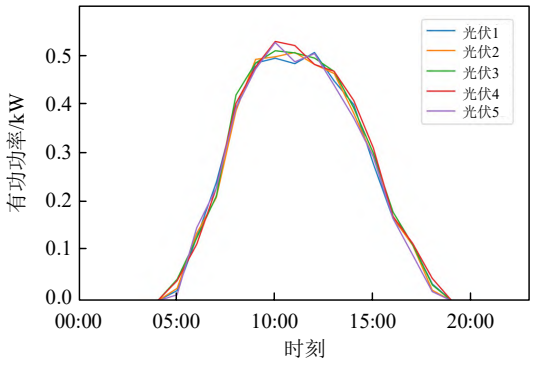


图 A1　光伏预测曲线

Fig. A1　Photovoltaic forecast curves

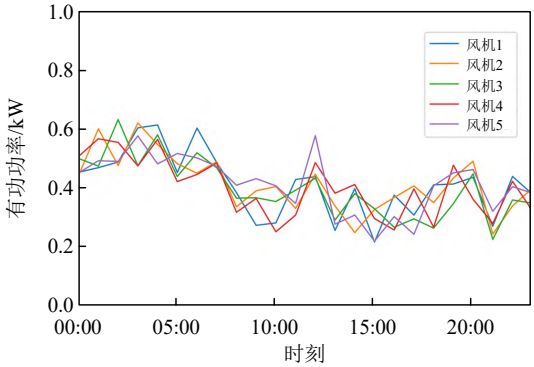


图 A2　风机预测曲线

Fig. A2　Wind turbine forecast curves

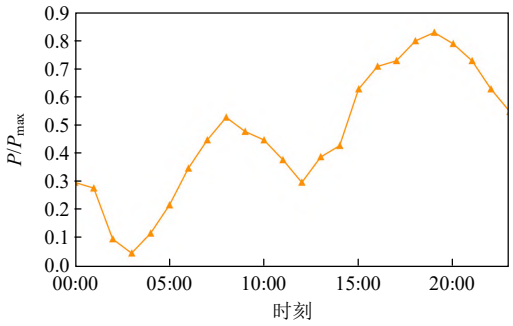


图 A3 负荷变化率曲线

Fig. A3 Load variation rate curve

附录 B 算法简介

1）DQN 算法。

DQN 是一种将神经网络与 Q-learning 相结合的方法，能够直接将状态作为神经网络的输入，将问题转化成 MDP，通过拟合动作价值函数 $Q(s,a)$，在智能体与环境交互过程中学习对应的 Q 值，并通过使用 Bellman 方程作为迭代更新估计动作价值函数，如式(B1)所示。

$$Q(s,a)=E[r+\gamma \max_{a'} Q^{*}(s',a')\,|\,s,a] \tag{B1}$$

本文设计了一个含有 2 层隐藏层的全连接神经网络，输入层包含 N 个神经元，输出层包含 M 个神经元，分别对应了配电网状态维度和输出的动作维度。隐藏层的神经元有 256 个，激活层为 ReLU 函数。将具有权重θ的神经网络函数可以通过最小化在每次迭代 i 处改变的损失函数 $L_i(\theta_i)$来训练 Q 网络。损失函数的定义如式(B2)所示。

$$L_i(\theta_i)=E_{s,a\sim p(\cdot)}\{[y_i-Q(s,a;\theta_i)]^2\} \tag{B2}$$

其中 y_i 是迭代 i 的目标，动作分布 p 是状态 s 和动作 a 对应的概率分布。通过随机梯度下降来优化损失函数。

2）DDPG 算法。

与 DQN 不同，DDPG 算法引入了 Actor-Critic 框架，将动作策略探索和学区分开实现。每一步动作通过 $a_t=\mu(s_t)$计算获得。用一个参数为θ^{μ}的策略网络(actor network，AN)模拟μ，用一个参数为θ^{Q}的Q网络来模拟 Q 函数(critic network，CN)。用函数 $J_{\pi}(\mu)$评价当前学习到策略的优劣。训练的目标即最大化 $J_{\pi}(\mu)$的同时最小化价值网络的损失。

本文的对比实验中，AN 和 CN 均含有 2 个隐藏层，输入层有 N 个神经元，代表状态的维度。隐藏层神经元的个数都为 128。CN 的损失函数的表达式为：

$$L(\theta^{c})=\frac{1}{M}\sum_{j=1}^{M}(y_j-Q(s,a;\theta^{c})) \tag{B3}$$

AN 通过采样得到的策略梯度来更新，如下表达式：

$$\nabla_J(\theta^{a})=\frac{1}{M}\sum_{j=1}^{M}[\nabla_a Q(s,a;\theta^{c})\nabla_{\theta^{a}}\pi_{\theta^{a}}(s)] \tag{B4}$$

分别采用随机梯度下降更新 AN、CN 的网络参数，即

$$\theta^{a'}\leftarrow\tau\theta^{a}+(1-\tau)\theta^{a'} \tag{B5}$$

$$\theta^{c'}\leftarrow\tau\theta^{c}+(1-\tau)\theta^{c'} \tag{B6}$$

在线出版日期：2022-03-29。
收稿日期： 2021-12-02。



胡丹尔

作者简介：

胡丹尔(1996)，女，博士研究生，主要研究方向为人工智能技术在电力系统中的应用，hdrmakeit@zju.edu.cn；

*通信作者：彭勇刚(1978)，男，教授，博士，研究方向为微电网与交直流混合供电系统、智能配用电，pengyg@zju.edu.cn；

习伟(1980)，男，硕士，教授级高级工程师，研究方向为电网数字化及芯片化，xiwei@csg.cn。

(**编辑** 乔宝榆，张光)

 DOI：10.13334/j.0258-8013.pcsee.213110

Multi-timescale Deep Reinforcement Learning for Reactive Power Optimization of Distribution Network

HU Daner[1], PENG Yonggang[1*], Wei Wei[1], XIAO Tingting[1], CAI Tiantian[2], XI Wei[2]

(1. Zhejiang University; 2. Digital Grid Research Institute, China Southern Power Grid.)

KEY WORDS: voltage control; deep reinforcement learning; multi-agent; Markov process; data-driven;

Volt-VAR control (VVC) is a key method for the modern distribution system management system. The increasing penetration of distributed renewable energy resources causes voltage fluctuations in distribution networks.

This paper presented a multi-timescale voltage regulation strategy based on a mathematical optimization model and data-driven method. First, the online tap changer and switching capacitor with slow-timescale regulation minimize the active power loss. The day ahead reactive power and voltage optimization model were based on mixed-integer second-order cone programming. Second, to meet the real-time requirements on the fast timescale stage, an intraday real-time scheduling method based on multi-agent reinforcement learning was proposed, transforming the real-time reactive power optimization problem into a Markov Game Process, and adopting a centralized training and decentralized execution framework. The two-timescale hybrid voltage control framework is proposed as shown in Fig. 1.

Specifically, we propose a multi-agent deep deterministic policy gradient (DDPG) algorithm to learn control policies. Compared with the traditional method, our proposed method does not depend on accurate power flow modeling based on the data prediction of day-ahead load and distributed generation data. The proposed strategy uses deep neural network to train the action functions of solar photovoltaic (PV) and wind turbine (WT) inverters as multiple agents and completes the training of deep neural networks in the process of interaction with the distribution network environment.

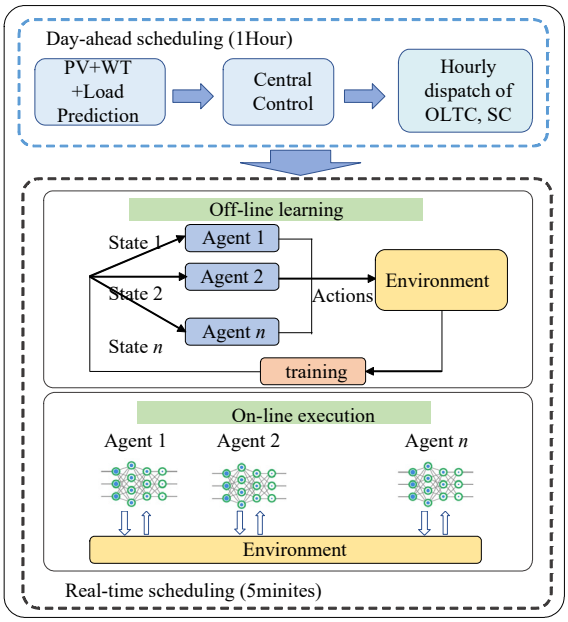


Fig. 1 Architecture of the proposed two-timescale voltage control with reactive power optimization

At each interaction step, the agent will choose an action based on its own policy network. The proposed MADDPG algorithm contains N agents including N policy networks and N critic networks. The action given by agent i according to observation. After the distribution system receives the agent's actions, it will calculate the power flow again and return an updated state to each agent. The learning process based on an actor-critic framework includes a policy network as well as a value network. The actor can teach the agent how to choose action, while the critic is supposed to evaluate the return of this action. The actor parameters are usually based on the return given by the critic and completed by the gradient-based method. Compared with traditional methods, this method has low communication cost, better real-time performance, and does not rely on an accurate power flow model.