DOI：10.13334/j.0258-8013.pcsee.240403 文章编号：0258-8013 (2025) 17-6709-14 中图分类号：TM 73 文献标识码：A

多时间尺度深度强化学习光储配电网电压优化

黄冬梅[1]，余京朋[1]，崔承刚[2]，董倩文[2]，周游[3]，龚春阳[1*]

(1. 上海电力大学电气工程学院，上海市 杨浦区 200090；2. 上海电力大学自动化工程学院，上海市 杨浦区 200090；3. 国网江苏省电力有限公司苏州供电分公司，江苏省 苏州市 215000)

Voltage Optimization for PV-ES Distribution Network With Multi-timescale Deep Reinforcement Learning Method

HUANG Dongmei[1], YU Jingpeng[1], CUI Chenggang[2], DONG Qianwen[2], ZHOU You[3], GONG Chunyang[1*]

(1. College of Electrical Engineering, Shanghai University of Electric Power, Yangpu District, Shanghai 200090, China;
2. College of Automation Engineering, Shanghai University of Electric Power, Yangpu District, Shanghai 200090, China;
3.State Grid Suzhou Power Supply Company, Suzhou 215000, Jiangsu Province, China)

ABSTRACT: The distributed photovoltaic is connected to the distribution network dispersedly, whose anti-regulation characteristic of output and load can easily cause over-voltage at points of common coupling. Existing methods optimize the voltage profile to some extent through reasonable energy storage configuration, but the mobilization of stored energy is highly coupled with other reactive power sources in the time domain, increasing the complexity of combined voltage regulation modeling and affecting the voltage regulation precision. The rapid and frequent charging and discharging, as well as overcharging and over-discharging will lead to lifespan degradation of energy storage system, thereby reducing the economic and safety performance of the system. Aiming at these issues, this paper proposes a voltage optimization strategy for the photovoltaic and energy storage (PV-ES) distribution network with multi-timescale deep reinforcement learning (DRL) method. Integrating with DRL's model-free feature, this strategy considers the action characteristics in time domain of various discrete/continuous voltage regulation equipment, photovoltaic inverters as well as energy storage devices, whose action and the state of charge (SOC) are restricted strictly based on the event-triggering mechanism. The voltage optimization scheme for distribution network is designed from a multi-timescale perspective, which aims to minimize voltage deviation and network loss. Finally, the proposed method is simulated and verified based on an modified IEEE 33-bus system with distributed photovoltaic, energy storage, and other voltage regulation devices. The results show that the proposed method exhibits smaller voltage deviations and average network losses compared with the results in reference, measuring 0.016 6 pu and 141.2 kW respectively, and more suitable for application scenarios with relatively high uncertainty in photovoltaic output. At the same time, it effectively limits the cutting action of on-load tap changers and capacitor banks to 6 and 3 times, respectively. Moreover, it also restricts SOC variation of energy storage devices within 15 minutes to below 30%, significantly reducing the action frequency to less than 10% of continuous situation, and maintaining the SOC within a safe range of 0.2~0.8.

KEY WORDS: deep reinforcement learning; multi-timescale; PV-ES distribution network; voltage optimization; event-triggering mechanism

摘要：分布式光伏分散接入配电网，其出力与负荷呈反调节特性，易导致公共接入点电压越限。现有方法通过合理配置储能一定程度上优化了电压分布，但储能调用在时域上与其余无功源高度耦合，加重了联合调压建模的复杂度，影响了调压精度，储能快速充放、过充过放及高频次充放亦将引发其寿命衰减，致使系统经济性与安全性下降。对此，该文提出一种采用多时间尺度深度强化学习的光储配电网电压优化策略，结合深度强化学习无模型的特点，通过计及多种离散/连续调压设备、光伏逆变器及储能设备动作时域特性，并基于事件触发机制严格限制储能设备动作次数与荷电状态，以电压偏移量与网损最小为目标，从多时间尺度设计配电网电压优化方案。最后，基于光储与其他调压设备接入改进的 IEEE 33 节点系统对所提方法进行仿真验证，结果表明，该文所提方法相对文献结果具有较小的电压偏移与平均网损量，分别为 0.016 6 pu 与 141.2 kW，适用于光伏出力不确定性相对较大的应用场景；同时，有载调压变压器与电容

基金项目：国家重点研发计划项目(2016YFC1401902)；上海市科委项目(21DZ1207300)；国网苏州供电公司科技项目(B11020223T26)。

National Key R&D Program of China (2016YFC1401902); Fund of Shanghai Science and Technology Development (21DZ1207300); State Grid Suzhou Power Supply Company Technology Project (B11020223T26).

中国知网 https://www.cnki.net

器组动作次数分别低至 6 次与 3 次，储能设备在 15 min 内的荷电状态变化量低于 30%，其动作频次大幅低至连续动作的 10%以下，维持其荷电状态始终处于 0.2~0.8 的安全区间。

关键词：深度强化学习；多时间尺度；光储配电网；电压优化；事件触发机制

0 引言

随着“双碳”目标的提出，整县制分布式光伏(distributed photovoltaic，DPV)应用的推进、碳达峰试点城市/园区落地示范项目建设的实施，我国新能源开发利用已步入快车道[1-2]。由于分布式光伏在电力系统中的渗透率不断攀升，分散接入配电网后其出力波动性和间歇性引发了一系列电能质量问题，其中公共接入点电压越限问题尤为显著[3-4]。实际运行中，通过对有载调压变压器(on-load tap changer，OLTC)、电容器组(shunt capacitor bank，SCB)以及静止无功补偿器(static var generator，SVG)等无功补偿设备的控制调度，在一定程度上改善了电压水平[5]，但存在调压精度受限或调压成本过高等不足。而通过智能逆变器实现光伏有功输出的部分转化，也为系统调压提供了较为可观的无功资源[6]，但该方案需充分考虑用户意愿，缺乏灵活性。相对而言，利用储能(energy storage，ES)固有的灵活选址、灵活调度和快速响应等特点[7]，使得通过合理配置储能便能够获得优化电压分布、提升系统运行稳定性的效果。对此，目前已有部分省市强制要求新能源按一定比例配储[8]。

然而，当公共接入点出现电压越限时，由于无功源与接入的 ES 在调用时存在时间尺度上的高度耦合，增大了联合调压时建模的复杂度，造成部分设备调压任务过载或闲置，影响调压精度，调压潜力未得到充分挖掘。同时，ES 寿命受快速充放及过充过放影响，存在循环次数限制，近年来虽通过采用新材料、新工艺降低成本并提高性能，但上述因素仍对系统经济性与安全性造成影响[9]。据此，在协同调压时如何综合考虑 ES 和其他无功源调用的时域特性，兼顾 ES 使用寿命同时限制其充放速度、深度与动作频次，并以系统鲁棒性、经济性为目标提出合理可行的控制策略，成为目前光储配电网电压优化研究所面临的严峻挑战，相关课题受到了学术界的广泛关注。

针对配电网电压优化，已有研究将多种调压设备间的协作视为多时间尺度的控制问题[10]。文献[11]提出基于模型预测控制的配电网多时间尺度无功优化方法，对配电网中多种设备进行建模，通过求解非线性方程，在多时间尺度上进行滚动无功优化。文献[12]提出考虑负荷特性的无功优化方法，通过日前、日内时间尺度协同优化配电网电压。但这些方法存在建模复杂，非线性求解难度大和实时响应能力差等不足，难以满足当前大规模 DPV 接入配电网的应用要求。随着基于数据驱动的人工智能算法不断发展，众多研究推动其广泛应用于能源、交通、自动化等领域，例如，深度强化学习(deep reinforcement learning，DRL)算法在配电网电能质量提升及优化调度等方面的研究[13-15]。

相对于传统的模型控制算法，DRL 的特点在于无须建立复杂的物理模型[16]，通过训练智能体与环境交互制定出最优策略，训练完成后智能体即拥有对未知环境较强的适应能力，更适用于配电网的电压优化。文献[17]考虑无功补偿设备的异步响应速度，基于 DRL 设计两个时间尺度的智能体进行无功优化，可以实现配电网电压的在线调控。文献[18]考虑不同无功补偿设备和不同 DRL 算法的特点，在长短时间尺度上进行多目标整合，从而解决配电网的电压调控问题。文献[19]将传统优化方法与多智能体 DRL 相结合，提高智能体的决策效率，具有较好的无功优化效果。上述文献虽实现了配电网电压优化，但仅考虑无功设备的参与，针对当前配电网中 DPV 配储参与电压调节场景已不再适用。

对此，已有部分研究考虑将 ES 联合其他调压设备共同参与配电网电压优化[20-21]。文献[22]分三阶段优化 ES 和光伏逆变器动作，充分发挥 ES 调峰调压能力，在优化其动作成本的同时有效控制电压，但与 OLTC、SCB 等传统调压设备的协作未展开深入讨论。文献[23]提出一种配电网双时间尺度有功无功协调优化策略，将 ES 作为长时间尺度设备进行优化，降低其动作次数并提高短时间尺度设备的决策速度，但牺牲了 ES 的灵活调节能力。文献[24]考虑分布式光储接入对配电网的影响，提出一种基于 DRL 的 ES 调压策略，实现多个 ES 自主协同调压，但由于所提方法需要 ES 在一天时间内做出多次连续动作，其忽略了对实际工况的考量。同时，以上文献均未对 ES 的快充快放以及过充过放问题进行刻画，仿真实验中也未展开详细的分析阐述，对应研究方法对 ES 寿命是否造成影响存疑，

中国知网 https://www.cnki.net

系统运行的安全性与经济性未得到充分验证。

针对以上问题与不足，本文提出一种考虑事件触发机制基于多时间尺度深度强化学习的光储配电网电压优化方法。根据不同设备的响应特性，将优化方法按 15 min 为步长划分为长、中、短 3 个时间尺度并对应设置决策时间分别为 1 h、30 min 及 15 min[25]，经马尔可夫决策过程并设置障碍函数限制电压处于安全范围。其中，在长时间尺度上采用双深度 Q 网络算法(double deep Q network，DDQN)，针对离散动作空间策略在减少估计偏差的同时提升其稳定性与效率[26]，通过动作 OLTC 抽头并投切 SCB 调整电压偏移，有效限制设备的调节次数；而在中时间尺度上采用孪生延迟深度确定性策略梯度算法(twin delayed deep deterministic policy gradient algorithm，TD3)，其适用于高维连续动作空间[27]，通过控制 SVG 和光伏逆变器输出，限制电压处于安全范围内，同时降低整体网损；在短时间尺度上采用柔性动作-评价算法(soft actor-critic，SAC)，引入熵正则化策略，加快收敛速度并增强学习过程的稳定性，满足 ES 动作的安全性与经济性要求，并结合事件触发机制，通过设定阈值控制 ES 充放电动作与荷电状态，实现电压偏移量的进一步优化，有效避免了储能出现快充快放、过充过放与高频次充放等现象。最后，通过算例仿真验证了所提方法的有效性和准确性。

1　基于 DRL 的光储配电网电压优化模型

1.1　光储配电网物理模型

在一个 N+1 条母线的配电网中，V={1,2,⋯,N}和 E={1,2,⋯,N}分别为配电网节点和线路的集合，节点 1 与主电网连接，起到平衡配电网有功和无功的作用。对于任一节点 $i\in V$，设定 v_i 和 θ_i 分别为其电压幅值和相角，$s_i=p_i+\mathrm{j}q_i$ 为注入节点的复功率。其中，p_i 代表节点 i 的有功功率；q_i 代表节点 i 的无功功率。

在对配电网进行无功补偿时，无功补偿的设备分为离散动作设备和连续动作设备。其中离散动作设备主要考虑 OLTC 与 SCB，在第 i 个节点上，其时间 t 的投切挡位状态 K 以及总投切次数 N 分别用 $K_{\mathrm{OLTC}}^{i}(t)$、N_{OLTC}^{i} 与 $K_{\mathrm{SCB}}^{i}(t)$、N_{SCB}^{i} 表示。考虑设备老化、成本增加等因素，OLTC 和 SCB 最大投切次数分别为 $N_{\mathrm{OLTC}}^{\max}$ 与 $N_{\mathrm{SCB}}^{\max}$。为确保 DRL 智能体在训练过程中的严格收敛，本文针对离散动作设备在 t–1 时刻的投切挡位与投切次数采用 one-hot 编码[28]。

同时，SVG 作为调压连续动作设备，其产生的无功功率大小 q_i^{SVG} 受单台 SVG 的容量限制。考虑到 DPV 具有光伏逆变器的响应特性，本文将其视作连续动作的无功补偿设备对配电网进行电压优化，产生的无功功率 q_i^{PV} 受 DPV 装机容量 s_i^{PV} 与输出有功功率 p_i^{PV} 影响。

此外，通过调用 ES 调节光储配电网电压，其中充放电效率分别为 η_{ch} 和 η_{dis}。采用荷电状态(state of charge，SOC)表征 ES 在某一时刻的实际容量与额定容量比值，其中 P_{es} 表示 ES 吸收或放出的有功功率，E_{es} 表示 ES 额定容量。ES 充放电过程中的 SOC 变化如下[29]：

$$\begin{cases} S_{\mathrm{OC}}(t)=S_{\mathrm{OC}}(t-1)+\dfrac{P_{\mathrm{es}}(t)\eta_{\mathrm{ch}}}{E_{\mathrm{es}}}, & P_{\mathrm{es}}(t)\geq 0 \\ S_{\mathrm{OC}}(t)=S_{\mathrm{OC}}(t-1)+\dfrac{P_{\mathrm{es}}(t)}{E_{\mathrm{es}}\eta_{\mathrm{dis}}}, & P_{\mathrm{es}}(t)<0 \end{cases} \tag{1}$$

1.2　长、中、短时间尺度响应设备划分

在进行 24 h 的光储配电网电压优化时，需要将具有不同响应特性的调压设备按照不同的时间尺度进行调节。其中，OLTC 与 SCB 由于响应速度慢且都为离散调节设备，两者归类为长时间尺度响应设备；光伏逆变器和 SVG 作为连续调节设备，响应速度较快，将两者视为中时间尺度响应设备；ES 相较中时间尺度响应设备其响应速度更快，为充分挖掘其调压能力，将其视为短时间尺度响应设备进行调控。

如图 1 所示，将 24 h 划分为 24 个单位，其中当 T=0,1,⋯,24 时，调度中心向长时间尺度响应设备

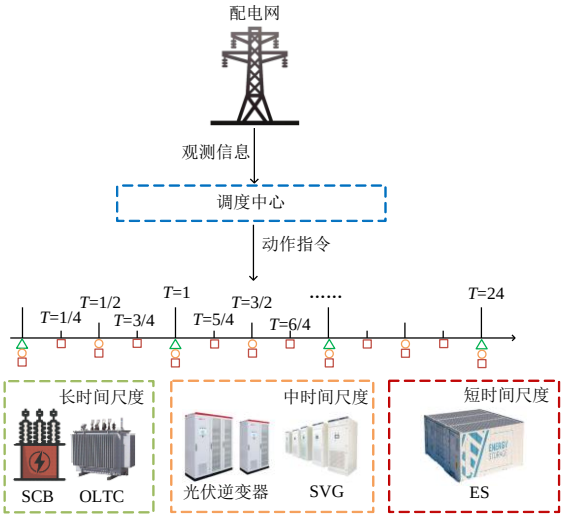


图 1　3 时间尺度划分

Fig. 1　Three-timescale division

中国知网　https://www.cnki.net

下达动作指令 1 次；当 T=0,1/2,1,…,24 时，调度中心向中时间尺度响应设备下达动作指令 1 次；当 T=0,1/4,1/2,3/4,1,…,24 时，调度中心向短时间尺度响应设备下达动作指令 1 次。当调度指令在某一时刻发生重叠时，如 T=0,1/2,1,3/2,…,24 时，调度中心根据“先粗调、再精调”的原则，按长时间尺度响应设备优先、中时间尺度响应设备次之和短时间尺度响应设备最后的顺序依次发送调节指令。

1.3 马尔可夫决策过程

马尔可夫决策过程(markov decision process，MDP)是 DRL 中的一个重要概念，用于描述具有随机性的序列决策问题。具体地，MDP 被抽象为一组状态空间、动作空间、奖励函数、状态转移矩阵与折扣因子的集合模型，在此处分别表征光储配电网物理特性、调压设备动作指令、设备动作评价指标、配电网运行状态变化概率以及设备动作对配电网未来运行状态的影响，其中所含序列可以通过变量 $<S, A, r, \boldsymbol{P}, \gamma>$ 表示[30]。

1）状态空间。

状态空间 S 是系统在某一时刻的特定状态，智能体通过状态空间感知环境进行学习。在多时间尺度的光储配电网 DRL 训练过程中，状态空间通过电压、有功、无功、K、N 与 SOC 等状态量来表征光储配电网的物理特征。

2）动作空间。

动作空间 A 代表智能体根据上一时刻的环境状态给出当前时刻的动作指令。在长时间尺度中，智能体的动作包含离散设备 OLTC 和 SCB 在 t 时刻的投切挡位 $K_{\mathrm{OLTC}}^{i}(t)$ 和 $K_{\mathrm{SCB}}^{i}(t)$。在中时间尺度中，智能体的动作包含光伏逆变器的无功功率输出 q^{PV} 以及 SVG 输出的无功功率 q^{SVG}。在短时间尺度中，智能体的动作是 ES 吸收或者放出的有功功率 P_{es}。根据智能体给出的动作更新环境的状态空间，将更新后的状态空间作为智能体下一时刻的状态输入。

3）奖励函数。

作为智能体判断某一时刻给出动作好坏评价的依据，奖励函数 r 指导智能体向更好的策略进行学习。智能体为得到更高的奖励，面对输入的状态空间会给出更优的动作选择。

4）状态转移矩阵。

状态转移矩阵 $\boldsymbol{P}$ 是一个描述状态转移概率的矩阵。在强化学习中，状态转移矩阵用于定义智能体在不同状态之间转移的概率。

5）折扣因子。

折扣因子 γ 表示对未来奖励回报的折算率。

1.4 电压障碍函数

本文定义平衡节点的参考电压为 1 pu，将电压安全范围定为 0.95~1.05 pu。通过构建电压障碍函数对电压进行约束，当节点电压处于约束范围内时，根据实时电压与参考电压的偏离给予较平缓的惩罚；当节点电压超出约束范围内时，根据其偏离程度提供出梯度较大的奖励函数。构建的电压障碍函数为

$$f_v(v_i)=\begin{cases}-bN(v_i,0.1^2)+c, & |v_i-1|<0.05\\ d\,|v_i-1|-e, & |v_i-1|\geq 0.05\end{cases} \tag{2}$$

式中：b、c、d、e 为调整梯度的超参数；v_i 为节点 i 的电压；$N(v_i,0.1^2)$是满足期望为 v_i、均值为 0.1 且满足正态分布的密度函数。

2 多时间尺度 DRL 电压优化

多时间尺度 DRL 电压优化训练过程在一天内循环进行，流程框图如图 2 所示。DRL 根据配电网当前状态量和实时奖励，按长、中、短时间尺度进行决策优化。

2.1 基于 DDQN 算法的长时间尺度优化

2.1.1 长时间优化模型

面向长时间尺度下的电压优化，本文所考虑的目标是配电网各节点的平均电压以及设备的动作次数：

$$\min F_1(v_{\mathrm{ave}}-v_{\mathrm{ref}}, C_{\mathrm{OLTC}}\sum_{n=1}^{i}N_{\mathrm{OLTC}}^{i}, C_{\mathrm{SCB}}\sum_{n=1}^{i}N_{\mathrm{SCB}}^{i}) \tag{3}$$

式中：$v_{\mathrm{ave}}-v_{\mathrm{ref}}$ 为配电网所有节点平均值和电压参考值的偏差；C_{OLTC}、$\sum_{n=1}^{i}N_{\mathrm{OLTC}}^{i}$ 和 C_{SCB}、$\sum_{n=1}^{i}N_{\mathrm{SCB}}^{i}$ 分别为第 i 个节点上 OLTC 和 SCB 的动作成本与动作次数总和；v_{ave} 为配电网中所有节点电压之和的平均值。

OLTC 和 SCB 设置抽头动作挡位上下限以及投切总次数约束，具体约束条件如下：

$$\begin{cases}K_{\mathrm{OLTC}}^{\max}\leq K_{\mathrm{OLTC}}\leq K_{\mathrm{OLTC}}^{\min}\\ K_{\mathrm{SCB}}^{\max}\leq K_{\mathrm{SCB}}\leq K_{\mathrm{SCB}}^{\min}\\ N_{\mathrm{OLTC}}\leq N_{\mathrm{OLTC}}^{\max}\\ N_{\mathrm{SCB}}\leq N_{\mathrm{SCB}}^{\max}\end{cases} \tag{4}$$

式中：$K_{\mathrm{OLTC}}^{\min}$ 和 $K_{\mathrm{OLTC}}^{\max}$ 分别为 OLTC 抽头动作的上下限；$K_{\mathrm{SCB}}^{\min}$ 和 $K_{\mathrm{SCB}}^{\max}$ 分别为 SCB 投切的上下限。

中国知网 https://www.cnki.net

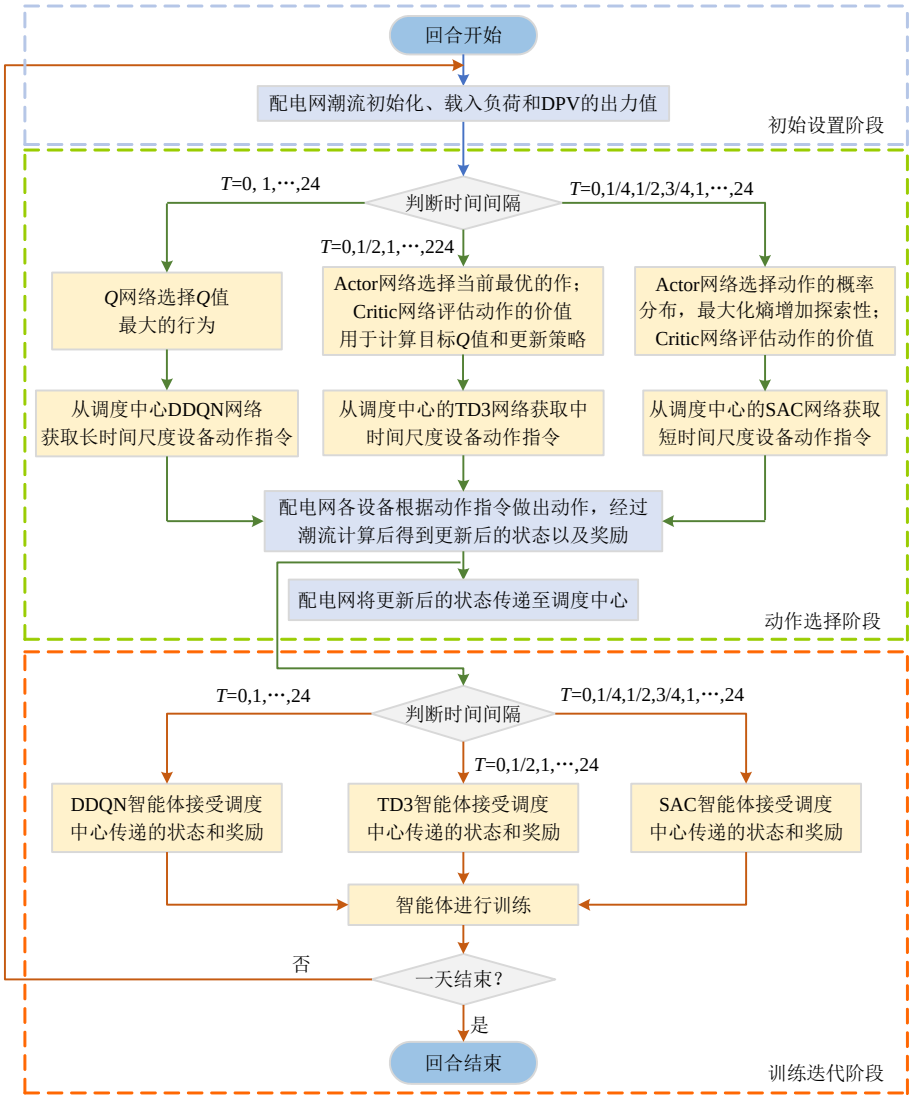


图 2　多时间尺度电压优化框图

Fig. 2　Framework of multi-timescale voltage optimization

考虑节点注入的有功、无功潮流约束如下：

$$p_i^{\mathrm{PV}}-p_i^{\mathrm{L}}=v_i^2\sum_{j\in V_i}g_{ij}-v_i\sum_{j\in V_i}v_j(g_{ij}\cos\theta_{ij}+b_{ij}\sin\theta_{ij}) \quad (5)$$

$$q_i^{\mathrm{PV}}-q_i^{\mathrm{L}}=-v_i^2\sum_{j\in V_i}b_{ij}-v_i\sum_{j\in V_i}v_j(g_{ij}\sin\theta_{ij}+b_{ij}\cos\theta_{ij}) \quad (6)$$

式中：g_{ij} 和 b_{ij} 分别为支路 ij 上的电导和电纳；θ_{ij} 为节点 ij 的相位差；p_i^{PV} 和 q_i^{PV} 分别为光伏注入节点 i 的有功功率和无功功率；p_i^{L} 和 q_i^{L} 分别为节点 I 上的有功负荷和无功负荷；v_j 为节点 j 的电压。

2.1.2　DDQN 算法

DDQN 算法引入了经验回放机制，包含两个结构完全相同的估计神经网络和目标神经网络，避免单个神经网络同时进行动作选择，以及针对目标 Q 值计算可能导致的过估计问题[31]。因此，本文选择采用 DDQN 算法求取离散空间下的 OLTC 和 SCB 响应动作，实现长时间尺度下的电压管控。DDQN 算法求取目标值 y_t：

$$y_t=r_{t+1}+\gamma[s_{t+1},\arg\max Q(s_{t+1},a;\omega_{\mathrm{e}});\omega_t] \quad (7)$$

式中：a 为智能体动作；Q 为动作价值函数；ω_{e} 为评估网络参数；ω_{t} 为目标网络参数；r_t 为 t 时刻的奖励；s_t 为 t 时刻的网络状态。

DDQN 算法可以通过估计神经网络和目标神经网络减轻过估计问题，其损失函数的定义如式(8)所示。针对估计神经网络的动作价值函数 Q 与目标神经网络的动作价值函数 Q_{tar}，该损失函数的目标是最小化两者差异。

$$L(\theta)=E_{(s_t,a_t,s_{t+1},r_t)}[(r_{t+1}+\gamma Q_{\mathrm{tar}}\{s_{t+1},\arg\max\cdot [Q(s_{t+1},a_{t+1})]\}-Q(s_t,a_t))^2] \quad (8)$$

式中：θ为目标神经网络；$E_{(s_t,a_t,s_{t+1},r_t)}$ 为智能体交互的环境。

在使用 DDQN 算法训练智能体时，为使智能

中国知网　https://www.cnki.net

体区分动作的好坏程度，采用奖励函数 r_1：

$$r_1=-[f_v(v_i)+C_{\mathrm{OLTC}}\sum_{n=1}^{i}N_{\mathrm{OLTC}}^{i}+C_{\mathrm{SCB}}\sum_{n=1}^{i}N_{\mathrm{SCB}}^{i}] \quad (9)$$

为保障学习过程的稳定性，类似 DQN 算法，DDQN 算法同样采用软更新策略对目标神经网络θ进行优化：

$$\theta=\lambda\theta+(1-\lambda)\theta' \quad (10)$$

式中λ为软更新系数，用以控制更新目标神经网络的幅度。

2.2 基于 TD3 算法的中时间尺度优化

2.2.1 中时间优化模型

针对中时间尺度下的光储配电网电压优化，调用光伏逆变器和 SVG 协同调节系统电压水平，该时间尺度以配电网节点的电压偏移和整体网损最小为目标，其目标函数如下：

$$\min F_2[f_v(v_i),\ P_{\mathrm{loss}}] \quad (11)$$

式中 P_{loss} 为配电网整体网损。

光伏逆变器的无功出力受到 DPV 装机容量以及实时有功出力影响，SVG 的无功出力受到其容量限制，约束条件如下：

$$q_{\mathrm{PV}}^2\le s_{\mathrm{PV}}^2-p_{\mathrm{PV}}^2 \quad (12)$$

$$|q_i^{\mathrm{SVG}}|\le s_i^{\mathrm{SVG}} \quad (13)$$

式中 s_{PV} 和 s_{SVG} 分别为接入的 DPV 和 SVG 额定容量。

2.2.2 TD3 算法

TD3 算法包含一个 Actor 与 Target Actor 网络，以及两个 Critic 与 Target Critic 网络，同时引入目标策略平滑正则化器，由于减少了过拟合，有助于提高系统稳定性，相对于广泛采用的 DDPG 算法而言，更加稳定且收敛速度更快[32]。同时，使用双 Q 网络并通过选取两者间的最小值，解决了 DDPG 算法中 Critic 易出现高估动作 Q 值的问题，避免了过估计。

在对两个 Critic 网络进行更新时，利用 Target Actor 网络计算求出一个 s 状态下的动作：

$$a=a+\varepsilon \quad (14)$$

$$\varepsilon\sim\mathrm{clip}[N(0,\sigma),-x,x] \quad (15)$$

式中ε为 TD3 算法运行时添加的随机噪声，其满足正态分布，同时采用裁剪函数 clip 对噪声进行剪切，裁剪的范围为$\pm x$，保证添加噪声后动作的泛化性。

求取动作 a 后，通过两个 Critic 网络计算目标值：

$$y_t=r_t+\gamma\min_{i=1,2}Q_i'(s_{t+1},a_{t+1}|\theta_i^{Q'}) \quad (16)$$

式中 $\min_{i=1,2}Q_i'(s_{t+1},a_{t+1}|\theta_i^{Q'})$ 为两个 Target Critic 网络估计值的较小值。

最后通过梯度下降法对评估值和目标值的差值δ进行最小化，从而更新两个 Critic 网络的参数值：

$$\delta=[Q_i(s_t,a_t|\theta^{Q_i})-y_t]^2,\quad i=1,2 \quad (17)$$

式中 $Q_i(s_t,a_t|\theta^{Q_i})$ 代表第 i 个 Critic 网络。

在 Critic 网络更新 m 步之后对 Actor 网络进行更新，利用 Actor 网络得到状态 s 时的动作 a_{new}：

$$a_{\mathrm{new}}=\mu(s|\theta^{\mu}) \quad (18)$$

式中 $\mu(s|\theta^{\mu})$ 为 Actor 网络。

最后通过 Critic 网络得出的状态动作(s, a_{new})的评估值 q_{new}，并通过 q_{new} 更新 Actor 网络：

$$q_{\mathrm{new}}=Q_1(s,a_{\mathrm{new}}|\theta^{Q_1}) \quad (19)$$

TD3 算法在学习过程中设置奖励函数：

$$r_2=-[f_v(v_i)+P_{\mathrm{loss}}] \quad (20)$$

2.3 基于 SAC 算法的短时间尺度优化

2.3.1 短时间优化模型

长、中时间尺度响应设备经过优化后，再对光储配电网各节点电压进行短时间尺度优化。然而，ES 作为短时间响应设备，采用 DRL 进行训练时，智能体将连续做出充放电动作，容易造成过充过放隐患。考虑到 ES 频繁动作对其自身寿命与系统安全性产生的不良影响，本文采用事件触发机制[33]，以配电网节点电压与 ES 的 S_{OC} 是否超过设定阈值作为判断依据，严格限制 ES 动作频次，进一步优化电压偏移量。短时间尺度以配电网各节点电压与参考电压的偏差值、ES 动作成本以及 S_{OC} 值最小为目标，其目标函数如下：

$$\min F_3[v_{\mathrm{ave}}-v_{\mathrm{ref}},C_{\mathrm{ES}}N_{\mathrm{ES}},\Gamma(S_{\mathrm{OC}})] \quad (21)$$

式中：C_{ES} 和 N_{ES} 分别为 ES 的动作成本与动作次数；$\Gamma(S_{\mathrm{OC}})$函数用于判断 ES 的 S_{OC} 是否超出设定阈值。

考虑过充过放易引发系统运行安全问题，ES 在充放电过程中必须对其 S_{OC} 进行约束。如式(22)所示，在调用 ES 过程中设定 S_{OC} 阈值，用以保证短时间尺度下电压优化的安全性：

$$S_{\mathrm{OCmin}}\le S_{\mathrm{OC}}\le S_{\mathrm{OCmax}} \quad (22)$$

式中 S_{OCmin} 和 S_{OCmax} 分别为 SOC 允许的最小和最大值。本文分别设置为 0.2 和 0.8。

中国知网 https://www.cnki.net

2.3.2　事件触发机制

事件触发是指智能体仅在触发函数满足的前提下进行更新，由此显著降低了智能体的通信频率并有效减少了系统的能耗。事件触发函数的设计与事件触发机制应用场景相关联。

本文采用的事件触发机制如图 3 所示。在每个采样周期 t 内，当长、中两个时间尺度的智能体响应后，短时间尺度智能体通过通信获得更新后的配电网平均电压 v_{ave}，同时设定 ES 动作的电压阈值并作为前置判断环节，若 v_{ave} 未超出所设定的电压阈值，则不满足触发条件，智能体将不会动作；若 v_{ave} 超出设定的电压阈值，则事件触发成立，智能体将根据环境状态控制 ES 做出充放电动作。

在触发 ES 动作时，首先需定义电压状态的偏差 $e(t)$，表征在 t 时刻系统的平均电压和设定电压阈值的偏差：

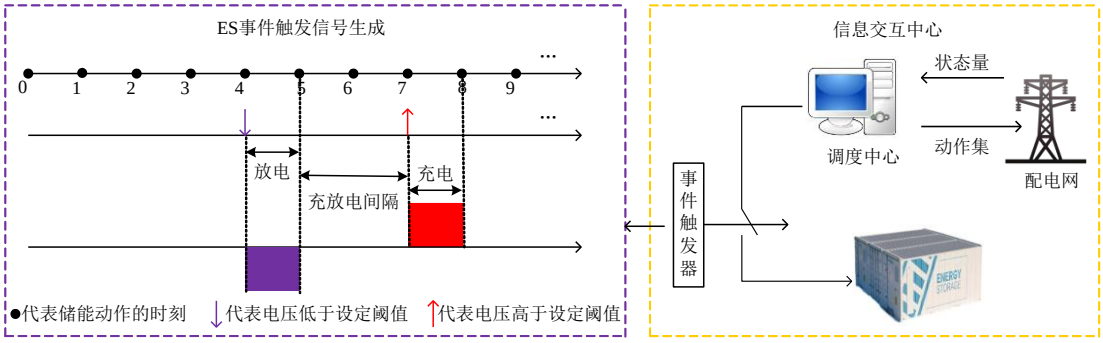


图 3　事件触发机制框图

Fig. 3　Framework of event-triggered mechanism

$$\begin{cases} e(t)=v_{\max}-v_{ave}, & v_{ave}\geq v_{ref} \\ e(t)=v_{ave}-v_{\min}, & v_{ave}<v_{ref} \end{cases} \tag{23}$$

式中：$v_{\max}$ 和 $v_{\min}$ 分别为本文设定的电压阈值上下限；v_{ref} 为电压参考值。可见，当且仅当某时刻配电网的平均电压与电压阈值的偏差低于设定范围，即 $e(t)<0$ 条件成立时进行事件触发。

2.3.3　SAC 算法

SAC 算法能够有效处理连续的动作空间，在实际应用中泛化性较强，具备面向未知环境的适应能力，以及在缺乏先验知识前提下的学习能力[34]。SAC 算法将政策熵集成到 MDP 中，激励智能体进行更广泛的探索学习，避免陷入无解，加速求解临近最优策略。SAC 算法的目标函数如下：

$$J(\upsilon)=\sum_{t=0}^{T}E_{(s_t,a_t)}\{r(s_t,a_t)+\alpha H[\upsilon(\cdot\,|\,s_t)]\} \tag{24}$$

$$H[\upsilon(\cdot\,|\,s_t)]=E[-\log\upsilon(\cdot\,|\,s_t)] \tag{25}$$

式中：T 为 ES 智能体与环境互动的步数；$E(\cdot)$为期望函数；$r(\cdot)$为某时刻状态 s 和动作 a 对应的奖励值；α为控制目标函数中熵的影响因子；$H[\upsilon(\cdot|s_t)]$代表熵值，熵值大小影响智能体对于环境的探索学习程度。

SAC 算法的价值函数 $Q(s_t, a_t)$定义如下：

$$Q(s_t,a_t)=E_{(s_t,a_t)}[r(s_t,a_t)+\gamma V^{\upsilon}(s_{t+1})] \tag{26}$$

式中：$E_{(s_t,a_t)}$ 为 s_t 状态下的期望；$V^{\upsilon}(s_t)$为策略 υ 下状态为 s_t 的价值函数。

SAC 算法学习过程中的奖励 r_3：

$$r_3=-[\lambda\,|\,v_{ave}-v_{ref}\,|+\beta+\rho|S_{OCt}-S_{OCt-1}|] \tag{27}$$

式中：β为 ES 动作后导致 S_{OC} 超出设定的安全范围的惩罚；ρ为 ES 动作后 S_{OC} 变化的惩罚系数，当 S_{OC} 变化在一定阈值范围内时ρ取得较小值，当超出阈值范围后ρ取得较大值，进而避免 S_{OC} 的快速变化。

3　仿真验证

3.1　算例系统

仿真基于 Intel(R) Core(TM) i5-12400F CPU，NVIDA RTX4060Ti GPU 硬件实现。配电网网络参数取自 Matpower 参数库，潮流计算方程调用 Python 中的 Pypower 包进行求解。同时，按本文 1.3 节所述马尔可夫决策过程搭建深度强化学习环境，算法在 Python 的 Pytorch 神经网络框架上实现。本文创建的光储配电网环境为改进的 IEEE 33 节点系统，系统的电压基准值为 12.66 kV，节点 1 设置为参考节点，其结构如图 4 所示。

本文基于原有 IEEE 33 节点系统，分别在节点 6、12、18、22、25、32 接入共 6 台 DPV，总装机容量为 6 MW。在系统 1、2 节点间接入 OLTC，可调电压为 0.95~1.05 pu，最大可调次数 9 次。在系统的 21 和 24 节点接入 SCB，可调挡位共 4 挡，每档可调容量 0.2 Mvar，最大可调次数 4 次。在系统的 10 和 30 节点接入 SVG，可调容量为±800 kvar。

中国知网　https://www.cnki.net

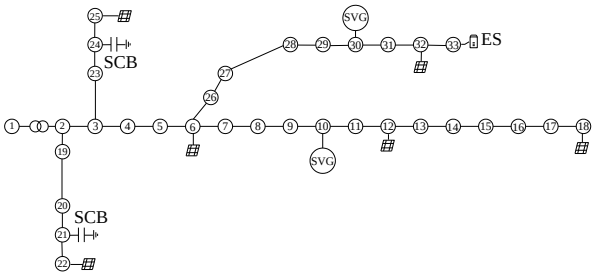


图 4 改进的 IEEE33 节点系统

Fig. 4 Modified IEEE 33-bus system

在系统的末尾节点接入 ES，容量为 1 MW·h，初始 SOC 设定为 0.5[24]。

本文选取比利时某地区 150 d 的光伏数据和负荷数据进行 DRL 训练，训练完成后再选取 50 个典型日数据进行测试，其中某典型日分布式光伏出力和负荷变化曲线如图 5 所示。

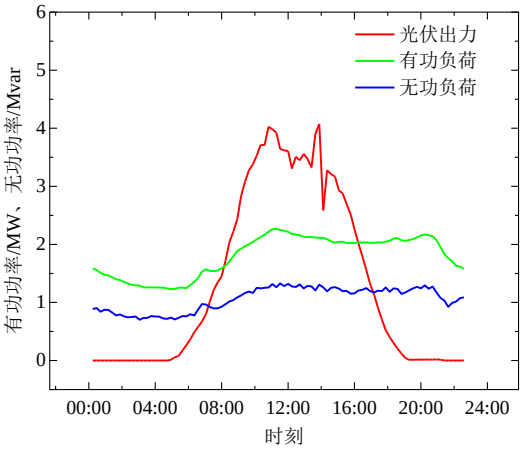
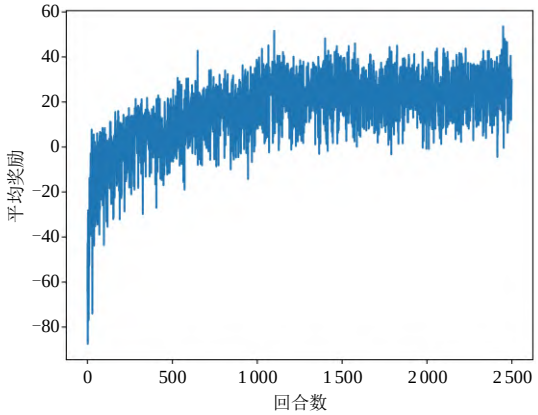


图 5 某典型日分布式光伏出力和负荷分布

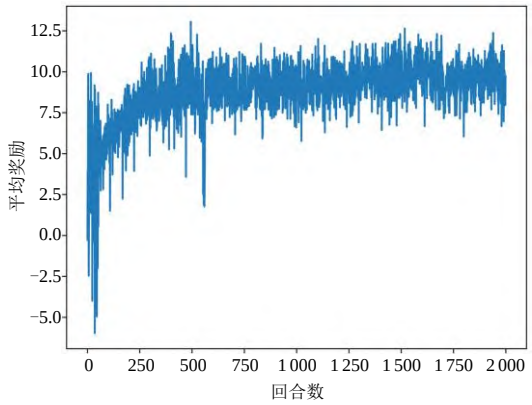
Fig. 5 DPV output and load profile on typical day

3.2 DRL 算法收敛过程

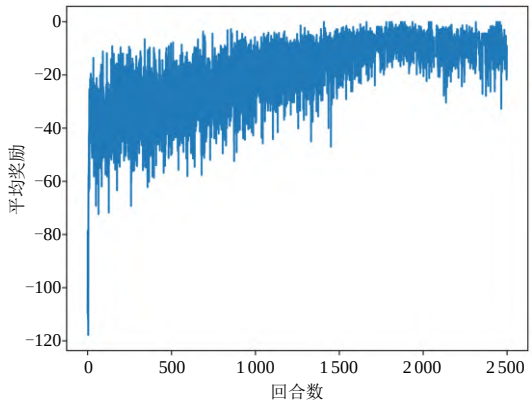
在进行长、中、短 3 时间尺度光储配电网 DRL 训练时，先进行决策时间为 1 h 的长时间尺度 DDQN 智能体训练，学习率设置为 0.000 5，神经网络有两层连接层，神经元个数为 256，折扣因子大小设置为 0.99，经验池的最大容量设置为 20 000，每个训练批次样本容量为 256，其收敛过程如图 6(a)所示。



(a) DDQN奖励值



(b) TD3奖励值



(c) SAC奖励值

图 6 智能体收敛情况

Fig. 6 Agent convergence case

中时间尺度 TD3 智能体以长时间尺度 DDQN 智能体决策过后的系统状态作为决策依据，每次的决策时间为 30 min，由此制定光伏逆变器和 SVG 的动作计划。TD3 智能体的 Actor 学习率设置为 0.001，Critic 学习率为 0.01，Actor 和 Critic 的两个神经网络连接层神经元个数分别为 256 和 128，折扣因子为 0.99，其收敛过程如图 6(b)所示。

短时间尺度 SAC 智能体以长、中两个时间尺度智能体决策过后的系统状态作为决策依据，每次的决策时间为 15 min，由此制定 ES 的动作计划。SAC 智能体的学习率为 0.001，两个全连接层神经元个数为 256，折扣因子大小为 0.99，收敛过程如图 6(c)所示。

可见，在长、中、短 3 时间尺度下，光储配电网 DRL 训练分别收敛于第 3 000、1 000、600 回合附近，表征 DDQN、TD3 以及 SAC 智能体学习效果均较好，动作决策均能够达到要求。

3.3 仿真结果分析

3.3.1 电压优化结果对比

在某典型日 09:00，长、中、短 3 时间尺度电压优化效果如图 7 所示。为充分体现所提方法的实

中国知网 https://www.cnki.net

施效果，本文方法就哈里斯鹰优化算法(Harris hawks optimization，HHO)、二阶锥规划算法(second-order cone programming，SOCP)及文献[17]方法进行横向对比。其中，文献[17]基于深度强化学习实现配电网双时间尺度无功优化，在长时间尺度与短时间尺度上分别采用 A2C 算法与 DQN 算法。同时，本文也对所提长时间尺度优化算法与长、中双时间尺度优化算法进行纵向比较，其中长时间尺度优化算法指仅采用本文所提 3 时间尺度中的长时间尺度智能体(DDQN 智能体)对配电网电压进行优化，长、中双时间尺度优化算法指联合采用原文所提 3 时间尺度中的长时间尺度智能体(DDQN 智能体)与中时间尺度智能体(TD3)智能体对配电网电压进行优化。各方法平均电压偏差如表 1 所示。可见，优化前部分节点出现电压越上限情况，在采用本文及上述对比方法后均能调控电压处于安全范围内。而针对电压偏移，本文方法相比 HHO 与文献[17]方法较小，同时接近 SOCP 优化结果，证明本文方法具有较好的调压效果。

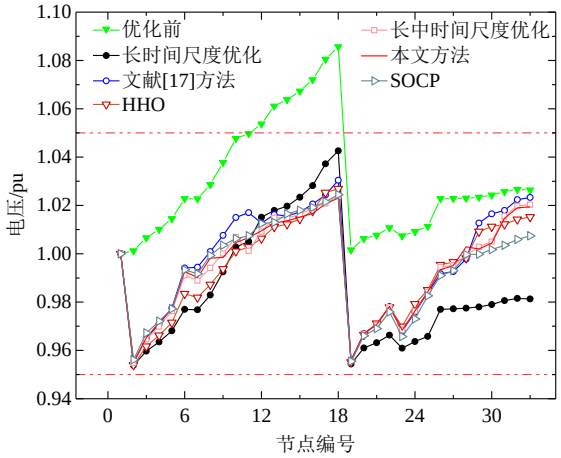


图 7　不同控制策略下各节点电压对比

Fig. 7　Voltage comparison of each bus under different control strategies

表 1　平均电压偏差比较

Table 1　Comparison of average voltage deviation

优化方法	平均电压偏差/pu
优化前	0.0295
长时间尺度优化	0.0258
文献[17]方法	0.0191
HHO	0.0177
长中时间尺度优化	0.0170
本文方法	0.0166
SOCP	0.0162

同时，通过纵向对比可以得知，在进行长时间尺度优化后，系统整体电压水平被调控至安全范围内，但部分节点电压接近临界状态，随 DPV 出力增加仍有越限风险。而采用中时间尺度优化后，部分节点电压呈现远离安全范围上下界并朝向参考电压值聚集的趋势，各节点电压偏移总和收窄。最后在短时间尺度上进一步缩小电压偏移总和，实现了系统各节点电压的优化分布，验证了本文方法的可行性。

为进一步验证本文方法在不确定场景下的实施效果，选取某典型日光伏出力数据并采用神经网络进行预测，其出力真实值和预测值如图 8 所示。

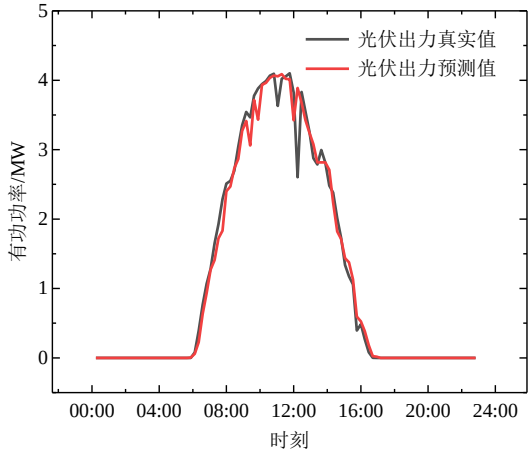
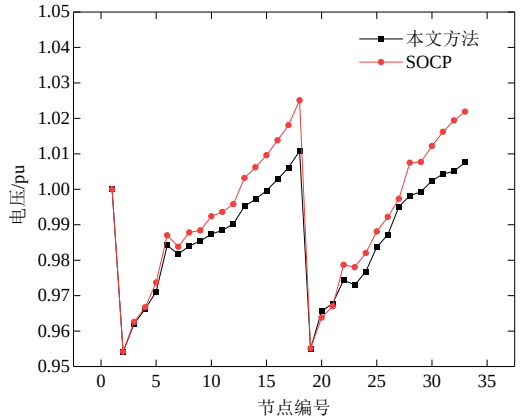


图 8　不确定场景下光伏出力

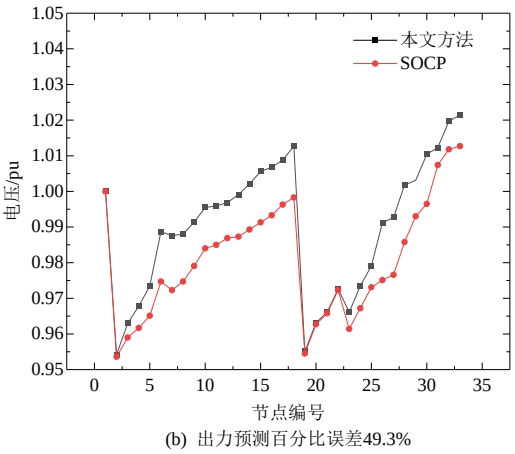
Fig. 8　Photovoltaic output under uncertainty scenarios

分别采用本文方法和 SOCP 就某典型日 10:00 与 13:00 光储配电网电压进行优化，其结果如图 9 所示。其中，两时刻出力预测百分比误差分别为 11.6%与 49.3%。可见，10:00 光伏出力实际值大于预测值，13:00 反之，而 SOCP 针对预测值求出的最优解显然增加了平均电压偏差。相对地，本文方法充分发挥了深度强化学习在不确定场景中较强的探索能力，在两时刻场景下相比 SOCP，其平均电压偏差分别减小 0.001 72 和 0.004 62 pu，在不确定性加剧时依旧保持了较好的电压调控效果，验证



(a) 出力预测百分比误差11.6%

中国知网　https://www.cnki.net



(b) 出力预测百分比误差49.3%

图 9 光伏出力不确定性场景下电压优化结果

Fig. 9 Voltage optimization comparison for photovoltaic output under uncertainty scenarios

了本文方法在不确定场景下的适用性与优越性。

3.3.2 3 时间尺度优化效果分析

针对本文所提长时间尺度优化，OLTC 和两组 SCB 在 24 h 内的挡位变化情况如图 10 所示。可见，OLTC 在 24 h 内抽头总动作次数为 6 次，而 SCB 投切次数分别为 4 次和 3 次，均满足 24 h 内设备动作次数的约束。同时，本文对比了采用 HHO、SOCP 及文献[17]方法在离散设备上的动作次数，如表 2 所示，结果表明本文方法在 OLTC 与 SCB 上均有较少的动作次数。

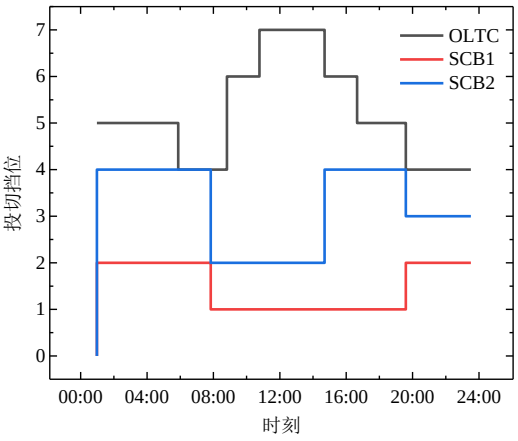


图 10 长时间尺度设备投切动作

Fig. 10 Long-timescale devices cutting action

表 2 不同方法下的离散设备累计动作次数

Table 2 Accumulative number of discrete devices action with different methods

优化方法	OLTC 动作次数	SCB1 动作次数	SCB2 动作次数
HHO	9	4	4
文献[17]方法	7	4	4
SOCP	8	4	4
本文方法	6	3	4

图 11 与表 3 展示了本文所提中时间尺度优化下光伏逆变器和 SVG 动作后的配电网网损情况。对比 HHO 及文献[17]方法可以看出，采用本文提出的方法，配电网网损在 24 h 内出现明显下降且平均网损量最低，即 141.2 kW，证明了本文方法的有效性与先进性。

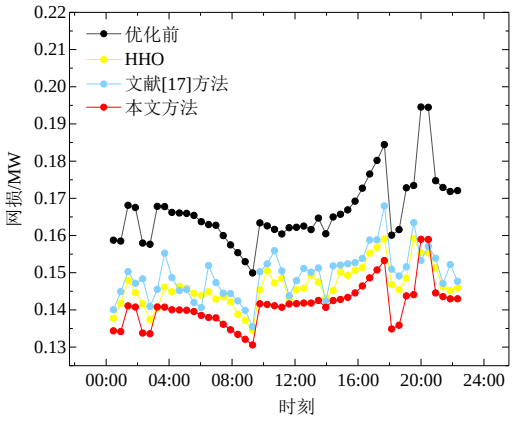


图 11 不同方法下网损对比

Fig. 11 Network loss comparison with different methods

表 3 平均网损对比

Table 3 Comparison of average network loss

优化方法	平均网损/kW
优化前	166.3
文献[17]方法	149.4
HHO	146.5
本文方法	141.2

在本文所提短时间尺度优化下，主要依靠智能体控制 ES 做出充放电动作，以此实现调控电压的目的。考虑 ES 快充快放、过充过放及高频连续动作将影响系统的经济性与安全性，本文通过设计奖励函数，鼓励智能体学习更安全的动作，并对导致 ES 的 S_{OC} 快速跳变的动作给予较大惩罚。同时，结合事件触发控制，本文严格限制了 ES 的动作次数与 S_{OC}，触发前后其平均电压调控结果与 S_{OC} 量如图 12、13

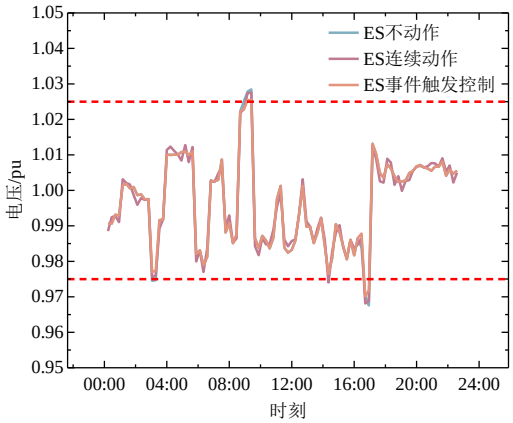


图 12 采用事件触发控制前后电压优化对比

Fig. 12 Voltage optimization comparison before and after adopting event-triggered control

中国知网 https://www.cnki.net

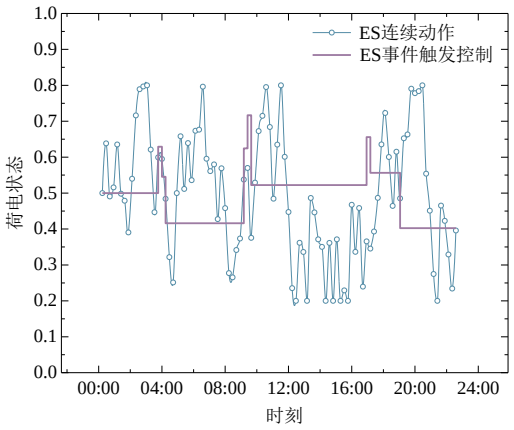


图 13　采用事件触发控制前后 SOC 对比

Fig. 13　SOC comparison before and after adopting event-triggered control

所示。可见，当部分时刻平均电压低于设定的最低电压阈值时，ES 做出放电动作并伴随 S_{OC} 值下降；当部分时刻平均电压超出设定的最高电压阈值时，ES 做出充电动作并伴随 S_{OC} 值上升。可以看出 S_{OC} 无论是否采用事件触发控制，其在 15 min 内变化均低于 30%，避免了 ES 的大电流快速充放电。同时，采用事件触发控制后，S_{OC} 被严格限制于 0.2~0.8 的约束范围，避免了 ES 出现的过充过放现象。而相较 ES 连续动作场景，本文方法大幅度减少了 ES 的动作次数，具体低至未采用事件触发的 10%以下，体现了该方法的有效性。

为充分讨论本文所提 3 种 DRL 算法与 3 时间尺度的适配性，在确定长时间尺度采用 DDQN 算法，中时间尺度采用 TD3 算法的基础之上，本文重点在短时间尺度下就 TD3 算法与 SAC 算法的电压优化实施效果进行了比较，其结果如图 14 所示。结果表明，经 TD3 算法优化后的配电网电压偏差明显大于 SAC 算法优化后的结果，验证了 SAC 算法相较 TD3 算法在短时间尺度下针对 ES 的控制更具有适配性与优越性。

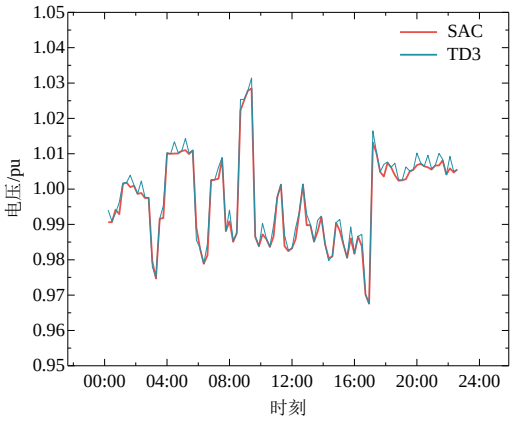


图 14　SAC 和 TD3 电压优化对比

Fig. 14　Voltage optimization comparison between SAC and TD3

4　结论

本文结合有功/无功调压设备的时域动作特性，基于 DRL 方法提出了多设备在多时间尺度上的协同控制策略，实现了光储配电网电压的有效调节与网损降低。同时，考虑 ES 快充快放、过充过放及连续充放影响，结合事件触发机制控制 ES 合理动作参与电压调节，确保系统运行安全。最后通过算例仿真，证明了本方法的有效性和可行性，并得出以下结论：

1）面向多类型混杂设备参与的光储配电网调压问题，考虑系统运行稳定性与经济性为优化目标，基于 DRL 的无模型特征可有效求解各设备最优出力，面向不确定场景时该方法相较传统优化算法更有优势。同时，长、中、短三时间尺度优化方法的建立相较单一或双时间尺度在当前场景下有其先进性与必要性，该方法可为实际工程应用提供可行研究思路与范式。

2）长时间尺度优化以系统整体电压偏移和离散设备调节次数为目标，利用 DDQN 算法训练长时间尺度智能体控制 OLTC 和 SCB 设备动作，限制动作次数分别低至 6 次与 3 次，保障系统电压整体处于安全范围内，确保离散设备动作次数最优。

3）中时间尺度优化以系统电压偏移和平均网损为优化目标，利用 TD3 算法训练中时间尺度智能体并控制光伏逆变器和 SVG 设备动作，进一步优化长时间尺度优化后的配电网电压，将电压偏移优化为 0.016 6 pu，同时降低系统整体网损至 141.2 kW。

4）短时间尺度优化通过合理设计奖励函数，避免了 ES 的快速充放电。同时，结合事件触发控制，设定 ES 动作的电压阈值与 S_{OC} 约束，即“先判断、再动作”，限制 S_{OC} 处于约束范围 0.2~0.8，并大幅降低 ES 的动作次数至无事件触发控制的 10%以下。所提方法确保了 ES 的使用循环寿命，进一步保障了系统的安全性和经济性。

本文在电压优化过程中将各参与调压设备统一视作单智能体进行训练求解，面向大规模配电网应用场景存在局限性。同时，本文针对 ES 寿命衰减对于电压优化的影响未做深入讨论，调度过程中其 SOC 依然存在临近甚至超出安全区间的可能。

中国知网　https://www.cnki.net

对此，考虑基于多智能体的 DRL 算法在多时间尺度下进行协调控制学习，同时计及 ES 寿命衰减并加设 SOC 柔性限制，由此进一步提升系统精细化管控调压设备的能力，保障系统运行的安全性，以上将作为本文下一步的研究重点。

参考文献

[1] 谢小荣，马宁嘉，刘威，等. 新型电力系统中储能应用功能的综述与展望[J]. 中国电机工程学报，2023，43(1)：158-168.
XIE Xiaorong，MA Ningjia，LIU Wei，et al. Functions of energy storage in renewable energy dominated power systems：review and prospect[J]. Proceedings of the CSEE，2023，43(1)：158-168(in Chinese).

[2] 舒印彪，张智刚，郭剑波，等. 新能源消纳关键因素分析及解决措施研究[J]. 中国电机工程学报，2017，37(1)：1-8.
SHU Yinbiao，ZHANG Zhigang，GUO Jianbo，et al. Study on key factors and solution of renewable energy accommodation[J]. Proceedings of the CSEE，2017，37(1)：1-8(in Chinese).

[3] ZHANG Cuo，XU Yan，WANG Yu，et al. Three-stage hierarchically-coordinated voltage/var control based on PV inverters considering distribution network voltage stability[J]. IEEE Transactions on Sustainable Energy，2022，13(2)：868-881.

[4] 姚宏民，杜欣慧，李廷钧，等. 光伏高渗透率下配网消纳能力模拟及电压控制策略研究[J]. 电网技术，2019，43(2)：462-469.
YAO Hongmin，DU Xinhui，LI Tingjun，et al. Simulation of consumption capacity and voltage control strategy of distribution network with high penetration of photovoltaics[J]. Power System Technology，2019，43(2)：462-469(in Chinese).

[5] 丁明，王伟胜，王秀丽，等. 大规模光伏发电对电力系统影响综述[J]. 中国电机工程学报，2014，34(1)：1-14.
DING Ming，WANG Weisheng，WANG Xiuli，et al. A review on the effect of large-scale PV generation on power systems[J]. Proceedings of the CSEE，2014，34(1)：1-14(in Chinese).

[6] 朱星旭，韩学山，杨明，等. 含分布式光伏与储能配电网时变最优潮流追踪的分布式算法[J]. 中国电机工程学报，2019，39(9)：2644-2657.
ZHU Xingxu，HAN Xueshan，YANG Ming，et al. A distributed algorithm for time-varying optimal power flow tracking in distribution networks with photovoltaics and energy storage[J]. Proceedings of the CSEE，2019，39(9)：2644-2657(in Chinese).

[7] 丁明，方慧，毕锐，等. 基于集群划分的配电网分布式光伏与储能选址定容规划[J]. 中国电机工程学报，2019，39(8)：2187-2201.
DING Ming，FANG Hui，BI Rui，et al. Optimal siting and sizing of distributed PV-storage in distribution network based on cluster partition[J]. Proceedings of the CSEE，2019，39(8)：2187-2201(in Chinese).

[8] 卢奇秀. 新能源强制配储愈演愈烈[N]. 中国能源报，2023-07-03(001).
LU Qixiu. The mandatory allocation and storage of new energy is becoming increasingly severe [N]. China Energy News，2023-07-03(001)(in Chinese).

[9] WANG Licheng，BAI Feifei，YAN Ruifeng，et al. Real-time coordinated voltage control of PV inverters and energy storage for weak networks with high PV penetration[J]. IEEE Transactions on Power Systems，2018，33(3)：3383-3395.

[10] JIN Dan，CHIANG H D，LI Peng. Two-timescale multi-objective coordinated volt/var optimization for active distribution networks[J]. IEEE Transactions on Power Systems，2019，34(6)：4418-4428.

[11] 任佳依，顾伟，王勇，等. 基于模型预测控制的主动配电网多时间尺度有功无功协调调度[J]. 中国电机工程学报，2018，38(5)：1397-1407.
REN Jiayi，GU Wei，WANG Yong，et al. Multi-time scale active and reactive power coordinated optimal dispatch in active distribution network based on model predictive control[J]. Proceedings of the CSEE，2018，38(5)：1397-1407(in Chinese).

[12] 王志强，郭晨阳，刘文霞，等. 计及负荷特性的配电网多时间尺度电压控制及协调修正[J]. 电力系统自动化，2017，41(15)：51-57.
WANG Zhiqiang，GUO Chenyang，LIU Wenxia，et al. Multi-time scale voltage control and coordinated correction for distribution networks considering load characteristics[J]. Automation of Electric Power Systems，2017，41(15)：51-57(in Chinese).

[13] XU Hanchen，DOMÍNGUEZ-GARCÍA A D，SAUER P W. Optimal tap setting of voltage regulation transformers using batch reinforcement learning[J]. IEEE Transactions on Power Systems，2020，35(3)：1990-2001.

[14] 杨挺，赵黎媛，王成山. 人工智能在电力系统及综合能源系统中的应用综述[J]. 电力系统自动化，2019，43(1)：2-14.
YANG Ting，ZHAO Liyuan，WANG Chengshan. Review on application of artificial intelligence in power system and integrated energy system[J]. Automation of Electric

中国知网 https://www.cnki.net

Power Systems，2019，43(1)：2-14(in Chinese).

[15] 冯斌，胡轶婕，黄刚，等．基于深度强化学习的新型电力系统调度优化方法综述[J]．电力系统自动化，2023，47(17)：187-199．
FENG Bin，HU Yijie，HUANG Gang，et al．Review on optimization methods for new power system dispatch based on deep reinforcement learning[J]．Automation of Electric Power Systems，2023，47(17)：187-199(in Chinese)．

[16] LIU Haotian，WU Wenchuan，WANG Yao，et al．Bi-level off-policy reinforcement learning for two-timescale volt/VAR control in active distribution networks[J]．IEEE Transactions on Power Systems，2023，38(1)：385-395．

[17] 倪爽，崔承刚，杨宁，等．基于深度强化学习的配电网多时间尺度在线无功优化[J]．电力系统自动化，2021，45(10)：77-85．
NI Shuang，CUI Chenggang，YANG Ning，et al．Multi-time-scale online optimization for reactive power of distribution network based on deep reinforcement learning [J]．Automation of Electric Power Systems，2021，45(10)：77-85(in Chinese)．

[18] 李鹏，姜磊，王加浩，等．基于深度强化学习的新能源配电网双时间尺度无功电压优化[J]．中国电机工程学报，2023，43(16)：6255-6265．
LI Peng，JIANG Lei，WANG Jiahao，et al．Optimization of dual-time scale reactive voltage for distribution network with renewable energy based on deep reinforcement learning[J]．Proceedings of the CSEE，2023，43(16)：6255-6265(in Chinese)．

[19] 胡丹尔，彭勇刚，韦巍，等．多时间尺度的配电网深度强化学习无功优化策略[J]．中国电机工程学报，2022，42(14)：5034-5044．
HU Daner，PENG Yonggang，WEI Wei，et al．Multi-timescale deep reinforcement learning for reactive power optimization of distribution network[J]．Proceedings of the CSEE，2022，42(14)：5034-5044(in Chinese)．

[20] 王继业．人工智能赋能源网荷储协同互动的应用及展望[J]．中国电机工程学报，2022，42(21)：7667-7681．
WANG Jiye．Application and prospect of source-grid-load-storage coordination enabled by artificial intelligence [J]．Proceedings of the CSEE，2022，42(21)：7667-7681(in Chinese)．

[21] 蔺伟山，王小君，孙庆凯，等．计及安全约束的综合能源系统深度强化学习优化调度策略研究[J]．电网技术，2023，47(5)：1970-1978．
LIN Weishan，WANG Xiaojun，SUN Qingkai，et al．Optimal dispatch strategy of integrated energy system based on deep reinforcement learning considering security constraints[J]．Power System Technology，2023，47(5)：1970-1978(in Chinese)．

[22] NGUYEN H T，CHOI D H．Three-stage inverter-based peak shaving and volt-VAR control in active distribution networks using online safe deep reinforcement learning [J]．IEEE Transactions on Power Systems，2022，13(4)：3266-3277．

[23] 张剑，崔明建，姚潇毅，等．基于数据驱动与物理模型的主动配电网双时间尺度协调优化[J]．电力系统自动化，2023，47(20)：64-71．
ZHANG Jian，CUI Mingjian，YAO Xiaoyi，et al．Dual-timescale active and reactive power coordinated optimization for active distribution network based on data-driven and physical model[J]．Automation of Electric Power Systems，2023，47(20)：64-71(in Chinese)．

[24] WANG Shengyi，DU Liang，FAN Xiaoyuan，et al．Deep reinforcement scheduling of energy storage systems for real-time voltage regulation in unbalanced LV networks with high PV penetration[J]．IEEE Transactions on Sustainable Energy，2021，12(4)：2342-2352．

[25] 张剑，崔明建，何怡刚．结合数据驱动与物理模型的主动配电网双时间尺度电压协调优化控制[J]．电工技术学报，2024，39(5)：1327-1339．
ZHANG Jian，CUI Mingjian，HE Yigang．Dual timescales coordinated and optimal voltages control in distribution systems using data-driven and physical optimization [J]．Transactions of China Electrotechnical，2024，39(5)：1327-1339(in Chinese)．

[26] 冯昌森，张瑜，谢路耀，等．配电系统双时间尺度电压管理的深度强化学习方法[J]．电力系统自动化，2022，46(12)：202-209．
FENG Changsen，ZHANG Yu，XIE Luyao，et al．Deep reinforcement learning approach for dual-timescale voltage management in distribution system[J]．Automation of Electric Power Systems，2022，46(12)：202-209(in Chinese)．

[27] QI Yunying，DANG Zhehui，YANG Pengcheng，et al．TD3-based voltage regulation for distribution networks with PV and energy storage system[C]//2023 Panda Forum on Power and Energy(PandaFPE)．Chengdu，China：IEEE，2023．

[28] 李琦，乔颖，张宇精．配电网持续无功优化的深度强化学习方法[J]．电网技术，2020，44(4)：1473-1480．
LI Qi，QIAO Ying，ZHANG Yujing．Continuous reactive power optimization of distribution network using deep reinforcement learning[J]．Power System Technology，

中国知网　https://www.cnki.net

2020，44(4)：1473-1480(in Chinese)．

[29] CAO Di，ZHAO Junbo，HU Weihao，et al．Data-driven multi-Agent deep reinforcement learning for distribution system decentralized voltage control with high penetration of PVs[J]．IEEE Transactions on Smart Grid，2021，12(5)：4137-4150．

[30] ZHANG Tingjun，YU Liang，YUE Dong，et al．Coordinated voltage regulation of high renewable-penetrated distribution networks：an evolutionary curriculum-based deep reinforcement learning approach [J]．International Journal of Electrical Power & Energy Systems，2023，149：108995．

[31] 全欢，彭显刚，刘涵予，等．基于深度强化学习的配电网实时电压优化控制方法[J]．电网技术，2023，47(5)：2029-2038．
QUAN Huan，PENG Xiangang，LIU Hanyu，et al．Voltage optimal control of distribution network based on deep reinforcement learning[J]．Power System Technology，2023，47(5)：2029-2038(in Chinese)．

[32] CAO Di，ZHAO Junbo，HU Weihao，et al．Deep reinforcement learning enabled physical-model-free two-timescale voltage control method for active distribution systems[J]．IEEE Transactions on Smart Grid，2022，13(1)：149-165．

[33] 董家伟，龚春阳，包俊，等．事件触发改进一致性算法的孤岛运行多逆变器微电网系统分布式二次调频方法[J]．中国电机工程学报，2024，44(2)：476-488．
DONG Jiawei，GONG Chunyang，BAO Jun，et al．Event-triggered improved consensus algorithm distributed secondary frequency regulation of multi- inverter microgrid systems with islanded operation [J]．Proceedings of the CSEE，2024，44(2)：476-488(in Chinese)．

[34] YAN Linfang，CHEN Xia，ZHOU Jianyu，et al．Deep reinforcement learning for continuous electric vehicles charging control with dynamic user behaviors[J]．IEEE Transactions on Smart Grid，2021，12(6)：5124-5134．



黄冬梅

在线出版日期：2024-10-15。
收稿日期：2024-02-22。

作者简介：
黄冬梅(1964)，女，教授，博士生导师，研究方向为海洋与电力时空信息技术，dmhuang@shou.edu.cn；
*通信作者：龚春阳(1991)，男，助理研究员，研究方向为新能源发电规划与控制，sh19900307@163.com。

(编辑 李泽荣，李新洁)

中国知网 https://www.cnki.net

 DOI：10.13334/j.0258-8013.pcsee.240403

Voltage Optimization for PV-ES Distribution Network With Multi-timescale Deep Reinforcement Learning Method

HUANG Dongmei[1], YU Jingpeng[1], CUI Chenggang[2], DONG Qianwen[2], ZHOU You[3], GONG Chunyang[1*]

(1.College of Electrical Engineering, Shanghai University of Electric Power; 2.College of Automation Engineering, Shanghai University of Electric Power; 3.State Grid Suzhou Power Supply Company)

KEY WORDS: deep reinforcement learning; multi-timescale; PV-ES distribution network; voltage optimization; event-triggered mechanism

With the increasing penetration of distributed photovoltaics (DPV) in distribution network, voltage over-limit issues have emerged. Additionally, the integration of various voltage regulation devices has increased the voltage regulation difficulty, bringing new challenges to maintaining voltage stability.

This paper proposes a multi-timescale voltage optimization method based on deep reinforcement learning (DRL), combining the characteristics of event-triggered mechanism. Aiming to minimize voltage deviation and network loss, the method considers the time domain characteristics of various voltage regulation devices and designs event-triggered mechanism to strictly limit number of energy storage (ES) actions and state of charge (SOC) in multi-timescale.

Aiming to optimize voltage in the distribution network, voltage regulation devices with different action characteristics are divided into different time scales. On-load tap changers (OLTC) and shunt capacitor banks (SCB) /PV inverters and static var generators (SVG)/ES are defined as long/medium/short-timescale action devices respectively with response speed from slow to fast. The three-timescale division is depicted in Fig. 1. (The *T* represents device response action time)

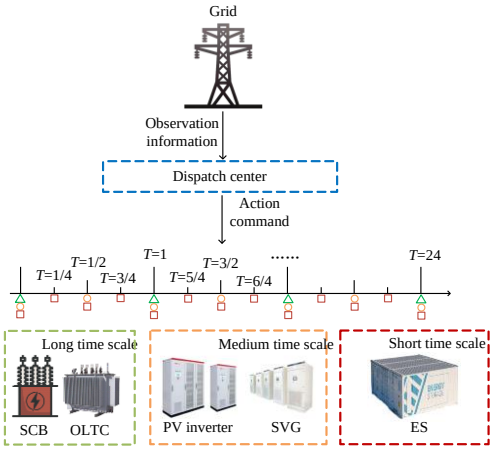


Fig. 1 Three-timescale division

For the three-timescale, this paper adopts DDQN/ TD3/SAC DRL to train the intelligent agent to achieve voltage regulation in distribution network. Especially, in the short-timescale, by reasonably designing the reward function, the rapid charging and discharging of ES are avoided. Meanwhile, setting voltage threshold and SOC constraint for ES operation under event-triggered mechanism, SOC is limited within the range of 0.2~0.8 and the frequency of ES operation is reduced dramatically. The event-triggered mechanism is shown in Fig. 2.

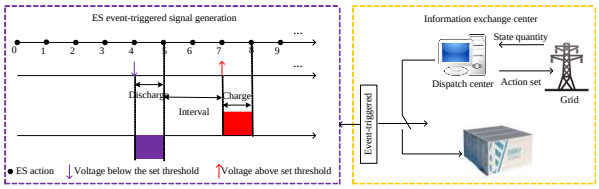
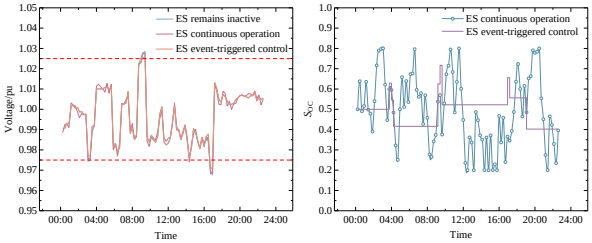


Fig. 2 Event-triggered mechanism

Compared to other existing research methods, this paper demonstrates a smaller voltage deviation and average network losses, measuring 0.016 6 pu and 141.2 kW respectively, and more suitable for application scenarios that appear relatively high uncertainty in photovoltaic output. In addition, it effectively limits the cutting actions of on-load tap changers and capacitor banks to 6 and 3 times, respectively. Simultaneously, it limits the SOC variation of ES within 30% over a 15-minute period, significantly reducing action frequency to less than 10% of continuous situation. Above comparison results before and after adopting event-triggered control are shown in Fig. 3.



(a) Voltage optimization (b) SOC variation

Fig. 3 Comparison results before and after adopting event-triggered control

中国知网 https://www.cnki.net