DOI：10.13334/j.0258-8013.pcsee.221170 文章编号：0258-8013 (2023) 16-6255-11 中图分类号：TM 714 文献标识码：A

基于深度强化学习的新能源配电网双时间尺度无功电压优化

李鹏，姜磊*，王加浩，夏辉，潘有朋

(华北电力大学电气与电子工程学院，河北省 保定市 071003)

Optimization of Dual-time Scale Reactive Voltage for Distribution Network With Renewable Energy Based on Deep Reinforcement Learning

LI Peng, JIANG Lei*, WANG Jiahao, XIA Hui, PAN Youpeng

(School of Electrical and Electronic Engineering, North China Electric Power University, Baoding 071003, Hebei Province, China)

ABSTRACT: A large amount of renewable energy is connected to the distribution network, and its volatility and intermittency are easy to cause frequent voltage fluctuation in distribution network. Traditional model-based reactive power and voltage optimization methods are highly dependent on the accurate modeling of the power grid, and their solution accuracy and calculation speed are difficult to meet the requirements for voltage control of distribution network with renewable energy. In this paper, a dual-time scale distribution network reactive power and voltage optimization method is proposed based on deep reinforcement learning. This method transforms the reactive voltage optimization problem of the power system into a Markov decision process, considers the differential regulation characteristics of reactive power compensation equipment and the characteristics of different deep reinforcement learning algorithms, and designs a dual-time scale optimization scheme by coordinated controlling for discrete equipment and continuous equipment. Among them, the switching plan of the shunt capacitor bank is formulated on the long-term scale to adjust the voltage deviation and minimize the network loss of the whole system; on the short-time scale, a rolling prediction window is set, and the SVG output plan is formulated to track the voltage change and solve the problem of frequent voltage fluctuation of distribution network due to the connection of renewable energy. Finally, the advantages of the data-driven scheme in the realization speed and effect of reactive power and voltage optimization are verified by an IEEE-33 node extension system.

KEY WORDS: distribution network with renewable energy; deep reinforcement learning; dual-time scale; reactive voltage optimization; Markov decision process

摘要：新能源大量接入配电网，其波动性及间歇性容易导致配电网电压的频繁波动问题。传统基于模型的无功电压优化方法高度依托于电网的精准建模，其求解精度与计算速度难以满足含新能源配电网对于电压控制的要求。该文基于深度强化学习，提出一种双时间尺度配电网无功电压优化方法。该方法将电力系统无功电压优化问题转化为马尔可夫决策过程，统筹考虑无功补偿设备的差异化调节特性和不同深度强化学习算法的特点，设计针对离散型设备和连续型 设备协调控制的双时间尺度优化方案。其中，长时间尺度上制定并联电容器组投切计划，以调整电压偏移，同时最小化全系统网损；短时间尺度上设置滚动预测窗，制定 SVG 出力计划，以跟踪电压变化，解决新能源并网带来的配电网电压频繁波动问题。最后通过 IEEE33 节点拓展系统验证该数据驱动方案在无功电压优化的实现速度和效果上所具有的优势。

关键词：新能源配电网；深度强化学习；双时间尺度；无功电压优化；马尔可夫决策过程

0 引言

随着社会的高速发展，经济全球化、工业化进程加快，能源需求大幅上升，化石能源等传统能源将逐渐难以支撑人类社会的可持续发展[1]。能源低碳转型是全球能源发展的必然趋势[2]。而新能源是引领电力系统绿色低碳发展及转型的重要前提[3]，在未来电力系统中占据主体地位。随着集中式新能源与各类分布式新能源在配电网所占比例的增加，新能源的波动性以及间歇性对配电网的影响加大，造成配电网电压的频繁波动问题，为无功支撑和电

基金项目：国家电网公司科技项目(5108-202018028A-0-0-00)。

Project Supported by Science and Technology Project of State Grid Corporation (5108-202018028A-0-0-00).

压安全带来新的挑战[4-6]。

配电网无功电压优化问题可以看作一个非线性，且拥有众多目标、变量及约束的混合整数优化问题。目前，动态无功电压优化的求解方法主要有传统运筹学优化[7-9]和启发式搜索[10, 11]，但这些方法往往存在收敛速度慢、计算量大且易陷入局部最优等问题，在实际系统运行过程中会耗费大量资源和时间，难以持续发挥作用。无功电压优化问题中应对新能源不确定性的方法有模糊优化[12]、随机优化[13]和鲁棒优化[14]等，这些方法分别存在易受决策者的主观态度影响、严重依赖预测数据和求解结果过于保守等问题。此外，大多数现有优化方法基于物理模型，无法避免对精准的电网参数的依赖。文献[15]将人工智能算法应用在无功电压优化领域，使电力系统在各种状况下能够及时准确地做出应对措施，为电力系统的运行控制提供了新思路。

对比常规控制方法，强化学习(reinforcement learning，RL)基于马尔可夫决策过程(Markov decision process，MDP)进行迭代求解[16]。利用 RL 强大的自主决策能力，能够在短时间内根据系统的环境信息，直接得到稳定的控制策略[17]，因此 RL 能够很好地应用于无功电压优化控制领域。文献[18]提出一种基于状态敏感度的简化强化学习方法，以此来搜索多目标混合协调二级电压控制的帕累托前沿。文献[19]利用了 RL 的在线学习功能和良好的收敛性能，基于 Q 学习方法保证了在当前学习阶段下无功电压调控设备的控制策略最优，弥补了启发式算法不能在线学习的劣势。但上述方法在面对连续的状态空间和动作空间时需进行离散化处理，若状态空间和动作空间具有高维度，则容易出现“维数灾”[20]。

深度强化学习(deep reinforcement learning，DRL)则在具有优秀决策能力的 RL 基础上加以改进，通过利用深度神经网络(deep neural net，DNN)作为函数逼近器来克服上述局限性。文献[15]提出电网脑框架，在正常和故障状态下分别根据电网信息计算出状态值和奖励值，并传入智能体(deep Q network，DQN)中，即可得到智能体提供的建议操作，实现了对发电机端电压设定值的优化，为无功电压优化提供了新角度。

为提高实际电力系统中无功电压的控制精度，更多研究向多时间尺度方向展开。文献[6]分别将 1h 与 15min 作为长短时间尺度，实现了含高比例新能源配电网的无功电压协调控制，所提方法能够降低能量损失，并且在源荷双向不确定性的影响下仍可维持安全的电压水平。但该方法采用的优化目标为一个不变的全局优化目标，使优化过程只能离线进行。离线优化的局限性会随着新能源在配电网所占比例的增加而逐渐体现，因此传统多时间尺度无功电压优化不能在进行未来充分长时间内的理想优化时有效兼顾实际存在的不确定性影响。

在此基础上，为解决新能源并网带来的配电网电压频繁波动问题，结合各类无功补偿设备的调节方式与响应时间存在差异的特点，本文提出一种基于深度强化学习(deep reinforcement learning，DRL)的双时间尺度配电网无功电压优化方法。统筹考虑无功补偿设备的差异化调节特性和不同深度强化学习算法的特点，分别选取 DQN 以及深度确定性策略梯度(deep deterministic policy gradient，DDPG)算法作为长短时间尺度优化内核。长时间尺度上制定电容器组各时刻点的补偿计划，以调整电压偏移，同时最小化全系统网损；短时间尺度上设置滚动预测窗，制定 SVG 出力计划，以跟踪电压变化，解决新能源并网带来的配电网电压频繁波动问题。最后通过算例验证本文所设计方法的正确性和有效性。

1 电力系统的 MDP 模型构建

1.1 电力系统物理量表示

在一个包含 N 个节点以及 L 条线路的含新能源配电网中，节点编号被包含在集合 $\boldsymbol{N}=\{1, 2, \ldots, N\}$ 中，线路编号被包含在集合 $\boldsymbol{L}=\{1, 2, \ldots, L\}$ 中，其中新能源并网节点和传统发电机节点编号分别包含在集合 $\boldsymbol{Nr}$ 和 $\boldsymbol{Ng}(\boldsymbol{Nr}, \boldsymbol{Ng}\in\boldsymbol{N})$ 中。用 v_i 表示第 i 节点电压幅值，$s_i=p_i+\mathrm{j}q_i$ 表示注入节点 i 的复功率。将各中枢节点电压信息以及各节点注入有功无功功率信息分别收集在向量 $\boldsymbol{v}, \boldsymbol{p}, \boldsymbol{q}$ 中。

此外，各发电机出力计划可以从调度中心直接获取，新能源出力以及各节点负荷信息可以从实时市场获取或利用预测算法得到[21]。

1.2 双时间尺度划分

将一天作为一个优化周期，并联补偿电容器组(shunt capacitor bank，SCB)在 $t=0, \ldots, K_l-1$ 时刻实施投切，再将 K_l 个长时间间隔细分为 K_s 个相同的短时间间隔，在每个短时间间隔内，静止无功补偿器[22](static var generator，SVG)在 $\tau=0, \ldots, K_s-1$ 时刻

调整无功出力值，如图 1 所示。

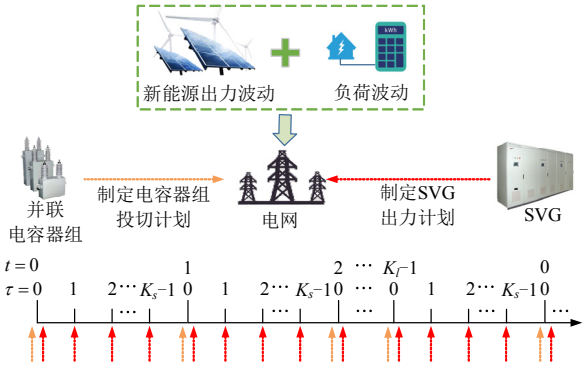


图 1　双时间尺度划分

Fig. 1　Dual-time scale division

将并联电容器组接入节点和静止无功补偿器接入节点的编号分别放入集合 $\boldsymbol{N}_{\mathrm{c}}$ 和 $\boldsymbol{N}_{\mathrm{SVG}}$ 中($\boldsymbol{N}_{\mathrm{c}}$, $\boldsymbol{N}_{\mathrm{SVG}}\in\boldsymbol{N}$)。并联在节点 $i(i\in\boldsymbol{N}\mathrm{c})$的电容器组在时刻 t 的补偿值 $q_{c,i}^{t}$ 取决于在这个时刻并联电容器组所处的投切档位状态 $T_i(t)$。为避免并联电容器组频繁投切给设备本身带来的绝缘介质老化以及电容量衰减等危害，设置并联在节点 i 的电容器组一天内的最大投切次数为 $C_i^{\max}$，在时刻 t 已投切次数用 $C_i(t)$ 表示。某一时刻全部并联电容器组投切状态元素 $T_i(t)$构成信息向量 $\boldsymbol{T}$，全部已投切次数元素 $C_i(t)$构成信息向量 $\boldsymbol{C}$。同时为避免在利用深度强化学习方法将数据输入到神经网络时发生较大的梯度更新，进而导致网络无法收敛，投切档位状态 $\boldsymbol{T}$ 以及已投切次数 $\boldsymbol{C}$ 均采用 one-hot 编码[23]。

另一方面，SVG 无功补偿值的设置需要考虑前一时刻的补偿情况。在时刻 τ–1 智能体做出决策 $a(\tau-1)$后，并联在节点 $i(i\in\boldsymbol{N}_{\mathrm{SVG}})$的 SVG 的补偿值 $q_{\mathrm{svg},i}(\tau-1)$会影响到时刻 τ 智能体动作 $a(\tau)$的选择。全部 SVG 的补偿值元素 $q_{\mathrm{svg},i}(\tau)$构成信息矩阵 $\boldsymbol{Q}$。

1.3　马尔可夫决策过程

马尔可夫决策过程(Markov decision process, MDP)通常被用来描述强化学习任务。应用在强化学习的马尔可夫决策过程可以由 5 个主要元素构成的元组<$\boldsymbol{S}$, $\boldsymbol{A}$, $\boldsymbol{P}$, $\boldsymbol{R}$, γ>来定义[24]。

1）状态空间。

状态空间 $\boldsymbol{S}$ 是智能体通过感知来描述各类环境状态的集合。$s(t)$表示在时刻 t 智能体做出决策 $a(t)$后的环境状态。在电力系统中，信息矩阵集合{$\boldsymbol{v}$, $\boldsymbol{p}$, $\boldsymbol{q}$, $\boldsymbol{T}$, $\boldsymbol{C}$, $\boldsymbol{Q}$}在双时间尺度无功电压优化模型中足以表征电力系统特征，可以将该集合作为 MDP 模型的状态空间。

2）动作空间。

动作空间 $\boldsymbol{A}$ 为智能体在感知状态后可能向环境做出的行为的集合。在长时间尺度上，智能体在 t 时刻基于 t–1 时刻的状态 $s(t-1)$获取并联电容器组动作 $a(t)=\boldsymbol{T}(t)$。而在短时间尺度上，智能体在 τ 时刻基于 τ–1 时刻的状态 $s(\tau-1)$获取 SVG 动作 $a(\tau)=\boldsymbol{Q}(\tau)$。

3）状态转移矩阵。

状态转移概率矩阵 $\boldsymbol{P}$ 中的每一个元素 $P_{ss'}^{a}$ 描述了环境在状态 s 下采取某一动作 a 能够在下一时刻到达状态 s' 的概率。在实际电网中由于各种微小因素的影响和庞杂的状态数量，难以精确获取状态转移概率，在此情况下智能体通过策略选择动作从而改变环境状态，而无需事先得知状态转移信息[25]。

4）奖励空间。

奖励空间 $\boldsymbol{R}$ 为环境在感知到智能体动作后反馈给智能体的即时奖励的集合，用来引导智能体选取更优的动作，奖励函数的构建会在后文中详细说明。

5）折扣因子。

折扣因子 γ 表示对未来奖励的折算系数。

6）智能体策略。

在马尔可夫模型中，智能体根据策略来选择动作。而策略是对智能体在全空间下行为方式的定义，给智能体的动作选择提供了直接依据。可以通过从状态空间到动作空间的一个映射 $\boldsymbol{\pi}$: $\boldsymbol{S}\to\boldsymbol{A}$ 来描述智能体选择动作的策略。

策略的优劣依赖于动作的价值，因此定义一个动作价值函数 $q_\pi(s, a)$，表示在状态 s 下，执行动作 a 后的期望累积折扣奖励[26]：

$$q_\pi(s,a)=\mathbb{E}_\pi(G_t|s_t=s,a_t=a)=$$
$$\mathbb{E}_\pi(r_{t+1}+\gamma r_{t+2}+\gamma^2 r_{t+3}+\ldots|s_t=s,a_t=a) \quad (1)$$

式中：$\mathbb{E}_\pi$ 为在状态 s 开始根据策略 π 选择动作所获得的期望总奖励；策略 π 为动作的分布从而影响到的即时奖励，进而对期望产生影响。

对于任意 $s\in\boldsymbol{S}$，$a\in\boldsymbol{A}$，最优动作值函数 q^*定义为

$$q^*(s,a)=\max_\pi q_\pi(s,a)=\sum_{s'\in S}P_{ss'}^{a}[R(s,a,s')+$$
$$\gamma\max_{a'\in A}q^*(s',a')] \quad (2)$$

式中 $R(s,\ a,\ s')$为在状态 s 下选择动作 a 使环境状态转移到状态 s' 的期望奖励。

由此可得出最优策略

$$\pi^*(s)=\arg\max_{a\in A}q^*(s,a) \quad (3)$$

由式(3)可知，确定最优动作值函数 q^*后很容易得到最优策略，因此只需求取在各状态下具有最大动作值函数的动作便可完成任务。

2 基于 DQN 的长时间尺度电压优化

2.1 长时间尺度优化模型

在长时间尺度上实时优化，无功电压优化的目标设置为中枢节点的电压偏差最小以及全系统网损最小：

$$\min F(\boldsymbol{T})=\{\min f_1(\boldsymbol{T}),\min f_2(\boldsymbol{T})\} \tag{4}$$

式中长时间尺度无功电压优化模型中的控制变量为无功补偿电容器组的投切情况 $\boldsymbol{T}$。$f_1(\boldsymbol{T})$和 $f_2(\boldsymbol{T})$的具体形式如式(5)—(6)所示：

$$f_1(\boldsymbol{T})=\left\|\boldsymbol{v}_{\text{pre}}^{t}(\boldsymbol{T}(t))-\boldsymbol{v}_{\text{ref}}(t)\right\| \tag{5}$$

$$f_2(\boldsymbol{T})=\sum_{\substack{i<j\\ i,j\in \boldsymbol{N}}}\left|p_{ij}(t)+p_{ji}(t)\right| \tag{6}$$

式中：$\boldsymbol{v}_{\text{pre}}^{t}$为中枢节点对应电压幅值；$\boldsymbol{v}_{\text{ref}}$为中枢节点对应电压参考值。

考虑运行潮流约束以及电压约束：

$$p_i-v_i\sum_{j=1}^{\text{N}}v_j(G_{ij}\cos\omega_{ij}+B_{ij}\sin\omega_{ij})=0 \tag{7}$$

$$q_i-v_i\sum_{j=1}^{\text{N}}v_j(G_{ij}\sin\omega_{ij}-B_{ij}\cos\omega_{ij})=0 \tag{8}$$

$$v_i^{\min}\le v_i\le v_i^{\max} \tag{9}$$

并联在节点 $i(i\in N_c)$的无功补偿电容器组的投切受到其档位上下限 $T_i^{\max}$ 和 $T_i^{\min}$ 的限制，同时其一天内的投切次数上限设置为 $C_i^{\max}$，表示为：

$$T_i^{\min}\le T_i\le T_i^{\max} \tag{10}$$

$$C_i\le C_i^{\max} \tag{11}$$

2.2 多目标整合

针对这样的多目标优化问题，采用加权求和方法容易导致优化结果对某一子目标不友好，本文采用隶属函数[27]对多目标进行整合：

$$\mu(f_i)=\begin{cases}1, & f_i<f_i^{\min}\\ \dfrac{f_i^{\min}+\delta_i-f_i}{\delta_i}, & f_i^{\min}\le f_i\le f_i^{\min}+\delta_i\\ 0, & f_i>f_i^{\min}+\delta_i\end{cases} \tag{12}$$

式中：$\mu(f_i)$为子目标 f_i 的隶属函数；该子目标单维度可能最小值 $f_i^{\min}$；容忍度 δ_i^l；均根据历史数据计算得到。

采用隶属函数映射后的新目标函数为

$$\min[-\mu(F)]=k_1\mu(f_1)+k_2\mu(f_2) \tag{13}$$

式中 k_1 和 k_2 分别为两个目标的权重系数。

2.3 DQN 算法

DQN 算法将神经网络用于值函数的近似。值函数与神经网络的区别在于值函数属于参数的线性函数，而 DQN 中的神经网络为参数的非线性逼近，因此神经网络有效解决了庞大动作空间带来的“维度灾”问题。各层网络的权重参数用θ表示，估计价值网络用 $q_\pi(s, a\,|\,\theta)$表示，整个过程的核心就由更新值函数转为更新网络参数θ。网络损失函数 $L(\theta)$作为指导网络参数正确迭代的工具，选取为动作价值函数的时间差分：

$$L(\theta)=\{r(t)+\gamma\min_{a\in \boldsymbol{A}}q_\pi^{\text{target}}[s(t),a\,|\,\theta^{\text{target}}]-q_\pi[(s(t-1),a(t)\,|\,\theta)]\}^2 \tag{14}$$

式中 q_π^{target} 由一个与估计价值网络形式相同的目标网络输出，该目标网络参数由估计价值网络每隔固定步长传入，因此目标网络相对估计价值网络具有一定滞后；$r(t)$通常为 $s(t-1)$和 $a(t)$的一个综合函数，表示 t 时刻根据状态 $s(t-1)$生成动作 $a(t)$所得到的实时奖励值。为更好区分动作好坏，奖励值变换到区间[−10, 10]，设置如式(15)所示：

$$r(t)=\begin{cases}20\mu(F)-10, & \forall v_i(t)\text{和}\forall C_i(t)\text{正常}\\ -\sigma_l, & \exists v_i(t)\text{或}\exists C_i(t)\text{异常}\end{cases} \tag{15}$$

式中σ_l为电压越限以及电容器投切次数越限的惩罚因子。

采用随机梯度下降对神经网络参数进行更新：

$$\theta_{t+1}\leftarrow\theta_t-\alpha\nabla L(\theta)\big|_{\theta_t} \tag{16}$$

式中α为学习率，通常由一个0到1之间的实数表示。

3 基于 DDPG 的短时间尺度电压优化

3.1 短时间尺度优化模型

在短时间尺度层面利用模型预测控制思想，依赖于新能源以及负荷的超短期预测数据，预测窗以短时间尺度间隔为周期前向滚动，制定每一控制时刻点的 SVG 出力计划。采用这种方法能够有效平抑新能源并网带来的配电网电压频繁波动。短时间尺度无功电压优化的控制目标为最小化中枢节点在预测窗内的电压值与参考值的偏差：

$$\min F(\boldsymbol{Q})=\sum_{K=0}^{n}\left\|\boldsymbol{v}_{\text{pre}}^{\tau+K}(\boldsymbol{Q}(\tau+K))-\boldsymbol{v}_{\text{ref}}(\tau+K)\right\| \tag{17}$$

式中控制变量为整个预测窗内各时刻的 SVG 无功

补偿情况 $\boldsymbol{Q}$。在整个预测窗内，并联电容器组并未进行投切操作，因此只需给环境提供预测窗内各时刻的新能源和负荷的超短期预测数据，便可通过潮流计算将各时刻中枢节点期望电压值与预测窗内各时刻的 SVG 无功补偿情况 $\boldsymbol{Q}(\tau+K)$一一对应。以上目标为预测窗内总目标，可分解为单步目标：

$$\min F=\{\min F_1,\min F_2,...,\min F_n\} \tag{18}$$

$$F_i=\left\|\boldsymbol{v}_{\text{pre}}^{\tau+i}(\boldsymbol{Q}(\tau+i))-\boldsymbol{v}_{\text{ref}}(\tau+i)\right\|,\quad i=1,...,n \tag{19}$$

约束条件除了要考虑运行潮流约束以及电压约束外，为应对电力系统中的突发情况，SVG 在调节过程中需要留出一定储备量：

$$q_{\text{svg},i}^{\min}\le q_{\text{svg},i}\le q_{\text{svg},i}^{\max} \tag{20}$$

式中 $q_{\text{svg},i}^{\max}$ 和 $q_{\text{svg},i}^{\min}$ 分别为并入节点 i 的 SVG 的无功储备上下限。

3.2　滚动优化

在 K 时刻，根据 K–1 时刻的 SVG 出力计划 $\boldsymbol{Q}(K\text{-}1)$，结合预测窗内的预测数据，由电网模型得到预测窗内所有时刻的中枢节点电压值 $\boldsymbol{v}_{\text{for}}(K\sim K+n|K-1)$，注入各节点的有功无功功率值 $\boldsymbol{p}_{\text{for}}(K\sim K+n|K-1)$，$\boldsymbol{q}_{\text{for}}(K\sim K+n|K-1)$。将$\{\boldsymbol{v}_{\text{for}},\boldsymbol{p}_{\text{for}},\boldsymbol{q}_{\text{for}}\}$按照 $K\sim K+n$ 的顺序纵向排列形成节点潮流矩阵 $\boldsymbol{F}$。由于此时节点潮流矩阵 $\boldsymbol{F}$ 维度较高且信息存在冗杂，影响了 DDPG 智能体中网络的收敛速度和收敛效果，因此需要对输入的矩阵 $\boldsymbol{F}$ 进行特征提取。

将矩阵 $\boldsymbol{F}$ 输入 3 层卷积神经网络(convolutional neural networks，CNN)中[28]，把特征提取结果展开为向量形式，并与在预测窗内保持不变的向量 $\boldsymbol{T}$，$\boldsymbol{C}$，$\boldsymbol{Q}(K-1)$拼接构成状态预测向量 $s_{for}(K-1)$，如图 2 所示。智能体基于预测向量生成预测窗内所有时刻点的出力计划 $\boldsymbol{Q}(K\sim K+n|K-1)$，并结合 K–1 时刻得

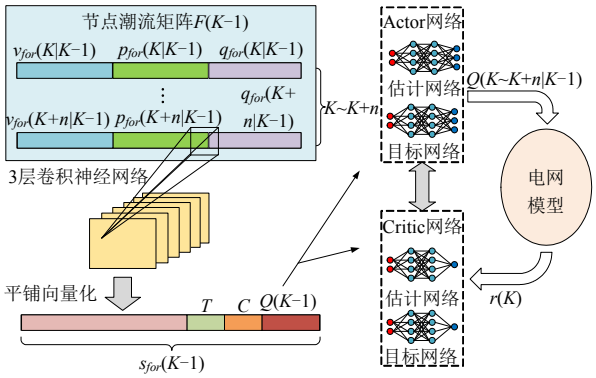


图 2　短时间尺度无功电压优化示意图

Fig. 2　Schematic diagram of the short-time scale reactive voltage optimization

到的预测窗内新能源以及负荷的预测数据，由电网模型得到所有时刻点的电压预计控制值 $\boldsymbol{v}_{\text{pre}}(K\sim K+n|K-1)$以及有功无功功率预计控制值 $\boldsymbol{p}_{\text{pre}}(K\sim K+n|K-1)$，$\boldsymbol{q}_{\text{pre}}(K\sim K+n|K-1)$，最终选择 $\boldsymbol{Q}(K)=\boldsymbol{Q}(K|K-1)$作为 K 时刻的 SVG 出力任务下发到各台设备。

3.3　DDPG 算法

由于 DQN 算法要求动作空间有限，只能应用在离散的动作空间上，如果用来控制 SVG 则需要将其补偿值离散化，这样大大削减了 SVG 的灵活性，而 DDPG 算法则可以较好地解决此问题。

DDPG 算法本质上是 Actor-Critic 的方法，Actor 网络可以在连续空间中直接选择动作值，而 Critic 网络通过拟合动作值函数来评判 Actor 的行为好坏[29]。和 DQN 相同，其神经网络均采用了估计价值网络和目标网络的双网络架构。Actor 网络的估计价值网络和目标网络的动作生成函数分别为$\psi(s)$和$\psi^{\text{target}}(s)$，网络参数分别为θ^{ψ}和$\theta^{\psi'}$。Critic 网络中估计价值网络和目标网络的参数分别为θ^{q} 和$\theta^{q'}$。为更好评判 Actor 网络选取的动作价值，Critic 网络的损失函数 $L(\theta')$同样选取为动作价值函数的时间差分，输入估计价值网络和目标网络的动作分别为 Actor 网络中对应网络的输出动作值：

$$L(\theta^q)=\mathbb{E}_\tau[\{y(\tau)-q[s_{\text{for}}(\tau),a(\tau)|\theta^q]\}^2]\approx \frac{1}{M}\sum_{m=1}^{M}\{y^m(\tau)-q[s_{\text{for}}^m(\tau),a^m(\tau)|\theta^q]\}^2 \tag{21}$$

由于 DDPG 算法是基于确定性策略梯度的求取方法，在不同状态下动作选取的概率分布不能确定，因此将期望值求取转化为 M 次采样的平均值，该 M 次采样数据从记忆库中随机不重复抽取。其中，$y^m(\tau)$可以看作第 m 次抽样的标签，$y(\tau)$表达式如式(22)所示：

$$y(\tau)=R(\tau)+\gamma q^{\text{target}}\{s_{\text{for}}(\tau+1),\psi^{\text{target}}[s_{\text{for}}(\tau)|\theta^{\psi'}]|\theta^{q'}\} \tag{22}$$

奖励值 $R(\tau)$为智能体在时刻τ基于预测值与环境进行 n 步交互获得的累积奖励值，过程中智能体生成一条$(s_{\tau-1},a_\tau,r_\tau,s_\tau,a_{\tau+1},r_{\tau+1},\ldots,s_{\tau+n-1},a_{\tau+n},r_{\tau+n})$的轨迹。$r_\tau$为每一步交互时智能体获得的即时奖励，定义如式(23)所示：

$$r_\tau=20\mu(F_i)-10 \tag{23}$$

式中：$\mu(F_i)$为子目标 F_i 的隶属函数，该子目标单维度可能最小值为 $F_i^{\min}$；容忍度为 δ_i^s。整个预测窗内的总奖励 $R(\tau)$可表示为

$$R(\tau)=\begin{cases}\sum_{i=0}^{n}\gamma^{i}r_{\tau+i}/\sum_{i=0}^{n}\gamma^{i}, & \forall v_{\mathrm{pre}}(\tau)\text{正常}\\ -\sigma_{s}, & \exists v_{\mathrm{pre}}(\tau)\text{异常}\end{cases} \tag{24}$$

Actor 网络基于 Critic 网络的评判采取梯度更新方法：

$$\nabla L(\theta^{\psi})=\mathbb{E}_{\tau}[\nabla_{a}q\big|_{s=s_{for},a=\psi(s_{for})}\cdot\nabla_{\theta^{\psi}}\psi\big|_{s=s_{for}}]\approx \frac{1}{M}\sum_{m=1}^{M}[\nabla_{a}q\big|_{s=s_{for}^{m},a=\psi(s_{for}^{m})}\cdot\nabla_{\theta^{\psi}}\psi\big|_{s=s_{for}^{m}}] \tag{25}$$

分别对 Actor 网络和 Critic 网络进行参数更新：

$$\theta_{\tau+1}^{\psi}\leftarrow\theta_{\tau}^{\psi}-\alpha_{1}\nabla L(\theta^{\psi})\big|_{\theta_{\tau}^{\psi}} \tag{26}$$

$$\theta_{\tau+1}^{q}\leftarrow\theta_{\tau}^{q}-\alpha_{2}\nabla L(\theta^{q})\big|_{\theta_{\tau}^{q}} \tag{27}$$

式中α_1和α_2分别为Actor 网络和 Critic 网络的学习率。

4 算例分析

4.1 算例系统介绍

本文仿真计算基于 Python3.7.0(64bit)环境，结合 PYPOWER 库，采用 Tensorflow-cpu2.3.1 平台，并使用 Spyder 作为代码编辑器，硬件配置为 AMD Ryzen 5 2500U 处理器，主频 2GHz，内存 8GB。

针对上述无功电压优化方法，本文采用 IEEE33 节点拓展系统进行仿真验证，该网络的电压基准值为 12.66kV，系统总功率为 5084.26+j2547kVA，其网架结构如图 3 所示。

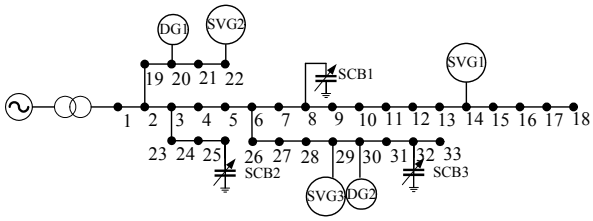


图 3 IEEE33 节点拓展系统图

Fig. 3 IEEE-33 node extension system diagram

在保证原有 IEEE33 节点配电网系统线路参数不变的基础上，在原系统节点 20 和节点 30 分别接入额定容量为 750kW 的双馈异步风力发电机(doubly fed induction generator，DFIG)，为验证该方法在面对新能源并网时的优化效果，不考虑 DFIG 的无功调节能力，将功率因数维持在 0.95。在原系统的 8 号、25 号和 32 号节点分别安装并联补偿电容器组 SCB1、SCB2 和 SCB3，其参数相同，最大档位均为 6，每档 0.4Mvar，总容量 2Mvar，日最大调节次数为 6 次。在原系统节点 14、节点 22 和节点 29 各接入一台 SVG，可调容量均为–800~ 800kvar。将节点 14、节点 22 以及节点 29 设置为该区域的中枢节点，节点电压上下限区间为[0.9, 1.1]。

智能体在训练阶段与电网模型进行交互时采用的新能源和负荷的出力数据，可用实际系统运行过程所保存的历史量测数据及生成的样本数据。测试阶段智能体选取确定策略，但仍然不断进行网络训练。实际应用场景中智能体通过潮流计算与环境交互，并且将从调度中心量测得到的智能体状态，实际调度执行的动作以及电网获取的真实奖励值保存至算法记忆库中，用于网络在线训练，以适应实际应用场景，保证动作的最优选择。

对加州电力调度中心[30]获取的典型日内负荷曲线以及风电出力曲线进行缩放，并采用蒙特卡洛模拟法[31]构造 500 天的电力系统运行数据，将前 400 天的数据作为驱动双智能体的训练数据，后 100 天的数据作为测试数据。图 4 以节点 24 所连负荷和节点 20 接入风机为例，分别展示了典型日内负荷曲线和风电出力曲线。

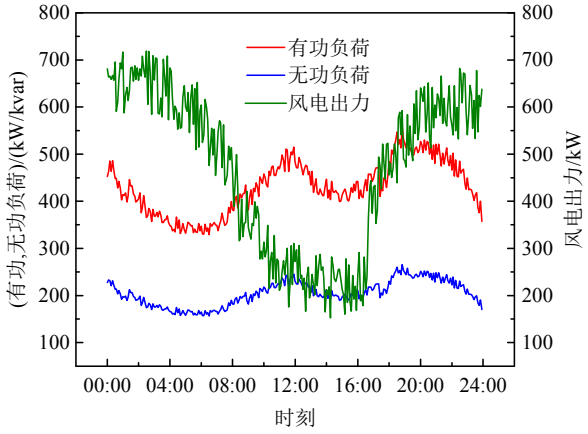


图 4 典型日负荷与风电出力曲线

Fig. 4 Typical daily load and wind power output curve

4.2 网络收敛情况

为适应无功补偿装置的动作时间，本文选取的长时间尺度决策时间为 1h，短时间尺度决策时间为 5min。在 DQN 智能体和 DDPG 智能体同时训练的过程中，长时间尺度上的决策结果和短时间尺度决策结果互为决策依据。长时间间隔内的短时间尺度 SVG 出力计划基于上一个 SCB 投切计划制定，而长时间尺度上 SCB 的投切计划则依据上一个长时间间隔末端的 SVG 出力计划制定。

长短时间尺度的惩罚因子均设置为 100。DQN 网络收敛情况如图 5(a)、(b)所示，在 1000 次学习后，网络已接近收敛，代表网络对动作值函数的拟

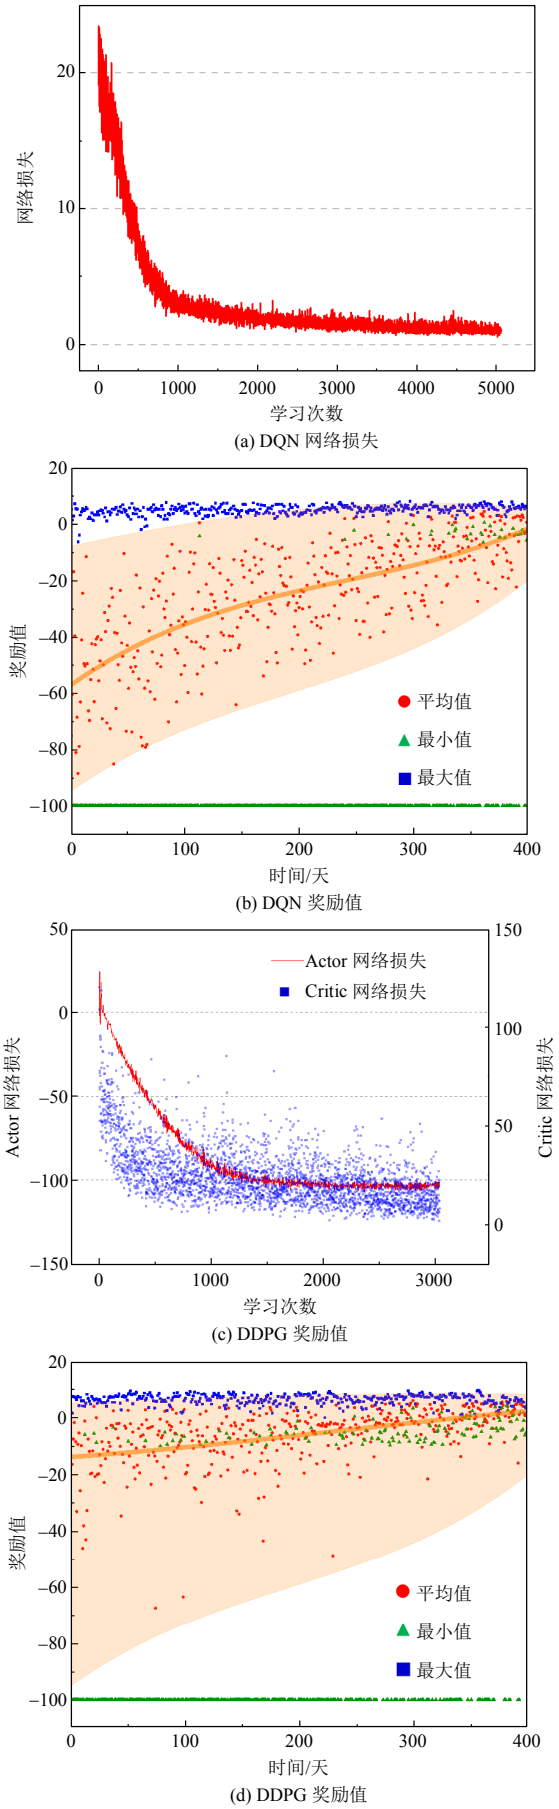


图 5　智能体收敛情况

Fig. 5　Agent convergence case

合效果较好。DDPG 网络收敛情况如图 5(c)、(d)所示，代表其动作决策以及评价水平均能够达到要求。

4.3　仿真结果

电容器组在投切过程中受到投切次数限制，图 6 展示了并联电容器组投切档位一天内的变化情况，其能够依据电容器当前投切次数以及此时电网运行状况决定下一时刻的投切计划是否执行。可以看到，在 04:00—08:00，风电出力充足且负荷需求较低时，并联电容器组置于较低档位，给予电网的无功支撑较少，而在 12:00—15:00，风电出力较少且负荷需求量大时，并联电容器组则调整至较高档位，抑制电压大范围波动。

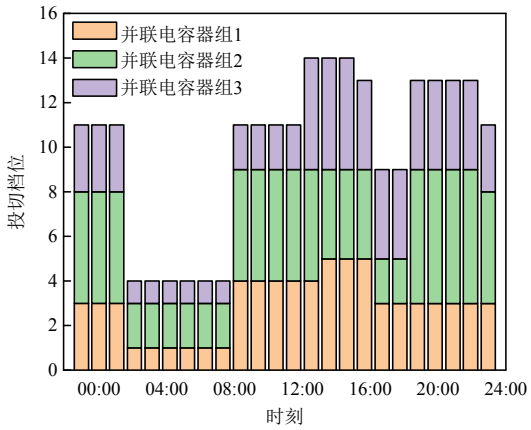


图 6　长时间尺度电容器组投切计划

Fig. 6　Long-timescale capacitor group cutting plan

图 7 展示了 100 天测试数据的日均网损，作为对比，长时间尺度上分别选取文献[32]中的粒子群优化算法(particle swarm optimization，PSO)和文献[33]中的遗传算法(genetic algorithm，GA)执行电容器组投切计划，而短时间尺度保持 DDPG 方法不

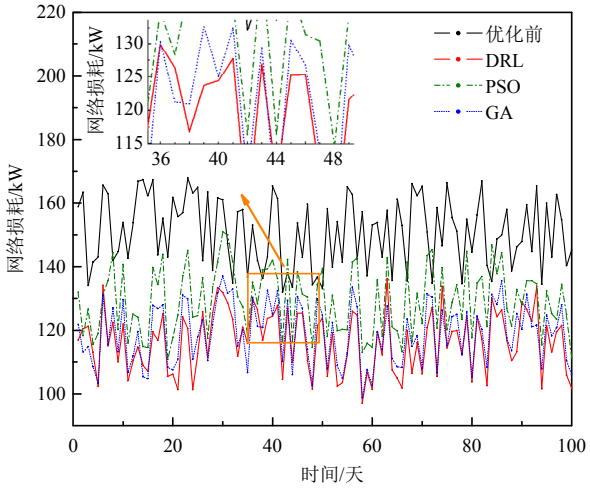


图 7　日均网损对比

Fig. 7　Daily net loss comparison

变。为实现算法的非线性整数优化，PSO 方法以及 GA 方法均对变量取整。本文所提方法在测试数据上的平均网损降低率为 22.76%，而 PSO 和 GA 的平均网损降低率分别为 14.29%和 21.20%，且在 81 天内网损优化效果优于 PSO 和 GA，充分显示了本文所提方法的优越性。

为验证本文所提方法的控制效果，同时分辨长时间尺度电压优化与短时间尺度电压优化差异。将本文所述方法分别单独在长时间尺度上执行计划和在长短时间尺度上结合执行计划，设置对照方案为长时间尺度基于 DQN，短时间尺度采用 PSO[32]以及 GA[33]的双时间尺度方案，其在一天内的电压优化效果对比如图 8。不论在 04:00—08:00 风电出力充足而负荷需求较低，各中枢节点电压水平较高时，还是在 12:00—15:00 风电出力较少而负需求量大，各中枢节点电压水平较低时，均能够实现长时间尺度上通过并联电容器组调节减小电压与参考值的偏差量，短时间尺度上通过 SVG 的无功出力调节精准调压。12:00 时各节点电压优化情况如图 9 所示，可以看到，12:00 时电网中各节点电压整体较低，通过本文方案实施，中枢节点 14、22、29 的电压抬升带动了电网各节点电压水平的整体抬升，基本平抑了新能源出力不确定性带来的电压频繁波动。

SVG 相比并联电容器组容量较小，主要用来抑

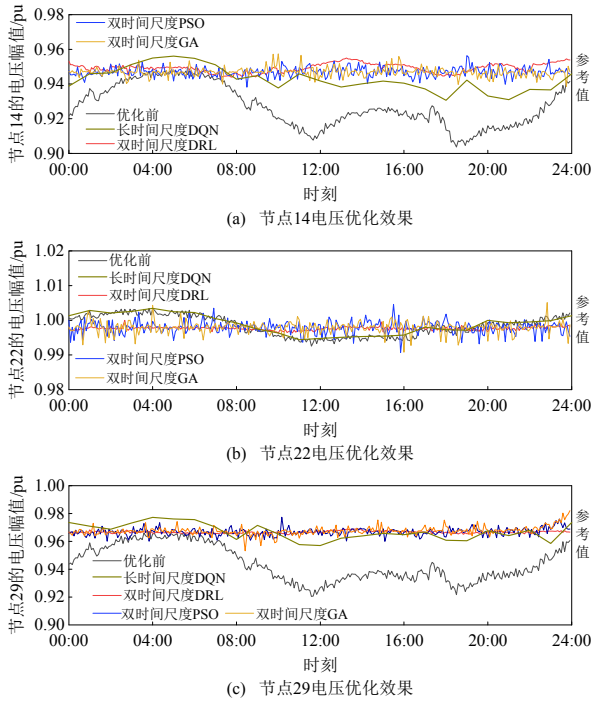


图 8 电压优化情况对比

Fig. 8 Voltage optimization situation comparison

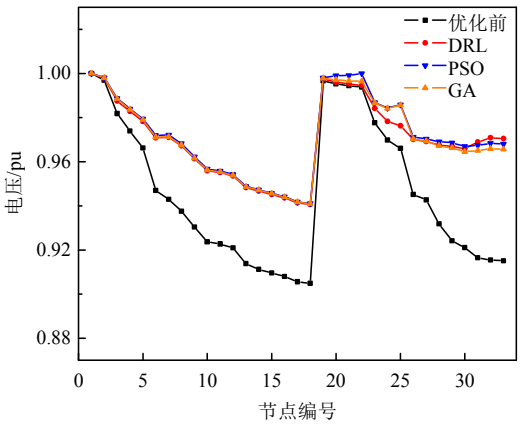


图 9 各节点电压优化对比

Fig. 9 Voltage optimization comparison of each node

制新能源并网带来的电压频繁波动，因此其出力变化频繁，SVG 一天内出力计划如图 10 所示。将短时间尺度 SVG 出力计划与单独长时间尺度执行方案下一天内电压优化效果对照来看，在执行长时间尺度计划后 SVG 依照电压现存偏差继续进行精准调压。以节点 22 为例，在长时间尺度上并联电容器组执行投切计划后，节点电压在 08:00—16:00 仍低于参考值，此段时间接入节点 22 的 SVG2 发出无功从而实现对节点 22 电压精准调节。SVG3 接入节点与新能源并网节点电气距离最短，受新能源出力波动影响大，因此 SVG3 在一天内出力变化最为频繁。

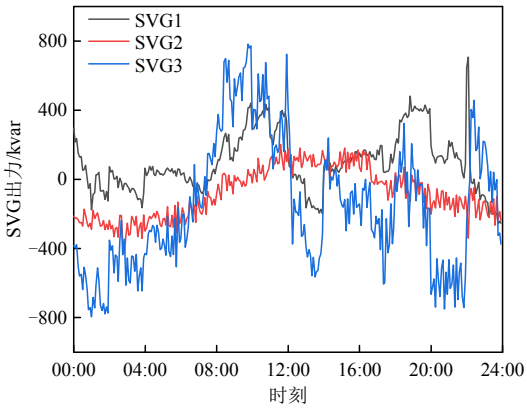


图 10 短时间尺度 SVG 出力计划

Fig. 10 Short-timescale SVG output plan

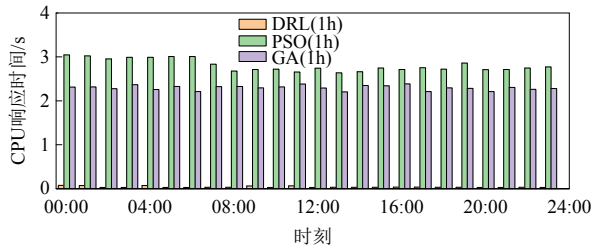
测试日内的平均网络损耗及中枢节点平均电压偏差如表 1 所示，可以看出，本文所述优化策略能够大幅降低系统网损及电压偏差。

此外，深度强化学习不仅在长短时间尺度上均有着卓越的优化效果，并且相比基于模型的优化策略，其在响应速度上具有独特优势。图 11 分别展示了深度强化学习、PSO 和 GA 在长时间尺度上各时刻点优化过程中的 CPU 响应时间以及每小时内

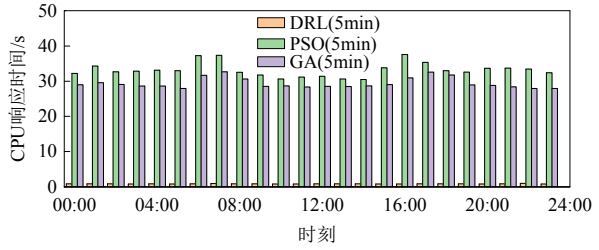
表 1　平均网络损耗与平均电压偏差

Table 1　Average network loss and voltage deviation

指标类型	平均网络损耗/kW	节点 14 平均电压偏差/pu	节点 22 平均电压偏差/pu	节点 29 平均电压偏差/pu
优化前	150.892	0.02	0.0026	0.0232
DRL	116.5557	0.0023	0.0005	0.0007
PSO	129.3272	0.0024	0.0013	0.002
GA	118.9042	0.0019	0.0011	0.002



(a)　长时间尺度CPU响应时间



(b)　短时间尺度CPU响应时间

图 11　CPU 响应时间

Fig. 11　CPU response time

在短时间尺度各时刻点优化过程中的累积 CPU 响应时间。PSO 在长短时间尺度上的平均响应时间分别为 2.81s 和 2.77s，GA 在长短时间尺度上的平均响应时间为 2.30s 和 2.45s。而采用 DRL 方法进行优化时 CPU 的平均响应时间达到 0.04s 和 0.07s，分别为 GA 方法的 1/61 和 1/35，为 PSO 方法的 1/75 和 1/40，充分显示了该方法的快速性。

5　结论

本文统筹考虑无功补偿设备的差异化调节特性，提出了一种基于深度强化学习的双时间尺度配电网无功电压优化方法，实现了长短时间尺度上无功电压优化的相互配合，在保证配电网安全运行的基础上提升了平抑电压波动的能力，最后通过算例验证了该方法的正确性和有效性，主要结论如下：

1）长时间尺度上以调整电压偏移，同时最小化全系统网损为目标，将 DQN 算法作为优化内核，在一天内各优化时刻点对电容器投切计划进行统筹安排，减小了电压与参考值的偏移量，并将平均网络损耗降低了 22.76%。

2）短时间尺度上通过设置预测窗，将 DDPG 算法作为优化内核实现 SVG 出力的滚动优化，依照电压现存偏差继续进行精准调压，进一步减小了电压与参考值的偏差量。

3）在长短时间尺度上通过两个智能体之间的相互配合，实现了各类无功补偿设备的优势互补。此外，本文所述优化策略在长时间尺度上 CPU 响应时间和短时间尺度上每小时累积 CPU 响应时间分别为 0.04s 和 0.07s，可有效应对新能源并网背景下配电网电压频繁波动问题，对工程应用具有实际意义。

参考文献

[1] 丁涛，牟晨璐，别朝红，等．能源互联网及其优化运行研究现状综述[J]．中国电机工程学报，2018，38(15)：4318-4328．
DING Tao，MU Chenlu，BIE Zhaohong，et al．Review of energy internet and its operation[J]．Proceedings of the CSEE，2018，38(15)：4318-4328(in Chinese)．

[2] 周孝信，鲁宗相，刘应梅，等．中国未来电网的发展模式和关键技术[J]．中国电机工程学报，2014，34(29)：4999-5008．
ZHOU Xiaoxin，LU Zongxiang，LIU Yingmei，et al．Development models and key technologies of future grid in China[J]．Proceedings of the CSEE，2014，34(29)：4999-5008(in Chinese)．

[3] 韩肖清，李廷钧，张东霞，等．双碳目标下的新型电力系统规划新问题及关键技术[J]．高电压技术，2021，47(9)：3036-3046．
HAN Xiaoqing，LI Tingjun，ZHANG Dongxia，et al．New issues and key technologies of new power system planning under double carbon goals[J]．High Voltage Engineering，2021，47(9)：3036-3046(in Chinese)．

[4] TANG Zhiyuan，HILL D J，LIU Tao，et al．Hierarchical voltage control of weak subtransmission networks with high penetration of wind power[J]．IEEE Transactions on Power Systems，2018，33(1)：187-197．

[5] 白建华，辛颂旭，刘俊，等．中国实现高比例可再生能源发展路径研究[J]．中国电机工程学报，2015，35(14)：3699-3705．
BAI Jianhua，XIN Songxu，LIU Jun，et al．Roadmap of realizing the high penetration renewable energy in China [J]. Proceedings of the CSEE，2015，35(14)：3699-3705(in Chinese)．

[6] XU Yan，DONG Zhaoyang，ZHANG Rui，et al．Multi-timescale coordinated voltage/var control of high renewable-penetrated distribution systems[J]．IEEE Transactions on Power Systems，2017，32(6)：4398-4408．

[7] 赵晋泉，居俐洁，戴则梅，等．基于分支定界—原对偶

内点法的日前无功优化[J]. 电力系统自动化，2015，39(15)：55-60.
ZHAO Jinquan，JU Lijie，DAI Zemei，et al. Day-ahead reactive power optimization based on branch and bound-interior point method[J]. Automation of Electric Power Systems，2015，39(15)：55-60(in Chinese).

[8] 汝锐锐，周步祥，林楠，等. 基于 NCP 理论的光滑牛顿法在无功优化中的应用[J]. 电力系统保护与控制，2013，41(20)：99-104.
RU Ruirui，ZHOU Buxiang，LIN Nan，et al. Application of NCP based smoothing Newton method in reactive power optimization[J]. Power System Protection and Control，2013，41(20)：99-104(in Chinese).

[9] 赵维兴，刘明波. 基于近似牛顿方向的多区域无功优化解耦算法[J]. 中国电机工程学报，2007，27(25)：18-24.
ZHAO Weixing，LIU Mingbo. A decomposition algorithm applied to multi-area reactive-power optimization based on approximate newton directions[J]. Proceedings of the CSEE，2007，27(25)：18-24(in Chinese).

[10] 蒋平，梁乐. 基于内点法和遗传算法相结合的交直流系统无功优化[J]. 高电压技术，2015，41(3)：724-729.
JIANG Ping，LIANG Le. Reactive power optimization of hybrid AC/HVDC power system combining interior point algorithm and genetic algorithm[J]. High Voltage Engineering，2015，41(3)：724-729(in Chinese).

[11] 李晓利，高金峰. 用于配电网多目标无功优化的改进粒子群优化算法[J]. 电力自动化设备，2019，39(1)：106-111.
LI Xiaoli，GAO Jinfeng. Improved particle swarm optimization algorithm for multi-objective reactive power optimization of distribution network[J]. Electric Power Automation Equipment，2019，39(1)：106-111(in Chinese).

[12] LI Yuanzheng，WU Qinghua，JIANG Lin，et al. Optimal power system dispatch with wind power integrated using nonlinear interval optimization and evidential reasoning approach[J]. IEEE Transactions on Power Systems，2016，31(3)：2246-2254.

[13] 高红均，刘俊勇，刘继春，等. 基于坏场景集的含风电机组组合模型[J]. 电力系统保护与控制，2013，41(10)：27-32.
GAO Hongjun，LIU Junyong，LIU Jichun，et al. The unit commitment with wind power based on the bad scenario set[J]. Power System Protection and Control，2013，41(10)：27-32(in Chinese).

[14] 张倩文，王秀丽，杨廷天，等. 含风电场电力系统的鲁棒优化调度[J]. 电网技术，2017，41(5)：1451-1459.
ZHANG Qianwen，WANG Xiuli，YANG Tingtian，et al. A robust dispatch method for power grid with wind farms[J]. Power System Technology，2017，41(5)：1451-1459(in Chinese).

[15] DIAO Ruisheng，WANG Zhiwei，SHI Di，et al. Autonomous voltage control for grid operation using deep reinforcement learning[C]//Proceedings of 2019 IEEE Power & Energy Society General Meeting(PESGM). Atlanta：IEEE，2019：1-5.

[16] 李亦言，胡荣兴，宋立冬，等. 机器学习在智能配用电领域中的应用：北美工程实践概述[J]. 电力系统自动化，2021，45(16)：99-113.
LI Yiyan，HU Rongxing，SONG Lidong，et al. Application of machine learning in field of smart power distribution and utilization：overview of engineering practice in North America[J]. Automation of Electric Power Systems，2021，45(16)：99-113(in Chinese).

[17] 杨挺，赵黎媛，王成山. 人工智能在电力系统及综合能源系统中的应用综述[J]. 电力系统自动化，2019，43(1)：2-14.
YANG Ting，ZHAO Liyuan，WANG Chengshan. Review on application of artificial intelligence in power system and integrated energy system[J]. Automation of Electric Power Systems，2019，43(1)：2-14(in Chinese).

[18] 李婷，刘明波. 求解多目标协调二级电压控制的简化强化学习方法[J]. 中国电机工程学报，2013，33(31)：130-139.
LI Ting，LIU Mingbo. Reduced reinforcement learning method applied to multi-objective coordinated secondary voltage control[J]. Proceedings of the CSEE，2013，33(31)：130-139(in Chinese).

[19] 刁浩然，杨明，陈芳，等. 基于强化学习理论的地区电网无功电压优化控制方法[J]. 电工技术学报，2015，30(12)：408-414.
DIAO Haoran，YANG Ming，CHEN Fang，et al. Reactive power and voltage optimization control approach of the regional power grid based on reinforcement learning theory[J]. Transactions of China Electrotechnical Society，2015，30(12)：408-414(in Chinese).

[20] ZHANG Yiwei，ZHANG Min，FAN Caixia，et al. Computing resource allocation scheme of IOV using deep reinforcement learning in edge computing environment [J]. EURASIP Journal on Advances in Signal Processing，2021，2021(1)：1-19.

[21] ZHANG Liang，WANG Gang，GIANNAKIS G B. Real-time power system state estimation and forecasting via deep unrolled neural networks[J]. IEEE Transactions on Signal Processing，2019，67(15)：4069-4077.

[22] 徐峰达，郭庆来，孙宏斌，等. 基于模型预测控制理论的风电场自动电压控制[J]. 电力系统自动化，2015，39(7)：59-67.
XU Fengda，GUO Qinglai，SUN Hongbin，et al. Automatic voltage control of wind farms based on model

predictive control theory[J]. Automation of Electric Power Systems，2015，39(7)：59-67(in Chinese).

[23] 蒋逸雯，李黎，李智威，等．基于深度语义学习的电力变压器运维文本信息挖掘方法[J]．中国电机工程学报，2019，39(14)：4162-4171．
JIANG Yiwen，LI Li，LI Zhiwei，et al．An information mining method of power transformer operation and maintenance texts based on deep semantic learning[J]．Proceedings of the CSEE，2019，39(14)：4162-4171(in Chinese)．

[24] 李琦，乔颖，张宇精．配电网持续无功优化的深度强化学习方法[J]．电网技术，2020，44(4)：1473-1480．
LI Qi，QIAO Ying，ZHANG Yujing．Continuous reactive power optimization of distribution network using deep reinforcement learning[J]．Power System Technology，2020，44(4)：1473-1480(in Chinese)．

[25] YANG Qiuling，WANG Gang，SADEGHI A，et al．Two-timescale voltage control in distribution grids using deep reinforcement learning[J]．IEEE Transactions on Smart Grid，2020，11(3)：2313-2323．

[26] 余涛，周斌，陈家荣．基于 Q 学习的互联电网动态最优 CPS 控制[J]．中国电机工程学报，2009，29(19)：13-19．
YU Tao，ZHOU Bin，CHAN K W．Q-learning based dynamic optimal CPS control methodology for interconnected power systems[J]．Proceedings of the CSEE，2009，29(19)：13-19(in Chinese)．

[27] 毛弋，刘文春，张鹏飞．利用模糊算法对电力市场下纯火电系统多目标综合经济负荷进行分配[J]．电力系统及其自动化学报，2000，12(6)：22-25，29．
MAO Yi，LIU Wenchun，ZHANG Pengfei．Using the fuzzy algorithm to thermal power system with aims synthetical real power economic dispatch in power market[J]．Proceedings of the EPSA，2000，12(6)：22-25，29(in Chinese)．

[28] 张宇精，乔颖，鲁宗相，等．含高比例分布式电源接入的低感知度配电网电压控制方法[J]．电网技术，2019，43(5)：1528-1535．
ZHANG Yujing，QIAO Ying，LU Zongxiang，et al．Voltage control for partially visible distribution networks with high DG penetration[J]．Power System Technology，2019，43(5)：1528-1535(in Chinese)．

[29] WANG Xuerao，WANG Qingling，SUN Changyin．Prescribed performance fault-tolerant control for uncertain nonlinear MIMO system using actor-critic learning structure[J]．IEEE Transactions on Neural Networks and Learning Systems，doi: 10.1109/TNNLS.2021.3057482．

[30] California Independent System Operator．California ISO open access same-time information system(OASIS)[EB/OL]．[2021-10-09]．http://oasis.caiso.com/mrioasis/logon.do．

[31] LIU Yuxiao，ZHANG Ning，WANG Yi，et al．Data-driven power flow linearization：a regression approach[J]．IEEE Transactions on Smart Grid，2019，10(3)：2569-2580．

[32] YOSHIDA H，KAWATA K，FUKUYAMA Y，et al．A particle swarm optimization for reactive power and voltage control considering voltage security assessment [J]．IEEE Transactions on Power Systems，2000，15(4)：1232-1239．

[33] MALACHI Y，SINGER S．A genetic algorithm for the corrective control of voltage and reactive power[J]．IEEE Transactions on Power Systems，2006，21(1)：295-300．



李鹏

在线出版日期：2022-08-29。
收稿日期：2022-05-11。

作者简介：
李鹏(1965)，男，教授，博士生导师，IEEE Senior Member，主要研究方向为新能源电力系统、综合能源系统与微网、能源互联网与智能电网、人工智能在智慧能源中的应用等，ncepulp@ncepu.edu.cn；
*通信作者：姜磊(1999)，男，硕士研究生，主要研究方向为人工智能在电网优化运行方面的应用，ncepujl@ncepu.edu.cn。

(**编辑**　乔宝榆，张文鑫)

 DOI：10.13334/j.0258-8013.pcsee.221170

Optimization of Dual-time Scale Reactive Voltage for Distribution Network With Renewable Energy Based on Deep Reinforcement Learning

LI Peng, JIANG Lei*, WANG Jiahao, XIA Hui, PAN Youpeng

(North China Electric Power University)

KEY WORDS: distribution network with renewable energy; deep reinforcement learning; dual-time scale; reactive voltage optimization; Markov decision process

With the increase in the proportion of centralized renewable energy and distributed renewable energy in distribution network, the volatility and intermittence of renewable energy have an increasing impact on distribution network, resulting in frequent voltage fluctuation in distribution network and bringing new challenges to reactive power support and voltage security.

This paper proposes a dual-time scale reactive power and voltage optimization method based on deep reinforcement learning (DRL), combining the characteristics of different regulation modes and response time of various reactive power compensation equipment. Deep Q Network (DQN) and Deep Deterministic Policy Gradient (DDPG) are selected as long and short time scale optimization kernels. The compensation plan at each time point of shunt capacitor banks is formulated on long-time scale to adjust the voltage deviation and minimize network loss of the whole system. The rolling prediction window is set on short-time scale, and SVG output plan is formulated to track the voltage change and solve the problem of frequent voltage fluctuation of distribution network due to the connection of renewable energy.

One day is taken as an optimization period, and the shunt capacitor banks (SCB) are switched at time t=0, …, K_l–1. Then, long-time intervals K_l is subdivided into short-time intervals K_s. In each short-time interval, static var generator (SVG) adjusts the reactive power output value at time τ=0, …, K_s–1, as shown in Fig. 1.

For real-time optimization on the long-time scale, the objective of reactive voltage optimization is to minimize the voltage deviation of the central node and the network loss of the whole system:

$$\min F(\boldsymbol{T}) = \{\min f_1(\boldsymbol{T}), \min f_2(\boldsymbol{T})\} \tag{1}$$

where $\boldsymbol{T}$ is the switching condition of SCB, $f_1(\boldsymbol{T})$ and $f_2(\boldsymbol{T})$ are the goal of voltage deviation and network loss.

On the short-time scale, model predictive control idea is used, which relies on the ultra-short-term prediction data of renewable energy and load. The

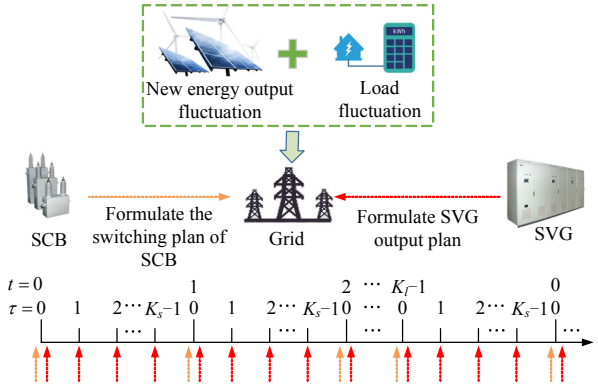


Fig. 1 Dual-time scale division

prediction window rolls forward with a short-time scale interval as a cycle, and formulates the SVG output plan at each control point, as shown in Fig. 2. The control objective of short-time scale reactive voltage optimization is to minimize the deviation between the voltage value of the central node in the prediction window and the reference value:

$$\min F(\boldsymbol{Q}) = \sum_{K=0}^{n} \left\| \boldsymbol{v}_{\text{pre}}^{\tau+K}(\boldsymbol{Q}(\tau+K)) - \boldsymbol{v}_{\text{ref}}(\tau+K) \right\| \tag{2}$$

where $\boldsymbol{v}_{\text{pre}}^{t}$ represents the voltage amplitude corresponding to the central node, $\boldsymbol{v}_{\text{ref}}$ is the reference voltage value corresponding to the central node.

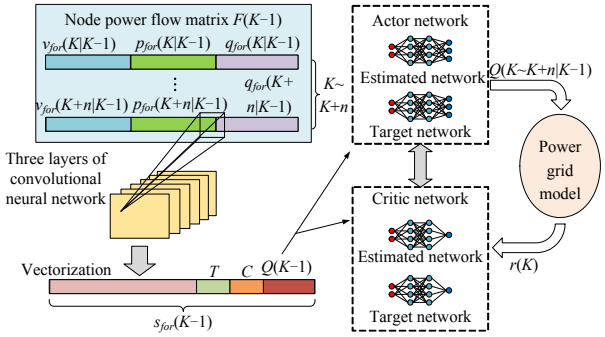


Fig. 2 Schematic diagram of the short time-scale reactive voltage optimization

Compared with traditional optimization methods, the proposed method in this paper can directly obtain stable control strategy according to the environmental information of the system in a short time, which has practical significance for engineering application.