

中国电机工程学报
*Proceedings of the CSEE*
ISSN 0258-8013,CN 11-2107/TM

# 《中国电机工程学报》网络首发论文

题目：混合多智能体强化学习分层协调的多微网配电网优化运行方法
作者：董雷，李金龙，张涛，韩笑，李烨，戴赛，蒲天骄
网络首发日期：2026-07-02
引用格式：董雷，李金龙，张涛，韩笑，李烨，戴赛，蒲天骄．混合多智能体强化学习分层协调的多微网配电网优化运行方法[J/OL]．中国电机工程学报．https://link.cnki.net/urlid/11.2107.TM.20260702.1420.005



**网络首发**：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认**：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-07-02 14:30:23　网络首发地址：https://link.cnki.net/urlid/11.2107.TM.20260702.1420.005



# 混合多智能体强化学习分层协调的多微网配电网优化运行方法

董雷[1*]，李金龙[1]，张涛[2]，韩笑[3]，李烨[3]，戴赛[3]，蒲天骄[3]

（1. 华北电力大学电气与电子工程学院，北京市 昌平区 102206; 2. 合肥工业大学电气与自动化工程学院，安徽省 合肥市 230009; 3. 中国电力科学研究院有限公司，北京市 海淀区 100192）

# Hierarchical Coordinated Optimization Method for Multi-Microgrid Distribution Networks with Hybrid Multi-Agent Reinforcement Learning

DONG Lei[1*], LI Jinlong[1], ZHANG Tao[2], HAN Xiao[3], LI Ye[3], DAI Sai[3], PU Tianjiao[3]

(1. School of Electrical & Electronic Engineering, North China Electric Power University, Changping District, Beijing 102206, China; 2. School of Electrical Engineering and Automation, Hefei University of Technology, Hefei 230009, Anhui Province, China; 3. China Electric Power Research Institute, Haidian District, Beijing 100192, China)

**ABSTRACT:** Driven by the dual-carbon strategy, large-scale microgrid cluster integration has prompted a shift from single-level operation to a multi-microgrid-distribution network (MMDN) coordination paradigm. Optimizing this MMDN system forms a cross-level, multi-regional and non-convex optimization problem, posing significant modeling and computational challenges. This paper proposes a hierarchical MMDN optimization method using hybrid multi-agent reinforcement learning (MARL). The upper level employs a MARL model with an attention mechanism to coordinate mixed discrete-continuous distribution network agents, mitigating dimensionality explosion and accelerating training. The lower level establishes a continuous MARL model for MMDN collaboration, adopting a communication- based centralized training with decentralized execution framework to ensure microgrid privacy. We propose a hybrid multi-agent soft actor-critic algorithm to solve the model, incorporating parallelization techniques to enhance training efficiency while reducing communication overhead. Case studies based on a modified IEEE 33-bus system demonstrate the effectiveness of the proposed methodology and algorithm.

**KEY WORDS：** Multi-microgrid-distribution network; multi-agent reinforcement learning; multi-agent; hierarchical coordination; optimal operation

**摘要：** 在双碳战略驱动下，微电网集群的规模化接入推动配电网运行方式由单级范式向多微网-配电网分层协调范式演变。然而，多微网-配电网的优化运行构成了跨层级、多区域的非凸优化问题，在模型分析求解层面带来了极大挑战。为此，本文提出一种基于混合多智能体强化学习分层协调的多微网-配电网优化运行方法。该方法上层构建了离散和连续多区域配电网智能体协调的强化学习模型，并引入注意力机制，以缓解维度爆炸并加速智能体的训练过程。下层考虑多微网与配电网协同互动需求，构建连续多智能体强化学习模型，采用基于通信的分布式训练分布式执行架构，保障多微网主体隐私性需求。提出混合多智能体软演员评论家算法对上述分层模型进行求解，引入并行化技术保障了训练效率，并降低了通信需求。最后，基于改进 IEEE-33 节点配-微电网系统开展算例分析，验证了所提模型和算法的有效性。

**关键词：** 多微网-配电网；多智能体强化学习；多主体；分层协调；优化运行

## 0 引言

随着我国“双碳”战略目标的持续推进，为促进各类型分布式资源的充分消纳，多微网-配电网(Multi-microgrid-distribution network, MMDN)系统得到研究[1]。然而，配电网运营商面临区域间协调互动与区域内离散、不确定性资源耦合运行的挑战[2]；与此同时，不同微电网运营商利益诉求存在差异，且不同运营商进行交互时需满足通信私密性需求[3]。因此，如何充分考虑 MMDN 多区域、多资源、多主体的运行特征，通过协调优化提升系统运行性能值得充分研究。

基金项目：国家自然科学基金项目（52277098）。
Project Supported by National Natural Science Foundation of China (52277098)

针对统集中式优化方法难以处理配微电网协调的优化问题，有文献提出基于交替方向乘子法[4]、目标级联分析法[5]和 Benders 分解法[6]等分布式优化分析方法。然而，上述方法属于机理模型驱动的数学规划方法，存在如下适配性不足的挑战：1) 由于离散设备导致模型非凸，致使传统分布式优化方法难以有效收敛；2) 随着互联配微电网规模的不断扩大，数学规划法求解时间长，难以在线应用；3) 间歇性可再生能源的接入需引入随机优化、鲁棒优化等方法，这进一步增加了模型分析求解的复杂性。综上，多微网-配电网协调优化问题，面临维数高，求解困难等挑战，难以采用传统机理模型的数学优化方法。因此，如何提高模型计算的收敛性、高效性和解的适应性成为亟需解决的热点问题。

近年来，基于数据驱动的多智能体深度强化学习方法(Multi-agent deep reinforcement learning, MADRL)被广泛应用于电力系统优化决策[7]。这对于解决复杂多主体非凸优化问题的收敛性差、计算效率低和不确定性挑战等带来了契机。针对多区域配电网优化运行领域有学者构建了基于MADRL的多智能体深度确定性策略梯度算法(Multi-agent deep deterministic policy gradient, MADDPG)[8]，多智能体柔性动作-评价算法(Multi-agent soft actor-critic, MASAC)[9]等。然而，上述研究仅涉及连续调控设备，并未针对离散设备进行协调优化。

鉴于此，文献[10]提出机理模型与数据驱动融合方法，但随着电网规模和优化时段的不断增加，该方法的求解效率将难以保证。为支持在线应用，可构建离散动作与连续动作混合多智能体，[11]。注意到，随着智能体维度的持续增加，动作空间和观测空间呈指数增长态势，致使训练过程中存在收敛速度缓慢甚至不收敛的问题[12]。为此，有研究提出降维策略，主要包括忽略部分状态信息[13]、分层学习架构[14]和智能体数量削减[15]等。上述方法未能基于全局信息开展训练，易导致决策结果陷入局部最优。注意力机制应运而生[16]，该方法通过重点关注完成当前任务的关键信息，弱化低关联性信息，以达到改善多智能体训练速度和精度的目的。因此，融合注意力机制的混合多智能体模型有待深入研究。

除此之外，多微网-配电网优化运行还要考虑跨层级多智能体的协同互动，这涉及多个运营商的协调优化[17]。当前，基于 MADRL 的优化方法历经了从集中式训练-集中式执行(Centralized training-centralized execution，CTCE)[18]到集中式训练-分布式执行(Centralized training-distributed execution, CTDE)[19]的演变。但现有基于全局信息共享的训练模式无法应用于多微网利益主体信息隐私性的场景。为此，有学者提出分布式训练-分布式执行框架(Distributed training-distributed execution, DTDE)，并成功将其应用于点对点能量交易[20]和智能社区负荷需求响应[21]等领域。然而，现有的 DTDE 方法面临训练环境非平稳性的挑战。因此，如何将其拓展至多微网-配电网协调优化运行领域，并实现训练过程的稳定性提升显得尤为重要；此外，现有配微电网多智能体模型离线训练时多采用串行架构，这显著增加了训练时长，如何提高效率亟待研究。

综上所述，本文提出一种基于混合多智能体强化学习分层协调的多微网-配电网优化运行方法。上层构建离散-连续混合多智能体模型对多区域配电网进行优化，并引入注意力机制缓解维度爆炸问题，并加速多智能体训练。下层计及微电网多利益主体互动的隐私性需求，构建基于通信的分布式训练-分布式执行框架，减轻了通信负担，显著提高训练效率与模型的可扩展性能。提出了混合多智能体软演员评论家算法对上述模型进行优化求解，在此过程中融合了并行化训练技术以减少离线训练效率。最后通过算例验证了本文所提模型和算法的可行性和有效性。

## 1 多微网-配电网运行框架和模型构建

### 1.1 混合多智能体分层协调框架

本文以多微网-配电网为研究对象，充分考虑其多区域、多资源、多主体的运行特征，通过构建混合多智能体分层协调优化框架实现系统运行经济性和安全性的提升，如图 1 所示。多微网-配电网接有分散式的微型燃气轮机(Microturbine, MT)、储能装置(Energy storage system, ESS)、风电机组(Wind turbine, WT)、光伏发电(Photovoltaic array, PV)，以及无功调控设备，包括静止无功补偿器(Static var compensator, SVC)有载调压变压器(On-load tap changers, OLTC)和可投切电容器(Capacitor banks, CBs)等。为在多区域配电网和多主体微电网系统中实现上述连续/离散、确定性/间歇性资源的协调优化，提出基于混合多智能体的分层强化学习模型。

上层针对多区域配电网，构建连续和离散协调的多智能体强化学习模型，其中连续多智能体模型

用于实现不同区域配电网的协调优化，离散多智能体模型支撑无功设备的协同控制，通过连续和离散多智能体模型的交互，可实现有功-无功调控资源的综合优化，从而有效降低配电网的运行成本。下层考虑多微电网主体和配电网协调互动的自治性需求，构建多个独立智能体，促进各微电网主体参与互动的积极性和可扩展性。

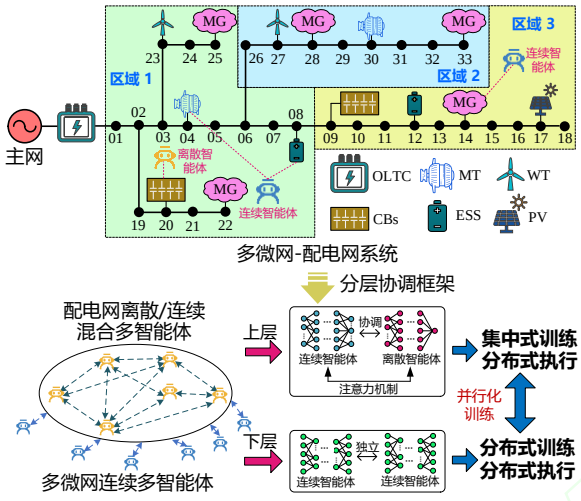



图 1　多微网配电网系统分层协调优化框架

**Fig. 1　The overall optimization framework for MMDN**

为实现上下层多智能体模型的协调优化，提出混合多智能体软演员评论家算法。配网离散-连续多智能体构建融合注意力机制的集中式训练-分布式执行框架(Multi-head attention mechanism based CTDE，MHAM-CTDE)进行协调，缓解智能体维度爆炸问题，同时加速了连续/离散多智能体模型的训练过程，支持分散式资源的灵活接入。配、微多智能体考虑隐私性需求，提出基于通信的分布式训练-分布式执行框架(Communication based DTDE, C-DTDE)，稳定训练的同时避免了隐私泄露，各智能体仅利用本地信息学习差异化策略，支持微电网主体可扩展地接入。上下层多智能体协调优化模型采用双层马尔可夫决策过程构建，以描述智能体间的通信协作关系。所提算法是在并行化环境中执行训练，有效缩短了模型的训练时长。通过配-微电网分层多智能体的交互训练与协同优化，极大改善了整个系统运行的经济性和安全性水平。

多智能体模型的设置主要取决两方面：1）配微电网的多区域与跨层级结构；2）系统内部调控资源的差异化特性（连续/离散）。

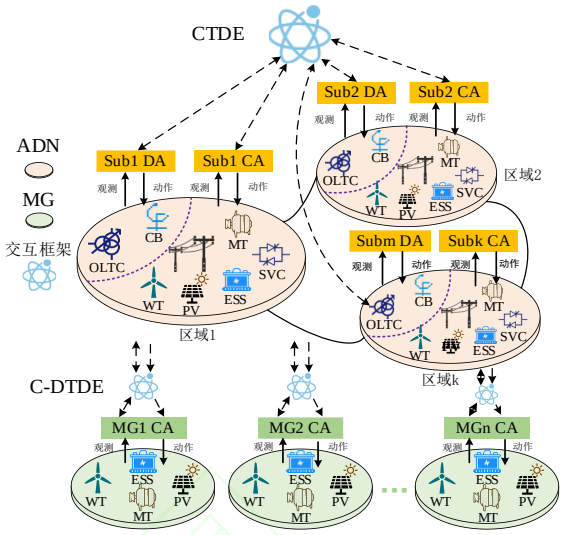



图 2　多微网配电网多智能体模型架构

**Fig. 2　Multi-agent model architecture for MMDN**

本文提出混合多智能体模型架构，如图 2 所示。针对上层配电网存在的若干自治区域，将各区域连续设备集中构建为连续智能体，分别记为区域 $i$ 连续智能体（Sub$i$ CA，$i$=1…$k$）；而将离散设备设置为离散智能体，分别记为区域 $i$ 离散智能体（Sub$i$ DA，$i$=1⋯$m$），上层配电网的连续、离散多智能体采用 CTDE 进行协调。下层微电网群构建为多个自治运行的连续智能体，分别记为微网 $i$ 连续智能体（MG$i$ CA，$i$=1⋯$n$）。考虑到微网群与配电网交互的隐私性，下层独立微电网智能体采用 C-DTDE 技术进行协调。

## 1.2 微电网优化调度模型

### 1.2.1 目标函数

微电网以总成本最小为目标函数，如下：

$$\min F_{\mathrm{MG},i}=\sum_{t=1}^{T}\left[\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{MT}}}F_{j,t}^{\mathrm{MT}}+\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{ESS}}}F_{j,t}^{\mathrm{ESS}}+F_{i,t}^{\mathrm{B\text{-}S}}\right] \tag{1}$$

$$F_{j,t}^{\mathrm{MT}}=a_j^{\mathrm{MT}}\left(P_{j,t}^{\mathrm{MT}}\right)^2+b_j^{\mathrm{MT}}P_{j,t}^{\mathrm{MT}}+c_j^{\mathrm{MT}} \tag{2}$$

$$F_{j,t}^{\mathrm{ESS}}=\rho_j\left|P_{j,t}^{\mathrm{ESS}}\right| \tag{3}$$

$$F_{i,t}^{\mathrm{B\text{-}S}}=\lambda_{IN,t}^{\mathrm{B}}(t)P_{i,t}^{\mathrm{B}}-\lambda_{\mathrm{IN},t}^{\mathrm{S}}P_{i,t}^{\mathrm{S}} \tag{4}$$

式中，$F_{\mathrm{MG},i}$ 为第 $i$ 个微电网的运行成本。

### 1.2.2 约束条件

1) 可再生能源(renewable energy source，RES)采用最大功率点跟踪模式发电，并利用无功容量参与调控，其运行约束为：

$$\left(P_{j,t}^{\mathrm{RES}}\right)^2+\left(Q_{j,t}^{\mathrm{RES}}\right)^2\le\left(S_{j,\max}^{\mathrm{RES}}\right)^2,\forall j\in N_{\mathrm{MG},i}^{\mathrm{RES}} \tag{5}$$

由于预测过程存在偏差，将 RES 预测数据叠加满足正态分布的预测误差表示其实际出力：

$$\hat{P}_{j,t}^{\mathrm{RES}} \sim N\left(P_{j,t}^{\mathrm{RES}},\ E_{j,t}^{\mathrm{RES}}\right) \tag{6}$$

式中：$E_{j,t}^{\mathrm{RES}}$ 为 $t$ 时段 RES 预测误差。RES 可观测状态为 $\hat{o}_{j,t}^{\mathrm{RES}}=\left[\hat{P}_{j,t}^{\mathrm{RES}},Q_{j,t-1}^{\mathrm{RES}}\right]$；负荷 $\hat{P}_{i,t}^{\mathrm{Load}}$ 设置同上。

2) MT 的运行约束

$$P_{j,\min}^{\mathrm{MT}} \le P_{j,t}^{\mathrm{MT}} \le P_{j,\max}^{\mathrm{MT}},\ \forall j \in N_{\mathrm{MG},i}^{\mathrm{MT}} \tag{7}$$

$$-R_{j,\mathrm{down}}^{\mathrm{MT}} \le P_{j,t}^{\mathrm{MT}} - P_{j,t-1}^{\mathrm{MT}} \le R_{j,\mathrm{up}}^{\mathrm{MT}} \tag{8}$$

$$\left(P_{j,t}^{\mathrm{MT}}\right)^2+\left(Q_{j,t}^{\mathrm{MT}}\right)^2 \le \left(S_{j,\max}^{\mathrm{MT}}\right)^2 \tag{9}$$

MT 可观测状态为 $o_{j,t}^{\mathrm{MT}}=\left[P_{j,t-1}^{\mathrm{MT}},Q_{j,t-1}^{\mathrm{MT}}\right]$。

3) ESS 的运行约束

$$P_{j,\min}^{\mathrm{ESS}} \le P_{j,t}^{\mathrm{ESS}} \le P_{j,\max}^{\mathrm{ESS}},\ \forall j \in N_{\mathrm{MG},i}^{\mathrm{ESS}} \tag{10}$$

$$soc_{j,t}=soc_{j,t-1}+\frac{\eta_j^{\mathrm{ch}}P_{j,t-1}^{\mathrm{ch}}}{E_{j,\max}^{\mathrm{ESS}}}\Delta t+\frac{P_{j,t-1}^{\mathrm{dis}}}{\eta_j^{\mathrm{dis}}\cdot E_{j,\max}^{\mathrm{ESS}}}\Delta t \tag{11}$$

$$soc_{j,\min} \le soc_{j,t} \le soc_{j,\max} \tag{12}$$

ESS 可观测状态为 $o_{j,t}^{\mathrm{ESS}}=\left[soc_{j,t},P_{j,t-1}^{\mathrm{ESS}}\right]$。

4）微电网功率平衡约束

$$P_{i,t}^{\mathrm{PCC}}=P_{i,t}^{\mathrm{Load}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{RES}}}P_{j,t}^{\mathrm{RES}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{MT}}}P_{j,t}^{\mathrm{MT}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{ESS}}}P_{j,t}^{\mathrm{ESS}} \tag{13}$$

$$Q_{i,t}^{\mathrm{PCC}}=Q_{i,t}^{\mathrm{Load}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{RES}}}Q_{j,t}^{\mathrm{RES}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{MT}}}Q_{j,t}^{\mathrm{MT}} \tag{14}$$

$$P_{i,\min}^{\mathrm{PCC}} \le P_{i,t}^{\mathrm{PCC}}=P_{i,t}^{\mathrm{B}}-P_{i,t}^{\mathrm{S}} \le P_{i,\max}^{\mathrm{PCC}} \tag{15}$$

$$\left(P_{i,t}^{\mathrm{PCC}}\right)^2+\left(Q_{i,t}^{\mathrm{PCC}}\right)^2 \le \left(S_{i,\max}^{\mathrm{PCC}}\right)^2 \tag{16}$$

### 1.3 配电网优化调度模型

1.3.1 目标函数

配电网的优化目标是最小化运行成本，包括发电成本和与主网、多微网间的交互成本。

$$\min F_{\mathrm{ADN}}=\sum_{t=1}^{T}\left[\sum_{j=1}^{N_{\mathrm{ADN}}^{\mathrm{MT}}}F_{j,t}^{\mathrm{MT}}+\sum_{j=1}^{N_{\mathrm{ADN}}^{\mathrm{ESS}}}F_{j,t}^{\mathrm{ESS}}+F_t^{\mathrm{d}}+F_t^{\mathrm{l}}\right] \tag{17}$$

$$F_t^{\mathrm{d}}=C^{\mathrm{oltc}}\left|T_t^{\mathrm{OLTC}}-T_{t-1}^{\mathrm{OLTC}}\right|+\sum_{j=1}^{N_{\mathrm{ADN}}^{\mathrm{CB}}}C_j^{\mathrm{cb}}\left|T_{j,t}^{\mathrm{CB}}-T_{j,t-1}^{\mathrm{CB}}\right| \tag{18}$$

$$F_t^{\mathrm{l}}=\lambda_{\mathrm{EX},t}^{\mathrm{B}'}P_t^{\mathrm{B}'}-\lambda_{\mathrm{EX},t}^{\mathrm{S}'}P_t^{\mathrm{S}'}-\sum_{i=1}^{N_{\mathrm{MG}}}F_{i,t}^{\mathrm{B\text{-}S}} \tag{19}$$

配电网中 MT 和 ESS 的运行约束如 1.2 节所述，此处不再赘述。

1.3.2 约束条件

1) OLTC 和 CB 动作次数约束

$$n_{j,t}^{\mathrm{x}}=\left|\mathrm{sgn}\left(T_{j,t}^{\mathrm{x}}-T_{j,t-1}^{\mathrm{x}}\right)\right|\ \forall \mathrm{x}\in\{\mathrm{OLTC}、\mathrm{CB}j\} \tag{20}$$

$$N_{j,t}^{\mathrm{x}}=\sum_{t'=0}^{t}n_{j,t'}^{\mathrm{x}} \le N_{j,\max}^{\mathrm{x}}\ \forall \mathrm{x}\in\{\mathrm{OLTC}、\mathrm{CB}j\} \tag{21}$$

OLTC 和 CB 可观测状态为 $o_t^{\mathrm{OLTC}}=\left[T_{t-1}^{\mathrm{OLTC}},N_{t-1}^{\mathrm{OLTC}}\right]$、$o_t^{\mathrm{CB}_j}=\left[T_{j,t-1}^{\mathrm{CB}},N_{j,t-1}^{\mathrm{CB}}\right]$。

2) 静止无功补偿器运行约束

$$Q_{j,\min}^{\mathrm{SVC}} \le Q_{j,t}^{\mathrm{SVC}} \le Q_{j,\max}^{\mathrm{SVC}},\forall j \in N_{\mathrm{ADN}}^{\mathrm{SVC}} \tag{22}$$

SVC 可观测状态为 $o_t^{\mathrm{SVC}}=\left[Q_{t-1}^{\mathrm{SVC}}\right]$。

3) 潮流约束

$$\begin{aligned}P_{k,t}&=\sum_{l\in\Omega(k)}V_{k,t}V_{l,t}\left(G_{kl}\cos\theta_{kl,t}+B_{kl}\sin\theta_{kl,t}\right)\\&=P_{k,t}^{\mathrm{RES}}+P_{k,t}^{\mathrm{MT}}+P_{k,t}^{\mathrm{ESS}}-P_{k,t}^{\mathrm{Load}}-P_{k,t}^{\mathrm{PCC}}\end{aligned} \tag{23}$$

$$\begin{aligned}Q_{k,t}&=\sum_{l\in\Omega(k)}V_{k,t}V_{l,t}\left(G_{kl}\sin\theta_{kl,t}-B_{kl}\cos\theta_{kl,t}\right)\\&=Q_{k,t}^{\mathrm{RES}}+Q_{k,t}^{\mathrm{MT}}+Q_{k,t}^{\mathrm{SVC}}+Q_{k,t}^{\mathrm{CB}}-Q_{k,t}^{\mathrm{Load}}-Q_{k,t}^{\mathrm{PCC}}\end{aligned} \tag{24}$$

$$V_{\min} \le V_{k,t} \le V_{\max} \tag{25}$$

$$\left|I_{kl,t}\right| \le I_{kl,\max} \tag{26}$$

如上所述，则为本文所构建的多微网-配电网优化模型，模型中变量的详细定义见附录表 A3。所提模型不仅涉及多个运行主体，还需统筹协调离散和连续等差异化调控资源，本质上属于跨层级、多区域的非凸优化问题，难以求解。为此，可通过混合多智能体的协调互动，极大提高模型分析求解的可行性。

## 2 混合多智能体分层强化学习模型

### 2.1 多智能体模型协调策略

2.1.1 配微电网多智能体分散式协调机制

考虑到多微电网主体和配电网互动的隐私性需求，配微电网分层模型采用 DTDE 框架，但现有文献广泛采用的 DTDE 存在非平稳性问题，本文提出一种 C-DTDE 框架，如图 3 所示。

在训练阶段，智能体仅使用本地的局部观测 $o_{i,t}^{\mathrm{local}}$、动作 $a_{i,t}^{\mathrm{local}}$ 信息以及与其交互智能体的边界特征信息 $o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$，训练自身神经网络模型。在执行阶段，智能体仅使用本地观测 $o_{i,t}^{\mathrm{local}}$ 和交互智能体的边界特征信息 $o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$ 在线决策运行。然而，边界耦合状态信息需要所有智能体做出决策后在下一时刻才能观测到，即智能体在当前观测中可以接收来自上一时刻共享的边界信息。为此，针对 Actor-Critic 多智能体架构，前置时序记忆的长短期记忆神经网络 (Long short term memory neural network，LSTM)[22] 来实现其从上一时刻的边界状态中推理出当前时刻可能的边界状态。

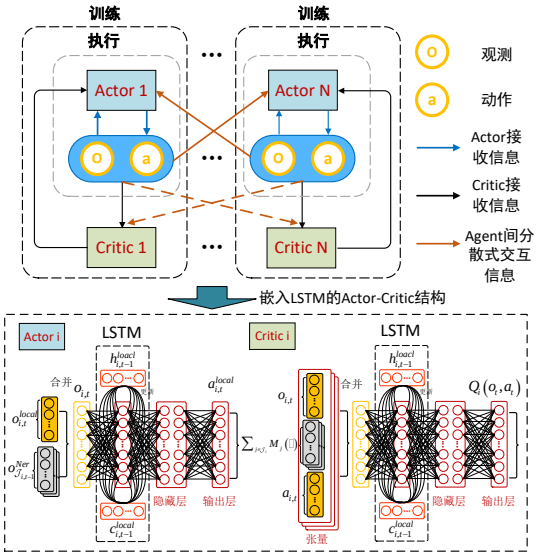



图 3　配微多智能体 C-DTDE 协调机制

**Fig. 3　C-DTDE framework for multi-agent of MMDN**

LSTM 输入与输出的迭代编码过程，如下：

$$\left(h_{i,t}^{\text{local}},c_{i,t}^{\text{local}}\right)=f\left(o_{i,t},\left(h_{i,t-1}^{\text{local}},c_{i,t-1}^{\text{local}}\right)\right) \tag{27}$$

式中，$h_{i,t}^{\text{local}}$ 和 $c_{i,t}^{\text{local}}$ 分别为智能体 $i$ 的隐藏状态和细胞状态。前向传播后 $\left(h_{i,t-1}^{\text{local}},c_{i,t-1}^{\text{local}}\right)=\left(h_{i,t}^{\text{local}},c_{i,t}^{\text{local}}\right)$。

在 C-DTDE 框架下，智能体的 Q 值函数满足：

$$Q_i\left(o_t,a_t\right)\approx Q_i\left(o_{i,t},a_{i,t},\sum\nolimits_{j\in\mathcal{J}_i}M_j\left(o_{j,t},a_{j,t}\right)\right) \tag{28}$$

式中，$\mathcal{J}_i$ 表示智能体 $i$ 的相邻智能体集合；$M_j$ 表示在经验池中从相邻智能体 $j$ 选择的张量信息。

采用 $o_{\mathcal{J}_i,t-1}^{\text{Ner}}$ 表示来自相邻智能体上一时刻共享的信息，对于智能体 $i$，其策略 $\pi$ 在 $t$ 时刻输入的观测空间可表示为：

$$o_{i,t}=o_{i,t}^{\text{local}}\cup o_{\mathcal{J}_i,t-1}^{\text{Ner}}=o_{i,t}^{\text{local}}\cup\left[o_{j,t-1}^{\text{Ner}}\right]_{j\in\mathcal{J}_i} \tag{29}$$

式中，$o_{i,t}^{\text{local}}$ 为智能体 $i$ 的本地观测；$o_{j,t-1}^{\text{Ner}}$ 表示相邻智能体 $j$ 存储在上一时刻选定的交换信息。

基于所提 C-DTDE，各智能体仅利用本地信息与少量外部交互信息即可学习差异化策略，稳定训练的同时有效避免了不同主体间的隐私泄露，降低了配微电网间的数据传输压力，并可支持新增微网可拓展地接入。

2.1.2 配电网离散-连续多智能体协调机制

如图 4 所示，在 CTDE 中，Critic 将所有智能体的观测 $o=\left(o_1,...,o_N\right)$ 和动作 $a=\left(a_1,...,a_N\right)$ 作为输入，用来计算联合 Q 值函数 $Q_i\left(o,a\right)$，特征维度为 $N*\left(\left|o_i\right|+\left|a_i\right|\right)$。可以看出，随着 ADN 中源网荷储设备数量的增多，Critic 网络接收的全局信息量呈现线性化增长，这会导致智能体训练难题。为此，本文引入注意力机制[20]，在 MHAM-CTDE 框架下，智能体 $i$ 选择性地关注其他智能体信息更新网络，其联合 Q 值函数输入为私有观测-动作编码信息 $e_{i,t}$ 和由注意力网络编码的其他智能体集成信息 $x_{i,t}$，特征维度大幅压缩为 $\left|e_i,x_i\right|$，有效解决了多智能体维数爆炸问题。

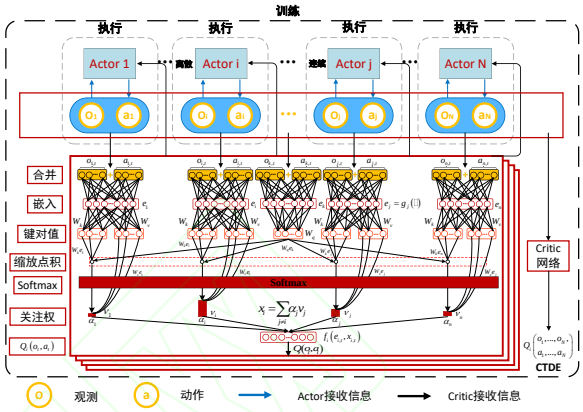



图 4　融合注意力机制的 CTDE 框架

**Fig. 4　CTDE framework incorporating MHAM**

针对多区域配电网离散-连续多智能体，采用 MHAM-CTDE 框架进行协调，具体实现如下：

$$Q_i\left(o_t,a_t\right)=f_i\left(e_{i,t},x_{i,t}\right)=f_i\left(g_i\left(o_{i,t},a_{i,t}\right),x_{i,t}\right) \tag{30}$$

式中，$f_i(\cdot)$、$g_i(\cdot)$ 均为多层感知器(multi-layer perceptron，MLP)函数；嵌入向量 $e_{i,t}=g_i(\cdot)$ 表示对智能体 $i$ 的观测-动作信息的嵌入操作；$x_{i,t}$ 表示其他智能体的观测-动作集成信息：

$$x_{i,t}=\sum_{j\neq i}\alpha_{j,t}v_{j,t}=\sum_{j\neq i}\alpha_{j,t}h\left(Ve_{j,t}\right) \tag{31}$$

式中，$v_{j,t}$ 为智能体 $j$ 嵌入值，使用 $e_{j,t}$ 进行编码，然后用共享矩阵 $\boldsymbol{V}$ 进行线性变换，最后通过非线性激活函数 $h(\cdot)$ 输出。$\alpha_{j,t}$ 为关注权值，表示嵌入向量 $e_{i,t}$ 与 $e_{j,t}$ 之间的相似性：

$$\alpha_{j,t}\propto\exp\left(\left(e_{i,t}\right)^T\boldsymbol{W}_k^T\boldsymbol{W}_qe_{j,t}\right) \tag{32}$$

式中，$\boldsymbol{W}_k$ 和 $\boldsymbol{W}_q$ 为变换矩阵。MHAM 使用多个注意力头，每个头使用一组单独的参数 $\left(\boldsymbol{W}_k,\boldsymbol{W}_q,\boldsymbol{V}\right)$ 产生所有其他智能体对智能体 $i$ 的总贡献。

## 2.2 多微网-配电网强化学习模型

基于前述所建立的多微网-配电网优化调度模型，可对其进行强化学习模型转换，其中多微电网主体构建为连续多智能体，多区域配电网构建为离散-连续多智能体，具体模型如下：

2.2.1 微电网连续多智能体模型

如前所述，式(1)-(16)构成了微电网优化运行模型，通过对该模型目标函数、运行约束与强化学习

的映射关系，可构建微电网智能体的观测空间、动作空间和奖励函数。其中，智能体的观测空间为$t$时刻MG $i$的设备状态、负荷、时刻、相邻边界状态等物理特征，上述变量在微电网优化运行模型中有详细描述，具体如式(33)所示。

$$o_{i,t}^{\mathrm{MG}}=\left[\hat{o}_{i,t}^{\mathrm{RES}},o_{i,t}^{\mathrm{ESS}},o_{i,t}^{\mathrm{MT}},\hat{P}_{i,t}^{\mathrm{Load}},\lambda_{\mathrm{IN},t}^{\mathrm{B}},\lambda_{\mathrm{IN},t}^{\mathrm{S}},t,o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}\right] \tag{33}$$

$$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}=\left[\lambda_{\mathrm{IN},t-1}^{\mathrm{B}},\lambda_{\mathrm{IN},t-1}^{\mathrm{S}},V_{i,t-1}^{\mathrm{PCC}}\right] \tag{34}$$

式中，$\hat{o}_t^{\mathrm{RES}}$和$\hat{P}_t^{\mathrm{Load}}$表示在预测数据中叠加服从正态分布的误差，以拟合不确定性状态，增强算法的鲁棒性。$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$为来自配网智能体的边界信息。

微电网智能体的动作空间为$t$时刻 MG $i$内可控连续设备，如RES、MT和ESS的有功和无功出力构成，具体如式(35)所示。

$$a_{i,t}^{\mathrm{MG}}=\left[Q_{i,t}^{\mathrm{RES}},P_{i,t}^{\mathrm{MT}},Q_{i,t}^{\mathrm{MT}},P_{i,t}^{\mathrm{ESS}}\right] \tag{35}$$

微电网智能体的奖励函数$r_{i,t}^{\mathrm{MG}}$包括微电网优化运行模型的目标函数，即式(1)，此外还包括功率和电压越限惩罚，如下：

$$r_{i,t}^{\mathrm{MG}}=-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{MT}}}F_{j,t}^{\mathrm{MT}}-\sum_{j=1}^{N_{\mathrm{MG},i}^{\mathrm{ESS}}}F_{j,t}^{\mathrm{ESS}}-F_{i,t}^{\mathrm{B\text{-}S}}-F_t^{\mathrm{L}}-\delta_i F_{\mathrm{t}}^{\mathrm{P}} \tag{36}$$

式中，$F_t^{\mathrm{L}}$为功率越限惩罚，包括配微电网间传输功率上下限约束越限惩罚$F_t^{\mathrm{L}_1}$和配微电网间传输功率容量约束越限惩罚$F_t^{\mathrm{L}_2}$，其数学描述如式(37)-(39)所示。$\delta_i$为微电网参与配网安全运行的意愿系数，$F_t^{\mathrm{P}}$为电压和电流约束越限惩罚，具体计算公式如后文式(46)-(48)所述。

$$F_t^{\mathrm{L}}=F_t^{\mathrm{L}_1}+F_t^{\mathrm{L}_2} \tag{37}$$

$$F_t^{\mathrm{L}_1}=\zeta_1\max\left(P_{\min}^{\mathrm{PCC}}-P_t^{\mathrm{PCC}},P_t^{\mathrm{PCC}}-P_{\max}^{\mathrm{PCC}},0\right) \tag{38}$$

$$F_t^{\mathrm{L}_2}=\zeta_2\max\left(\left(P_t^{\mathrm{PCC}}\right)^2+\left(Q_t^{\mathrm{PCC}}\right)^2-\left(S_{\max}^{\mathrm{PCC}}\right)^2,0\right) \tag{39}$$

式中，$\zeta_{1,2}$为越限惩罚权重。

2.2.2 配电网离散−连续混合多智能体模型

式(2)-(12)和式(17)-(26)构成了本文所提配电网优化运行模型，基于该模型的目标函数和约束条件可构建配电网连续和离散多智能体模型的观测空间、动作空间和奖励函数。其中，配电网智能体的观测空间包括$t$时段位于区域$i,i\in I$的离散-连续智能体所含设备状态、负荷、分时电价信息、时刻、相邻边界状态等状态变量，具体如式(40)所示，$I$为分区数。

$$o_{\mathrm{sub}_i,t}^{\mathrm{ADN}}=\begin{bmatrix}o_{i,t}^{\mathrm{OLTC}},o_{i,t}^{\mathrm{CB}},\hat{o}_{i,t}^{\mathrm{RES}},o_{i,t}^{\mathrm{SVC}},o_{i,t}^{\mathrm{MT}},\\ o_t^{\mathrm{price}},o_{i,t}^{\mathrm{ESS}},\hat{P}_{\mathrm{sub}_i,t}^{\mathrm{Load}},t,o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}\end{bmatrix} \tag{40}$$

$$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}=\left[P_{j,t-1}^{\mathrm{PCC}},Q_{j,t-1}^{\mathrm{PCC}}\right]_{j\in N_{\mathrm{MG}}} \tag{41}$$

式中，$o_t^{\mathrm{price}}=\left[\lambda_{\mathrm{IN},t}^{\mathrm{B}},\lambda_{\mathrm{IN},t}^{\mathrm{S}},\lambda_{\mathrm{EX},t}^{\mathrm{B}'},\lambda_{\mathrm{EX},t}^{\mathrm{S}'}\right]$表示购售电价集合；$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$表示来自MG智能体的边界信息。

配电网智能体动作空间分为$t$时刻区域$i$离散智能体的动作空间和连续智能体的动作空间组成，具体为各离散和连续智能体内部调控设备的决策变量，如式(42)-(43)所示。

$$a_{\mathrm{sub}_i,t}^{\mathrm{ADN,D}}=\left[T_{i,t}^{\mathrm{OLTC}}\right]/\left[T_{i,t}^{\mathrm{CB}}\right] \tag{42}$$

$$a_{\mathrm{sub}_i,t}^{\mathrm{ADN,C}}=\left[Q_{i,t}^{\mathrm{RES}},P_{i,t}^{\mathrm{MT}},Q_{i,t}^{\mathrm{MT}},P_{i,t}^{\mathrm{ESS}},Q_{i,t}^{\mathrm{SVC}}\right] \tag{43}$$

式中，$a_{\mathrm{sub}_i,t}^{\mathrm{ADN,D}}$为区域$i$中配电网离散智能体的动作空间，由OLTC或CB的挡位构成；$a_{\mathrm{sub}_i,t}^{\mathrm{ADN,C}}$为区域$i$中配电网离散智能体的动作空间，包括RES、MT、ESS、SVC的出力值。

配电网离散智能体的奖励函数由离散设备的动作成本$F_t^{\mathrm{d}}$，即式(18)所示，此外还包括全局连续设备动作成本$r_{\mathrm{whole},t}^{\mathrm{ADN,C}}$；如式(44)所述。

$$r_{\mathrm{sub}_i,t}^{\mathrm{ADN,D}}=-F_t^{\mathrm{d}}+r_{\mathrm{whole},t}^{\mathrm{ADN,C}} \tag{44}$$

连续智能体的奖励函数$r_{\mathrm{whole},t}^{\mathrm{ADN,C}}$由其运行成本、电压和电流约束越限惩罚构成，如下：

$$r_{\mathrm{whole},t}^{\mathrm{ADN,C}}=-\sum_{j=1}^{N_{\mathrm{ADN}}^{\mathrm{MT}}}F_{j,t}^{\mathrm{MT}}-\sum_{j=1}^{N_{\mathrm{ADN}}^{\mathrm{ESS}}}F_{j,t}^{\mathrm{ESS}}-F_t^{\mathrm{l}}-F_t^{\mathrm{P}} \tag{45}$$

$$F_t^{\mathrm{P}}=F_t^{\mathrm{P}_1}+F_t^{\mathrm{P}_2} \tag{46}$$

$$F_t^{\mathrm{P}_1}=\sum_{i=1}^{W}\psi_1\max\left(V_{\min}-V_{i,t},V_{i,t}-V_{\max},0\right) \tag{47}$$

$$F_t^{\mathrm{P}_2}=\sum_{j=1}^{V}\psi_2\max\left(\left|I_{j,t}\right|-I_{j,\max},0\right) \tag{48}$$

式中，$F_t^{\mathrm{P}_{1,2}}$分别为配网电压、支路潮流约束越限惩罚函数；$\psi_{1,2}$分别为二者惩罚函数的权重；$W$、$V$分别为配网节点、支路总数。

## 3 混合多智能体软演员评论家算法

### 3.1 算法基本原理

为求解上述配微电网分层多智能体模型，本文提出混合多智能体软演员评论家算法(Hybrid MASAC, H-MASAC)，如图5所示。该算法基于前述多智能体模型协调策略实现，其中配微电网多智能体使用分散式协调机制，配电网离散−连续多智能体融合了注意力机制。

MG $i$智能体需与相邻ADN智能体交换所选择的边界状态信息$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$。定义$\tilde{o}_{i,t}=o_{i,t}^{\mathrm{local}}\cup o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$。各MG $i$智能体的Critic通过最小化贝尔曼残差更新参数，损失值如下式所示：

$$L_i^{Q_{1,2}}\left(\phi_{1,2}\right)=\mathbb{E}_{\tau_i\in\mathrm{D}}\left[\left(Q_i^{\phi_{1,2}}\left(\tilde{o}_{i,t},a_{i,t}\right)-y_{i,t}\right)^2\right] \tag{49}$$

$$y_{i,t}=r_{i,t}+\gamma\left(\min_{i=1,2}Q^{\bar{\phi}_i}\left(\tilde{o}_{i,t+1},a'_{i,t+1}\right)-\alpha_i\mathcal{H}_{i,t+1}\right) \tag{50}$$

式中，$L_i^{Q_{1,2}}(\cdot)$ 是为避免 Q 值高估所建立的双 Q 网络；$\tau_i$ 为采样片段；D 为经验池；$\phi_{1,2}$、$\bar{\phi}_{1,2}$ 分别为估值、目标 Critic 网络参数；$\gamma$ 为折扣因子；$\alpha_i$ 为温度参数；$\mathcal{H}_{i,t+1}=\log\pi_{\theta_i}\left(a'_{i,t+1}\middle|\tilde{o}_{i,t+1}\right)$ 为熵值。

各 MG $i$ 智能体的单 Actor 网络和温度参数使用引入最大熵的策略梯度进行更新，如下式所示：

$$L_i^{\pi}(\theta_i)=-\mathop{\mathbb{E}}_{\tau\sim\mathrm{D}}\left[\min_{i=1,2}Q^{\phi}\left(\tilde{o}_{i,t},a'_{i,t}\right)-\alpha_i\mathcal{H}_{i,t}\right] \quad (51)$$

$$L_i^{\pi}(\alpha_i)=-\mathop{\mathbb{E}}_{\tau\sim\mathrm{D}}\left[\alpha_i\log\pi_{\theta_i}\left(a'_{i,t}\middle|\tilde{o}_{i,t}\right)+\alpha_i\bar{\mathcal{H}}\right] \quad (52)$$

式中，$\theta_i$ 为策略网络参数；$\bar{\mathcal{H}}$ 为目标熵值。

ADN 智能体需要接受所有 MG 智能体的边界状态信息 $o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$，且 ADN 智能体间共享注意力参数。故 ADN 离散-连续智能体的 Critic 可通过集中式联合回归损失函数进行更新，如下式所示：

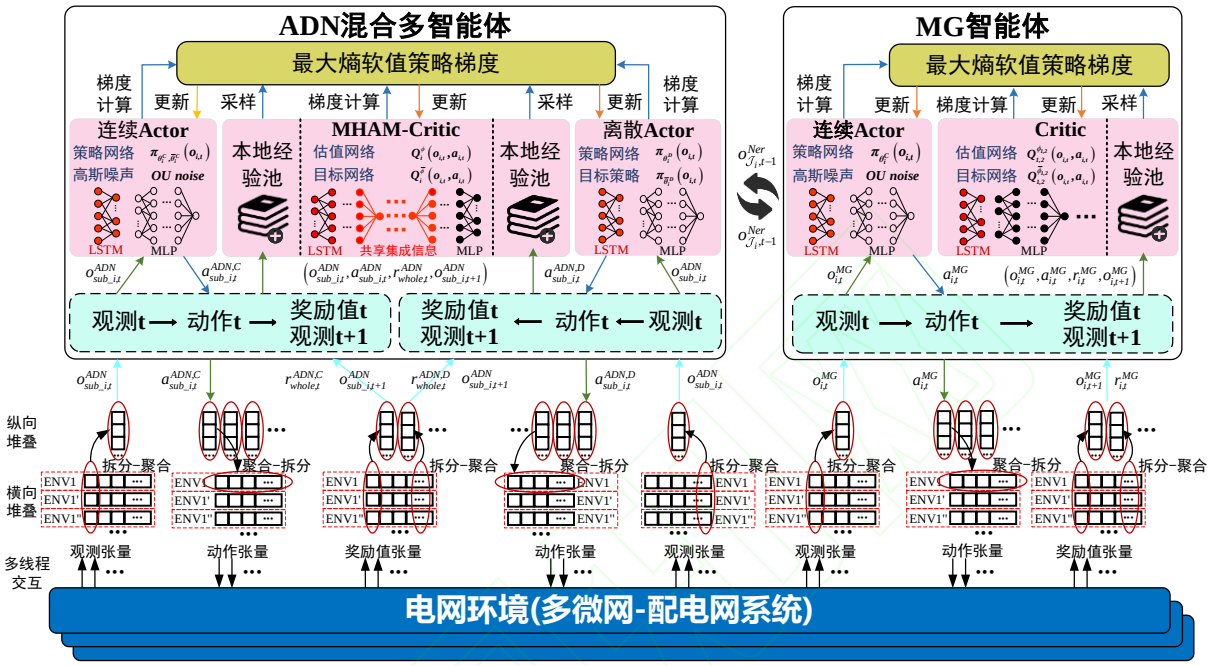



图 5 多智能体训练框架

**Fig. 5 Framework of multi-agent training process**

$$L^{\mathrm{Q}}(\phi)=\sum_{i=1}^{N_{\mathrm{ADN}}}\mathop{\mathbb{E}}_{\tau\in D}\left[\left(Q_i^{\phi}\left(\tilde{o}_{i,t},a_t\right)-y_{i,t}\right)^2\right] \quad (53)$$

$$y_{i,t}=r_{i,t}+\gamma\mathop{\mathbb{E}}_{a'\sim\pi_{\bar{\theta}}(\cdot|o')}\left[Q_i^{\bar{\phi}^{\mathrm{D}}}\left(\tilde{o}_{i,t+1},a'_{t+1}\right)-\alpha\tilde{\mathcal{H}}_{i,t+1}\right] (54)$$

$$Q_i^{\phi}\left(\tilde{o}_{i,t},a_t\right)=f_i\left(e_{i,t},\sum_{h=1}^{H}\sum_{j\neq i}\alpha_{j,t}^{h}h\left(V_h e_j\right)\right) \quad (55)$$

式中，$N_{\mathrm{ADN}}$ 为离散-连续智能体总数；熵值函数 $\tilde{\mathcal{H}}_{i,t+1}=\log\pi_{\bar{\theta}_i}\left(a'_{i,t+1}\middle|\tilde{o}_{i,t+1}\right)$；$\bar{\theta}_i$ 为目标策略网络参数；$H$ 为多头注意力的数量。

用于配网离散-连续智能体 Actor 网络采用式(56)更新的损失函数。

$$L_i^{\pi}(\theta_i)=\mathop{\mathbb{E}}_{\substack{\tau\sim\mathrm{D}\\ a\sim\pi_\theta}}\left[\alpha\log\left(\pi_{\theta_i}\left(a'_{i,t}\middle|\tilde{o}_{i,t}\right)\right)-A_i\left(\tilde{o}_{i,t},a_t\right)\right] \quad (56)$$

$$A_i\left(\tilde{o}_{i,t},a_t\right)=Q_i^{\phi}\left(\tilde{o}_{i,t},a_t\right)-b\left(\tilde{o}_{i,t},a_{\setminus i,t}\right) \quad (57)$$

式中，$A_i(\square)$ 为优势函数，用于判断当前动作的优劣；$\setminus i$ 为除智能体 $i$ 之外的所有智能体；$b\left(o_t,a_{\setminus i,t}\right)$ 是状态基线，旨在突出对目标任务更有帮助的决策，从而获得更好地学习策略，离散-连续型 Actor 网络所用的状态基线不同，分别如下式所示：

$$b\left(\tilde{o}_{i,t},a_{\setminus i}\right)=\sum_{a'_{i,t}\in A_i}\pi_{\theta_i}\left(a'_{i,t}\middle|\tilde{o}_{i,t}\right)Q_i^{\phi}\left(\tilde{o}_{i,t},\left(a'_{i,t},a_{\setminus i,t}\right)\right) \quad (58)$$

$$b\left(\tilde{o}_{i,t},a_{\setminus i}\right)=\mathop{\mathbb{E}}_{a_{i,t}\sim\pi_{\theta_i}(\cdot)}\left[Q_i^{\phi}\left(\tilde{o}_{i,t},\left(a_{i,t},a_{\setminus i,t}\right)\right)\right] \quad (59)$$

此外，将 OU 噪声引入到连续智能体 Actor 中，以增强探索能力，策略 $\pi_{\theta_i}$ 的决策可以改写成：

$$\tilde{a}_{i,t}=\pi_{\theta_i}\left(\tilde{o}_{i,t}\right)+\beta,\ \beta\sim clip\left(\mathcal{N}(0,\sigma),-c,c\right) \quad (60)$$

式中，$\beta$ 为 Actor 网络添加的剪切高斯噪声。

### 3.2 算法训练流程

H-MASAC 算法的伪代码如算法 1 所示。该算法在并行化环境中，各智能体根据观测做出决策后，将决策动作作用于电网环境，各智能体将获得奖励值。$o_{\mathcal{J}_i,t-1}^{\mathrm{Ner}}$ 将存储在时刻 $t$ 中，以便在下一时刻连接到新的观测中。所有智能体从经验池 D 中进行小批量采样以更新神经网络参数。MG 智能体软更新双 Critic 参数 $\bar{\phi}_{1,2}$，如下式所示：

$$\bar{\phi}_{1,2}\leftarrow\upsilon\phi_{1,2}+(1-\upsilon)\bar{\phi}_{1,2} \quad (61)$$

式中，$\upsilon$ 为软更新因子，$\upsilon\in(0,1)$。

ADN 离散-连续智能体软更新双 MHAM 的 Critic 参数 $\bar{\phi}$ 和双 Actor 参数 $\bar{\theta}_i$，如下式所示：

$$\bar{\phi} \leftarrow \upsilon\phi + (1-\upsilon)\bar{\phi} \quad (62)$$

$$\bar{\theta}_i \leftarrow \upsilon\theta_i + (1-\upsilon)\bar{\theta}_i \quad (63)$$

**算法 1**：所提 H-MASAC 算法

**初始化参数**：回合数 $M$，回合总步数 $T_{\text{sum}}$，定更新步长 $T_{\text{update}}$，学习率 $\sigma_{\text{MG}}$、$\sigma_{\text{ADN}}$，经验池等

**初始化网络参数** $\phi_{1,2}, \bar{\phi}_{1,2}, \theta_i$、$\phi, \bar{\phi}, \theta_i, \bar{\theta}_i$ **和电网环境**

**For** 回合 1 到 $M$ **do 并行**

  接收所有智能体的初始本地观测和初始 $o^{\text{Ner}}_{\mathcal{J}_i,t-1}$

  **For** 时间步 1 到 $T$ **do**

    各离散-连续智能体依据观测 $o_{i,t}$ 给出决策动作 $a_{i,t}$，根据式(33)-(35)、(40)-(43)

  **End**

  通过式(13)-(16)，(23)-(26)计算潮流；所有智能体从相邻智能体接收下一时刻通信消息 $o^{\text{Ner}}_{\mathcal{J}_i,t}$，形成新观测值(33), (40)，获得奖励值(36)、(44)、(45)

  将经验样本存放至 D 中，环境进入到下一状态

  **If** 时间步总和超过 $T_{\text{update}}$ **do**

    **For** MG 智能体 $i = 1,2,...N_{\text{MG}}$ **do**

      从 D 中采样更新，根据式(49),(51),(52)：

      $$\phi^{\text{C}}_{1,2} \leftarrow \phi^{\text{C}}_{1,2} - \sigma_{\text{MG}} \nabla_{\phi^{\text{C}}_{1,2}} L^{\text{Q}_{1,2}}_i \left(\phi^{\text{C}}_{1,2}\right)$$

      $$\theta^{\text{C}}_i \leftarrow \theta^{\text{C}}_i - \sigma_{\text{MG}} \nabla_{\theta^{\text{C}}_i} L^{\pi}_i \left(\theta^{\text{C}}_i\right)$$

      $$\alpha^{\text{C}}_i \leftarrow \alpha^{\text{C}}_i - \sigma_{\text{MG}} \nabla_{\alpha^{\text{C}}_i} L^{\pi}_i \left(\alpha^{\text{C}}_i\right)$$

    **End**

    **For** ADN 分区智能体 $i = 1,2,...N_{\text{ADN}}$ **do**

      从 D 中采样更新，根据式(53),(56)：

      $$\phi \leftarrow \phi - \sigma_{\text{ADN}} \nabla_{\phi} L^{\text{Q}}\left(\phi\right)$$

      $$\theta_i \leftarrow \theta_i - \sigma_{\text{ADN}} \nabla_{\theta_i} L^{\pi}_i \left(\theta_i\right)$$

    **End**

    各智能体软更新目标网络，根据式(61)-(63)

  **End if**

**End**

值得注意的是，针对离散和连续设备协调优化导致模型收敛困难的挑战，本文上层构建了离散和连续多智能体协调的强化学习模型，该模型的收敛性在现有研究中已有分析[15]；在此基础上，为提高智能体维度爆炸对模型收敛性的影响，本文进一步引入了注意力机制以改善模型收敛性能。与此同时，为提高配-微电网多智能体间在训练过程中的稳定性，受[23], [24]启发，本文所提方法允许相邻智能体在训练过程中相互通信以交换有限的特征信息，而不是收集全局信息进行集中式训练，这为处理非平稳环境具有促进作用。因此，上述方式可有效改善所提模型的收敛性能。

## 4 算例仿真与分析

### 4.1 系统参数设置

采用改进的 IEEE33 节点系统进行仿真分析，拓扑结构如图 6 所示，配电网包含 3 个自治区域。节点 17, 21, 32 接有 3 个微电网；节点 6, 14 接有 PV；节点 25 接有 WT；节点 15 处接有 ESS；节点 23 和 30 分别接有 SVC 和 MT；节点 8, 27 接有 CB；节点 0-1 之间接有 OLTC；调度周期为 $T = 24\text{h}$，以 1h 为一个调度时段。各设备参数和各时段电价信息如附录 A 所示。负荷和 RES 发电来自开源数据集[25]，使用 20 天的数据训练所提算法，并在训练数据中叠加 $\mu = 0, \varepsilon = 5\%$ 的高斯噪声，其余 10 天的数据作为测试集。三个微电网中可再生能源出力及负荷曲线参照附录 B。

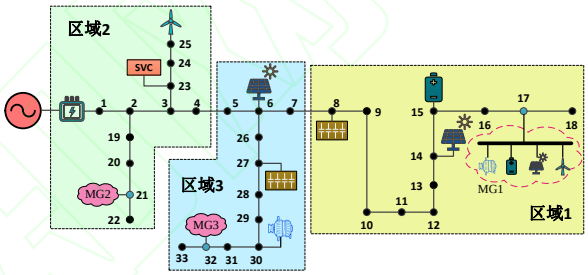



图 6 改进 IEEE33 节点系统图

**Fig. 6 Improved IEEE33 node system diagram**

训练回合数为 $M = 12000$，采样样本数为 1024，注意力头数量为 $H = 4$，所用 Actor 与 Critic 网络的学习率 $\sigma$ 为 0.001，折扣因子为 $\gamma = 0.99$，MG 和 ADN 的温度参数 $\alpha$ 分别为 0.2、0.01，高斯噪声初始值为 0.3，随着回合数的增加衰减至 0。算例分析采用 PyTorch1.13.1 框架实现，测试系统在配置 Intel(R) Core(TM) i9-12900H CPU @2.30 GHz, 32 GB 内存，14 核(6P+8E)，显卡为 NVIDIA GeForce RTX 3070 Ti 的电脑上，操作系统为 Win10 64 位。

### 4.2 所提模型和算法的有效性分析

#### 4.2.1 优化调度结果分析

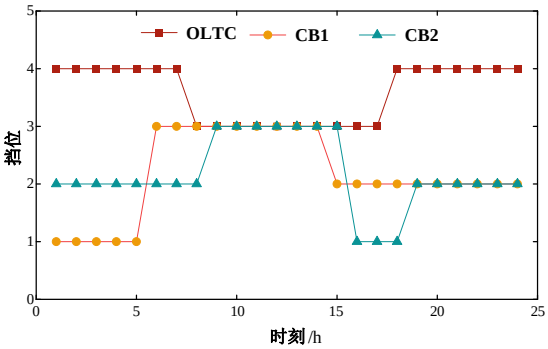



图 7 离散设备调节挡位

**Fig. 7 Discrete device adjustment gear**

各时段离散设备 OLTC 和 CBs 的调度结果如图 7 所示。可以看出，OLTC 分接头共动作 2 次，CB1 和 CB2 分别动作 2 次和 3 次，满足每日最大可调节次数；OLTC 和 CBs 通过挡位的调节，可改善电压分布，防止电压越限。

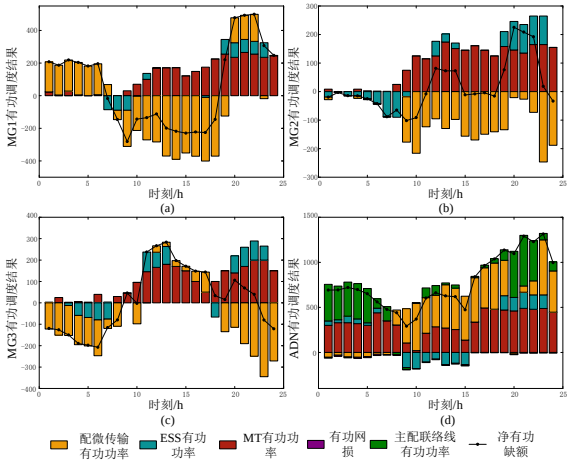



**图 8　有功调度结果**

**Fig. 8　Results of active power dispatching**

图 8 展示了有功调度结果。可以看出，优化结果受购售电价的影响。在 01:00-8:00 电价谷时段，由于 MG 自身发电成本较高，当净有功缺额为正时，MG 会向 ADN 购电；当净有功缺额为负时，MG 可向 ADN 售电或将富裕的电量存储在 ESS 中，以便在电价峰平时段获利；此时配、微电网间售电价格较低，ADN 调度其内部的 MT 和 ESS，不足功率从主网中购得。在 09:00-24:00 电价峰平时段，由于配、微电网间售电价格较高，MG 调度其内部 MT 和 ESS 向 ADN 售电以获取收益；当其内部无法满足自身缺额时，MG 会向 ADN 购电。ADN 在 09:00-15:00 为 ESS 充电，以便在夜间 19:00-23:00 净有功缺额高峰时段降低成本，而在 16:00-24:00 从主网购电以降低运行成本。

4.2.2 有功-无功协同优化性能分析

为验证有功-无功协同优化的有效性，设置 3 种不同优化方案进行对比分析：

方案 1：配、微系统仅对有功设备进行优化。

方案 2：考虑配电网内部 OLTC、CBs、SVC 等无功设备，MGs 仅进行有功优化。

方案 3：在方案 2 的基础上，进一步考虑 MGs 对 ADN 的无功支持。

图 9 所示为各方案的电压幅值分布情况，三种方案运行成本分别为 11815.6￥，10910.1￥和 10530.9￥。可以看出，方案 1 中仅有功设备参与优化，电压幅值出现越限情况。与之相比，方案 2 考虑了配电网的无功调节能力，确保电压维持在安全范围内，且与方案 1 相比运行成本降低了 7.6%。方案 3 中，微网提供的连续无功功率进一步缓解了电压偏差，运行成本较方案 2 降低了 3.5%。因此，通过对配微电网内的有功和无功资源协调优化，可改善电压分布并降低运行成本。

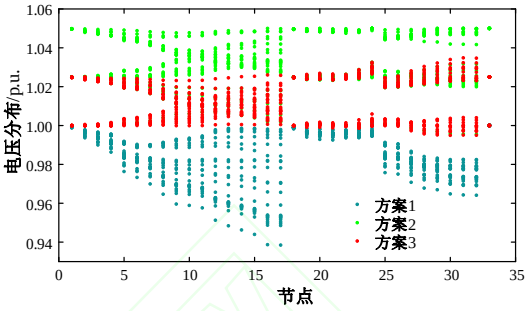



**图 9　各节点电压幅值分布**

**Fig. 9　Each node voltage amplitude distribution**

4.2.3 算法有效性验证

为验证本文所提出的 H-MASAC 方法的有效性，将其和以下方法进行对比，包括 H-MATD3 方法、H-MADDPG 方法、H-MAPPO、QMIX、QTRAN、数学规划法、启发式 PSO 算法以及交替方向乘子法(ADMM)。

**表 1　不同方法的结果对比**

**Tab.1　Comparison of results among different methods**

| 算法 | 在线决策 | 运行成本/元 | | | | 总成本/元 |
|---|---|---|---|---|---|---|
| | 时间/s | MG1 | MG2 | MG3 | ADN | |
| **H-MASAC** | **0.17** | **1346.64** | **769.68** | **1132.56** | **7282.08** | **10530.96** |
| H-MATD3 | 0.19 | 1137.52 | 644.72 | 827.07 | 9551.28 | 12160.59 |
| H-MADDPG | 0.21 | 1524.96 | 1430.64 | 1336.56 | 10369.2 | 14661.36 |
| H-MAPPO | 0.20 | 1513.43 | 1443.78 | 1330.04 | 10321.42 | 14608.67 |
| QMIX | 0.19 | 1505.77 | 1142.47 | 1192.04 | 8495.56 | 12335.84 |
| QTRAN | 0.20 | 1311.23 | 944.91 | 998.37 | 7861.11 | 11115.62 |
| 数学规划法 | 64.70 | 1159.07 | 795.28 | 840.08 | 6961.44 | 9755.87 |
| PSO | 176.45 | 1253.96 | 717.84 | 816.56 | 7016.4 | 9804.76 |
| ADMM | 1393.14 | 1200.38 | 788.8 | 756.32 | 7102.56 | 9848.06 |

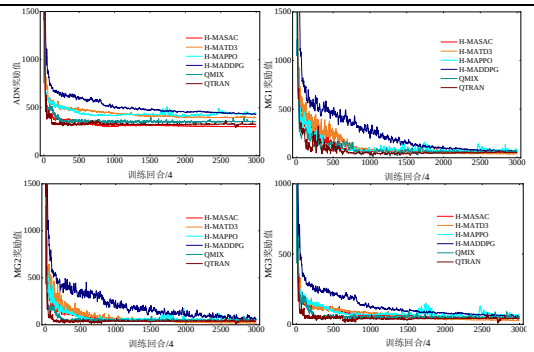



**图 10　不同 MADRL 算法的训练结果**

**Fig. 10　Training results of MADRL methods**

表 1 所示为本文方法与其他方法的结果对比，

图 10 为不同人工智能方法的训练曲线。可以看出，数学规划法在求解大规模整数规划问题时，求解效率较低，进而导致基于机理模型的分布式优化方法 ADMM，计算时间超过 1000s，难以满足在线应用需求。与机理模型方法相比智能优化方法的求解时间在 1s 内，极大提高了计算效率，可支持在线应用。人工智能方法都可以有效收敛，然而与本文所提 H-MASAC 算法相比，H-MATD3、H-MADDPG、H-MAPPO、QMIX、QTRAN 等算法虽然提高了计算效率，但是存在求解精度不足的挑战，运行成本远高于数学规划法和启发式方法。原因在于，数学规划方法、PSO 方法与 ADMM 方法均是在已知全天源荷数据的情况下，进行凸优化建模求解得到的，即理论上数学规划方法所得到的总成本是该问题的最优解。而强化学习方法均是在完成训练后，带有高斯噪声的未知源荷测试数据上的测试结果，其总成本略高于传统数学规划方法，但求解速度可满足实时调度要求。综上，本文所提 H-MASAC 方法的运行成本与数学规划法相比较为接近，在提高计算效率的同时，确保了解的精确性。

为验证训练数据对算法收敛性的影响，将训练数据时长分别扩充至 90、180、300 天，算法的收敛结果如图 11 所示。可以看出，随着训练数据的增多，算法依旧能收敛到稳定值，这验证了本文所提方法具有较好的收敛性。

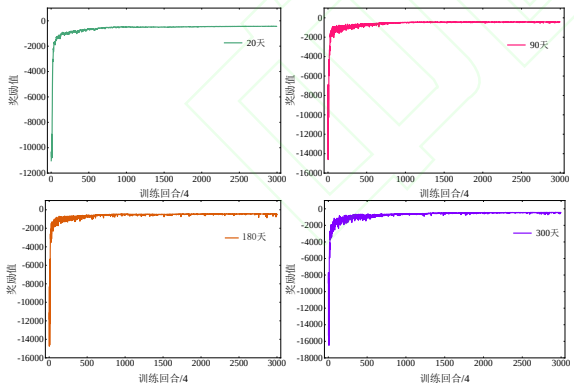



**图 11　不同训练天数训练结果对比**

**Fig. 11　Comparison of training results of different training days**

## 4.3 算法性能提升验证

### 4.3.1 微电网 C-DTDE 协调架构的有效性分析

为验证所提 C-DTDE 训练框架的有效性，将其和 CTDE、DTDE 框架进行对比，结果如下：

**表 2　不同框架下的通信需求**

**Tab.2 Communication demand of different frameworks**

| 算法 | 通信数据类型 | 是否保护隐私 | 相邻更新步智能体间通信数据量 |
|---|---|---|---|
| **C-DTDE** | **边界信息和奖惩信息** | **是** | **0→1/2/3:5×96**<br>**1/2/3→0:2×96** |
| CTDE | 配微观测和动作信息 | 否 | 0→1/2/3:96×1024<br>1→0/2/3:15×1024<br>2→0/1/3:18×1024<br>3→0/1/2:15×1024 |
| DTDE | 奖惩信息 | 是 | 0→1/2/3:2×96<br>1/2/3→0:0×96 |

注:0 表示配网；1-3 表示微网；0→1 表示智能体 0 向 1 传递信息

表 2 所示为三种框架的通信需求，可以看出，在相邻更新步间，采用 C-DTDE 框架时配微智能体间传递的数据量明显少于 CTDE，略高于 DTD E。在 CTDE 框架中，各智能体采用集中训练模式，要完成一次梯度更新，需向各智能体 $i$ 传递从经验池采样的 $\left(n_i^{\text{state}}+n_i^{\text{action}}\right)\times n_i^{\text{batch}}$ 维观测-动作数据（$n_i^{\text{state}}$、$n_i^{\text{action}}$ 为观测、动作张量维数；$n_i^{\text{batch}}$ 为批量采样数量）。因此，集中训练增加了通信压力，可能出现隐私泄露的风险。而 C-DTDE 框架下各智能体拥有独立的经验池，仅需相邻智能体间传递边界低维特征与奖惩信息，不仅通信量更少，更保障了配微主体的隐私。

### 4.3.2 消融实验分析

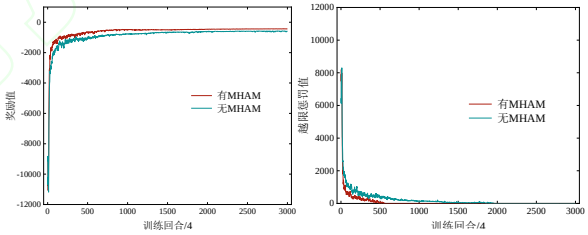



**图 12　有无注意力机制训练对比**

**Fig. 12　Comparison of training with and without attention mechanism**

图 12 展示了 3 个离散设备下有无注意力机制的两组训练结果的对比，可以观察到前者相比于后者的收敛所需次数更少，收敛精度更高。这是因为注意力机制通过编码，降低了弱关联信息的权重，进而增强了智能体的感知和寻优能力。

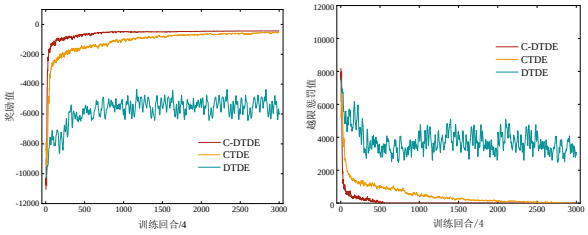



**图 13　不同训练框架对比**

**Fig. 13　Comparison of different training frameworks**

图 13 展示了三种技术在训练数据集保持一致

的情况下的训练结果。可以看出，本文所提 C-DTDE 与 CTDE 技术均可收敛，而 DTDE 训练过程发散。原因是 DTDE 框架由于未处理非平稳环境和缺乏智能体间的协调，未能收敛到稳定的策略；CTDE 框架的收敛速度缓慢且收敛精度低于 C-DTDE，原因是含多微网的配电网智能体均需要高维 Critic 网络来指导智能体的决策。相比之下，C-DTDE 框架通过压缩 Critic 网络的观测空间来减轻计算负担，提升了寻优性。

4.3.3 并行化技术有效性分析

为验证并行化技术有效性，在同一进程中设置不同线程数量执行并行训练，结果如下：

**表 3　不同线程数量下算法收敛结果**

**Tab.3　Algorithm results under different thread counts**

| 线程数量 | 1 | **4** | 8 | 12 |
|---|---|---|---|---|
| 总训练时间/h | 4.32 | **1.34** | 0.93 | 0.64 |
| 运行成本/元 | 10537.68 | **10530.96** | 10707.12 | 10860.24 |

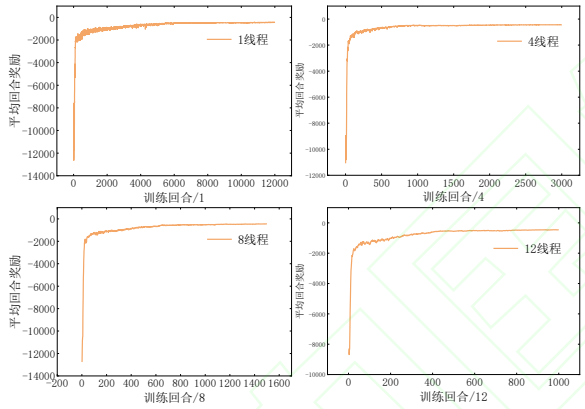



**图 14　不同线程数量下对比**

**Fig. 14 Comparison under different number of threads**

表 3 和图 14 分别为不同线程数量下算法收敛结果。可以看出，训练时间和收敛回合数均会随着并行化线程数量的增多呈现逐渐降低的趋势，而运行成本值却略有上升，原因是并行化采样环境的数量应该与智能体定更新步长相匹配，过多过少均会影响算法收敛结果。

4.3.4 可扩展性分析

**表 4　不同 MG 数量下可扩展性比较**

**Tab.4　Scalability comparison with different MGs**

| MG 数量 3/6/9/12 | **HMASAC (C-DTDE)** | HMASAC (CTDE) | HMASAC (DTDE) | 数学规划法 |
|---|---|---|---|---|
| 总训练时间/h | **1.34** | 2.21 | 1.29 | —— |
| | **2.83** | 4.67 | 2.64 | |
| | **4.54** | 6.31 | 4.12 | |
| | **6.71** | 10.46 | 6.24 | |
| 执行时间/s | **0.17** | 0.18 | 0.15 | 64.70 |
| | **0.25** | 0.27 | 0.19 | 106.82 |
| | **0.33** | 0.35 | 0.24 | 172.68 |
| | **0.41** | 0.44 | 0.30 | 284.19 |

由表 4 可知，随着 MG 数量的增加，智能模型的训练时间增加，但 C-DTDE 的训练时间优于 CTDE。同时，与数学规划法相比，智能优化方法可在 1 秒内完成优化求解，而数学规划法随着 MG 数量的增加显著提高。上述结果表明随着 MG 的规模化接入，本文所提方法依然可以有效收敛。与此同时，上层配电网多智能体模型融合了注意力机制（MHAM），可改善其优化性能。

**表 5　不同离散设备接入下的可扩展性**

**Tab.5　Scalability with different discrete devices**

| 离散设备数量 0/3/6/9 | **HMASAC (有 MHAM)** | HMASAC (无 MHAM) | 混合整数规划 | ADMM |
|---|---|---|---|---|
| 总训练时间/h | **0.79** | 1.21 | —— | —— |
| | **1.34/** | 1.87/ | | |
| | **1.63/** | 2.48 | | |
| | **2.06** | 3.64 | | |
| 执行时间/s | **0.10** | 0.12 | 6.01/ | 12.57/ |
| | **0.17/** | 0.19/ | 64.70/ | 1393.14/ |
| | **0.20/** | 0.23/ | 197.234/ | —— |
| | **0.25** | 0.31 | 296.944 | —— |

表 5 为不同离散设备接入下模型的优化结果。可以看出，智能优化方法的训练时间均会随着离散设备数量增加而增加。总体上，融合 MHAM 后可减少模型的训练时间。同时，与机理模型方法相比，离散设备的增加会极大提高计算时间，而智能优化方法受此影响较小，有利于海量资源接入下的快速分析求解。上述结果表明，随着调控资源的不断接入，本文所提方法的收敛性和计算效率都能保证，可扩展性较好。

4.3.5 鲁棒性测试

为验证本文算法应对不确定性场景的鲁棒性，设置多组源荷波动场景，如依次给源荷数据叠加 5%、10%、15%和 20% 的预测误差，并假设误差遵循高斯分布。4 种场景下算法的训练结果如图 15 所示。由结果可以发现，本文所提算法在 4 种源荷波动场景下均具备良好的收敛性和精确性，这验证了本文所提方法可有效应对源荷波动场景。

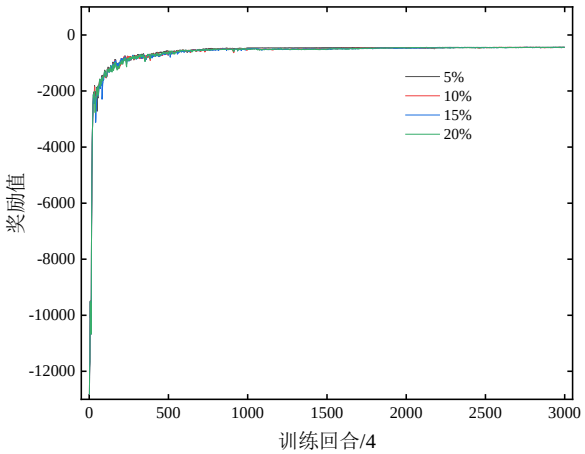



图 15 不同源荷波动场景下收敛性

**Fig. 15 Convergence under different source-load fluctuation scenarios**

为进一步验证所提方法的不确定性适应能力，将其与随机优化方法进行对比。四种不确定性场景的优化结果如图 16 所示。

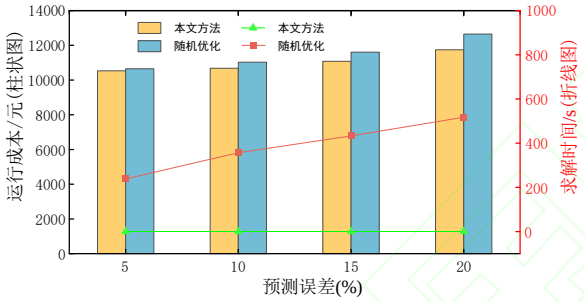



图 16 不确定性方法对比

**Fig. 16 Comparison of different uncertainty methods**

图 16 所示为本文方法与随机优化在求解时间和运行成本上的对比情况。可以看出，相比于随机优化方法，所提 H-MASAC 大幅缩减了求解时间，且求解精度较高。同时，随着源荷波动幅度的增加，本文方法的优越性愈加明显。原因在于，在训练阶段 H-MASAC 考虑了源荷出力叠加预测误差的扰动，这有效提高了算法的鲁棒性。而随机优化方法依赖于精确的运行场景，其调度决策难以动态地对源荷随机变化做出响应。与此同时，随着源荷预测误差的提高，为保障求解精度，所需典型场景增多，进一步增加了求解时长。

### 4.3.6 通信延迟影响分析

由于本文方法在训练阶段智能体间需要相互通信，考虑到通信系统非理想，难免出现通信中断、数据丢包等问题，这里对比不同程度的通信中断情况下智能体组的训练效果，如图 17 所示。

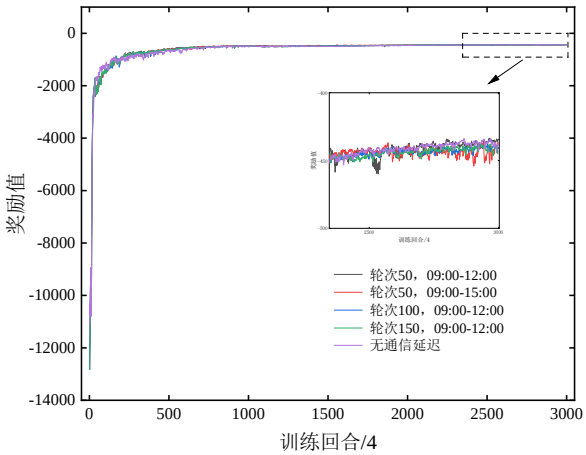



图 17 通信中断情况下的训练效果

**Fig. 17 Training effectiveness under communication interruption**

可以看出，有限时间的通信中断并不会对方法的收敛性造成很大的影响，这是因为在通信中断后，受影响的智能体不更新参数，保留当前策略，而当通信恢复后，智能体会继续训练，只要训练次数充足便能够收敛到与没有通信中断相当的结果。数据丢包同理，通信中断仅停止策略的更新优化，并不影响当前策略的执行。综上所述，本文方法对通信中断以及数据丢包等问题具有较好的鲁棒性。

## 4.4 大规模测试系统的可行性验证

为进一步验证本文所提算法在更大规模系统中的实用性，采用改进的 IEEE123 节点系统进行测试。系统拓扑结构如图 18 所示，算法参数与 IEEE33 节点系统算例相同。

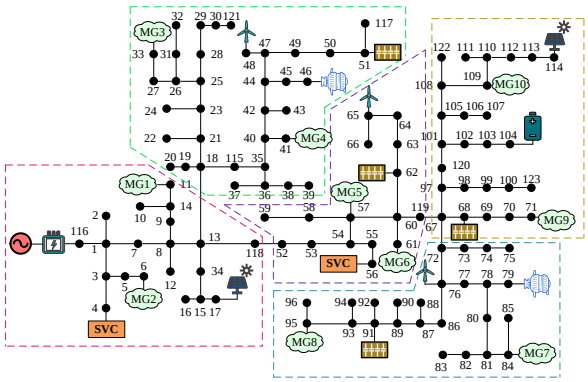



图 18 改进 IEEE123 节点系统图

**Fig. 18 Improved IEEE123 system diagram**

优化结果如图 19 所示，可以看出：

1）图(a)证实了模型可以收敛到一个稳定的最优策略，配、微多智能体在探索过程中不断降低系统的总运行成本。

2）图(b)为测试日系统节点电压幅值分布，由图可知，该方法可满足系统的电压安全，不会发生

电压越限。

3）图(c)和(d)分别展示了系统在主配、配微网络联络线上有功和无功调度结果。通过对系统内的有功和无功资源协调优化有利于改善潮流分布，降低运行成本。

4）同时，算法在大规模测试系统中需要 6.7h 的离线训练时间和 7.2s 的在线执行时间。与数学规划方法相比（388.6s），在确保计算精度的同时，极大提升了模型的计算效率。

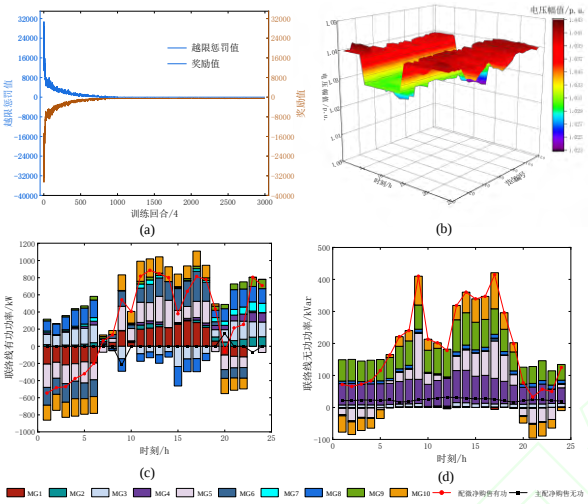



**图 19　大规模系统的优化结果**

**Fig. 19　Optimization results of large-scale system**

上述结果表明，本文所提方法可用于更大规模系统的优化分析，展现出了其较好的应用前景。

## 5　结论

针对多微网-配电网跨层级、多区域的非凸优化难题，本文提出混合多智能体强化学习分层协调的优化方法。通过大量算例分析验证了所提模型和算法的有效性，可以得出如下结论：

1）构建了混合多智能体分层协调优化模型。通过上层配电网离散/连续多智能体和下层微电网连续智能体的分层协调，实现了多源异构资源接入下多微网-配电网系统的优化调度。

2）提出了多智能体模型协调优化策略。上层配电网多智能体融合了注意力机制，下层微电网采用 C-DTDE 框架。通过上述方式，有效减轻了智能体间的通信压力，提高模型收敛性和训练效率的同时，增强了其可扩展性。

3）提出 H-MASAC 优化算法。相比于串行架构，并行架构缩短了离线训练时长，相比于 H-MATD3 和 H-MADDPG，所提算法训练优化精确性较高，与传统优化方法相比，可支持在线应用，算法在更大规模测试系统上展现了可行性。

## 参考文献

[1] 朱继忠，董瀚江，李盛林，等. 基于分布式新能源集群的微能源网优化调度综述[J]. 中国电机工程学报，2024，44(20)：7952-7970.
ZHU Jizhong，DONG Hanjiang，LI Shenglin，et al. Review of optimal dispatching for the aggregation of micro-energy grids based on distributed new energ-y[J]. Proceedings of the CSEE，2024，44(20)：7952-7970(in Chinese).

[2] 张波，高远，李铁成，等. 考虑光伏电源可靠性的新能源配电网数据驱动无功电压优化控制[J]. 中国电机工程学报，2024，44(15)：5934-5946.
ZHANG Bo，GAO Yuan，LI Tiecheng，et al. Date-driven voltage/var optimization control of active distribution network considering the reliability of photovoltaic power supply[J]. Proceedings of the CSEE，2024，44(15)：5934-5946(in Chinese).

[3] 王逸群，彭寒梅，谭貌，等. 基于两阶段博弈的多微电网配电系统功率互济协调优化方法[J]. 电力系统自动化，2024，48(21)：92-101.
WANG Yiqun，PENG Hanmei，TAN Mao，et al. Power coordination optimization method of multi-microgrid distribution system based on two-stage game[J]. Automation of Electric Power Systems，2024，48(21)：92-101(in Chinese).

[4] Yuan Zhipeng，Li Peng，Li Zhenlong，et al. A fully distributed privacy-preserving energy management system for networked microgrid cluster based on homomorphic encryption[J]. IEEE Transactions on Smart Grid，2024，15(2)：1735-1748.

[5] Wang Chunling，Liu Chunming，Zhou Xiulin，et al. Hierarchical optimal dispatch of active distribution networks considering flexibility auxiliary service of multi-community integrated energy systems[J]. IEEE Transactions on Industry Applications，2025，61(2)：2770-2781.

[6] Yang Lun，Li Hui，Zhang Hongcai，et al. Stochastic-distributionally robust frequency-constrained optimal planning for an isolated microgrid[J]. IEEE Transactions on Sustainable Energy，2024，15(4)：2155-2169.

[7] 张津源，蒲天骄，李烨，等. 基于多智能体深度强化学习的分布式电源优化调度策略[J]. 电网技术，2022，46(9)：3496-3504.
ZHANG Jinyuan，PU Tianjiao，LI Ye，et al. Multi-agent deep reinforcement learning based optimal dispatch of distributed generators[J]. Power System Technology，2022，46(9)：3496-3504(in Chinese).

[8] 张继行，张一，王旭，等. 基于多代理强化学习的多新型市场主体虚拟电厂博弈竞价及效益分配策略[J]. 电网

技术，2024，48(05)：1980-1991.
ZHANG Jihang，ZHANG Yi，WANG Xu，et al．Game bidding and benefit allocation strategies for virtual power plants with multiple new market entities based on multi-agent reinforcement learning[J]. Power System Technology，2024，48(05)：1980-1991(in Chinese).

[9] 乔骥，王新迎，张擎，等．基于柔性行动器-判别器深度强化学习的电-气综合能源系统优化调度[J]．中国电机工程学报，2021，41(3)：819-832.
QIAO Ji，WANG Xinying， ZHANG Qing，et al．Optimal dispatch of integrated electricity-gas system with soft actor-critic deep reinforcement learning [J]． Proceedings of CSEE，2021， 41(3)： 819-832(in Chinese).

[10] 张晓，吴志，郑舒，等．基于贝叶斯深度强化学习的主动配电网电压控制[J]. 电力系统自动化，2024，48(20)：81-90.
ZHANG Xiao，WU Zhi，ZHENG Shu，et al．Voltage Control for active distribution network based on bayesian deep reinforcement learning[J]． Automation of Electric Power Systems，2024，48(20)：81-90(in Chinese).

[11] 巨云涛，陈希．基于双层多智能体强化学习的微网群分布式有功无功协调优化调度[J]．中国电机工程学报，2022，42(23)：8534-8548.
JU Yuntao，CHEN Xi．Distributed active and reactive coordinated optimal scheduling of microgrid groups based on two-layer multi-agent reinforcement learning [J]. Proceedings of the CSEE，2022，42(23)：8534- 8548(in Chinese).

[12] 洪芦诚，吴明贺，朱进，等．基于约束增强安全强化学习的光-储-充高渗透配电网有功/无功优化决策方法[J/OL]．中国电机工程学报，网络首发.
HONG Lucheng，WU Minghe，ZHU Jin，et al．Constraint-enhanced safe reinforcement learning based decision-making method for re/active power optimization in highly penetrated pv-storage-charging distribution network [J/OL]. Proceedings of the CSEE，early access (in Chinese).

[13] 刘硕，冯斌，郭创新，等．考虑自注意力和时序记忆的深度强化学习配电网无功电压控制策略[J]. 中国电机工程学报，2025，45(02)：565-577.
LIU Shuo，FENG Bin，GUO Chuangxin，et al．Volt-var Control strategy of distribution network based on deep reinforcement learning considering self-attention and temporal-memory [J]． Proceedings of the CSEE，2025，45(02)：565-577(in Chinese).

[14]Yan Linfang, Chen Xia, Chen Yin, et al. A hierarchical deep reinforcement learning-Based community energy trading scheme for a neighborhood of smart households [J]. IEEE Transactions on Smart Grid，2022，13(6)：4747-4758.

[15] Dong Lei，Lin Hao，Qiao Ji，et al．A coordinated active and reactive power optimization approach for multi-microgrids connected to distribution networks with multi-actor-attention-critic deep reinforcement learning[J]．Applied Energy，2024，373：123870.

[16] Zhang Yiwen，Mei Zhen，Wu Xiaoqian，et al．Two-step diffusion policy deep reinforcement learning method for low-carbon multi-energy microgrid energy management[J]. IEEE Transactions on Smart Grid，2024，15(5)：4576-4588.

[17] Wang Yi，Qiu Dawei，Wang Yu，et al．Graph lear-ning-based voltage regulation in distribution networks with multi-microgrids[J]．IEEE Transactions on Power Systems，2024，39(1)：1881-1895.

[18] Xu Xuesong，Xu Kai，Zeng Ziyang，et al．Collaborative optimization of multi-energy multi-microgrid system： A hierarchical trust-region multi-agent reinforcement learning approach[J]. Applied Energy，2024，375：123923.

[19] 李彬贤，李佳勇，海征，等．基于多智能体深度强化学习的配电网三相不平衡在线治理方法[J]. 中国电机工程学报，2025，45(05)：1729-1741.
LI Binxian，LI Jiayong，HAI Zheng，et al．Three-phase unbalanced online governance of distribution network based on multi-agent deep reinforcement learning[J]. Proceedings of the CSEE，2025，45(05)：1729-1741(in Chinese).

[20] Wu Yuxin， Zhao Tianyang， Yan Haoyuan， et al．Hierarchical hybrid multi-agent deep reinforcement learning for peer-to-peer energy trading among multiple heterogeneous microgrids[J]．IEEE Transactions on Smart Grid，2023，14(6)：4649-4665.

[21] Bai Yuyang，Chen Siyuan，Zhang Jun，et al．An adaptive active power rolling dispatch strategy for high proportion of renewable energy based on distributed deep reinforcement learning[J]．Applied Energy，2023，330：120294.

[22] Hochreiter S， Schmidhuber J． Long short-term memory[J]. Neural computation，1997，9(8)：1735-1780.

[23] Chu TS，Wang J，Codecà L，et al．Multi-agent deep reinforcement learning for large-scale traffic signal control[J]．IEEE Transactions on Intelligent Transportation Systems，2020，21(3)：1086-1095.

[24] Chen D，Chen KA，Li ZJ， et al．PowerNet：Multi-agent deep reinforcement learning for scalable powergrid control[J]．IEEE Transactions on Power Systems，2022，37(2)：1007-1017.

[25] ELIA Group. Transparency on grid data [DB/OL]．(2019-06-03)．https://www.elia.be/en/grid-data.

## 附录 A

**表 A1　设备运行参数**

**Tab.A1 Operation parameters of device.**

| 设备类型 | 参数类型 | ADN | MG1 | MG2 | MG3 |
|---|---|---|---|---|---|
| PV | $S_{\max}^{\mathrm{PV}}$/kVA | 500 | 700 | 500 | - |
| WT | $S_{\max}^{\mathrm{WT}}$/kVA | 850 | - | 500 | 500 |
| MT | $a_{\mathrm{MT}}/b_{\mathrm{MT}}/c_{\mathrm{MT}}$ | 0/0.33/10 | 0/0.63/5 | 0/0.61/3 | 0/0.68/5 |
| | $P_{\min}^{\mathrm{MT}}$/kW | 20 | 0 | 0 | 0 |
| | $P_{\max}^{\mathrm{MT}}$/kW | 500 | 275 | 175 | 200 |
| | $R_{\mathrm{down}}^{\mathrm{MT}}$/(kW/h) | 200 | 50 | 50 | 50 |
| | $R_{\mathrm{up}}^{\mathrm{MT}}$/(kW/h) | 200 | 50 | 50 | 50 |
| | $\phi^{\mathrm{MT}}$ | 0.9 | 0.9 | 0.9 | 0.9 |
| | $S_{\max}^{\mathrm{MT}}$ | 700 | 400 | 300 | 300 |
| ESS | $\rho$ | 0.005 | 0.005 | 0.005 | 0.005 |
| | $P_{\min}^{\mathrm{BESS}}$/kW | 100 | 100 | 100 | 100 |
| | $P_{\max}^{\mathrm{BESS}}$/kW | 100 | 100 | 100 | 100 |
| | $\eta_{\mathrm{ch}}$ | 0.95 | 0.95 | 0.95 | 0.95 |
| | $\eta_{\mathrm{dis}}$ | 0.95 | 0.95 | 0.95 | 0.95 |
| | $soc_{\min}/soc_{\max}$ | 0.02/0.92 | 0.03/0.86 | 0.03/0.86 | 0.03/0.86 |
| | $E_{\max}^{\mathrm{BESS}}$/(kW·h) | 1300 | 700 | 700 | 700 |
| OLTC | $C_{\mathrm{OLTC}}$ | 2 | - | - | - |
| | $N_{\max}^{\mathrm{OLTC}}$ | 6 | - | - | - |
| | $\Delta V_{\mathrm{TAP}}^{\mathrm{OLTC}}$ | 2.5% | - | - | - |
| CB | $C_{\mathrm{CB}}$ | 2 | - | - | - |
| | $N_{\max}^{\mathrm{CB}}$ | 6 | - | - | - |
| | $Q^{\mathrm{CB}}$/kVar | 100 | - | - | - |
| SVC | $Q_{\min}^{\mathrm{SVC}}$/kVar | 300 | - | - | - |
| | $Q_{\max}^{\mathrm{SVC}}$/kVar | 300 | - | - | - |

表 A2　分时电价

**Tab.A2 Time-of-use electricity price.**

| 对象 | 时段 | 时刻 | 购电电价 /(元·(kW·h)$^{-1}$) | 售电电价 /(元·(kW·h)$^{-1}$) |
|---|---|---|---|---|
| 主配 | 峰 | 11:00-14:00;21:00-23:00 | 0.68 | 0.35 |
| | 平 | 9:00-10:00;15:00-20:00 | 0.5 | 0.26 |
| | 谷 | 00:00-8:00 | 0.3 | 0.17 |
| 配微 | 峰 | 11:00-14:00;20:00-23:00 | 0.472 | 0.372 |
| | 平 | 9:00-10:00;15:00-19:00 | 0.355 | 0.312 |
| | 谷 | 00:00~8:00 | 0.236 | 0.185 |

表 A3　变量命名

**Tab.A3　Variable nomenclature.**

| | |
|---|---|
| **缩写词** | |
| MG | 微电网 |
| ADN | 有源配电网 |
| MMDN | 多微网-配电网 |
| MADRL | 多智能体深度强化学习 |
| MADDPG | 多智能体深度确定性策略梯度 |
| MATD3 | 多智能体双延迟策略梯度 |
| MAPPO | 多智能体近端策略优化 |
| MASAC | 多智能体软演员评论家 |
| QMIX | Q 值混合 |
| QTRAN | Q 值变换 |
| CTCE | 集中式训练集中式执行 |
| CTDE | 集中式训练分布式执行 |
| DTDE | 分布式训练分布式执行 |
| MHAM-CTDE | 融合多头注意力机制的集中式训练分布式执行 |
| C-DTDE | 基于通信的分布式训练分布式执行 |
| MT | 微型燃气轮机 |
| ESS | 储能装置 |
| WT | 风电机组 |
| PV | 光伏机组 |
| SVC | 静止无功补偿器 |
| OLTC | 有载调压变压器 |
| CB | 可投切电容器 |
| RES | 可再生能源机组 |
| Load | 负荷 |
| PCC | 公共耦合节点 |
| LSTM | 长短期记忆神经网络 |
| Sub*i* CA | 配电网区域 *i* 连续智能体 |
| Sub*i* DA | 配电网区域 *i* 离散智能体 |
| MG*i* CA | 微电网 *i* 连续智能体 |
| **参数** | |
| $T$ | 优化时长 |
| $N_{\mathrm{MG}}$ | 微电网总数 |
| $N_{\mathrm{MG}}^{\mathrm{MT}}, N_{\mathrm{ADN}}^{\mathrm{MT}}$ | 微电网/配电网燃气机组总数 |
| $N_{\mathrm{MG}}^{\mathrm{ESS}}, N_{\mathrm{ADN}}^{\mathrm{ESS}}$ | 微电网/配电网储能机组总数 |
| $N_{\mathrm{MG}}^{\mathrm{RES}}, N_{\mathrm{ADN}}^{\mathrm{RES}}$ | 微电网/配电网可再生能源机组总数 |
| $N_{\mathrm{ADN}}^{\mathrm{CB}}$ | 配电网可投切电容器总数 |
| $N_{\mathrm{ADN}}^{\mathrm{SVC}}$ | 配电网静止无功补偿器总数 |
| $a^{\mathrm{MT}}, b^{\mathrm{MT}}, c^{\mathrm{MT}}$ | 燃气机组成本系数 |
| $\rho$ | 储能机组的度电成本 |
| $\lambda_{\mathrm{IN}}^{\mathrm{B}}, \lambda_{\mathrm{IN}}^{\mathrm{S}}$ | 配-微电网有功购、售电价 |
| $\lambda_{\mathrm{EX}}^{\mathrm{B}'}, \lambda_{\mathrm{EX}}^{\mathrm{S}'}$ | 主-配电网有功购、售电价 |
| $S_{\max}^{\mathrm{RES}}$ | 可再生能源视在功率 |
| $P_{\min}^{\mathrm{MT}}, P_{\max}^{\mathrm{MT}}$ | 燃气机组有功出力最小、最大值 |
| $R_{\mathrm{down}}^{\mathrm{MT}}, R_{\mathrm{up}}^{\mathrm{MT}}$ | 燃气机组最大向下、向上爬坡功率 |
| $S_{\max}^{\mathrm{MT}}$ | 燃气机组最大视在功率 |
| $P_{\min}^{\mathrm{ESS}}, P_{\max}^{\mathrm{ESS}}$ | 储能机组有功充放电最小、最大值 |
| $soc_{\min}, soc_{\max}$ | 储能机组荷电量最小、最大值 |
| $\eta^{\mathrm{ch}}, \eta^{\mathrm{dis}}$ | 储能机组充、放电效率 |
| $E_{\max}^{\mathrm{ESS}}$ | 储能机组最大储电量 |
| $P_{\min}^{\mathrm{PCC}}, P_{\max}^{\mathrm{PCC}}$ | 配-微网间有功最小、最大值 |
| $S_{\max}^{\mathrm{PCC}}$ | 配-微网间视在功率 |
| $C^{\mathrm{oltc}}$ | 有载调压变压器成本系数 |
| $C^{\mathrm{cb}}$ | 可投切电容器成本系数 |
| $N_{\max}^{\mathrm{OLTC}}, N_{\max}^{\mathrm{CB}}$ | 有载调压变压器/可投切电容器动作次数上限 |
| **变量** | |
| $F_{\mathrm{MG}}, F_{\mathrm{ADN}}$ | 微电网/配电网总运行成本 |
| $F^{\mathrm{MT}}$ | 燃气机组运行成本 |
| $F^{\mathrm{ESS}}$ | 储能机组运行成本 |
| $F^{\mathrm{B\text{-}S}}$ | 微电网向配网购售电成本 |
| $F^{\mathrm{d}}$ | 离散设备动作总成本 |
| $F_t^1$ | 配电网向主网和微电网购售电总成本 |
| $P^{\mathrm{MT}}, Q^{\mathrm{MT}}$ | 燃气机组有功、无功出力 |

| | |
|---|---|
| $P^{\mathrm{ESS}}$ | 储能机组有功出力 |
| $P^{\mathrm{ch}}, P^{\mathrm{dis}}$ | 储能机组充、放电功率 |
| $P^{\mathrm{B}}, P^{\mathrm{S}}$ | 配-微网间有功购、售功率 |
| $P^{\mathrm{B}'}, P^{\mathrm{S}'}$ | 主-配网间有功购、售功率 |
| $P^{\mathrm{RES}}, Q^{\mathrm{RES}}$ | 可再生能源有功、无功出力 |
| $P^{\mathrm{Load}}, Q^{\mathrm{Load}}$ | 负荷有功、无功出力 |
| $E^{\mathrm{RES}}$ | 可再生能源预测误差 |
| $soc$ | 储能机组荷电量 |
| $P^{\mathrm{PCC}}, Q^{\mathrm{PCC}}$ | 配-微网间传输的有功、无功功率 |
| $T^{\mathrm{OLTC}}$ | 有载调压变压器档位 |
| $T^{\mathrm{CB}}$ | 可投切电容器档位 |
| $n^{\mathrm{OLTC}}, n^{\mathrm{CB}}$ | 有载调压变压器/可投切电容器是否动作 |
| $N^{\mathrm{OLTC}}, N^{\mathrm{CB}}$ | 有载调压变压器/可投切电容器已经动作次数 |
| $Q^{\mathrm{SVC}}$ | 静止无功补偿器无功输出功率 |
| $P_k, Q_k, V_k$ | 节点 $k$ 处净注入的有功、无功和电压幅值 |
| $I_{kl}$ | 支路 $kl$ 电流数值 |

## 附录 B

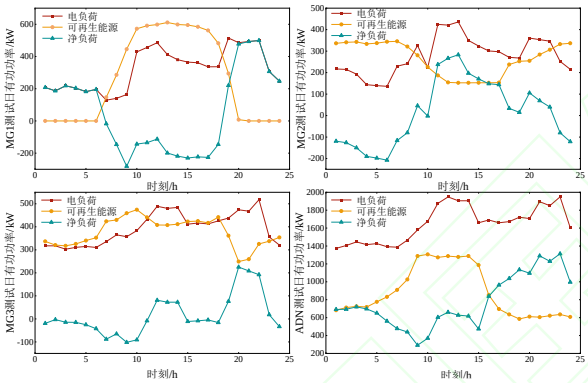



图 B1 可再生能源出力及负荷曲线

**Fig. B1 Renewable energy output and load curve**

作者简介：



董雷

董雷(1967)，女，教授，博士生导师，通信作者，主要从事电网优化调度与控制、综合能源系统优化、人工智能在电力系统中的应用等方面的研究工作；E-mail：hbdldl@126.com

李金龙(2000)，男，硕士研究生，研究方向为电力系统分析、运行与控制。E-mail：3491249884@qq.com