基于深度确定性策略梯度的主动配电网有功－无功协调优化调度

孙国强，殷岩岩，卫志农，臧海祥，楚云飞
（河海大学能源与电气学院，南京市 211100）

摘 要： 为了实现主动配电网（active distribution network，ADN）的有功－无功资源协调控制，提高配电系统供电可靠性及经济性，提出一种基于深度确定性策略梯度（deep deterministic policy gradient，DDPG）的 ADN 有功－无功协调优化调度策略。首先，在避免电压和潮流越限的情况下，以 ADN 日运行成本最小为目标，计及可投切电容器组、有载调压变压器、微型燃气轮机和能量储存系统构建 ADN 有功－无功协调调度模型。其次，将 ADN 实时调度问题转化成马尔科夫决策过程，并定义系统的状态空间、动作空间及奖励函数。然后，为提升深度确定性策略梯度的离线训练速度和奖励回报，在算法中加入优先经验回放（priority experience replay，PER）机制，并搭建了基于优先经验回放机制的深度确定性策略梯度（PER-DDPG）ADN 在线调度框架。最后，在修改的 IEEE-34 节点配电系统上进行仿真，算例结果表明，PER-DDPG 方法通过高效的经验学习，能够为 ADN 提供安全、经济的调度策略。

关键词： 主动配电网；有功无功协调优化；深度确定性策略梯度（DDPG）；在线调度框架；优先经验回放机制

Coordinated Optimal Dispatch of Active and Reactive Power in Active Distribution Networks Using Deep Deterministic Strategy Gradient

SUN Guoqiang，YIN Yanyan，WEI Zhinong，ZANG Haixiang，CHU Yunfei
（College of Energy and Electrical Engineering，Hohai University，Nanjing 211100，China）

ABSTRACT: To achieve coordinated control of active power and reactive power resources within the active distribution network（ADN）and enhance the reliability and cost-effectiveness of the distribution system's power supply，we propose an optimization strategy for ADN active power and reactive power coordination based on deep deterministic policy gradient（DDPG）scheduling. First and foremost，our approach focuses on minimizing the daily operating costs of the ADN while avoiding voltage and power flow exceeding their limits. It takes into account various factors，including switchable capacitor banks，on-load voltage regulating transformers，micro gas turbines，and energy storage systems. We establish a model for the coordinated dispatch of active and reactive power within the ADN. Next，we transform the real-time scheduling problem in the ADN into a Markov decision process，defining the state space，action space，and reward function for the system. To enhance the offline training speed and reward returns of the DDPG algorithm，we introduce a priority experience replay（PER）mechanism. This leads to the development of an online scheduling framework known as PER-DDPG for the ADN. Finally，we conduct simulations on the modified IEEE-34 node power distribution system. The results of these simulations demonstrate that the PER-DDPG method effectively provides a secure and cost-efficient dispatch strategy for the ADN，achieved through efficient empirical learning.

This work is supported by National Natural Science Foundation of China（No. U1966205）.

KEYWORDS: active distribution network；coordinated optimization of active and reactive power；depth deterministic policy gradient（DDPG）；online dispatch framework；priority experience playback mechanism

中图分类号： TM732 **文献标志码：** A **文章编号：** 1000－7229（2023）11－0033－10
DOI：10.12204/j.issn.1000－7229.2023.11.004

0 引 言

随着分布式电源（distributed generation，DG）在配电层面的广泛接入，配电系统正从无源网络演变为有源配电网络，即主动配电网（active distribution network，ADN）。同时，光伏发电（photovoltaic，PV）、风电（wind turbines，WT）的随机性和波动性增加了 ADN 的不确定性，导致电压、潮流越限等问题变得更加严重[1-2]。

目前，为了实现 ADN 的协调优化控制，国内外

基金项目：国家自然科学基金项目（U1966205）

学者已经提出诸多基于模型的优化方法。例如,文献[3]构建了ADN的混合整数非线性规划模型和等效混合整数二次约束模型,用于配电网中的电压管理。文献[4]将非线性潮流约束进行二阶锥松弛,从而将配电网经济运行优化模型转化为混合整数二阶锥规划问题,提高了求解精度。进一步,考虑到DG不确定性因素对配电网运行的影响,文献[5]中构建了基于随机规划的多阶段调度模型,验证了该模型能在随机状态下自适应调整储能装置、换流站及需求响应决策。然而,随机规划需获取不确定变量的概率分布参数[6],并采用大量场景刻画不确定信息,导致准确性和求解效率偏低[7-8]。为了消除ADN优化配置模型中DG相关的不确定性变量,文献[9]构建了鲁棒优化框架,并采用渐紧线切割算法和列和约束生成算法相结合的方法对转化模型求解,缩小了凸松弛间隙,提高了模型求解效率。文献[10]计及新能源的预测误差,基于离散不确定性域改进了现有鲁棒优化方法,从而获得了更广泛的"恶劣场景集"。上述鲁棒优化方法无需获取不确定性量的概率分布,而是通过不确定性集来描述DG出力的不确定性,形式简洁。但由于其在不确定性集的最恶劣实现情况下做出决策,因此可能导致优化结果过于保守[11-13]。

基于模型的方法在ADN协调优化控制方面取得了广泛的成效。然而,此方法依赖于完整且明确的配电网物理模型,需要获取详细的网络拓扑、线路参数、负荷功率等信息[14-15]。然而这些信息在现实获得过程中经常有所缺失、准确性低。如果参数和物理模型不准确,将会导致不经济甚至不切实际的调度决策[16]。此外,基于模型的方法计算复杂度高、存在维度灾等问题,这使得模型计算十分耗时,难以实现在ADN中进行实时优化控制[17]。

近年来,深度强化学习(deep reinforcement learning, DRL)以其在线响应快、无需对DG的随机性分布建模的独特优势[18-19],在电力系统领域获得了广泛关注。文献[20]将能量储存系统(energy storage systems, ESS)考虑到配电网的电压控制中,并采用Q深度神经网络来逼近ESS的最佳动作价值。文献[21]提出了一种基于深度Q网络的有功安全校正策略,在消除线路过载和调节机组出力上具有良好的效果,但需要对连续动作空间离散化,可能会带来维度灾难问题[22]。为了使DRL智能体学习连续状态和动作空间之间的映射关系,文献[23]将深度确定性策略梯度(deep deterministic policy gradient, DDPG)方法应用到综合能源经济调度中。针对电压控制问题,文献[24]基于多智能体的DDPG算法协调优化光伏逆变器的无功功率输出,但未考虑无功-电压控制设备,如可投切电容器组(switchable capacitor banks, SCB)、有载调压变压器(on-load tap-changers, OLTC)等。针对配电系统优化控制问题,上述文献侧重于关注单一有功或无功资源控制,这在保证配电系统供电安全和降低运行成本方面存在一定局限性。此外,传统DDPG方法中的经验回放机制忽略了不同经验的重要程度,可能存在训练效率低、过度学习等问题[25]。另一方面,优先经验回放(priority experience replay, PER)机制在机器人控制和游戏任务中的应用取得了巨大成功,提高了学习效率和策略稳定性[26]。

基于此,本文将PER机制结合到DDPG方法中,构建了一种基于PER-DDPG的ADN在线调度框架。首先,以ADN日运行成本最小为目标,在计及节点电压偏移和潮流越限约束的基础上,协调SCB、OLTC、微型燃气轮机(micro-gas turbines, MT)和ESS等有功/无功资源,构建了ADN有功-无功协调调度模型。其次,将此模型转化为马尔科夫决策过程(Markov decision process, MDP),并基于PER-DDPG框架进行离线训练及在线测试。仿真结果表明,相较于传统的DDPG方法,本文所提出的基于优先经验重放的DPPG方法可以实现对连续动作空间的精确控制,并通过高效的经验学习以获得安全、经济的动作策略。本文研究有望为基于深度确定性策略梯度的有功-无功协调优化调度提供技术参考。

1 ADN有功-无功协调调度强化学习建模

本节首先构建了基于ADN的有功-无功协调调度数学模型。在计及潮流约束和配电网安全约束的基础上,该模型旨在以ADN日运行成本最小为目标,在不同时段协调各有功/无功资源的出力。然后,本节将此数学模型转化成基于MDP的调度模型,以充分利用DRL自适应源荷不确定性的优势进行求解。

1.1 基于ADN的有功-无功协调调度数学模型

1.1.1 目标函数

本文的目标函数包括变电站的能源交易成本和MT的燃料成本:

$$\begin{cases} \min f = \sum C_t^{\text{grid}} + C_t^{\text{mt}},\ t \in \Omega_{\text{t}} \\ C_t^{\text{grid}} = \begin{cases} \sigma_t^{\text{buy}} P_t^{\text{grid}} \Delta t,\ P_t^{\text{grid}} < 0,\ t \in \Omega_{\text{t}} \\ \sigma_t^{\text{sell}} P_t^{\text{grid}} \Delta t,\ P_t^{\text{grid}} > 0,\ t \in \Omega_{\text{t}} \end{cases} \\ C_t^{\text{mt}} = \sum \left[a_i^{\text{mt}} \left(P_{i,t}^{\text{mt}} \right)^2 + b_i^{\text{mt}} P_{i,t}^{\text{mt}} + c_i^{\text{mt}} \right] \Delta t, \\ i \in \Omega_{\text{bus}},\ t \in \Omega_{\text{t}} \end{cases} \tag{1}$$

式中: t 为时段; C_t^{grid} 和 C_t^{mt} 分别为 t 时段变电站的交易成本和 MT 的燃料成本; Ω_{t} 为时段的集合; Ω_{bus} 为 ADN 的节点集合; P_t^{grid} 为变电站与输电网络交互的有功功率，当 $P_t^{\mathrm{grid}} < 0$ 时，ADN 从输电网络购买电力，购买电力价格为 σ_t^{buy}，当 $P_t^{\mathrm{grid}} > 0$ 时，ADN 能量充足，向上级电网售卖电力，售卖价格为 σ_t^{sell}; $P_{i,t}^{\mathrm{mt}}$ 为 MT 在节点 i 的有功功率; a_i^{mt}、b_i^{mt} 和 c_i^{mt} 分别为 MT 发电的二次成本系数、线性成本系数和固定成本系数。

1.1.2　约束条件

1.1.2.1　潮流约束

$$\begin{cases} P_{j,t}^{\mathrm{pv}} + P_{j,t}^{\mathrm{wt}} + P_{j,t}^{\mathrm{ess}} + P_{j,t}^{\mathrm{mt}} - P_{j,t}^{\mathrm{l}} = \sum\limits_{k\in j} P_{jk,t} - \\ \sum\limits_{i\in j}\left(P_{ij,t} - r_{ij}\tilde{I}_{ij,t}\right) + g_{ij}\tilde{U}_{i,t},\ i,j\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \\ Q_{j,t}^{\mathrm{scb}} + Q_{j,t}^{\mathrm{mt}} - Q_{j,t}^{\mathrm{l}} = \sum\limits_{k\in j} Q_{jk,t} - \\ \sum\limits_{i\in j}\left(Q_{ij,t} - x_{ij}\tilde{I}_{ij,t}\right) + b_{ij}\tilde{U}_{i,t},\ i,j\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \end{cases} \tag{2}$$

$$\tilde{U}_{j,t} = \tilde{U}_{i,t} - 2\left(P_{ij,t}r_{ij,t} + Q_{ij,t}x_{ij}\right) + \tilde{I}_{ij,t}\left(r_{ij}^2 + x_{ij}^2\right),\ ij\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \tag{3}$$

$$\left\| \begin{matrix} 2P_{ij,t} \\ 2Q_{ij,t} \\ \tilde{I}_{ij,t} - \tilde{U}_{i,t} \end{matrix} \right\|_2 \leqslant \tilde{I}_{ij,t} + \tilde{U}_{i,t},\ ij\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \tag{4}$$

式中: $P_{j,t}^{\mathrm{pv}}$、$P_{j,t}^{\mathrm{wt}}$、$P_{j,t}^{\mathrm{ess}}$ 和 $P_{j,t}^{\mathrm{l}}$ 分别为 PV、WT、ESS 和负荷注入节点 j 的有功功率; $Q_{j,t}^{\mathrm{scb}}$、$Q_{j,t}^{\mathrm{mt}}$ 和 $Q_{j,t}^{\mathrm{l}}$ 分别为 SCB、MT 和负荷注入节点 j 的无功功率; $P_{ij,t}$ 和 $Q_{ij,t}$ 分别为从节点 i 注入节点 j 的有功及无功功率; r_{ij} 和 x_{ij} 分别为节点 i 与节点 j 之间的电阻和电抗; g_{ij} 和 b_{ij} 分别为节点 i 与节点 j 之间的电导和电纳; $\tilde{I}_{ij,t}$ 和 $\tilde{U}_{i,t}$ 分别为支路电流和节点电压幅值的平方。式(2)为功率平衡约束; 式(3)为支路电压降落约束; 式(4)为基于二阶锥松弛的支路容量约束。

1.1.2.2　配电网安全约束

$$\underline{U}_i \leqslant U_{i,t} \leqslant \bar{U}_i,\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \tag{5}$$

式中: $U_{i,t}$ 为节点 i 的电压幅值; $\bar{U}_i$ 和 $\underline{U}_i$ 分别为节点电压的最大最小限值。

1.1.2.3　可控设备运行约束

1) SCB 运行约束:

$$0 \leqslant n_{i,t}^{\mathrm{scb}} \leqslant \bar{n}_i^{\mathrm{scb}},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \tag{6}$$

式中: $n_{i,t}^{\mathrm{scb}}$ 为节点 i 可控制运行的 SCB 数量; $\bar{n}_i^{\mathrm{scb}}$ 为 SCB 的最大可运行单元数; $n_{i,t}^{\mathrm{scb}}$ 为 0 到 $\bar{n}_i^{\mathrm{scb}}$ 范围内的任意整数值; SCB 注入节点的无功功率 $Q_{i,t}^{\mathrm{scb}}$ 由所在节点的连接数量和节点电压决定。

2) OLTC 运行约束:

$$-\bar{l}_{ij}^{\mathrm{oltc}} \leqslant l_{ij,t}^{\mathrm{oltc}} \leqslant \bar{l}_{ij}^{\mathrm{oltc}},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \tag{7}$$

式中: $l_{ij,t}^{\mathrm{oltc}}$ 为节点 i、j 间的 OLTC 的分接头位置; $\bar{l}_{ij}^{\mathrm{oltc}}$ 为 OLTC 的最大向上/向下分接头位置; $l_{ij,t}^{\mathrm{oltc}}$ 为 $-\bar{l}_{ij}^{\mathrm{oltc}}$ 到 $\bar{l}_{ij}^{\mathrm{oltc}}$ 的任意整数值。

3) MT 运行约束:

$$\begin{cases} 0 \leqslant P_{i,t}^{\mathrm{mt}} \leqslant \theta_i^{\mathrm{mt}} \cdot \bar{S}_i^{\mathrm{mt}},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \\ \theta_i^{\mathrm{mt}} \leqslant \cos\left[\tan^{-1}\left(Q_{i,t}^{\mathrm{mt}}/P_{i,t}^{\mathrm{mt}}\right)\right] \leqslant 1, \\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \end{cases} \tag{8}$$

式中: $Q_{i,t}^{\mathrm{mt}}$ 为节点 i 的无功功率; $\bar{S}_i^{\mathrm{mt}}$ 为 MT 的视在功率; θ_i^{mt} 为 MT 运行的最小功率因数。MT 的可控变量分别为 $P_{i,t}^{\mathrm{mt}}$ 和 $Q_{i,t}^{\mathrm{mt}}$。

4) ESS 运行约束:

$$\begin{cases} -\bar{P}_{i,\mathrm{dch}}^{\mathrm{ess}} \leqslant P_{i,t}^{\mathrm{ess}} \leqslant \bar{P}_{i,\mathrm{ch}}^{\mathrm{ess}},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \\ \underline{E}_i^{\mathrm{ess}} \leqslant E_{i,t}^{\mathrm{ess}} \leqslant \bar{E}_i^{\mathrm{ess}},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \\ S_{\mathrm{OC}\ i,t+1} = S_{\mathrm{OC}\ i,t} + \eta^{\mathrm{ess}}P_{i,t}^{\mathrm{ess}}\Delta t/\bar{E}_i^{\mathrm{ess}}, \\ P_{i,t}^{\mathrm{ess}} \geqslant 0,\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \\ S_{\mathrm{OC}\ i,t+1} = S_{\mathrm{OC}\ i,t} + P_{i,t}^{\mathrm{ess}}\Delta t/\eta^{\mathrm{ess}}\bar{E}_i^{\mathrm{ess}}, \\ P_{i,t}^{\mathrm{ess}} < 0,\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \end{cases} \tag{9}$$

式中: 当 $P_{i,t}^{\mathrm{ess}} < 0$ 时，ESS 进行充电，当 $P_{i,t}^{\mathrm{ess}} \geqslant 0$ 时，ESS 进行放电; $\bar{P}_{i,\mathrm{dch}}^{\mathrm{ess}}$ 和 $\bar{P}_{i,\mathrm{ch}}^{\mathrm{ess}}$ 分别为 ESS 的最大放电及充电功率; $E_{i,t}^{\mathrm{ess}}$ 为 ESS 的剩余电量; $\underline{E}_i^{\mathrm{ess}}$ 和 $\bar{E}_i^{\mathrm{ess}}$ 分别为 ESS 的最小和最大储存电量; $S_{\mathrm{OC}\ i,t}$ 为 ESS 的荷电状态; η^{ess} 为 ESS 的充放电效率系数。

1.2　基于 MDP 的调度模型

本节将 ADN 有功－无功协调优化调度问题建模为 MDP。MDP 通常由学习环境 E、状态空间 S、动作空间 A 和奖励空间 R 组成。在每个时段 t，DRL 智能体通过观察 ADN 当前的状态 $s_t\in S$，执行动作 $a_t\in A$，并从环境 E 中获得奖励值 $r_t\in R$，然后 ADN 的当前状态 s_t 将根据状态转移概率函数 $p(s_{t+1}\mid s_t, a_t)$ 转换到下一状态 s_{t+1}。直至 t 达到总调度时段 T 时，此过程终止。t 时段 MDP 的详细制定描述如下。

1.2.1　状态空间

$$\begin{aligned} s_t = \{ & t, S_{\mathrm{OC}i,t}, \sigma_{t-T}, \cdots, \sigma_{t-1}, P_{i,t-T}^{\mathrm{pv}}, \cdots, \\ & P_{i,t-1}^{\mathrm{pv}}, P_{i,t-T}^{\mathrm{wt}}, \cdots, P_{i,t-1}^{\mathrm{wt}}, P_{i,t-T}^{\mathrm{l}}, \cdots, P_{i,t-1}^{\mathrm{l}}, \\ & Q_{i,t-T}^{\mathrm{l}}, \cdots, Q_{i,t-1}^{\mathrm{l}} \},\ i\in\Omega_{\mathrm{bus}},\ t\in\Omega_{\mathrm{t}} \end{aligned} \tag{10}$$

状态空间包括当前时段、ESS 的荷电状态、过去 T 个时段内的电价、过去 T 个时段内 PV、WT 的有功

功率和过去 T 个时段内负荷的有功无功功率; 状态空间中的各个变量都是连续性变量; 为充分利用新能源,本文假设 PV 和 WT 是不可调度资源,并以固定单位功率因数运行[27],故在状态空间中不考虑新能源无功功率。

1.2.2 动作空间

$$a_t = \left(n_{i,t}^{\mathrm{scb}}, l_{ij,t}^{\mathrm{oltc}}, P_{i,t}^{\mathrm{mt}}, Q_{i,t}^{\mathrm{mt}}, P_{i,t}^{\mathrm{ess}}\right),\ i,j \in \Omega_{\mathrm{bus}},\ t \in \Omega_{\mathrm{t}} \tag{11}$$

动作空间包括 SCB 的运行组数、OLTC 的分接头位置、MT 的有功无功功率和 ESS 的充放电功率; $n_{i,t}^{\mathrm{scb}}$ 和 $l_{ij,t}^{\mathrm{oltc}}$ 属于离散动作, $P_{i,t}^{\mathrm{mt}}$、$Q_{i,t}^{\mathrm{mt}}$ 和 $P_{i,t}^{\mathrm{ess}}$ 属于连续动作。

1.2.3 奖励函数

1.2.3.1 日运营成本项

本文构建的优化目标函数旨在将 ADN 日运行成本最小,主要包括变电站与上级电网的交易成本以及 MT 的发电成本。DRL 智能体的学习目标是未来折扣奖励最大化,因此本文选取 ADN 日运行成本的相反数作为奖励函数的第一部分,即 r_t^1。智能体得到的奖励越大,ADN 日运行成本越小。具体地, r_t^1 如下所示:

$$r_t^1 = -C_t^{\mathrm{grid}} - C_t^{\mathrm{mt}},\ t \in \Omega_{\mathrm{t}} \tag{12}$$

式中: C_t^{grid} 和 C_t^{mt} 分别为变电站的交易成本和 MT 的燃料成本。

1.2.3.2 约束违反项

鉴于 ADN 安全运行的重要性,奖励函数中还应当考虑电压违反和潮流越限的风险。因此,本文采用惩罚机制,对电压违反和潮流越限进行惩罚。

1) 电压违反惩罚项:

$$\begin{cases} r_t^2 = -C_t^{\mathrm{v}},\ t \in \Omega_{\mathrm{t}} \\ C_t^{\mathrm{v}} = \sum \eta_{\mathrm{v}} \cdot \left[\max\left(0, U_{i,t} - \bar{U}_i\right) + \max\left(0, \underline{U}_i - U_{i,t}\right)\right],\ i \in \Omega_{\mathrm{bus}},\ t \in \Omega_{\mathrm{t}} \end{cases} \tag{13}$$

式中: r_t^2 为奖励函数的第二部分,表示电压违反时的惩罚量,应为负值; η_{v} 为电压过高或过低的惩罚系数。

2) 潮流越限惩罚项:

$$r_t^3 = \begin{cases} -C_t^{\mathrm{s}}, & \varepsilon_{\mathrm{s}} = 0 \\ 0, & \varepsilon_{\mathrm{s}} = 1 \end{cases},\ t \in \Omega_{\mathrm{t}} \tag{14}$$

式中: r_t^3 为奖励函数的第三部分,旨在确保 ADN 的潮流计算收敛; C_t^{s} 为一个正常数; ε_{s} 为判断潮流计算是否收敛的因子,当 $\varepsilon_{\mathrm{s}} = 1$ 时,表示潮流计算收敛,当 $\varepsilon_{\mathrm{s}} = 0$ 时,表示潮流计算发散。

综上,奖励函数定义如下:

$$r_t = r_t^1 + r_t^2 + r_t^3 = \begin{cases} -C_t^{\mathrm{grid}} - C_t^{\mathrm{mt}} - C_t^{\mathrm{v}}, & \varepsilon_{\mathrm{s}} = 1 \\ -C_t^{\mathrm{s}}, & \varepsilon_{\mathrm{s}} = 0 \end{cases},\ t \in \Omega_{\mathrm{t}} \tag{15}$$

式(15)表明,当潮流计算收敛时,奖励函数的主要目标是使 ADN 的日运营成本最小,同时避免电压违反。当潮流计算发散时,智能体将会受到一个较大的惩罚值。

1.2.4 状态动作价值函数

为了在不同状态下获得最优动作,需要使用状态 - 动作价值函数 $Q^{\pi}(s_t, a_t; \theta)$ 来描述在当前状态 s_t 下执行动作 a_t,并遵循策略 π 后所能带来的预期奖励,该策略由一组网络参数 θ 来控制。状态 - 动作价值函数如下式所示:

$$Q^{\pi}(s_t, a_t; \theta) = E\left(\sum_{\tau=t}^{T} \gamma^{(\tau-t)} r_\tau \mid s_t, a_t\right) \tag{16}$$

式中: π 为从综合状态映射到调度计划的策略,智能体在状态 s_t 选择何种动作 a_t 由策略 $\pi(s_t) = a_t$ 决定; γ 为折扣因子,用来平衡未来奖励和即时奖励, $\gamma \in [0,1]$; $E(\cdot)$ 为数学期望。

在 ADN 调度问题中,DRL 智能体的目标是在与环境的不断交互过程中找到最优策略 π^*,使 ADN 日运行成本最低。这个最优策略可以通过最大化状态 - 动作价值函数来实现:

$$Q^{\pi^*}(s_t, a_t; \theta) = \max_{\pi} Q^{\pi}(s_t, a_t; \theta) \tag{17}$$

式中: $Q^{\pi^*}(s_t, a_t; \theta)$ 为最优状态 - 动作价值函数。

2 基于 DDPG 的 ADN 有功 - 无功协调调度

2.1 PER-DDPG 学习框架

为有效解决 ADN 有功 - 无功协调优化中存在的连续动作空间问题,本文构建了基于 PER-DDPG 算法的 ADN 在线调度框架,如图 1 所示,该框架中的 DDPG 智能体由 Actor 网络和 Critic 网络组成,每个网络都有自己的目标网络以提高算法的稳定性。为了提高智能体的采样效率,该框架引入了优先级经验缓冲区 B。在训练过程中,智能体与 ADN 环境交互并收集若干组经验单元 $e_t = \{s_t, a_t, r_t, s_{t+1}\}$,然后根据优先级 p_t 对经验单元进行重要性采样。p_t 值越大,相应经验单元的重要性越高,智能体从中学到经验越多。

本文在文献[25]的基础上,对 p_t 计算公式进行改进:

$$p_t = |\delta_t| + \varepsilon \tag{18}$$

式中: δ_t 为时间差分(temporal difference, TD)误差;

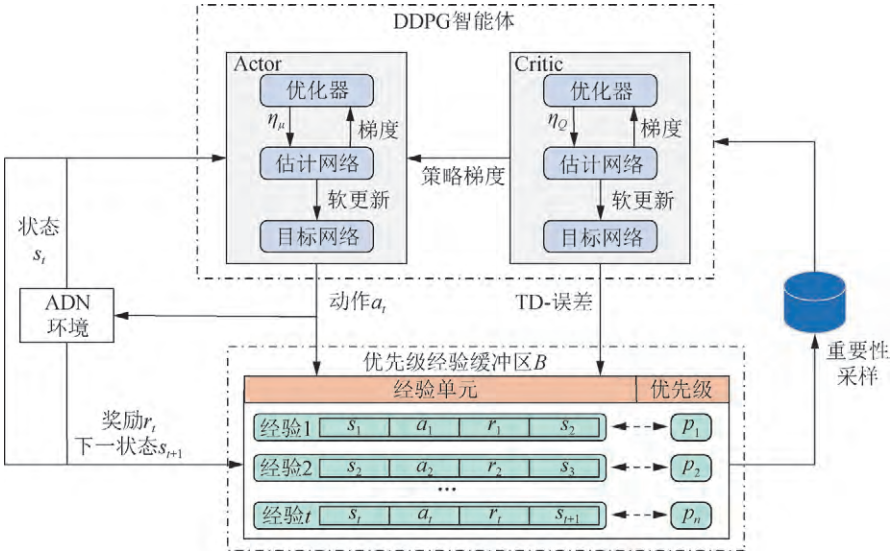


图 1　PER-DDPG 算法学习框架

Fig. 1　Learning framework of PER-DDPG algorithm

ε 为较小正常数，用以确保每个经验单元即使 TD-误差为零时仍有一定概率被抽样。

在常规方法中，智能体往往更倾向于重放 p_t 值较高的经验单元，这可能会改变状态访问频率，导致神经网络的训练过程出现振荡或发散。针对上述问题，本文使用了重要性采样权重来计算每个经验单元对于权重变化的贡献：

$$w_i = \frac{(B_{\text{size}} \cdot p_i)^{-\kappa}}{\max_{j<t} w_j} \tag{19}$$

式中：w_i 为第 i 个经验单元所占权重；p_i 为第 i 个经验单元的优先级；B_{size} 为经验缓冲区的大小；$\kappa \in [0, 1]$。

接下来详细介绍 Critic 网络和 Actor 网络在离线训练阶段的更新过程：

1) Critic 网络。

在训练过程中，Critic 网络使用具有参数 θ_Q 的深度神经网络来估计状态－动作价值函数。智能体根据经验优先级对一小批经验单元进行抽样，在每次抽样中，Critic 网络试图最小化以下损失函数：

$$L(\theta_Q) = E_{e_t \sim B}[w_t \cdot \delta_t^2(s_t, a_t; \theta_Q)] \tag{20}$$

$$\delta_t(s_t, a_t; \theta_Q) = r_t + \gamma \max_{a_{t+1}} Q^{\pi}(s_{t+1}, a_{t+1}; \theta_Q^-) - Q^{\pi}(s_t, a_t; \theta_Q) \tag{21}$$

式中：θ_Q^- 为目标网络中的旧参数。

为进一步提高训练过程的稳定性，目标网络参数遵循 $\theta_Q^- \leftarrow \nu\theta_Q + (1-\tau)\theta_Q^-$ 定期软更新，ν 为软更新率，$\nu \in [0, 1]$。优化器使用梯度下降法更新估计网络中的参数：

$$\theta_Q \leftarrow \theta_Q - \eta_Q w_t \delta_t(s_t, a_t; \theta_Q) \nabla_{\theta_Q} Q(s_t, a_t; \theta_Q) \tag{22}$$

式中：η_Q 为 Critic 网络的学习率；∇为梯度计算函数。

2) Actor 网络。

在训练过程中，Actor 网络用于学习动作策略和执行动作。Actor 网络中的参数化函数 $\mu(s_t; \theta_\mu)$ 可以确定性地将状态映射到特定动作来指定当前策略。动作策略定义的目标如下：

$$J(\theta_\mu) = E_{s_t \sim B}[Q^{\pi}(s_t, \mu(s_t; \theta_\mu); \theta_Q)] \tag{23}$$

确定性策略梯度使动作策略向状态－动作价值函数的梯度方向移动，即网络参数 θ_μ 按比例向 $\nabla_{\theta_\mu} Q^{\pi}(s_t, \mu(s_t; \theta_\mu); \theta_Q)$ 更新。通过链式规则可以分为如下两个部分，首先计算采样的策略梯度：

$$\nabla_{\theta_\mu} J = E_{s_t}[\nabla_{\theta_\mu} \mu(s_t; \theta_\mu) \nabla_{a_t} Q^{\pi}(s_t, a_t; \theta_Q)|_{a_t = \mu(s_t; \theta_\mu)}] \tag{24}$$

其次，基于动作参数 θ_μ 更新：

$$\theta_\mu \leftarrow \theta_\mu + \eta_\mu \nabla_{\theta_\mu} J \tag{25}$$

式中：η_μ 为 Actor 网络的学习率。

2.2　离线训练过程

本文所提 PER-DDPG 方法的离线训练过程如图 2 所示。在每一轮训练中：首先，DDPG 智能体的 Actor 网络根据参数化函数 $\mu(s_t; \theta_\mu) + \Delta\mu_t$ 制定 SCB、OLTC、MT 和 ESS 有功/无功资源的调度策略，$\Delta\mu_t$ 为随机噪声。然后，智能体在当前状态 s_t 下执行动作 a_t，经潮流计算后获得奖励 r_t，并观察到新的状态 s_{t+1}，历史样本通过上述交互被收集存储在经验缓冲区中的经验单元 e_t。最后，智能体根据优先经验回放机制对经验单元进行小批量采样，并更新 Actor 和 Critic 估计网络和目标网络参数。当 t 达到 T 时，一个训练集结束。重复以上步骤，直到训练集数达到最大训练集 $u_{\max}$，离线训练过程结束，保存此时最优的神经网络模型。

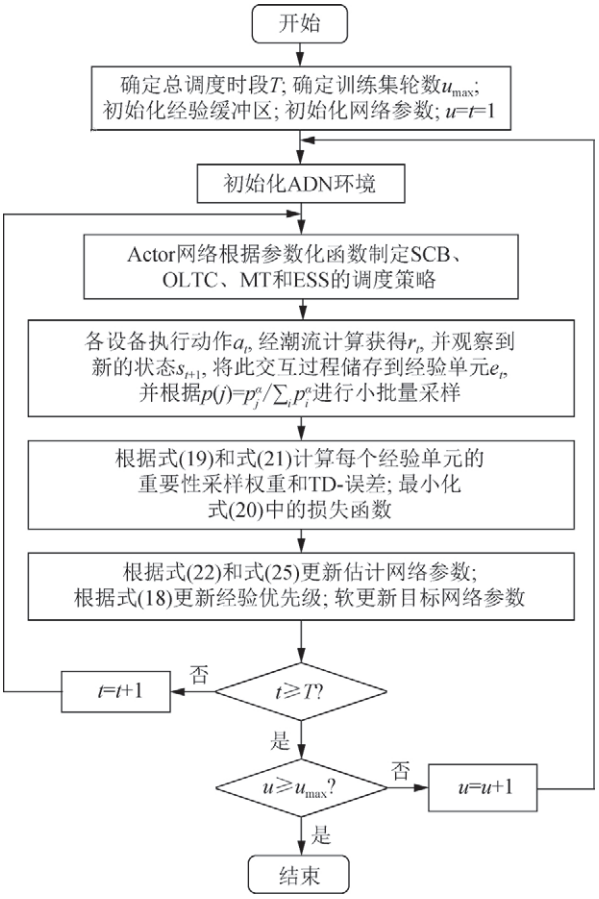


图 2 PER-DDPG 算法流程

Fig. 2 Flow chart of PER-DDPG algorithm

3 算例分析

3.1 算例设置

为了验证所提 PER-DDPG 方法在 ADN 有功－无功协调优化调度的有效性，本文采用如图 3 所示修改的 IEEE-34 节点配电算例[27]进行仿真验证。该配电系统接入了 2 个 MT、1 个 ESS、3 组 PV 和 3 台 WT，各设备参数详见表 1。在节点 7、8 之间以及节点 19、20 之间分别接入 2 个 OLTC，均具有 33 档调节位置，调节范围在 －10% ～10% 之间。2 个 SCB 分别安装在节点 24 和节点 34，每个 SCB 共有 4 组运行单元，每组运行单元的无功功率为 120 kvar。变电站的容量为 2 500 kVA。配电网节点电压的限制范围为0.95 ～ 1.05 pu。为了获取配电网电价、各节点负荷需求和新能源有功及无功功率数据，本文基于加州 ISO 开放存取同步信息系统时间序列数据[28]进行分析，并以 1 h 为时间段提取 2018—2020 三年的数据信息。其中，将 2018—2019 年的数据作为训练集，2020 年的数据作为测试集，用以验证所提方法在 ADN 有功－无功协调优化调度问题上的有效性。总调度时段 T 为 24 h。

本文采用 Python 中 Tensorflow 2.2.0 实现所提

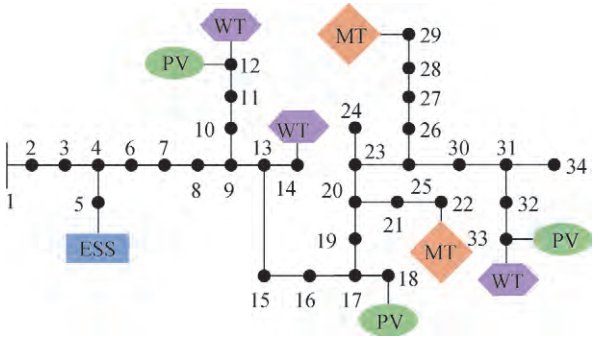


图 3 修改后的 IEEE-34 节点标准配电系统

Fig. 3 Modified IEEE-34 Node Standard Power Distribution System

表 1 各设备参数

Table 1 Parameters of each equipment

设备	参数		数值
MT	$\bar{S}_i^{mt}$/kVA	节点 22	625
		节点 29	825
	θ_i^{mt}	节点 22	0.8
		节点 29	0.8
	a_i^{mt}/[元/(kWh)^2]	节点 22	0.715
		节点 29	0.715
	b_i^{mt}/[元/kWh]	节点 22	0.518
		节点 29	0.369
	c_i^{mt}/元	节点 22	3.583
		节点 29	3.300
ESS	$\bar{E}_i^{ess}$/kWh	节点 5	2 000
	$\underline{E}_i^{ess}$/kWh	节点 5	200
	$\bar{P}_{i,ch}^{ess}$/kW	节点 5	500
	$\bar{P}_{i,dch}^{ess}$/kW	节点 5	500
	η_{ess}	节点 5	0.98
PV	有功功率峰值/kW	节点 12	100
		节点 18	100
		节点 33	100
WT	有功功率峰值/kW	节点 12	100
		节点 14	100
		节点 33	100

算法，并基于 OpenAI Gym 标准搭建了 ADN 有功－无功协调优化调度学习环境。同时，为了进行潮流计算判断收敛性，本文依赖电力系统分析包 Pandapower。所有的算例仿真都在 Intel(R) Core(TM) i7-11800H 处理器 2.30 GHz 的工作站上进行。

3.2 离线训练

本文所提 PER-DDPG 方法的详细参数设置如表 2 所示。在本文所建立的 MDP 中，动作空间同时存在连续和离散动作。然而 PER-DDPG 方法只能处理连续动作空间。因此在智能体离线训练之前，本文对

离散动作进行了连续化处理，将离散－连续混合动作空间转化成连续动作空间。在使用 PER-DDPG 方法进行训练后，本文再将 OLTC 和 SCB 的连续动作值舍入到最近的整数值。

表 2　所提方法参数设置
Table 2　Parameter settings of the proposed method

参数	数值
电压惩罚系数 η_v	500
潮流发散惩罚 C_t^s	200
折扣因子 γ	0.95
Critic 网络的学习率 η_Q	0.001
Actor 网络的学习率 η_μ	0.0001
计算重要性采样指数 κ	0.4
软更新参数 τ	0.001
经验缓冲区的大小 B_{size}	10 000
决定训练案例数量的 mini-batch 大小	128

由于 PER 机制可以从本文提出的方法中单独分离，因此本文将所提 PER-DDPG 方法与 DDPG 方法进行比较。表 3 展示了不同方法在离线训练和在线测试（迭代一次）上的平均耗时对比。本文对每种方法使用不同的随机种子运行 5 次，每次离线训练的最大迭代次数为 10^6。结果表明，两种 DRL 方法均能实现秒级在线求解，实现 ADN 有功－无功协调优化在线调度策略。与 DDPG 方法相比，本文所提 PER-DDPG 方法的离线训练时间和在线测试时间更短，计算资源损耗更小。

表 3　不同算法的离线训练和在线测试时间对比
Table 3　Comparison of offline training and online testing time of different algorithms

方法	离线训练时间/h	在线测试时间/s
DDPG	4.571	0.180
PER-DDPG	3.265	0.174

本文进一步比较了所提 PER-DDPG 方法和 DDPG 方法在不同随机种子情况下的训练过程性能，如图 4 所示。实线代表各 DRL 智能体的平均奖励值，阴影部分代表奖励值的波动范围。通过图 4 可以看出，在智能体与 ADN 环境的交互学习过程中，PER-DDPG 方法和 DDPG 方法的奖励值逐步增加，并最终均可收敛到一个稳定值，表明两种方法均可通过学习获得使 ADN 日运行成本最小的经济调度策略。其中，PER-DDPG 方法迭代到约 2×10^5 次时出现了一定振荡，这属于训练早期智能体探索 ADN 环境的正常行为，并不影响其总体收敛性。值得注意的是，PER-DDPG 方法迭代到约 5.7×10^4 次时获得奖励值－19 500，而 DDPG 方法需要迭代到约 17.1×10^4 次时才能得到相同的奖励值。因此，本文所提 PER-DDPG 方法的智能体能够快速学习到成功样本，积累得到一定的成功经验，从而更迅速学到 ADN 有功－无功协调调度策略。此外，基于 PER-DDPG 方法的最终收敛稳定奖励值为－9 500，而 DDPG 方法的最终稳定奖励值相对较低，为－10 500。因此，本文所提出的 PER-DDPG 方法具有更快的收敛速度，未来折扣奖励回报相较 DDPG 方法提升了 9.52%。

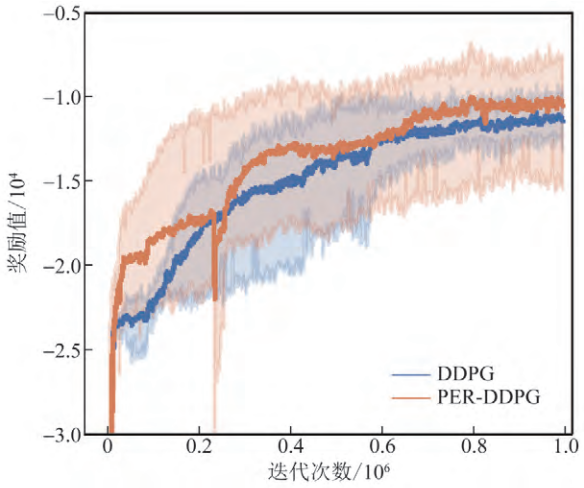


图 4　不同算法下的训练过程
Fig. 4　Training process under different algorithms

3.3　在线测试表现

在实验交互过程达到所设置的最大迭代次数后，离线训练过程完成，本文保存此时训练完成的最优神经网络模型，并在测试集上进行测试。如图 5 所示，测试集中 PER-DDPG 方法和 DDPG 方法的累积运行成本分别为 243.07 万元和 396.27 万元。结果表明，PER-DDPG 方法在一年内能够降低 38.66% 的 ADN 运行成本，相比之下，DDPG 方法效果较为有限。

本文所提 PER-DDPG 智能体在测试集中某天的调度决策结果如图 6 所示。

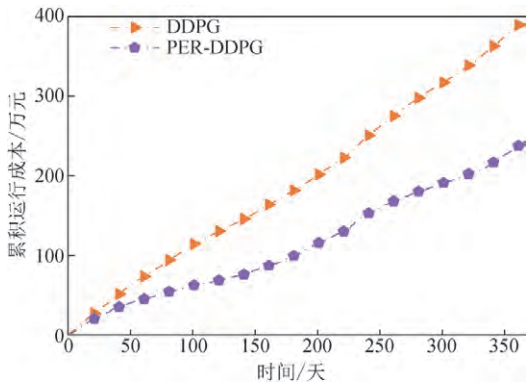


图 5　不同算法下测试过程的累计成本
Fig. 5　Cumulative cost of testing process under different algorithms

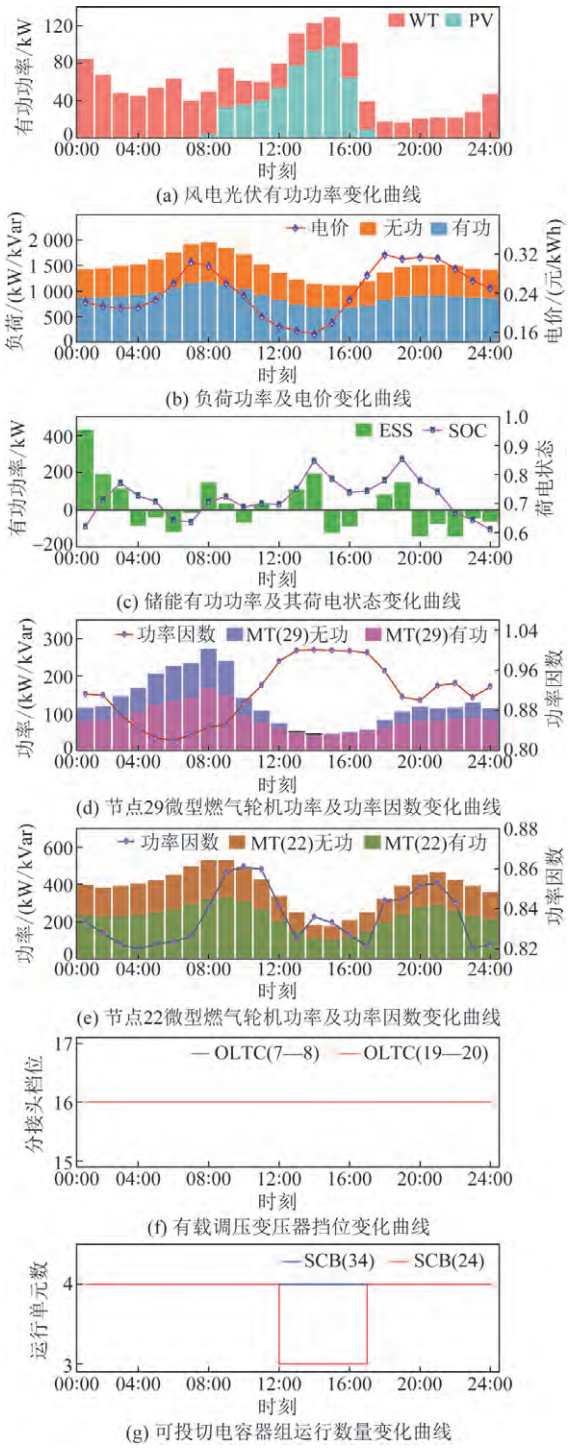


图6 测试集中某天的运行调度结果

Fig. 6 The results of the running schedule for a day in the test set

图6(a)展示了当天WT和PV的有功功率输出变化。图6(b)展示了负荷有功无功功率需求以及电价变化情况。由图6(c)可知,智能体在低电价时段调度ESS进行充电以储存能量;而在高电价时段,智能体调度ESS进行放电以满足负荷运行需求,从而降低配变功率峰谷差。由图6(d)—(e)可知,两个MT的功率因数被限制在0.8以上,智能体根据当前电价和ADN负荷需求动态地调整MT的发电量。当负荷需求减少或电价下降时,智能体调度MT减小发电量以避免过剩的电力浪费;而当负荷需求增多或电价上涨时,智能体调度MT增大发电量以缓解ADN的运行压力。在08:00—16:00之间,风电和光伏的总有功功率较大,ESS进行充电且MT减少输出功率,以就地消纳新能源,减少功率倒送。通过上述调度方式,一定程度上减小了新能源随机性对配电系统的干扰。

图6(f)—(g)分别展现了OLTC的挡位及SCB的运行数量变化情况,均满足调度周期内动作次数不宜过多的规定。在12:00—17:00时,风电和光伏发电出力较大,SCB减少运行数量,防止因新能源功率倒送引起电压越限。

不同时段各节点的电压分布情况如图7所示。由图7可知,在无功电压调节设备SCB和OLTC的共同作用下,ADN的各节点电压都被限制在安全范围0.95~1.05 pu内。其中,在14:00时节点22上的电压最低,为0.970 7 pu;在15:00时节点5上的电压最高,为1.001 3 pu。

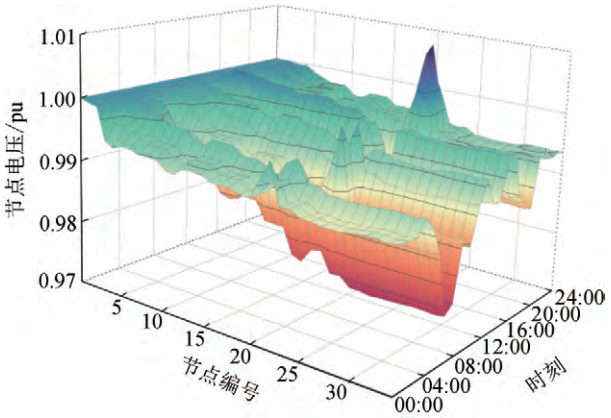


图7 不同节点的电压分布

Fig. 7 Voltage distribution at different nodes

从算例结果可以看出,经本文提出的PER-DDPG方法离线训练后,智能体能够在线调度ESS、MT、OLTC和SCB有功/无功资源动作,并与PV及WT协同作用,以具有成本效益的方式响应ADN电力负荷需求。该方法在新能源消纳、削峰填谷和需求响应等方面具有良好的效果。

4 结 论

本文针对ADN的有功-无功协调优化调度问题,在DDPG方法的基础上添加了PER机制,提出一种基于深度确定性策略梯度的主动配电网有功-无功协调优化调度策略。基于算例分析,得到如下结论:

1) 本文所设计的MDP模型最大程度地模拟了

ADN 实际环境，不依赖于任何物理模型，避免了对新能源、负荷及电价的不确定性建模，具有实际应用价值。

2）采用本文所提出的 PER-DDPG 框架进行离线训练得到的最优神经网络模型可以在线生成 ADN 调度策略，能够有效解决电压和潮流越限的问题，并同时最小化日常运行成本。

3）在离线训练过程中，本文所提 PER-DDPG 方法相较于 DDPG 方法具有更高的未来折扣奖励和更快的收敛速度。

5　参考文献

[1] 李军徽，马得轩，朱星旭，等. 基于 ADMM 算法的主动配电网分层优化经济调度 [J]. 电力建设，2022，43(8)：76-86.
LI Junhui，MA Dexuan，ZHU Xingxu，et al. Multi-level optimization of economic dispatching based on ADMM algorithm for active distribution network [J]. Electric Power Construction，2022，43(8)：76-86.

[2] 孟令卓超，杨锡运，赵泽宇. 考虑光－荷不确定性和旋转备用约束的主动配电网经济优化调度策略 [J]. 电力建设，2022，43(11)：63-72.
MENG Lingzhuochao，YANG Xiyun，ZHAO Zeyu. Economic optimization dispatch strategy of active distribution network considering light-load uncertainty and spinning reserve constraints [J]. Electric Power Construction，2022，43(11)：63-72.

[3] CAPITANESCU F，BILIBIN I，ROMERO RAMOS E. A comprehensive centralized approach for voltage constraints management in active distribution grid [J]. IEEE Transactions on Power Systems，2014，29(2)：933-942.

[4] 涂辉，周建聪，石文超，等. 考虑多种调节手段的配电网经济运行优化 [J]. 电力建设，2018，39(8)：42-52.
TU Hui，ZHOU Jiancong，SHI Wenchao，et al. Economical operation optimization of distribution network considering multiple adjustment measures [J]. Electric Power Construction，2018，39(8)：42-52.

[5] 裴蕾，卫志农，陈胜，等. 交直流混合配电网多阶段随机优化调度模型 [J]. 电力系统保护与控制，2022，50(14)：23-32.
PEI Lei，WEI Zhinong，CHEN Sheng，et al. Multi-stage stochastic optimization dispatch model for AC-DC hybrid distribution power networks [J]. Power System Protection and Control，2022，50(14)：23-32.

[6] 朱刘柱，尹晨旭，王宝，等. 计及风/光/荷不确定性的综合能源站随机规划研究 [J]. 电网与清洁能源，2021，37(5)：96-105.
ZHU Liuzhu，YIN Chenxu，WANG Bao，et al. Stochastic programming of integrated energy station considering the uncertainties of wind power，photovoltaic and load [J]. Power System and Clean Energy，2021，37(5)：96-105.

[7] 张旭，么莉，陈晨，等. 交直流混合配电网网络重构与无功优化协同的两阶段鲁棒优化模型 [J]. 电网技术，2022，46(3)：1149-1162.
ZHANG Xu，YAO Li，CHEN Chen，et al. A novel two-stage robust model for co-optimization of reconfiguration and reactive power in AC/DC hybrid distribution network [J]. Power System Technology，2022，46(3)：1149-1162.

[8] 邱革非，张鹏坤，贺漂. 考虑风电接入的电力系统鲁棒经济优化调度 [J]. 电力建设，2021，42(10)：101-109.
QIU Gefei，ZHANG Pengkun，HE Piao. Economic dispatch of power system considering wind power integration [J]. Electric Power Construction，2021，42(10)：101-109.

[9] 方一晨，张沈习，程浩忠，等. 含智能软开关的主动配电网分布式光伏准入容量鲁棒优化 [J]. 电力系统自动化，2021，45(7)：8-17.
FANG Yichen，ZHANG Shenxi，CHENG Haozhong，et al. Robust optimization of distributed photovoltaic hosting capacity of active distribution network with soft open point [J]. Automation of Electric Power Systems，2021，45(7)：8-17.

[10] 随权，林湘宁，童宁，等. 基于改进两阶段鲁棒优化的主动配电网经济调度 [J]. 中国电机工程学报，2020，40(7)：2166-2179，2396.
SUI Quan，LIN Xiangning，TONG Ning，et al. Economic dispatch of active distribution network based on improved two-stage robust optimization [J]. Proceedings of the CSEE，2020，40(7)：2166-2179，2396.

[11] 贺帅佳，阮贺彬，高红均，等. 分布鲁棒优化方法在电力系统中的理论分析与应用综述 [J]. 电力系统自动化，2020，44(14)：179-191.
HE Shuaijia，RUAN Hebin，GAO Hongjun，et al. Overview on theory analysis and application of distributionally robust optimization method in power system [J]. Automation of Electric Power Systems，2020，44(14)：179-191.

[12] 李笑竹，王维庆. 基于贝叶斯理论的分布鲁棒优化在储能配置上的应用 [J]. 电网技术，2022，46(10)：4001-4011.
LI Xiaozhu，WANG Weiqing. Application of distributed robust optimization based on Bayesian theory in energy storage configuration [J]. Power System Technology，2022，46(10)：4001-4011.

[13] 徐澄莹，朱旭，窦真兰，等. 基于数据驱动鲁棒优化的用户侧综合能源舱低碳规划 [J]. 电力建设，2022，43(12)：27-36.
XU Chengying，ZHU Xu，DOU Zhenlan，et al. Research on low carbon planning based on data driven robust optimization for user-side integrated energy module [J]. Electric Power Construction，2022，43(12)：27-36.

[14] KOU P，LIANG D L，WANG C，et al. Safe deep reinforcement learning-based constrained optimal control scheme for active distribution networks [J]. Applied Energy，2020，264：114772.

[15] 刘帅，孔亮，刘自发，等. 基于深度强化学习的输电网网架规划方法 [J]. 电力建设，2021，42(7)：101-109.
LIU Shuai，KONG Liang，LIU Zifa，et al. Transmission network grid planning method based on deep reinforcement learning [J]. Electric Power Construction，2021，42(7)：101-109.

[16] CHU Y F，WEI Z N，FANG X C，et al. A multiagent federated reinforcement learning approach for plug-In electric vehicle fleet charging coordination in a residential community [J]. IEEE Access，2022，10：98535-98548.

[17] 曹迪. 主动配电网电压控制策略研究 [D]. 成都：电子科技大学，2021.

CAO Di. Research on voltage control strategy of active distribution network [D]. Chengdu: University of Electronic Science and Technology of China, 2021.

[18] 王新迎，赵琦，赵黎媛，等. 基于深度 Q 学习的电热综合能源系统能量管理 [J]. 电力建设，2021，42(3)：10-18.
WANG Xinying, ZHAO Qi, ZHAO Liyuan, et al. Energy management of electric and thermal integrated energy systems based on deep Q learning [J]. Electric Power Construction, 2021, 42(03): 10-18.

[19] 张津源，蒲天骄，李烨，等. 基于多智能体深度强化学习的分布式电源优化调度策略 [J]. 电网技术，2022，46(9)：3496-3504.
ZHANG Jinyuan, PU Tianjiao, LI Ye, et al. Multi-agent deep reinforcement learning based optimal dispatch of distributed generators [J]. Power System Technology, 2022, 46(9): 3496-3504.

[20] 史景坚，周文涛，张宁，等. 含储能系统的配电网电压调节深度强化学习算法 [J]. 电力建设，2020，41(3)：71-78.
SHI Jingjian, ZHOU Wentao, ZHANG Ning, et al. Deep reinforcement learning algorithm of voltage regulation in distribution network with energy storage system [J]. Electric Power Construction, 2020, 41(3): 71-78.

[21] 孙立钧，顾雪平，刘彤，等. 一种基于深度强化学习算法的电网有功安全校正方法 [J]. 电力系统保护与控制，2022，50(10)：114-122.
SUN Lijun, GU Xueping, LIU Tong, et al. A deep reinforcement learning algorithm-based active safety correction method for power grids [J]. Power System Protection and Control, 2022, 50(10): 114-122.

[22] 蒋明喆，成贵学，赵晋斌. 基于改进 DDPG 的多能园区典型日调度研究 [J]. 电网技术，2022，46(5)：1867-1880.
JIANG Mingzhe, CHENG Guixue, ZHAO Jinbin. Typical daily scheduling if improved DDPG multifunctional industrial park [J]. Power System Technology, 2022, 46(5): 1867-1880.

[23] 杨挺，赵黎媛，刘亚闯，等. 基于深度强化学习的综合能源系统动态经济调度 [J]. 电力系统自动化，2021，45(5)：39-47.
YANG Ting, ZHAO Liyuan, LIU Yachuang, et al. Dynamic economic dispatch for integrated energy system based on deep reinforcement learning [J]. Automation of Electric Power Systems, 2021, 45(5): 39-47.

[24] CAO D, HU W H, ZHAO J B, et al. A multi-agent deep reinforcement learning based voltage regulation using coordinated PV inverters [J]. IEEE Transactions on Power Systems, 2020, 35(5): 4120-4123.

[25] HOU Y N, LIU L F, WEI Q, et al. A novel DDPG method with prioritized experience replay [C]//2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2017: 316-321.

[26] MACEDO L H, FRANCO J F, RIDER M J, et al. Optimal operation of distribution networks considering energy storage devices [J]. IEEE Transactions on Smart Grid, 2015, 6(6): 2825-2836.

[27] MOEIN M A, PAYMAN D, MEHDI D. Energy management of plug-in hybrid electric vehicles in renewable-based energy hubs [J]. Sustainable Energy, Grids and Networks, 2022, 32: 100932.

[28] LI H P, HE H B. Learning to operate distribution networks with safe deep reinforcement learning [J]. IEEE Transactions on Smart Grid, 2022, 13(3): 1860-1872.

收稿日期： 2023-03-08

作者简介：

孙国强(1978)，男，博士，教授，主要研究方向为电力系统调度与优化、虚拟电厂等；

殷岩岩(1997)，男，硕士研究生，通信作者，主要研究方向为深度强化学习在配电网优化中的应用，E-mail: 1109851959@qq.com；

卫志农(1962)，男，博士，教授，主要研究方向为电力系统运行分析与控制、输配电系统自动化等；

臧海祥(1986)，男，博士，副教授，主要研究方向为电力系统规划与运行分析、人工智能在电力系统中的应用等；

楚云飞(1990)，男，博士，主要研究方向为人工智能在电力系统中的应用。

（编辑　张小飞）