

中国电机工程学报
Proceedings of the CSEE
ISSN 0258-8013,CN 11-2107/TM

《中国电机工程学报》网络首发论文

题目：基于大语言模型辅助多智能体深度强化学习的配电网无功调压策略
作者：余兆芮，李佳勇，汪涛，张聪，朱利鹏，周柯，帅智康
DOI：10.13334/j.0258-8013.pcsee.260314
收稿日期：2026-02-10
网络首发日期：2026-06-03
引用格式：余兆芮，李佳勇，汪涛，张聪，朱利鹏，周柯，帅智康．基于大语言模型辅助多智能体深度强化学习的配电网无功调压策略[J/OL]．中国电机工程学报．https://doi.org/10.13334/j.0258-8013.pcsee.260314



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-06-03 09:24:00　网络首发地址：https://link.cnki.net/urlid/11.2107.tm.20260602.1556.008

DOI：10.13334/j.0258-8013.pcsee.260314

基于大语言模型辅助多智能体深度强化学习的配电网无功调压策略

余兆芮[1]，李佳勇[1]，汪涛[1]，张聪[1]，朱利鹏[1]，周柯[1]，帅智康[1]

（1.湖南大学电气与信息工程学院，湖南省 长沙市 410082）

Volt-var Control Strategy for Distribution Networks Based on Large Language Model-Assisted Multi-Agent Deep Reinforcement Learning

Yu Zhaorui[1], Li Jiayong[1], Wang Tao[1], Zhang Cong[1], Zhu Lipeng[1], Zhou Ke[1], Shuai Zhikang[1]

(1. College of Electrical and Information Engineering, Hunan University, Changsha 410082, Hunan Province, China)

ABSTRACT: With the large-scale integration of distributed resources such as photovoltaics (PV) into distribution networks, the network structure has undergone profound changes, characterized by complex and highly volatile power flows that significantly increase the risk of node voltage violations; addressing the limitations of traditional multi-agent deep reinforcement learning (MADRL), where reliance on manual expertise for reward function design and poor scenario adaptability often lead to local optima, this paper proposes a Large Language Model (LLM)-assisted MADRL strategy for reactive power regulation. Specifically, the distribution network is partitioned into zones with PV control agents to establish a distributed framework based on the Multi-Agent Attention Actor-Critic (MAAC) algorithm, while a differentiated hybrid reward function—combining global loss and local voltage violation penalties—is designed to balance safety and economy; furthermore, an LLM is embedded as a high-level cognitive module to dynamically adapt the reward function based on feedback, complemented by a reward relabeling mechanism to mitigate policy oscillations caused by non-stationarity, and finally, simulation results on the IEEE 141-node system verify the superiority of the proposed method in enhancing both the operational safety and economic efficiency of distribution networks.

KEY WORDS： distribution networks; voltage control; deep reinforcement learning; large language model

摘要： 随着光伏等分布式资源规模化接入配电网，配电网形态结构发生了深刻变化，潮流呈现复杂化与强波动特征，节点电压越限风险显著提升。针对传统多智能体深度强化学习奖励函数设计依赖人工经验与场景适应性差导致其在无功调压中易陷入局部最优解的问题，本文提出了一种大语言模型辅助多智能体深度强化学习的无功调压策略。首先，将配电网划分为多个区域，在每个区域设置一个光伏控制智能体，构建基于多智能体注意力动作-评价算法(multi-agent attention actor-critic，maac)的分布式无功控制框架；其次，为协同实现抑制电压越限与降低网络损耗的目标，设计一种由全局网损惩罚项与局部电压越限惩罚项组合的差异化混合奖励函数；然后，将大语言模型作为高层认知模块嵌入智能体训练闭环，利用训练与测试反馈对奖励函数进行动态自适应调整；同时，引入了奖励重标记机制，以缓解奖励非平稳性导致的策略震荡。最后，在 IEEE 141 节点配电系统开展仿真实验，结果验证了所提方法在提升配电网无功调压安全性与经济性方面的优越性。

关键词： 配电网；电压控制；深度强化学习；大语言模型

0 引言

在国家“双碳”战略目标推动下，以光伏为代表的分布式可再生能源在配电网中的渗透率持续提升，电力系统运行模式正由集中式、单向潮流向分布式协同控制与双向潮流的新运行形态转变[1]。受

基金项目： 国家自然科学基金项目(52377095、52377184、52437008)；湖南省科技创新计划项目(2023RC3114、2024RC3110、2025RC1023)；智能电网重大专项(2030)资助(2026ZD0811900)。

Project Supported by National Natural Science Foundation of China (No. 52377095, 52377184，52437008); The science and technology innovation Program of Hunan Province (No. 2023RC3114, 2024RC3110, 2025RC1023); Smart-Grid National Science and Technology Major Project(2026ZD0811900)

分布式光伏出力间歇性和随机性影响，其规模化接入易导致配电网节点注入功率波动加剧；同时，其并网引入的双向潮流特性易导致局部节点电压抬升，加剧电压越限风险[2]。因此，在高比例新能源接入下，构建快速、灵活与协调的无功调压策略，是保障配电网安全、经济运行的关键。

针对配电网电压控制问题，传统方法多采用基于数学模型的无功调压策略，通过求解确定性模型实现无功资源协调控制[3]。然而，这类方法对系统模型和参数精度依赖较强，随着分布式电源渗透率提升及运行状态快速变化，在计算效率与实时响应方面存在局限，难以满足复杂运行环境下电压实时控制需求[4]。近年来，深度强化学习（DRL）凭借无模型依赖与自主交互学习的优势[5]，被逐步引入配电网无功调压领域。然而，现有单智能体建模方法[6]在控制对象增多时，易面临状态-动作空间膨胀、计算复杂度攀升等瓶颈。为此，基于多智能体深度强化学习（Multi-Agent DRL, MADRL）的分布式无功协同控制[7]被视为更优的解决方案。例如，文献[8]提出多时间尺度无功优化框架，在短时间尺度基于 MADRL 实现多设备协同控制，提升设备协调性与实时决策能力。文献[9]提出基于多智能体软动作-评论算法的两阶段控制框架，实现光伏逆变器与传统调节设备的协同控制，有效抑制了快速电压越限问题。文献[10]提出一种基于多智能体软动作-评论家算法的双模公平-安全电压控制方法，实现配电网电压优化、公平有功削减及鲁棒安全控制。文献[11]引入多智能体双延迟深度确定性策略梯度算法，在 Dec-POMDP 模型下实现逆变器间的无功协同，提升了随机环境中的控制稳定性。文献[12]针对三相不平衡系统提出多智能体深度 Q 网络方法，通过精细化奖励设计实现调压与降损的协同优化。尽管 MADRL 在分布式无功调压中展现出一定潜力，但是智能体的性能上限在很大程度上受制于奖励函数的设计质量[13]。文献[14]系统分析了 L1 型、L2 型及碗型奖励函数在梯度引导特性上的差异，表明奖励函数形式会影响多约束任务下的收敛稳定性与任务达成率。文献[15]在奖励函数中引入指数屏障函数，有效避免了智能体采取次优策略，确保电压运行在安全阈值内。文献[16]构建了基于状态感知的自适应奖励函数，引导智能体根据环境与荷电状态实时调整决策，有效规避了传统静态奖励导致的局部最优问题。然而，目前多数 MADRL 奖励函数设计仍依赖专家经验与人工试错，存在开发周期长、成本高及多智能体信用分配难等问题[17]。

目前，大语言模型（Large Language Model, LLM）凭借其强大的语义理解、逻辑推理与上下文学习等方面的能力突破，在人工智能领域取得快速发展[18]。在奖励函数优化方面，现有超参数优化方法多局限于预设奖励函数框架下的数值寻优，在配电网无功调压场景中，固定结构的奖励函数通常难以同时满足电压安全性和系统经济性目标。相比之下，LLM 不仅能优化参数，还能动态重构奖励函数的数学结构。文献[17]指出 LLM 可用于辅助强化学习中的奖励函数设计与优化。文献[19]提出通过 LLM 迭代生成与修正奖励函数，在无需人工反馈的情况下获得与专家设计奖励相当甚至更优的性能。文献[20]利用 LLM 推理能力实现奖励函数自动化设计，有效降低了交通控制中稀疏奖励工程对专家经验的依赖。针对多智能体信用分配问题，文献[21]利用 LLM 生成融合全局奖励指标与个体奖励信号的奖励函数，有效引导智能体生成更高效的协作策略。为解决配电网能量管理中安全约束调优难题，文献[22]在配电网能量管理场景中引入 RL2 机制，利用 LLM 设计奖励函数并结合强化学习反馈迭代优化，提升了系统运行的安全性与经济性。尽管利用 LLM 设计奖励函数的研究在多个领域已取得初步进展，但在配电网无功调压领域的相关研究仍较为匮乏。此外，现有研究普遍采用单一形式的奖励结构，尚未采用由全局奖励和局部奖励相结合的混合奖励函数形式，且 LLM 对奖励函数的调整通常发生在训练闭环外，限制了学习效率与最终性能。

针对上述挑战，本文提出了一种基于 LLM 辅助 MADRL 的配电网无功调压策略（LLM-Assisted MADRL for Volt-Var Control，LLM-MADRL）。构建了基于 MAAC 的分布式控制框架，设计了全局网损惩罚项与局部电压惩罚项结合的差异化奖励函数；同时，将 LLM 嵌入训练闭环以动态重构奖励函数，并引入奖励重标记机制保障收敛稳定性。最后，在 IEEE 141 节点系统上的仿真结果证实，所提方法有效克服了信用分配难题，在电压越限抑制与网损降低上均优于传统方法。

1 基于大模型辅助多智能体深度强化学习

的无功调压架构

1.1 配电网无功调压问题建模

中低压配电网普遍面临电压越限与波动问题。分布式光伏出力的时空不确定性进一步加剧了电压波动问题。因此，为保证配电网安全可靠运行，亟需通过灵活的功率调节来改善电压分布，确保各节点电压幅值维持在安全阈值内。

本文构建了以最小化网络损耗为目标，同时满足节点电压安全约束的光伏逆变器无功调压优化模型，为后续基于强化学习的策略求解提供模型支撑。具体目标函数为：

$$\min P^{\text{loss}} = \sum_{i\in\mathcal{L}} r_i \frac{P_i^2 + Q_i^2}{V_{\pi_i}^2} \tag{1}$$

式中：P^{loss} 为网络损耗；$\mathcal{L}=\{1,2,\ldots,N_{\text{node}}\}$为线路集合；$r_i$为线路 i 的电阻；P_i和 Q_i分别为线路 i 的有功和无功功率；π_i为节点 i 的父节点，V_{π_i} 为节点π_i的电压幅值。

本文采用文献[23]的 Distflow 模型来描述配电网中的功率平衡约束。在无功调压任务中，系统各节点电压幅值V_i需控制在[0.95,1.05]区间内。同时，分布式光伏逆变器输出的有功功率 p_i^{pv} 和无功功率 q_i^{pv} 满足 $0 \le p_i^{\text{pv}} \le p_{i,\max}^{\text{pv}}$ 和 $(p_i^{\text{pv}})^2 + (q_i^{\text{pv}})^2 \le (s_i^{\max})^2$，其中 $s_i^{\max}$ 为光伏逆变器的额定视在功率；$p_{i,\max}^{\text{pv}}$ 为光伏逆变器最大可用有功功率。

1.2 大模型辅助多智能体深度强化学习的无功调压总体架构

在多智能体深度强化学习框架下，传统人工设计的静态奖励函数难以兼顾电压安全约束与经济性目标，易导致智能体性能受限。为此，本文提出了一种 LLM-MADRL 框架，将 LLM 作为一个高级认知模块嵌入到 MADRL 的训练闭环中,利用 LLM 强大的语义理解、逻辑推理和上下文能力，实现对训练进程的深层感知，从而对奖励函数进行动态调整。具体内容如图 1 所示。

LLM 对强化学习多智能体的辅助机制具体表现为：首先，在训练初始化阶段，通过设计系统提示词调用 LLM，构建初始混合奖励函数。其次，根据动态获取的配电网状态与逆变器动作数据，计算并存储混合奖励函数值。然后，采用集中式训练方法，从经验回放缓冲区中随机采样数据，对多智能体的策略网络和评价网络进行训练。在智能体训练过程中，当满足预设的奖励函数更新条件，智能体暂停训练并进行性能测试；随后，将当前的混合奖励函数、训练回合数、测试性能指标以及思维链建议转化为反馈提示词，并输入到 LLM，实现奖励函数中电压越限惩罚函数与网损系数的自适应调整。在分布式执行阶段，各区域智能体根据训练完成的策略网络，仅根据本区域观测信息生成动作，并将

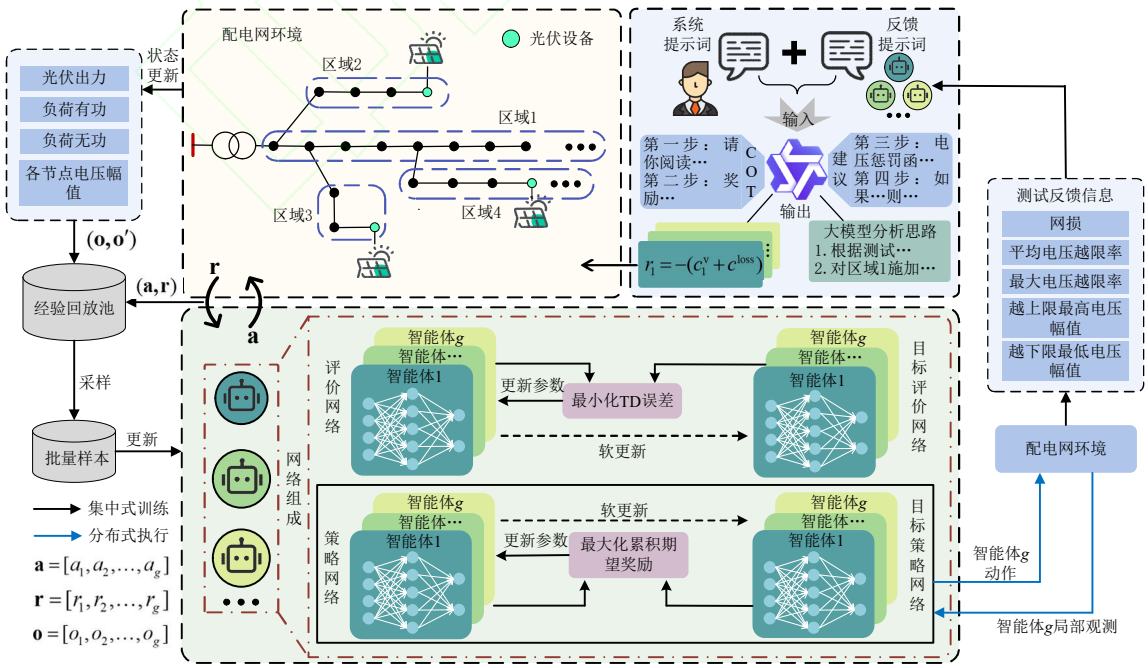


图 1　基于大语言模型辅助多智能体深度强化学习的无功调压框架

Fig. 1 Volt-var control framework based on LLM-Assisted MADRL

功出力，实现配电网电压和网络损耗的协同优化。

针对训练闭环中动态调整奖励函数所引发的智能体策略训练震荡问题[25]，本文设计了奖励重标记机制：当 LLM 更新奖励函数后，重新计算经验回放池中历史样本的奖励值，旨在消除历史交互数据与当前优化目标之间的价值评估偏差，保障控制策略在训练过程中的收敛平稳性。

2 基于大模型辅助多智能体深度强化学习的无功调压模型构建

2.1 马尔可夫决策过程构建

本文参照文献[26]的方式构建了多智能体的部分可观测马尔可夫决策过程（Partially Observable Markov Decision Process, POMDP）。在多智能体协同任务中，共享奖励函数难以准确界定单一智能体动作对系统整体收益的具体贡献，易陷入信用分配困境。为克服这一难题，本文在 LLM 辅助机制下构建了混合奖励函数。该函数不仅包含了降低网损的全局目标，还引入了针对智能体所辖区域的电压控制目标，为各智能体提供了平衡整体协作与个体贡献的差异化奖励，从而引导其在策略生成过程中有效兼顾网络损耗与电压安全。因此，智能体 g 的混合奖励函数如式(2)所示：

$$r_g = -\left(c_g^{\mathrm{v}} + c^{\mathrm{loss}}\right), \forall g \in \mathcal{G} \tag{2}$$

$$c_g^{\mathrm{v}} = \frac{1}{N_g}\sum_{i=1}^{N_g} f\left(V_i - V_{\mathrm{r}}\right) \tag{3}$$

$$c^{\mathrm{loss}} = w * p^{\mathrm{loss}} \tag{4}$$

式中：r_g 为智能体 g 的奖励；$\mathcal{G}$ 为智能体集合；c_g^{v} 为局部奖励项，表示智能体 g 控制区域内所有节点电压越限惩罚的平均值；f 为电压惩罚函数；V_{r} 为电压基准值，该函数对上下越限采用对称结构；N_g 表示智能体 g 控制区域内的节点数目；c^{loss} 为全局奖励项，表示网损惩罚值；w 为网损系数，p^{loss} 为网络损耗；电压越限惩罚函数 f_{v} 和网损系数 w 由大模型根据当前的训练与测试状态反馈动态调整。

2.2 基于 MAAC 算法的智能体网络搭建

综合上述 POMDP 过程，为每个智能体 g 搭建独立的评价网络 Q_g^{ϕ} 和策略网络 μ_g^{θ}，并构建对应的目标网络 $Q_g^{\tilde{\phi}}$ 和 $\mu_g^{\tilde{\theta}}$[27]。采用“集中式训练-分布式执行”的范式：在训练阶段，各智能体的评价网络引入了注意力机制，利用所有智能体的联合观测与联合动作进行集中学习；在执行阶段，智能体仅依据本地局部观测实现分布式自主决策[28]。

2.2.1 评价网络搭建

各评价网络在训练阶段接收所有智能体的联合观测状态 $o=\{o_1,o_2...o_{|\mathcal{G}|}\}$ 和联合动作信息 $a=\{a_1,a_2...a_{|\mathcal{G}|}\}$，输出目标智能体在当前状态下采取动作 a_g 的长期累积回报期望 $Q_g^{\phi}(o,a)$。在此过程中，评价网络首先将各智能体的观测状态和动作信息编码为特征向量，然后采用注意力机制[26]计算出目标智能体特征向量与其他智能体特征向量的关联权重，并加权聚合成包含全局交互信息的特征向量，使目标智能体在参数更新过程中有选择性地提取其余智能体的关键信息。评价网络参数 ϕ 通过最小化关于当前估计值 $Q_g^{\phi_g}(o,a)$ 与目标值 y_g 的损失函数 $L(\phi)$ 进行更新。

$$L(\phi) = \sum_{g=1}^{N_{\mathrm{a}}} \mathbb{E}_{(o,a,r_z,o')\sim\mathcal{D}}\left[\left(Q_g^{\phi_g}(o,a) - y_g\right)^2\right] \tag{5}$$

式中：$\mathcal{D}$ 代表经验回放缓冲区，用于存储智能体与配电网环境交互而产生的四元组经验样本 (o,a,r_z,o')，其中 o' 为下一时刻所有智能体的联合观测状态。在计算目标值 y_g 时，MAAC 将目标策略分布的动作熵融入长期回报中，如式(6)所示。

$$y_g = r_g + \gamma \mathbb{E}_{a'\sim\tilde{\pi}^{\theta}}[Q_g^{\tilde{\phi}}(o',a') - \beta\log(\mu_g^{\tilde{\theta}}(a_g' \mid o_g'))] \tag{6}$$

式中：$\gamma \in [0,1)$ 为折扣因子，用于平衡即时奖励与未来长期收益；β 为温度参数，用于平衡即时奖励与动作熵之间的权重；$-\beta\log(\mu_g^{\tilde{\theta}}(a_g' \mid o_g'))$ 表示动作熵，用于鼓励智能体积极探索环境，避免控制策略过早收敛到局部最优解；a_g' 表示智能体 g 下一时刻根据其目标策略网络及局部观测 o_g' 生成的确定性动作；$\tilde{\theta}$ 表示目标策略网络参数。在计算目标值 y_g 时，所有智能体的下一时刻动作均由各自的目标动作网络生成。

2.2.2 策略网络搭建

在训练阶段，智能体策略网络基于局部观测 o_g 生成动作 a_g，并接收来自评价网络的全局价值信息。随后，策略网络依据最大熵策略梯度定理迭代

更新参数 θ_g，从而驱动智能体动作向保障电压安全与最小化网损的方向收敛，如式(7)所示：

$$\nabla_{\theta_g} J(\mu_\theta) = \mathbb{E}_{o\sim D, a\sim\mu}[\nabla_{\theta_g} \log(\mu_{\theta_g}(a_g \mid o_g)) \times (-\beta \log(\mu_{\theta_g}(a_g \mid o_g)) + A_g(o,a))] \tag{7}$$

$$A_g(o,a) = Q_g^{\phi}(o,a) - b(o,a_{\mathcal{G}\setminus g}) \tag{8}$$

$$b(o,a_{\mathcal{G}\setminus g}) = \mathbb{E}_{a_g\sim\mu_g(o_g)}\left[Q_g^{\phi}(o,(a_g,a_{\mathcal{G}\setminus g}))\right] \tag{9}$$

式中：$J(\mu_\theta)$ 表示智能体策略的期望累积回报；∇_{θ_g} 表示其关于智能体 g 策略网络参数的梯度；$A_g(o,a)$ 表示多智能体优势函数；$b(o,a_{\mathcal{G}\setminus g})$ 表示多智能体基准值。

在执行阶段，各智能体策略网络无需信息交互，仅以本区域观测状态 o_g 作为输入，生成无功调节动作 a_g。策略网络输出层通过 tanh 激活函数输出归一化动作，并将动作进一步映射为满足功率约束的实际无功出力。

2.2.3 目标网络软更新机制

为进一步增强训练过程的平稳性，MAAC 算法引入了目标网络软更新机制对目标网络参数进行迭代更新。在训练过程中，软更新机制采用滑动平均的方式对目标网络参数进行微幅迭代。在每一次主网络的参数更新步骤后，目标网络参数分别依据式(10)与式(11)进行追踪更新。

$$\tilde{\phi}_g \leftarrow \tau\phi_g + (1-\tau)\tilde{\phi}_g \tag{10}$$

$$\tilde{\theta}_g \leftarrow \tau\theta_g + (1-\tau)\tilde{\theta}_g \tag{11}$$

式中：$\tau \ll 1$ 为软更新系数，本文取 0.01。

2.3 大模型提示词设计

在所提框架中，LLM 能够综合分析测试反馈中的电压越限程度与网络损耗变化趋势，自适应调整电压越限惩罚函数 f_v 和网损系数 w。为此，本文构建了一套面向大模型的提示词体系，旨在将强化学习训练过程中的全局网损信息与局部电压越限特征进行结构化整合，引导大模型生成适配各区域智能体的差异化混合奖励函数。该体系包含两类提示词：系统提示词与反馈提示词，分别对应强化学习智能体训练的基础认知指引与强化反馈调优阶段。

2.3.1 系统提示词

在交互初期，构建混合奖励函数的初步设计模板，并设计规范化的系统提示词，输入 LLM，协助其理解无功电压控制任务物理背景与决策逻辑，生成初始奖励函数。该提示词的内容包含五个维度，具体架构如图 2 所示。

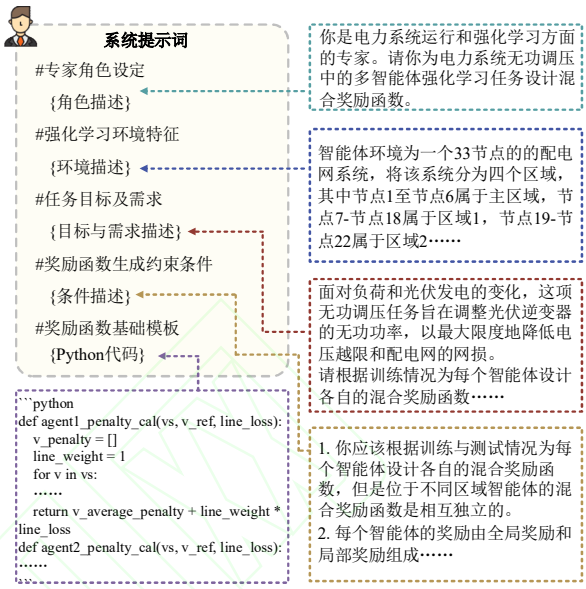


图 2　系统提示词示意图

Fig. 2　Schematic illustration of the system prompt

1）专家角色设定：明确 LLM 的身份定位，将其设定为“电力系统运行与深度强化学习双领域专家”，引导 LLM 从其预训练的领域知识与通用世界知识中提取相关信息。

2）强化学习环境特征：描述多智能体深度强化学习环境下的配电网拓扑区域划分情况及智能体配置方案。

3）任务目标及需求：描述大模型需要执行的任务，明确无功调压的核心优化目标，为大模型设计奖励函数提供关键物理约束与性能指标信息，支撑 LLM 设计具有安全主导性的混合奖励函数。

4）奖励函数生成约束条件：描述奖励函数生成的结构化约束与可执行规范，包括奖励分解方式、分区独立奖励要求、电压安全边界以及函数数量与代码合规性规则。

5）奖励函数基础模板：提供标准化的 Python 代码范式。LLM 需在此模板基础上，根据特定的优化需求进行参数调整与逻辑重构，保证输出代码的规范性与可执行性。

2.3.2 反馈提示词

设计反馈提示词，旨在向 LLM 提供智能体训练与测试的动态信息，并结合思维链建议引导其发挥逻辑推理能力。当满足奖励函数调整的触发条件

时，智能体将暂停训练并执行独立测试，获取全局与局部的性能指标，并将此类量化数据嵌入至反馈提示词中，向 LLM 提供结构化的训练与测试状态描述。为进一步引导大模型在奖励函数生成过程中进行系统性推理，反馈提示词中还整合了思维链推理指引，促使 LLM 设计更具适应性与鲁棒性的混合奖励函数。该提示词主要包含四个维度：

1）目前混合奖励函数：记录当前训练阶段所采用的混合奖励函数结构与参数，为 LLM 提供优化的基准，支撑其基于性能差异进行归因分析。

2）智能体训练进度：记录当前智能体已完成的训练回合数与即将进行的测试回合数。

3）智能体全局与局部性能指标测试结果：智能体全局性能指标为网损，局部性能指标包括平均电压越限率（Voltage Violation Rate, VVR）、最大VVR、越上限最大电压幅值、越下限最小电压幅值。

4）思维链建议：提供大模型优化奖励函数的思考流程，引导大模型将奖励函数设计任务分解为若干子任务，提升大模型推理过程中的逻辑严谨性与结果可靠性。

2.4 多智能体训练与执行过程

本文提出的 LLM-MADRL 方法包含离线训练与在线执行两个阶段。训练阶段利用大模型的高层认知能力动态调整混合奖励函数，协助多智能体策略的快速收敛与鲁棒优化；执行阶段则依托训练成熟的策略网络实现各光伏逆变器的分布式自主调控。具体流程如下：

1）系统初始化阶段

首先，初始化配电网环境及多智能体深度强化学习网络参数。对于系统中的$|\mathcal{G}|$个智能体，随机初始化其策略网络μ_g^{θ}与评价网络Q_g^{ϕ}的权重参数，并建立对应的目标网络$\mu_g^{\tilde{\theta}}$与$Q_g^{\tilde{\phi}}$。同时，初始化经验回放缓冲区$\mathcal{D}$以存储交互样本。在此阶段，大模型基于上述系统提示词生成初始混合奖励函数代码，并将其加载至强化学习训练环境。

2）环境交互与数据采集

进入训练循环后，各智能体g获取局部观测状态o_g，通过策略网络生成动作a_g来控制光伏逆变器无功输出。然后系统执行潮流计算并更新配电网状态，同时反馈联合观测o'和当前混合奖励函数的数值r_g，最后智能体将四元组经验样本(o,a,r_g,o')存入经验回放缓冲区$\mathcal{D}$。

3）神经网络参数更新

在每个训练步，从缓冲区$\mathcal{D}$中随机采样小批量样本$\mathcal{B}$，利用目标网络计算目标价值y_g(式 6)。通过最小化损失函数$L(\phi)$更新评价网络参数ϕ，使其拟合当前策略的长期回报；随后，利用最大熵策略梯度定理(式 7)，基于评价网络对动作的梯度反馈更新策略网络参数。最后，通过软更新机制(式 10-11)微调目标网络参数，维持训练稳定性。

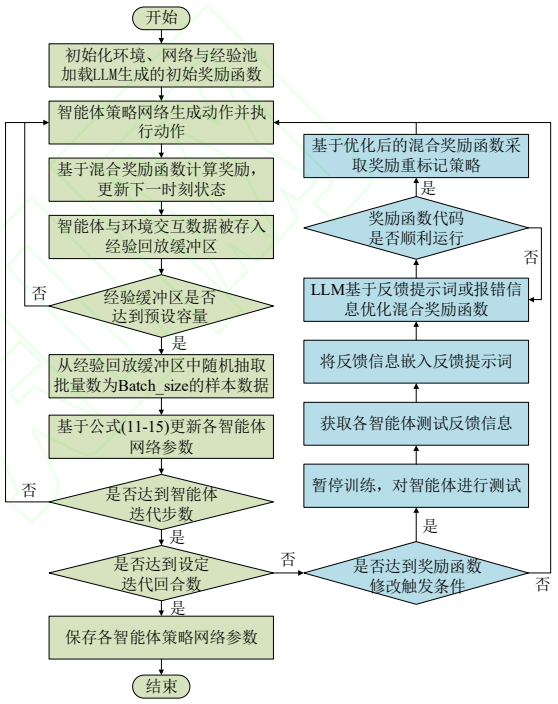


图 3 所提方案的多智能体训练过程

Fig. 3 Multi-agent training process of the proposed method

4）LLM 辅助的奖励函数动态调整

系统基于滑动窗口机制监测连续 20 个训练回合的性能指标。当满足预设的 LLM 干预条件时，暂停参数更新，冻结当前策略网络并在验证集上执行独立测试，获取全局网损及局部电压越限统计指标，并将其嵌入反馈提示词输入 LLM，后者利用思维链推理能力分析当前奖励函数的性能瓶颈，输出修正后的混合奖励函数。然后，系统将 LLM 生成的混合奖励函数代码封装于隔离的沙箱环境，对其进行静态语法解析与结构合法性校验，重点检查函数定义完整性、函数调用规范性以及变量定义完整性等约束；随后，构造电压和网损输入对奖励函数

进行调用，验证其可执行性。若调用过程中触发异常，系统将自动捕获完整的错误追溯信息，并结合当前奖励函数代码、输入样本及错误类型，构建结构化提示词反馈至 LLM，以驱动其进行针对性修复。在此期间，主干强化学习训练进程保持暂停，直至该奖励函数代码通过验证。最后，执行奖励重标记机制：利用 LLM 最新生成的混合奖励函数，对经验回放缓冲区 $\mathcal{D}$ 中所有历史样本的奖励值 r_g 进行重新计算，减小历史数据与当前优化目标之间的价值评估偏差，确保主网络参数在更新时所依据的梯度信号与当前优化目标一致。重复步骤 2-4 直至达到最大训练回合数。

5）在线分布式执行阶段

训练完成后，仅保留各智能体的策略网络 μ_g^θ 进行在线部署。在实际运行时，各智能体仅根据本地实时观测 o_g 直接生成无功功率调节指令。

3 算例仿真

3.1 仿真设置

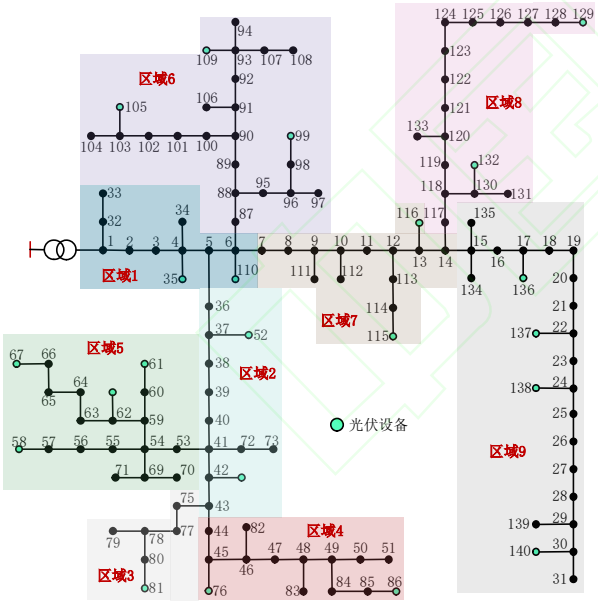


图 4 IEEE 141 节点配电网拓扑结构及区域划分情况

Fig. 4 Topology structure and zonal partitioning of the IEEE 141-bus distribution network

为验证所提方法的有效性，选取 IEEE 141 节点配电系统作为仿真算例，并将其划分为 9 个区域，在每个区域配置至少一台分布式光伏设备。系统的拓扑结构、区域划分方案及光伏接入位置详见图 4。此外，为确保无功调压场景的真实性与泛化性，仿真采用文献[14]提供的实测负荷与光伏出力数据集，其时间跨度为 3 年，分辨率为 3 min。

本文采用大语言模型 Qwen3-max 对混合奖励函数进行动态调整。在智能体进行训练时，当连续 20 个训练回合的 VVR 与网损的方差低于预设标准，表征智能体的动作探索趋于停滞，策略可能已经陷入局部最优；若此时 VVR 与网损均值高于预设标准，则说明当前策略未能充分保障配电网的安全与经济运行要求。只有当 VVR 与网损的方差低于预设标准且均值高于预设标准时，系统才会判定智能体遭遇性能瓶颈，进而触发 LLM 辅助机制。其中，为确定方差标准，本文在前期实验统计了多智能体基准算法陷入局部最优时 VVR 和网损的方差特征。VVR 均值标准严格遵循配电网运行的安全规范，网损均值则参考多智能体基准算法收敛后的网损水平。此外，本文将 LLM 辅助终止回合阈值设定为 600，当训练回合超过该值时，系统将自动终止 LLM 辅助机制。这一设定基于以下考量：受文献[29]启发，动态调整奖励函数虽能在训练前期有效帮助智能体跳出局部最优，但在训练后期，为了保障 MAAC 算法能够平稳收敛至全局最优策略，必须提供一个完全稳定的奖励环境供智能体进行训练。该阈值是前期实验测定出的经验最优值。表 1 列出了本文模型训练阶段的具体参数配置[14]。为满足自动化调用的需求，本文通过 API 与 LLM 进行程序化交互，并构建一种基于对话历史的上下文维护机制：将每次交互的提示词与响应持久化存储，并在后续调用中作为上下文信息，使大模型能够感知混合奖励函数动态优化的调整过程。

表 1 所提强化学习算法的参数配置情况

Tab. 1 Parameter configuration of the proposed RL algorithm

参数	数值	参数	数值
优化器	Adam	训练总回合数	800
经验回放缓冲区容量	55 000	VVR 均值标准	0
网络更新采样批次容量	128	VVR 方差标准	0.000 05
每回合步长	240	网损均值标准	0.27
策略/评价网络学习率	0.000 1	网损方差标准	0.001 2
折扣因子	0.99	LLM 辅助终止阈值	600

3.2 LLM 生成性能分析

为了量化智能体在训练过程中的控制性能，本文选取电压越限率 $\eta_{\text{ave}}^{\text{v}}$ 和网络损耗 $P_{\text{ave}}^{\text{loss}}$ 作为评价指标，具体如式(12)和式(14)所示。

$$\eta_{\text{ave}}^{\text{v}}=\frac{1}{\text{N}_{\text{node}}\text{T}}\sum_{t=1}^{\text{T}}\sum_{i=1}^{\text{N}_{\text{node}}}\mathbb{I}(V_{i,t})\,. \tag{12}$$

$$\mathbb{I}(V_{i,t})=\begin{cases}1, & \text{if } V_{i,t}<V_{\min} \text{ or } V_{i,t}>V_{\max}\\ 0, & \text{otherwise}\end{cases} \tag{13}$$

$$P_{\text{ave}}^{\text{loss}}=\frac{1}{\text{T}}\sum_{t=1}^{\text{T}}P_t^{\text{loss}} \tag{14}$$

式中：N_{node} 为节点数；T 代表一个训练回合内的时间步数，本文取 T=240；$V_{\min}=0.95$ p.u.和 $V_{\max}=1.05$ p.u.分别代表电压幅值下限和电压幅值上限。

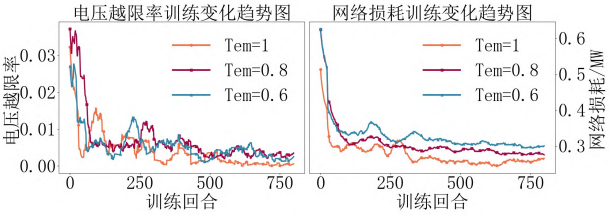


图 5 不同温度系数下电压越限率和网损的收敛曲线

Fig. 5 Convergence curves of voltage violation rate and line loss under different temperature

为探究 LLM 推理温度参数对强化学习训练收敛稳定性的影响，本文进行了针对不同温度系数的敏感性对比实验。由图 5 可知，当温度系数为 1.0 时，最终实现了最低的网络损耗以及最稳定、最接近零的电压越限状态；相比之下，较低温度最终的降损和电压越限抑制效果相对较差。由此可见，较低的温度会使得 LLM 的输出趋于保守，难以发生实质性的结构变化；虽然高温度往往会导致文本生成的结构松散，但是激活了 LLM 的发散性思维，使其能够更全面地根据反馈提示词设计出差异化的混合奖励函数。另外，本文在 LLM 的系统提示词中设计了严格的奖励函数生成约束条件与奖励函数基础模板。LLM 必须在给定的 Python 代码格式下进行参数调整与逻辑重构。这种强格式约束使得即使在 T=1.0 的高温度下，LLM 输出的代码在整个训练周期内依然保持着高度的可执行性与语法正确性，未出现逻辑崩溃，最终实现了安全性与经济性协同优化的最佳收敛效果。

为探究不同滑动窗口大小对大模型辅助频率及强化学习训练收敛稳定性的影响。本文进行了针对不同滑动窗口大小的对比实验。根据图 6 和表 2，当滑动窗口大小设为 10 时，LLM 辅助触发过于频繁，导致智能体未能在当前奖励函数下充分探索，评价网络也未稳定收敛，进而引发策略剧烈震荡并增加推理开销，最终使得电压越限率难以收敛至零。当滑动窗口大小设为 30 时，系统对智能体性能瓶颈的敏感度降低，导致 LLM 高层认知引导滞后。这使得智能体在陷入局部最优后，仍需经历一段无效训练才能触发奖励修改，最终延缓了电压越限率与网络损耗的整体收敛进程。相比之下，滑动窗口大小为 20 时在探索充分性与调整及时性之间取得了较优平衡，使多智能体能够更稳定地收敛至最优电压越限率与网络损耗水平。

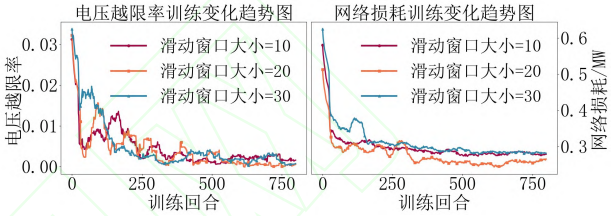


图 6 不同滑动窗口大小下电压越限率和网损的收敛曲线

Fig.6 Convergence curves of voltage violation rate and line loss under different sliding window sizes

表 2 不同滑动窗口大小下 LLM 动态调整次数情况

Tab. 2 LLM dynamic adjustment frequency under different sliding window sizes

滑动窗口大小	LLM 动态调整次数
10	8
20	6
30	4

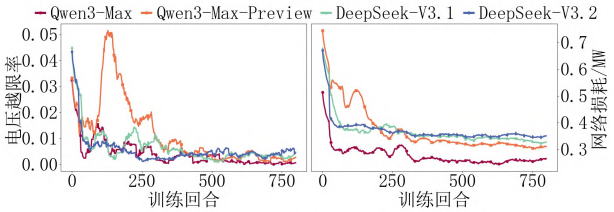


图 7 不同大模型下电压越限率和网损的收敛曲线

Fig.7 Convergence curves of voltage violation rate and line loss under different LLM

图 7 探究了不同版本大模型对无功调压性能的影响。结果表明，四者均能引导策略收敛，但 Qwen3-Max 在降损与抑制电压越限方面表现最优；DeepSeek 系列虽能稳定电压，但网损显著偏高，说明上下文能力更强且推理能力均衡的大模型在分析多轮奖励函数迭代的历史反馈时具备更优的全局寻优能力。同时，Qwen3-Max-Preview 在训练前期引发了明显的策略震荡，且网损高于 Max 正式版。说明模型版本的迭代与成熟度提升能增强上下

文逻辑与代码生成的稳定性，从而为智能体提供更高质量的奖励函数，引导智能体向最优策略收敛。

图 8 展示了混合奖励函数设计与调整的过程，并对其中的关键修改环节进行了可视化标注，包括智能体 5 的初始奖励函数、第 3 次调整、第 5 次调整及最终调整结果。由图 8 分析可知，在系统提示

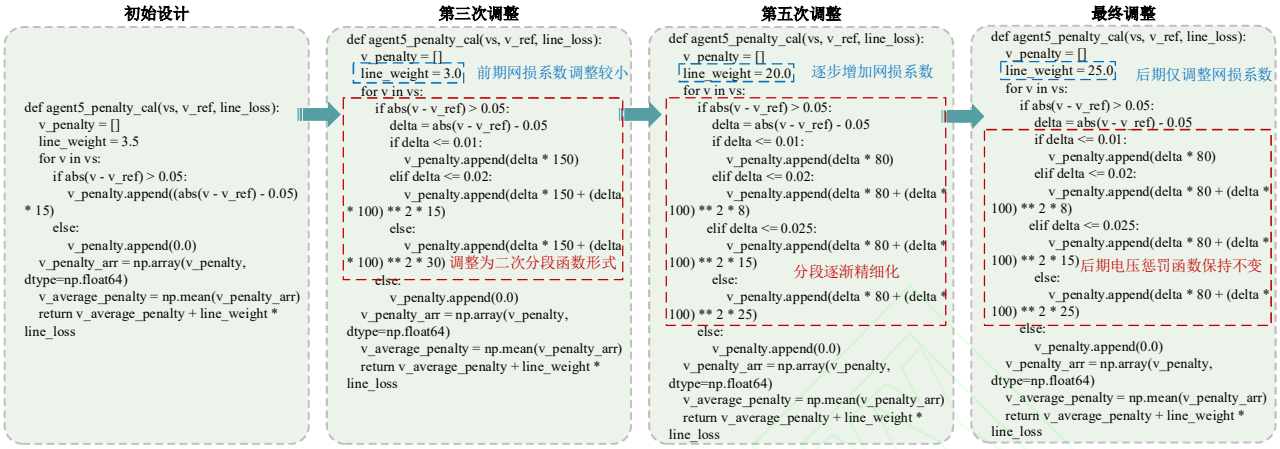


图 8　大模型动态调整混合奖励函数示例图

Fig. 8　Illustration of dynamically modifying the hybrid reward function with LLM

词的引导下，大模型能够识别配电网的区域划分、智能体的配置状态以及电压安全阈值等信息。通过提示词的显式约束，LLM 针对电压越限这一核心安全约束，为多智能体差异化地构建了合理的混合奖励函数。此外，LLM 严格遵循给定的 Python 代码模板，生成的奖励函数代码在整个训练周期内均未出现语法错误，具备高度的可执行性。因此，LLM 能够理解配电网无功电压调控任务的内在机理及其运行安全规定，生成合理的混合奖励函数。

进一步观察图 8 展示的混合奖励函数迭代过程可知，在训练前期，LLM 仅微调网损系数而专注于局部电压奖励项的探索，基于反馈提示词中的反馈信息在函数空间内执行随机性搜索，挖掘具备更高安全性的电压惩罚函数。当识别出分段二次分段函数能够提升智能体安全性能，LLM 会进入函数模式确定阶段，锁定其数学结构并逐渐增加分段精细度。最后，在电压越限问题被稳步改善后，LLM 专注于网损系数的校准，以实现经济性与安全性的协同优化。最终，智能体 5 混合奖励函数的电压越限惩罚函数 f 和网损惩罚项 c^{loss} 的如下式所示：

$$r_5 = -\left(c_5^{\text{v}} + c^{\text{loss}}\right) \tag{15}$$

$$c^{\text{loss}} = 50\,p^{\text{loss}} \tag{16}$$

$$c_5^{\text{v}} = \frac{1}{N_5}\sum_{i=1}^{N_5} f\left(V_i - V_{\text{r}}\right) \tag{17}$$

$$f = \begin{cases} 0, \Delta \le 0.05 \\ 80\Delta, 0.05 < \Delta \le 0.06 \\ 80\Delta + (100\Delta)^2 \times 8, 0.06 < \Delta \le 0.07 \\ 80\Delta + (100\Delta)^2 \times 15, 0.07 < \Delta \le 0.075 \\ 80\Delta + (100\Delta)^2 \times 25, \ \Delta > 0.075 \end{cases} \tag{18}$$

$$\Delta = |V_i - V_{\text{r}}| \tag{19}$$

式中：r_5 为智能体 5 的奖励；c_5^{v} 为局部奖励项，表示智能体 5 控制区域内所有节点电压越限惩罚的平均值。；f 为电压惩罚函数；V_{r} 代表电压基准值，该函数对上下越限采用对称结构；N_5 表示智能体 5 控制区域内的节点数目；V_i 代表智能体控制区域内节点 i 的电压幅值；c^{loss} 为全局奖励项，表示网损惩罚值；p^{loss} 为网络损耗。

图 9 展示了本文所提方法在训练全周期内电压越限率与网络损耗的收敛过程，其中蓝色标记点表示 LLM 调整奖励函数的时刻。在训练前 300 个回合的初步探索阶段，电压越限率和网损均呈现较大幅度的波动，表明前期设计的奖励函数难以有效兼顾安全约束和经济性；随着训练的推进，LLM 基于测试反馈对混合奖励函数的数学结构及权重系数进行动态重构，调整了智能体的优化方向。在持续的动态引导下，智能体逐步收敛至最优策略，电压越限率呈稳步下降趋势并在 600 回合后收敛至 0 附近；同时，网络损耗也在满足电压安全约束的前提下稳定在较低水平，实现了两者的协同优化。尽管

LLM 的干预引入了奖励非平稳性，但由于奖励重标记机制，策略在干预点后并未出现剧烈震荡，保障了物理指标的稳态收敛，验证了所提策略在提升配电网安全性与经济性方面的有效性。

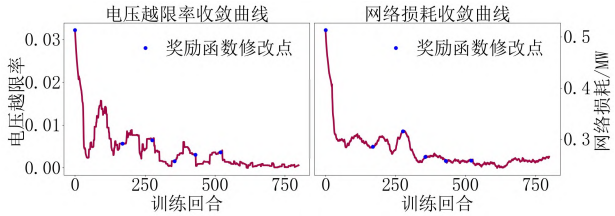


图 9 所提方法的电压越限率和网损的收敛曲线

Fig. 9 Convergence curves of voltage violation rate and line loss for the proposed method

3.3 强化学习智能体控制性能分析

为验证本文提出的基于大语言模型辅助的多智能体深度强化学习框架在无功调压任务中的有效性，并考察 MAAC 算法在其中的作用，设计了以下四组对比实验：

方案一：本文所提方法，引入大模型辅助，采用多智能体差异化奖励机制，并基于 MAAC 算法进行训练；

方案二：未引入大模型辅助，保留多智能体差异化奖励机制，基于 MAAC 算法进行训练；

方案三：未引入大模型辅助，保留多智能体差异化混合奖励机制，基于 MADDPG 算法进行训练；

方案四：未引入大模型辅助，采用传统的多智能体共享奖励机制，基于 MAAC 算法进行训练。

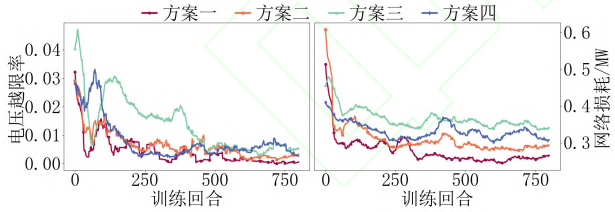


图 10 不同训练方案下电压越限率和网损的收敛曲线

Fig. 10 Convergence curves of voltage violation rate and line loss under different training method

图 10 展示了四种方案下智能体在整个训练过程中电压越限率与网络损耗的变化趋势。观察结果可知，在训练初期，四种方案均呈现出高电压越限率与高网络损耗的特征。随着训练的推进，各项指标逐渐下降并趋于稳态，表明智能体逐步在电压安全性与运行经济性之间实现协同优化。进一步观察可知，虽然方案一在整个训练周期存在阶段性波动，但整体指标逐渐下降，并实现了最低的电压越限率和网络损耗。这一优越的收敛性能主要归因于 LLM 的动态辅助机制能够有效调整混合奖励函数，引导智能体控制策略向全局最优收敛，从而取得了最佳的协同优化效果。

为验证本文选用的 MAAC 算法基础框架的优越性，引入了基于 MADDPG 算法的方案三作为基准对照组。对比结果显示，采用 MAAC 算法的方案二在各项指标的收敛表现上均显著优于方案三。配电网无功调压属于典型的高维连续动作控制任务，MADDPG 算法在处理众多分布式设备时极易陷入信用分配困境[28]；相比之下，基于 MAAC 算法的评价网络引入了注意力机制，使每个智能体在参数更新过程中有选择性地提取其余智能体的关键信息，从而在复杂的连续动作空间中保证了策略更新的准确性与平稳性。

此外，将采用差异化混合奖励机制的方案二与采用传统共享奖励机制的方案四对比可知，方案二的网络损耗与电压越限率均低于方案四。这一结果证实了差异化奖励机制能够克服多智能体信用分配问题，使各智能体能够兼顾局部状态信息与全局优化目标，从而实现更准确的策略更新与更优的全局协同性能。

表 3 方案一与方案二、方案五的计算时间成本对比

Tab. 3 Comparison of computational time overheads among Scheme 1, Scheme 2, and Scheme 5

方案	单次调用 LLM 平均耗时/s	训练总耗时/h	决策平均耗时/s
方案一	38.45	4.73	0.037 5
方案二	0	4.54	0.037 6
方案五	0	0	0.580 0

为了评估所提策略的工程实用性，本文对引入 LLM 前后的时间成本进行了量化分析，并增设了基于数学模型驱动的无功调压策略（方案五）作为对照组之一。由表 3 可知，在离线训练阶段，方案一需与大模型进行程序化交互，从而引入了额外的 LLM 计算时间，其单次 API 调用平均耗时约为 38.45 秒，导致总训练时间高于方案二；同时，该阶段的通信仅通过互联网对 LLM 进行 API 调用，无需为配电网部署额外的专用通信链路，且其通信时间已涵盖在上述 API 调用耗时中。然而，当处于在线分布式执行阶段，智能体仅依据本地实时观测直接

输出无功功率调节指令，智能体之间无需进行数据交互，此过程不再依赖 LLM 的实时反馈，因此不会产生任何与 LLM 相关的计算开销和通信开销。因此，尽管方案一引入 LLM 在离线阶段增加了一定的训练成本，但智能体决策推理耗时与方案二几乎相同，系统的实时响应能力未受负面影响。此外，由于 LLM 仅参与离线阶段的奖励函数辅助设计，实际工程在线部署时，仅需部署训练完成的轻量级 MADRL 智能体即可，端侧无需配置大模型推理算力，也不依赖持续的 API 调用，因此并未增加实质性的在线部署硬件成本与运行代价。在此基础上，进一步对比各方案的在线决策效率可以发现，基于 MADRL 算法的方案一和方案二的决策耗时远少于基于数学模型的方案五，显著提升了决策效率，充分证明了所提策略在提升配电网无功调压安全性与经济性的同时，能够满足实际工程部署中的在线实时控制需求。

在模型评估阶段，为了全面评估智能体在不同工况下的控制性能与泛化能力，本文采用分层随机采样策略从测试集中选取测试样本。该测试样本涵盖四个季节，每个季节随机抽取 3 个典型日，共计 12 天、576 0 组样本。表 4 统计了各方案在测试样本上的性能指标，包括电压越限次数、电压越上限最大值、电压越下限最小值以及网络损耗的均值与方差。统计结果显示，与无控制措施的“优化前”场景相比，五种方案在安全性与系统经济性方面均取得了显著的改善效果。在 MADRL 算法性能层面，基于 MAAC 算法的方案二与方案四在电压稳定性与经济性指标上均优于基于 MADDPG 算法的方案三，表明了在光伏海量接入的高维状态-动作空间下，MAAC 算法特有的注意力机制使智能体展现出更强的策略鲁棒性。

表 4　各训练方案在测试样本上的智能体性能对比

Tab. 4　Performance comparison of agents across different training schemes on test samples

训练方案	电压越限次数/次		电压越上限最大值/p.u.		电压越下限最小值/p.u.		网损/MW	
	平均值	方差	平均值	方差	平均值	方差	平均值	方差
优化前	4.395 1	57.967	1.068 1	0.000 170	0.943 8	0.000 14	0.440 9	0.027 157
方案一	0	0	0	0	0	0	0.250 7	0.004 811
方案二	0.164 7	1.228 6	1.055 3	0.000 013	0	0	0.272 5	0.004 846
方案三	1.308 4	10.259	0	0	0.945 6	0.000 07	0.344 0	0.009 023
方案四	0.217 3	1.346 6	0	0	0.948 2	0.000 02	0.295 1	0.005 932
方案五	0	0	0	0	0	0	0.232 7	0.005 071

针对 RL 奖励机制的实验分析表明，引入差异化混合奖励机制的方案二相较于传统共享奖励机制的方案四，电压越限次数由 0.217 3 次下降至 0.164 7 次，网损均值由 0.295 1 MW 降至 0.272 5 MW。这一结果证实，差异化奖励机制能更有效地引导智能体在局部电压约束与全局经济目标之间寻找最优平衡点。

为进一步验证所提策略的优越性，本文将方案一与表现较好的方案二、以及代表理想控制效果方案五进行了多维度的对比。结果显示，方案五凭借确定性数学模型约束，实现了零电压越限的绝对安全保证；然而，此类传统模型驱动策略面临极高的计算复杂度，其实际应用难以满足配电网环境下的实时响应需求。相比之下，本文所提的方案一实现了所有 MADRL 方案中最低的网损均值与最小的网损方差，同时消除了电压越限次数。这表明，所提策略在具备快速决策优势的同时，其电压控制性能与模型驱动基准相当，且在降低网络损耗方面逼近模型驱动基准，验证了该策略在配电网无功电压控制中的有效性和优越性。

为了直观展示各方案在典型日内的电压控制性能，本文从测试集中随机选取一个典型日的运行数据（480 个时间节点），分析各节点的电压极值变化及网络损耗情况。表 5 与图 11 分别展示了该典型日下各方案的网损统计指标及电压极值的时序变化趋势。

根据表 5 的统计数据，方案一在网损的平均值、最大值及最小值三项关键指标上均低于其他 MADRL 方案，方案五虽取得了最低的网损均值，但存在较大的网损波动。这一结果表明，在所提策略的引导下，智能体的动作不仅能够满足电压安全约束，还能在可行域内搜索到兼顾经济性的更优运行

点，体现了较强的全局寻优能力。结合图 11 进一步分析可见，在光伏出力高峰时段，系统面临过电压风险。方案二未能有效抑制电压越限，系统最高电压明显超过 1.05 p.u.的安全上限。相比之下，本文所提方案将系统最高电压有效限制在安全阈值以内，其电压曲线峰值显著低于方案二。在傍晚负荷高峰时段，系统主要面临低电压挑战。从最低电压幅值变化曲线可以看出，方案三和方案四出现了电压幅值逼近甚至跌落安全下限以下的情况；而在该时段内，方案一各节点电压幅值始终保持在 0.95 p.u.以上，展现出更优的电压调节能力。整体而言，方案一不仅在电压控制水平上接近理想状态的方案五，还有效保证了在线调节的实时性，充分证明了该策略在配电网无功调压实际任务中的有效性与工程应用价值。

表 5　各方案在某典型日内的网损统计结果

Tab. 5　Statistical results of power loss for different schemes on a typical day

训练方案	网损/MW			
	最大值	最小值	平均值	方差
方案一	0.396 0	0.159 1	0.255 1	0.004 2
方案二	0.424 1	0.176 8	0.280 1	0.004 8
方案三	0.558 8	0.256 1	0.351 0	0.008 0
方案四	0.451 3	0.195 6	0.299 3	0.005 3
方案五	0.368 2	0.066 7	0.233 7	0.005 0

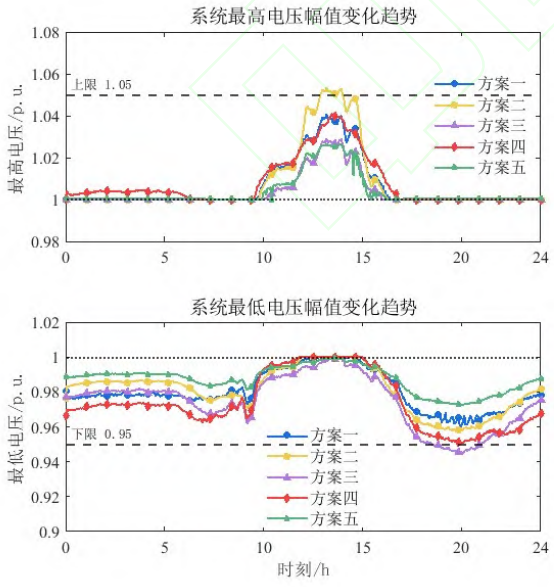


图 11　各方案在某典型日内的系统电压极值变化趋势图

Fig. 11　Trend of system voltage extrema under various schemes on a typical day

4　结论与展望

本文围绕高比例分布式光伏接入背景下的配电网无功调压难题，提出了一种基于大语言模型辅助多智能体深度强化学习的无功调压策略。以区域光伏控制器为智能体，构建了基于 MAAC 算法的无功控制框架。同时，设计了一种由全局网损惩罚项与局部电压越限惩罚项组合而成的差异化混合奖励函数，将 LLM 作为高层认知模块嵌入强化学习训练闭环，基于智能体反馈信息对奖励函数进行动态调整，并结合奖励重标记机制提升训练稳定性。最后，在 IEEE 141 节点系统的仿真结果验证了所提策略在提升配电网运行安全性与经济性方面的有效性与优越性。

尽管已在仿真中验证本文方法的有效性，但仍存在若干值得深入研究的工作：一是开展电力专用大模型的训练或微调，探究其在加速策略收敛与提升无功调压性能上限方面的实际效果；二是探索多时间尺度下与传统调压设备的协同控制机制。

参考文献

[1] 王勇，王颖. 中国实现碳减排双控目标的可行性及最优路径——能源结构优化的视角[J]. 中国环境科学, 2019, 39(10): 4444-4455.
Wang Yong., Wang Ying. Feasibility and Optimal Path for Achieving China's Dual Carbon Emission Control Targets: From the Perspective of Energy Structure Optimization[J]. China Environmental Science, 2019, 39(10): 4444-4455(in Chinese).

[2] 杨龙月，任烜辰，蔡智鹏，等. 高光伏渗透率配电网电压控制策略研究综述[J]. 电网技术，2024，48(12): 5056-5070.
Yang Longyue., Ren Xuanchen., Cai Zhipeng, et al. A Review of Voltage Control Strategies for Distribution Networks with High Photovoltaic Penetration[J]. Power Grid Technology, 2024, 48(12): 5056-5070(in Chinesee).

[3] Dall'Anese E, Dhople S V, Giannakis G B. Optimal dispatch of photovoltaic inverters in residential distribution systems[J]. IEEE Transactions on Sustainable Energy, 2014, 5(2): 487-497.

[4] 习伟，李鹏，李鹏，等. 基于深度强化学习的分布式电源就地自适应电压控制方法[J]. 电力系统自动化, 2022, 46(22): 25-31.
Xi Wei, Li Peng, Li Peng, et al. A Local Adaptive Voltage Control Method for Distributed Generators Based on Deep Reinforcement Learning[J]. Automation of Electric Power

Systems, 2022, 46(22): 25–31 (in Chinese).

[5] 王甜婧, 汤涌, 王兵, 等. 传统方法与人工智能:潮流控制优化算法的现状、挑战与未来方向[J]. 中国电机工程学报, 2023, 43(5): 1799-1818.
Wang Tianjing, Tang Yong, Wang Bing, et al. Traditional Methods versus Artificial Intelligence: Current Status, Challenges, and Future Directions of Power Flow Control Optimization Algorithms[J]. Proceedings of the CSEE , 2023, 43(5): 1799–1818 (in Chinese).

[6] 李琦, 乔颖, 张宇精. 配电网持续无功优化的深度强化学习方法[J]. 电网技术, 2020, 44(4): 1473-1480.
Li Qi, Qiao Ying, Zhang Yujing. A Deep Reinforcement Learning Approach for Continuous Reactive Power Optimization in Distribution Networks[J]. Power System Technology, 2020, 44(4): 1473–1480 (in Chinese).

[7] 刘硕, 冯斌, 郭创新, 等. 考虑自注意力和时序记忆的深度强化学习配电网无功电压控制策略[J]. 中国电机工程学报, 2025, 45(2): 565-577.
Liu Shuo, Feng Bin, Guo Chuangxin, et al. A Deep Reinforcement Learning-Based Reactive Power and Voltage Control Strategy for Distribution Networks Considering Self-Attention and Temporal Memory[J]. Proceedings of the CSEE, 2025, 45(2): 565–577 (in Chinese).

[8] 胡丹尔,彭勇刚,韦巍,等.多时间尺度的配电网深度强化学习无功优化策略[J].中国电机工程学报,2022,42(14):5034-5045.
Hu Daner, Peng Yonggang, Wei Wei, et al. Multi-timescale Deep Reinforcement Learning Strategy for Reactive Power Optimization of Distribution Network[J]. Proceedings of the CSEE, 2022, 42(14): 5034-5045 (in Chinese).

[9] Cao D, Zhao J, Hu W, 等. Deep Reinforcement Learning Enabled Physical-Model-Free Two-Timescale Voltage Control Method for Active Distribution Systems[J]. IEEE Transactions on Smart Grid, 2022, 13(1): 149-165.

[10] 耿骏,李正烁.面向三相不平衡配电网双模公平-安全多智能体深度强化学习的电压优化控制[J/OL].中国电机工程学报,1-15[2026-03-27].https://link.cnki.net/urlid/11.2107.tm.20250808.1437.004.
Geng Jun, Li Zhengshuo. Voltage Optimization Control for Three-phase Unbalanced Distribution Network Based on Dual-mode Fairness-Security Multi-agent Deep Reinforcement Learning[J/OL]. Proceedings of the CSEE, 1-15 [2026-03-27]. https://link.cnki.net/urlid/11.2107.tm.20250808.1437.004.

[11] 全欢, 彭显刚, 刘涵予, 等. 基于深度强化学习的配电网实时电压优化控制方法[J]. 电网技术, 2023, 47(5): 2029-2039.
Quan Huan, Peng Xiangang, Liu Hanyu, et al. A Real-Time Voltage Optimization Control Method for Distribution Networks Based on Deep Reinforcement Learning[J]. Power System Technology, 2023, 47(5): 2029-2039 (in Chinese).

[12] Zhang Y, Wang X, Wang J, et al. Deep reinforcement learning based volt-var optimization in smart distribution systems[J]. IEEE Transactions on Smart Grid, 2020, 12(1): 361-371.

[13] Ma Y J, Liang W, Wang G, et al. Eureka: Human-level reward design via coding large language models[J]. arXiv preprint arXiv:2310.12931, 2023.

[14] Wang J, Xu W, Gu Y, et al. Multi-agent reinforcement learning for active voltage control on power distribution networks[J]. Advances in neural information processing systems, 2021, 34: 3271-3284.

[15] Hossain R, Gautam M, MansourLakouraj M, et al. Topology-Aware Reinforcement Learning for Voltage Control: Centralized and Decentralized Strategies[J]. IEEE Transactions on Industry Applications, 2025.

[16] 杨迪,王辉,杨睿彤,等.基于自适应奖励函数-多智能体深度强化学习的移动储能时空调度策略[J/OL].中国电机工程学报,1-13[2026-01-23].https://doi.org/10.13334/j.0258-8013.pcsee.251329.
Yang Di, Wang Hui, Yang Ruitong, et al. Mobile Ene-rgy Storage Spatio-Temporal Dispatch Strategy Based on Adaptive Reward Function–Multi-Agent Deep Reinforcement Learning [J/OL]. Proceedings of the CSEE, 2026: 1–13 [2026-01-23].https://doi.org/10.13334/j.0258-8013.pcsee.251329

[17] Cao Y, Zhao H, Cheng Y, et al. Survey on Large Language Model-Enhanced Reinforcement Learning: Concept, Taxonomy, and Methods[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2024: 1-21. DOI:10.1109/TNNLS.2024.3497992.

[18] 赵俊华, 文福拴, 黄建伟, 等. 基于大语言模型的电力系统通用人工智能展望：理论与应用[J]. 电力系统自动化, 2024, 48(6): 13-28.
Zhao Junhua, Wen Fushuan, Huang Jianwei, et al. Prospect of General Artificial Intelligence in Power Systems Based on Large Language Models: Theory and Applications[J]. Automation of Electric Power Systems, 2024, 48(6): 13-28 (in Chinese).

[19] Sun S, Liu R, Lyu J, et al. A large language model-driven reward design framework via dynamic feedback for reinforcement learning[J]. Knowledge-Based Systems, 2025, 326: 114065.

[20] Yu J, Wang Y, Ma W. Large language model-enhanced reinforcement learning for generic bus holding control strategies[J]. Transportation Research Part E: Logistics and Transportation Review, 2025, 200: 104142.

[21] Wei Y, Shan X, Li J. LERO: LLM-driven Evolutionary framework with Hybrid Rewards and Enhanced Observation for Multi-Agent Reinforcement Learning[A]. arXiv, 2025.

[22] Yang X, Lin C, Liu H, et al. Rl2: Reinforce large language model to assist safe reinforcement learning for energy management of active distribution networks[J]. IEEE Transactions on Smart Grid, 2025.

[23] Li J, Xu Z, Zhao J, et al. Distributed Online Voltage Control in Active Distribution Networks Considering PV Curtailment[J]. IEEE Transactions on Industrial Informatics, 2019, 15(10): 5519-5530.

[24] Duan J, Shi D, Diao R, et al. Deep-reinforcement-learning-based autonomous voltage control for power grid operations[J]. IEEE Transactions on Power Systems, 2019, 35(1): 814-817.

[25] Lee K, Smith L, Abbeel P. Pebble: Feedback-efficient interactive reinforcement learning via relabeling experience and unsupervised pre-training[J]. arXiv preprint arXiv:2106.05091, 2021.

[26] 李彬贤, 李佳勇, 海征, 等. 基于多智能体深度强化学习的配电网三相不平衡在线治理方法[J]. 中国电机工程学报, 2025, 45(5): 1729-1741.
Li Binxian, Li Jiayong, Hai Zheng, et al. An Online Mitigation Method for Three-Phase Unbalance in Distribution Networks Based on Multi-Agent Deep Reinforcement Learning[J]. Proceedings of the CSEE, 2025, 45(5): 1729–1741 (in Chinese).

[27] 路小俊, 吴在军, 李培帅, 等. 面向光伏集群的配电网模型-数据联合驱动无功/电压控制[J]. 电力系统自动化, 2024, 48(9): 97-106.
Lu Xiaojun, Wu Zaijun, Li Peishuai, et al. Model-Data Joint-Driven Reactive Power/Voltage Control for Dis-tribution Networks with Photovoltaic Clusters[J]. Automation of Electric Power Systems, 2024, 48(9): 97–106 (in Chinese).

[28] Iqbal S, Sha F. Actor-attention-critic for multi-agent reinforcement learning[C]//International conference on machine learning. PMLR, 2019: 2961-2970.

[29] Gupta A, Pacchiano A, Zhai Y, et al. Unpacking reward shaping: Understanding the benefits of reward engineering on sample complexity[J]. Advances in Neural Information Processing Systems, 2022, 35: 15281-15295.

收稿日期：2026-02-10