基于知识图谱增强大语言模型强化微调的配电网动态重构

陈宗源[1]，余 涛[1]，卢建刚[2]，潘振宁[1]，罗庆全[1]，周国勋[1]
（1. 华南理工大学电力学院，广东省广州市 510641；2. 广东电网有限责任公司，广东省广州市 510180）

摘要：配电网动态重构通过调整拓扑结构可实现更灵活的运行调控，但现有决策技术难以兼顾计算的实时性和可靠性。大语言模型凭借强大的语义理解、上下文学习与生成式决策能力，在配电网动态重构等复杂决策问题中展现出应用潜力。然而，直接将其应用于动态重构优化面临着结构化领域知识缺失、任务理解与适应能力不足、物理约束嵌入困难等问题，决策可靠性难以保障。为此，提出了基于知识图谱增强大语言模型强化微调的配电网动态重构方法。首先，构建动态知识图谱显式表征配电网运行的时序演化与因果逻辑关系；其次，通过知识图谱子图采样生成高质量微调数据集，对预训练大语言模型进行监督微调以提升其任务理解与指令响应能力；最后，基于知识图谱结构化先验知识设计多维度奖励函数，引入群组相对策略优化对模型进行强化微调。算例分析表明，所提方法显著提升了配电网动态重构策略的生成效率和物理一致性，有效提高了配电网运行水平。

关键词：配电网；动态重构；大语言模型；人工智能；强化；微调；运行调控；知识图谱

0 引言

随着双碳目标的加速推进，海量具有强随机波动特性的分布式新能源和电动汽车接入配电网，显著加剧了净负荷时空分布不均，进而引发网损增加、电压越限、新能源弃电等问题，严重威胁系统安全经济运行[1-2]。作为应对上述挑战的重要手段，配电网动态重构通过灵活调整开关状态实现拓扑结构实时优化，有效提升系统灵活调控能力[3]。

配电网动态重构涉及离散、连续及随机变量，包含大量非线性约束，本质为高维、复杂的混合整数非线性随机优化问题。近年来，国内外学者围绕配电网动态重构开展了大量研究，包括模型驱动的数学优化方法和数据驱动的人工智能方法。数学优化方法通过模型简化技术对模型进行松弛，以实现可解性[4]，但在应用于大规模配电网时求解耗时长，无法满足实时运行调控需求[5-7]。人工智能方法摆脱了对系统物理机理显式建模的依赖，可显著降低计算复杂度[8-9]。文献[10]提出了基于强化学习的双层求解模型，以实现主动配电网动态重构协同优化。文献[11]提出了一种两阶段多智能体强化学习方法进行配电网动态重构。强化学习方法提升了决策效率，可以支撑实时决策，但其物理嵌入依赖于奖励函数中的惩罚项设计或仿真环境中的规则设定。由于强化学习方法难以有效处理文本类知识，特别是在理解配电网运行规程和专家经验等领域知识方面存在不足，而这些知识往往包含复杂的时序演化与因果逻辑关系，难以通过简单的规则或惩罚项进行解析和表达。因此，现有强化学习方法在应对复杂动态环境时策略探索能力受限，难以充分保障决策可靠性[12-13]。

近年来，大语言模型（large language model，LLM）凭借强大的语义理解、上下文学习与生成式决策能力，在复杂决策任务中展现出独特优势，为解决上述问题提供了新的技术路径[14]，已有研究初步探索了其在电力系统决策任务中的应用潜力。文献[15]提出将LLM应用于实时最优潮流计算中，通过其语义理解能力解析自然语言形式的电网规程，并转化为强化学习中的奖励函数。文献[16]则将LLM应用于主动配电网能源管理中，使其理解能源管理问题和安全约束并生成惩罚函数，引导强化学习智能体进行策略更新。上述研究展现了LLM在规则解析与语义理解方面的潜力，但其角色仍局限于辅助传统强化学习智能体进行策略更新，尚未作为决策主体发挥其生成式决策能力[17]。

与传统小模型相比，LLM作为决策主体的突出优势在于其强大的语义理解、上下文学习和快速适

收稿日期：2025-07-19；修回日期：2025-11-03。
上网日期：2026-01-07。
智能电网国家科技重大专项资助项目（2024ZD0802200）。

中国知网 https://www.cnki.net

应复杂决策任务的能力。LLM不仅能够准确解析复杂的指令和文本输入，还可以有效融合配电网运行规程、专家经验等领域知识[18]。LLM的上下文学习能力可支撑其在多轮交互过程中保持任务的上下文信息，有效捕捉电网决策任务的长期依赖关系。与传统小模型依赖海量标注样本不同，LLM通过少量高质量样本进行监督微调，即可完成对复杂决策任务的快速理解与初始策略学习[19]。通过结构化知识引导和强化微调，LLM可在探索试错中快速响应环境变化并生成可靠的决策策略，进一步提升其在复杂动态环境中的自主决策能力[20]。

然而，利用LLM直接实现电网复杂任务的端到端决策，仍处于起步阶段。以配电网动态重构为例，LLM的应用需要解决以下关键挑战：1)现有LLM微调数据集的生成高度依赖人工经验进行样本标注，无法对配电网多源异构运行数据中蕴含的复杂时序演化与因果逻辑关系进行高效建模，限制了样本生成的规模与多样性；2)在缺乏先验知识注入的情况下，直接对预训练LLM进行强化微调，使得模型难以理解动态重构任务指令与最优开关动作之间的语义映射关系，导致策略搜索空间过大、优化路径不明确；3)现有LLM强化微调多数关注自然语言层面的格式规范性及内容准确性，缺乏面向动态重构任务物理约束与运行目标的反馈机制，模型决策的可靠性难以保障。

为应对上述挑战，亟须利用结构化知识引导LLM实现动态重构任务的理解与适应。作为结构化表达领域知识与实体关系的有效载体，知识图谱具备多源异构数据融合与复杂关系建模能力，通过先验知识注入可有效提升LLM在复杂决策任务中的决策可靠性[21]。近年来，已有研究将知识图谱与LLM相结合并应用于问答、推荐与逻辑推理等任务中，但现有方法多聚焦于静态知识建模、自然语言理解与文本语义推理，难以捕捉具有强时序演化特征和因果逻辑关系的系统状态动态变化，尚未见应用于配电网动态重构这一复杂决策任务的研究[22-23]。

本文提出了一种知识图谱增强LLM强化微调的配电网动态重构方法，主要工作如下：

1)融合海量多源异构数据，构建面向配电网动态重构的动态知识图谱，显式表征配电网中关键实体及其复杂耦合关系，为LLM微调训练提供结构化知识引导。

2)基于时间戳在知识图谱中进行子图采样，生成具备时序演化与因果逻辑的高质量微调数据集，通过监督微调预热训练提升LLM对配电网重构逻辑的语义理解与指令响应能力。

3)基于知识图谱结构化先验知识设计多维度奖励函数，引入群组相对策略优化(group relative policy optimization，GRPO)机制对LLM进行强化微调，引导模型在与环境交互试错中持续更新策略，进一步提升模型的推理能力和环境适应性。

采用改进的IEEE 33节点配电系统及南方某区域225节点配电网验证本文方法的可行性及优越性。结果表明，所提方法显著提升了配电网动态重构策略的生成效率和决策可靠性，有效提升了系统灵活调控能力。

1　配电网动态重构优化模型

1.1　目标函数

本文研究以一天为调度周期的配电网动态重构策略优化，综合考虑开关动作成本、网损降低、新能源消纳提升等多维运行优化目标：

$$\begin{cases}\min C_{\mathrm{DN}}=(C_{\mathrm{line}}+C_{\mathrm{loss}}+C_{\mathrm{RES}}+C_{\mathrm{BUY}})\\ C_{\mathrm{line}}=\sum_{t=1}^{T}\sum_{l\in\Psi_{\mathrm{L}}}c_{\mathrm{line}}[\alpha_{l,t-1}(1-\alpha_{l,t})+\alpha_{l,t}(1-\alpha_{l,t-1})]\Delta t\\ C_{\mathrm{loss}}=\sum_{t=1}^{T}\sum_{l\in\Psi_{\mathrm{L}}}c_{\mathrm{loss}}\,I_{l,t}^{2}r_{l}\Delta t\\ C_{\mathrm{RES}}=\sum_{t=1}^{T}\sum_{i\in\Psi_{\mathrm{RES}}}c_{\mathrm{RES}}(P_{i,t}^{\mathrm{RES,f}}-P_{i,t}^{\mathrm{RES}})\Delta t\\ C_{\mathrm{BUY}}=\sum_{t=1}^{T}\sum_{i\in\Psi_{\mathrm{s}}}c_{\mathrm{BUY},t}P_{i,t}^{\mathrm{sub}}\Delta t\end{cases}\tag{1}$$

式中：C_{DN}为综合运行成本；C_{line}、C_{loss}、C_{RES}和C_{BUY}分别为开关动作成本、网损成本、新能源弃电成本和配电网购电成本，其单位功率成本系数分别为c_{line}、c_{loss}、c_{RES}和$c_{\mathrm{BUY},t}$；$\alpha_{l,t}$为t时刻支路l的通断状态；r_l和$I_{l,t}$分别为支路l的电阻、电流值；Ψ_{L}为支路集合；Ψ_{RES}为连接新能源机组的节点集合，包括风电和光伏；Ψ_{s}为连接变电站的节点集合；$P_{i,t}^{\mathrm{RES,f}}$、$P_{i,t}^{\mathrm{RES}}$分别为节点i处新能源机组在t时刻的预测值和有功出力；$P_{i,t}^{\mathrm{sub}}$为节点i处变电站在t时刻的有功功率；T为调度周期，取24 h；Δt为一个调度时段的时长，取1 h。

1.2　约束条件

配电网辐射状运行的Distflow潮流约束为：

$$\begin{cases}P_{i,t}=P_{i,t}^{\mathrm{sub}}+P_{i,t}^{\mathrm{RES}}-P_{i,t}^{\mathrm{d}}\\ Q_{i,t}=Q_{i,t}^{\mathrm{sub}}+Q_{i,t}^{\mathrm{RES}}-Q_{i,t}^{\mathrm{d}}\end{cases}\tag{2}$$

$$U_{j,t}^{2}=U_{i,t}^{2}-2(P_{l,ij,t}r_{l}+Q_{l,ij,t}x_{l})+(r_{l}^{2}+x_{l}^{2})I_{l,ij,t}^{2}\tag{3}$$

中国知网 https://www.cnki.net

$$\begin{cases}\sum\limits_{i\in f(j)}\alpha_{l,ij,t}(P_{l,ij,t}-r_l I_{l,ij,t}^2)+P_{j,t}=\sum\limits_{h\in s(j)}\alpha_{l,jh,t}P_{l,jh,t}\\ \sum\limits_{i\in f(j)}\alpha_{l,ij,t}(Q_{l,ij,t}-x_l I_{l,ij,t}^2)+Q_{j,t}=\sum\limits_{h\in s(j)}\alpha_{l,jh,t}Q_{l,jh,t}\end{cases}\tag{4}$$

$$(U_{i,t}I_{l,ij,t})^2=P_{l,ij,t}^2+Q_{l,ij,t}^2\quad\alpha_{l,ij,t}=1\tag{5}$$

式中：i、j和j、h分别为支路的两端节点编号；$U_{i,t}$、$U_{j,t}$分别为节点i、j的电压幅值；$P_{i,t}$和$P_{i,t}^{\mathrm{d}}$分别为节点i处的有功功率和负荷有功值；$Q_{i,t}$、$Q_{i,t}^{\mathrm{sub}}$、$Q_{i,t}^{\mathrm{RES}}$及$Q_{i,t}^{\mathrm{d}}$分别为节点i处的无功功率、变电站无功功率、新能源机组的无功出力及负荷无功值；x_l为支路l的电抗；$\alpha_{l,ij,t}$、$\alpha_{l,jh,t}$分别为端节点是i和j、j和h的支路l的通断状态，其值为1表示导通，为0表示关闭；$f(j)$、$s(j)$分别为节点j的父、子节点集合；$P_{l,ij,t}$、$Q_{l,ij,t}$、$I_{l,ij,t}$分别为端节点是i、j的支路l的有功潮流、无功潮流和电流值。

节点电压与支路电流约束为：

$$\begin{cases}\underline{U}_i\leqslant U_{i,t}\leqslant\bar{U}_i\\ 0\leqslant I_{l,ij,t}\leqslant\bar{I}_{l,ij}\end{cases}\tag{6}$$

式中：$\bar{U}_i$、$\underline{U}_i$分别为节点i处电压幅值的上、下限；$\bar{I}_{l,ij}$为端节点是i、j的支路l的电流上限。

新能源机组出力约束为：

$$\begin{cases}P_i^{\mathrm{RES,min}}\leqslant P_{i,t}^{\mathrm{RES}}\leqslant P_i^{\mathrm{RES,max}}\\ Q_i^{\mathrm{RES,min}}\leqslant Q_{i,t}^{\mathrm{RES}}\leqslant Q_i^{\mathrm{RES,max}}\end{cases}\tag{7}$$

式中：$P_i^{\mathrm{RES,max}}$、$P_i^{\mathrm{RES,min}}$和$Q_i^{\mathrm{RES,max}}$、$Q_i^{\mathrm{RES,min}}$分别为节点i处新能源机组有功出力和无功出力上限、下限。

由于上述优化模型目标函数及约束条件中的平方项具有强非凸性，通过引入辅助变量$u_{i,t}$、$i_{l,ij,t}$及大M法对节点电压、线路潮流进行松弛，转换为混合整数二阶锥规划(mixed-integer second-order cone programming，MISOCP)模型。

$$u_{i,t}=U_{i,t}^2\tag{8}$$

$$i_{l,ij,t}=\frac{P_{l,ij,t}^2+Q_{l,ij,t}^2}{U_{i,t}^2}\tag{9}$$

$$\begin{cases}u_{i,t}-u_{j,t}\leqslant 2(P_{l,ij,t}r_l+Q_{l,ij,t}x_l)-\\ \qquad(r_l^2+x_l^2)i_{l,ij,t}+(1-\alpha_{l,ij,t})M\\ u_{i,t}-u_{j,t}\geqslant 2(P_{l,ij,t}r_l+Q_{l,ij,t}x_l)-\\ \qquad(r_l^2+x_l^2)i_{l,ij,t}-(1-\alpha_{l,ij,t})M\end{cases}\tag{10}$$

式中：M为一个足够大的常数。

$$\begin{cases}-\alpha_{l,ij,t}S_{l,ij}^{\max}\leqslant P_{l,ij,t}\leqslant\alpha_{l,ij,t}S_{l,ij}^{\max}\\ -\alpha_{l,ij,t}S_{l,ij}^{\max}\leqslant Q_{l,ij,t}\leqslant\alpha_{l,ij,t}S_{l,ij}^{\max}\end{cases}\tag{11}$$

式中：$S_{l,ij}^{\max}$为端节点是i、j的支路l的容量。

$$\begin{cases}\sum\limits_{i\in f(j)}(P_{l,ij,t}-r_l i_{l,ij,t})+P_{j,t}=\sum\limits_{h\in s(j)}P_{l,jh,t}\\ \sum\limits_{i\in f(j)}(Q_{l,ij,t}-x_l i_{l,ij,t})+Q_{j,t}=\sum\limits_{h\in s(j)}Q_{l,jh,t}\end{cases}\tag{12}$$

二阶锥松弛约束为：

$$\|[\,2P_{l,ij,t}\quad 2Q_{l,ij,t}\quad i_{l,ij,t}-u_{i,t}\,]^{\mathrm{T}}\|_2\leqslant i_{l,ij,t}+u_{i,t}\tag{13}$$

配电网通常被设计为闭环结构，并在开环状态下运行，需满足辐射状与连通性的拓扑约束：

$$\begin{cases}\sum\limits_{l\in\Psi_{\mathrm{L}}}\alpha_l=N_{\mathrm{b}}-N_{\mathrm{s}}\\ \alpha_l=\beta_{l,ij}+\beta_{l,ji}\\ \sum\limits_{i\in\Psi_{\mathrm{d}},j\in\Psi(i)}\beta_{l,ij}=1\\ \sum\limits_{i\in\Psi_{\mathrm{s}},j\in\Psi(i)}\beta_{l,ij}=0\end{cases}\tag{14}$$

式中：N_{b}为节点数；N_{s}为源节点数；Ψ_{d}为负荷节点集合；$\Psi(i)$为与节点i连接的节点集合；$\beta_{l,ij}$为0-1变量，i为j的父节点时取1，否则取0。

1.3　KGE-REFT-LLM模型框架

本文设计了基于知识图谱增强LLM强化微调(knowledge graph-enhanced reinforcement fine-tuning of large language model，KGE-REFT-LLM)的配电网动态重构框架，如图1所示。

首先，基于上述配电网动态重构优化模型抽取配电网动态重构知识，包括任务定义、基本概念、目标函数、约束条件等内容，完成知识图谱本体的自顶向下的构建。利用海量多源异构数据进行知识抽取，完成知识图谱自底向上的数据层构建。基于Neo4j图数据库平台完成模式层与数据层的融合建模，构建面向配电网动态重构的动态知识图谱。

其次，基于时间戳在知识图谱中进行子图采样，将结构化的子图转化为微调样本，生成高质量微调数据集，为LLM的微调训练提供高质量数据支撑。LLM的微调训练共分为以下2个阶段。

1)监督微调训练：第1阶段，基于少量高质量微调样本对预训练LLM进行监督微调训练。通过预热训练提升LLM对配电网重构逻辑的语义理解与指令响应能力，有效缩减强化微调阶段的策略搜索空间，显著提升策略学习的效率与稳定性。

2)强化微调训练：在监督微调后的LLM基础上，第2阶段基于海量高质量微调样本进行模型强化微调训练。基于动态知识图谱中的结构化先验知识设计多维度奖励函数，对模型策略更新进行知识引导。引入群组相对策略优化机制，提升模型在复杂动态环境中的策略探索能力与决策质量。

中国知网　https://www.cnki.net

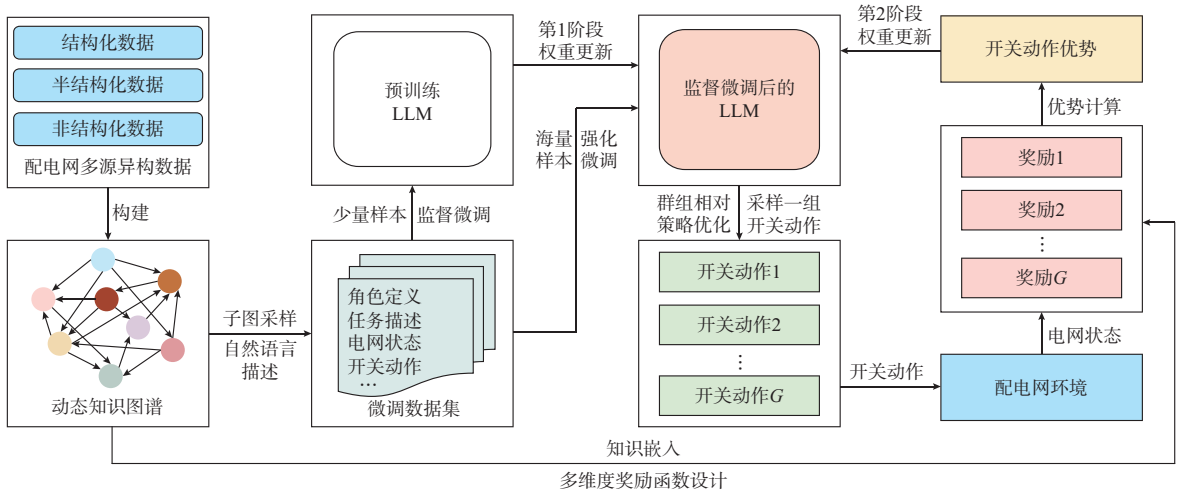


图1　基于KGE-REFT-LLM的配电网动态重构框架

Fig. 1　Dynamic reconfiguration framework of distribution network based on KGE-REFT-LLM

2　面向配电网动态重构的动态知识图谱

2.1　动态知识图谱定义

知识图谱是一种以图结构形式组织客观世界中实体、属性及其关系的语义网络，具备良好的多源异构数据融合与复杂关系建模能力，每一条知识可直观地表示为＜头实体，关系，尾实体＞的静态三元组。配电网动态重构本质上是一个多阶段决策过程，涉及多源异构运行数据的动态关联与持续演化。开关动作导致拓扑结构调整，进而影响潮流分布与电网运行状态，体现出显著的时序演化与因果逻辑关系。传统的静态三元组知识图谱通常难以刻画该时序动态特性。为此，在原有三元组基础上，引入时间戳信息，构建＜头实体，关系，尾实体，时间戳＞的动态四元组表示形式，将配电网运行的上下文语义、时序演化过程以及物理约束显式嵌入到结构化的图中，如图2所示。图中：不同颜色圆表示配电网中不同实体。

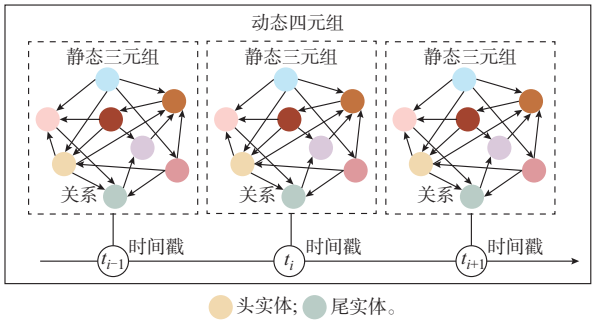


图2　知识图谱动态四元组示意图

Fig. 2　Schematic diagram of knowledge graph dynamic quadruple

2.2　动态知识图谱构建流程

面向配电网动态重构的动态知识图谱采用自顶向下、自底向上相结合的构建方法。构建流程可分为3个阶段：模式层构建、数据层构建与图谱集成实现。

首先，从配电网动态重构优化模型中抽取结构化的动态重构知识，包括任务定义、基本概念、目标函数、约束条件、运行规程等内容，这些知识为图谱本体的自顶向下构建提供了理论支撑。基于此建立包括多个本体在内的知识图谱模式层，如变电站本体、分段开关/联络开关本体、负荷本体、分布式光伏本体以及风电本体等。

其次，在配电网运行过程中积累了海量运行数据、运行方式变更单、调度日志以及专家经验，这些半结构化和非结构化数据中蕴含着丰富的配电网动态重构知识。采用规则驱动和半监督学习相结合的方式对上述数据进行知识抽取，通过实体对齐、关系映射等方式将抽取出的知识补充到已有本体结构中，完成知识图谱自底向上的数据层构建。

最后，完成模式层与数据层的融合建模，构建面向配电网动态重构的动态知识图谱。在知识图谱静态三元组基础上引入时间戳信息，形成动态四元组表示形式的图数据，有效表征配电网的时序演化与因果逻辑关系。基于Neo4j图数据库平台，可实现图数据的高效存储和可视化展示。此外，Neo4j图数据库的图查询语言支持对图数据的快速检索，能够准确追踪和分析配电网的动态变化过程。

构建完成的动态知识图谱主要从两个方面增强LLM的决策能力。首先，通过引入时间戳实现多源

中国知网 https://www.cnki.net

异构运行数据复杂时序关系的结构性表征，为LLM微调训练生成时序演化与因果逻辑关系的高质量微调数据集。其次，动态知识图谱融合了调度经验、运行规则、设备约束等多源异构知识，为LLM强化微调阶段的多维度奖励函数设计提供结构化先验知识，引导模型在与环境交互过程中实现更具物理一致性的策略优化。

3　LLM监督微调及强化微调

3.1　微调数据集构建

首先，通过时间戳在动态知识图谱中进行子图采样，采样后的子图不仅保留了原始图谱中的拓扑结构与语义关系，还捕捉了配电网动态重构前后状态变化及其上下文关联。基于时间戳采样的子图能够有效反映配电网运行状态的时间演化和因果逻辑。基于子图生成的微调样本能够有效支持后续的模型微调训练，帮助模型理解电网状态的时序依赖关系并捕捉因果关系，从而提升模型的任务理解和决策能力。

其次，依据LLM微调训练的输入输出格式规范，将结构化子图转化为自然语言描述的微调样本。具体而言，将子图中的关键实体、关系及其演化过程转化为“指令-输入-输出”文本对，构建可用于LLM微调训练的高质量微调数据集。微调数据集的指令包括配电网动态重构任务描述、目标函数、约束条件、输出格式要求；输入包括初始拓扑结构、线路阻抗信息、节点负荷预测数据、光伏出力预测数据、风电出力预测数据等配电网重构决策方案的关键影响因素；输出为最优的配电网重构方案。

高质量样本不仅要求在格式上符合微调训练的输入输出规范，还体现在内容的准确性和完整性上。与普通样本或低质量样本相比，高质量样本的指令描述更加精确，输入数据全面涵盖了影响配电网动态重构决策的关键因素，从而显著提升微调训练的稳定性。

在上述的子图采样和语义转换过程中，知识图谱中已有的实体、关系和属性信息可直接映射为微调样本中的关键元素，避免了人工逐条标注场景、构造微调样本的繁琐流程，从而显著降低人工标注的工作量和成本，为LLM在配电网动态重构任务的高效训练提供高质量的数据支撑。

3.2　LLM监督微调

直接对预训练LLM进行强化微调通常面临收敛缓慢、训练不稳定的问题，主要由于奖励信号稀疏且方差较高，难以提供稳定的优化梯度。此外，预训练LLM掌握的是通用语言模式，与配电网重构任务存在分布差异，直接进行强化微调容易导致模型探索效率低下，甚至陷入次优策略。

为缓解上述问题，首先通过少量高质量样本进行监督微调，向预训练LLM注入基础配电网动态重构知识，确保模型在强化微调阶段能够准确响应任务指令并按照输出格式要求进行决策，将模型引导至任务相关的策略搜索空间，显著提升策略学习的效率与稳定性。

基于构建完成的微调数据集，引入基于低秩自适应（low-rank adaptation，LoRA）微调的参数高效微调方法，对预训练LLM进行监督微调[24]。LoRA微调通过在预训练模型的线性变换层与多头自注意力机制层中引入可训练的低秩矩阵，同时冻结原始预训练参数，从而在保持模型原有表达能力的前提下，实现对配电网动态重构领域知识的高效嵌入。相比传统的全参数微调策略，LoRA微调大幅减少了模型更新所需的参数量与显存开销，有效提升了微调效率与资源利用率。

LoRA微调的示意图如图3所示。图中：$\mathcal{N}(0,\sigma^2)$为数学期望为0、方差为σ^2的高斯分布。

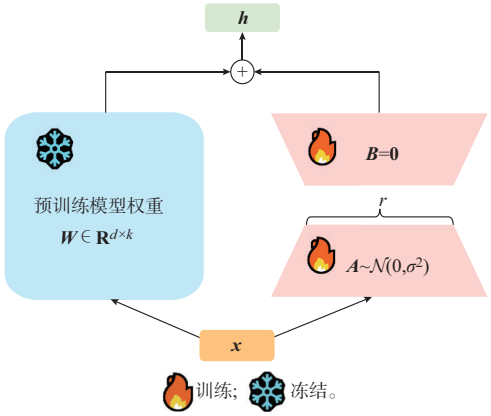


图3　LoRA微调示意图

Fig. 3　Schematic diagram of LoRA fine-tuning

对于预训练模型的权重矩阵$\boldsymbol{W}\in\mathbf{R}^{d\times k}$，其在训练过程中被冻结，不再进行梯度更新。训练过程仅更新增量权重矩阵$\Delta\boldsymbol{W}=\boldsymbol{BA}$，其中，$\boldsymbol{A}\in\mathbf{R}^{d\times r}$，$\boldsymbol{B}\in\mathbf{R}^{r\times k}$，$r\ll\min(d,k)$。分别采用随机高斯分布和零矩阵对低秩矩阵$\boldsymbol{A}$和$\boldsymbol{B}$进行初始化，微调过程中更新的矩阵$\boldsymbol{W}'$可以表示为：

$$\boldsymbol{W}'=\boldsymbol{W}+\frac{a}{r}\Delta\boldsymbol{W} \tag{15}$$

式中：r为增量权重矩阵$\Delta\boldsymbol{W}$的秩；a为缩放系数，可以控制低秩矩阵对原始权重的缩放比例。

在完成LoRA微调后，对于输入$\boldsymbol{x}$，模型的输出$\boldsymbol{h}$可以表示为：

中国知网　https://www.cnki.net

$$\boldsymbol{h}=\boldsymbol{W}'\boldsymbol{x}=\left(\boldsymbol{W}+\frac{a}{r}\Delta\boldsymbol{W}\right)\boldsymbol{x} \tag{16}$$

监督微调采用交叉熵损失函数$\mathcal{L}_{\mathrm{SFT}}$,其表达式如下:

$$\mathcal{L}_{\mathrm{SFT}}=-\frac{1}{N}\sum_{i=1}^{N}[\,y_i\log\hat{y}_i+(1-y_i)\log(1-\hat{y}_i)\,] \tag{17}$$

式中:N为批量训练样本数;y_i为第i个训练样本真实标签;$\hat{y}_i$为模型对第i个训练样本预测概率值。

3.3 LLM强化微调的多维度奖励函数设计

在完成对预训练LLM的监督微调后,模型已具备基础的配电网动态重构任务理解能力,能够遵循任务指令及输入数据生成配电网重构决策方案。然而,由于监督微调阶段依赖少量高质量样本,模型在面对未见工况、复杂场景时仍存在策略保守、适应性差的问题。

为进一步增强模型的策略探索能力与动态环境适应性,强化微调阶段基于动态知识图谱中的机理知识和专家经验设计多维度奖励函数。该奖励函数综合考虑了配电网动态重构任务的输出格式规范、目标函数和关键物理约束,为强化微调过程提供了结构化的奖励反馈机制,能够引导模型在与配电网仿真环境的交互过程中通过试错积累高质量决策经验。通过强化微调迭代训练,可有效提升模型在复杂动态环境下的决策能力。

多维度奖励函数包括奖励与惩罚两部分,用于评估并引导LLM的策略更新。

1)奖励部分

奖励主要由两部分构成:

一是模型输出结果在遵循输出格式方面的准确性奖励R_{format},针对模型输出结果中的关键词、时间戳、线路进行校验,用于引导模型生成符合指令要求和语义完整的决策,确保输出结果的准确性,并减少模型产生幻觉的概率。具体而言,模型输出应包含“配电网动态重构后打开线路集合为:”这一关键词,这是确保模型输出结果符合指令要求的首要步骤。其次,模型输出中的时间戳,需按时间顺序列出,并包含每个时间戳下的打开线路集合。最后,打开线路集合中的线路应确保在配电网的线路编号范围内。若上述任何一项没有通过校验,则奖励为0,表示模型输出不符合规范。

二是重构后系统运行成本降低奖励$R_{\mathrm{operation}}$,以引导模型生成满足经济性要求的最优重构方案,该奖励参考式(1)进行计算。

2)惩罚部分

惩罚部分主要针对配电网动态重构过程中违反关键物理约束的情况进行惩罚,包括节点电压越限、支路电流越限、电网拓扑环网等。通过在强化微调阶段施加上述惩罚,能够有效引导模型在生成重构策略时,主动规避不满足运行安全性的方案。

对于不满足式(6)所示的节点电压与支路电流约束的重构策略予以较高惩罚,对于约束范围内的动作则不设置惩罚。

节点电压惩罚P_{Volt}为:

$$P_{\mathrm{Volt}}=\begin{cases}P_{\mathrm{U}}(U_{\mathrm{ref}}+|U_{i,t}-\underline{U}_i|) & U_{i,t}<\underline{U}_i\\ P_{\mathrm{U}}(U_{\mathrm{ref}}+|U_{i,t}-\bar{U}_i|) & U_{i,t}>\bar{U}_i\\ 0 & \underline{U}_i\leqslant U_{i,t}\leqslant\bar{U}_i\end{cases} \tag{18}$$

式中:P_{U}为节点电压惩罚系数;U_{ref}为额定电压,取1.0 p.u.。

支路电流惩罚P_{Current}为:

$$P_{\mathrm{Current}}=\begin{cases}P_{\mathrm{I}}(I_{l,ij,t}-\bar{I}_{l,ij}) & I_{l,ij,t}>\bar{I}_{l,ij}\\ 0 & I_{l,ij,t}\leqslant\bar{I}_{l,ij}\end{cases} \tag{19}$$

式中:P_{I}为支路电流惩罚系数。

电网拓扑环网惩罚P_{Loop}为:

$$P_{\mathrm{Loop}}=\begin{cases}P_{\mathrm{f}} & \text{存在环网}\\ 0 & \text{不存在环网}\end{cases} \tag{20}$$

式中:P_{f}为电网拓扑环网惩罚系数。

综合奖励部分及惩罚部分,多维度奖励函数r_{DNR}计算如下:

$$r_{\mathrm{DNR}}=R_{\mathrm{format}}+R_{\mathrm{operation}}-P_{\mathrm{Volt}}-P_{\mathrm{Current}}-P_{\mathrm{Loop}} \tag{21}$$

3.4 群组相对策略优化

在多维度奖励函数设计的基础上,基于GRPO对LLM进行强化微调[25]。与传统强化学习方法严重依赖价值函数进行策略更新不同,GRPO通过引入一种基于组内相对优势评估的策略优化机制,显著提升模型在复杂环境中的策略探索能力。此外,传统强化学习容易因策略更新过快而陷入“策略漂移”问题,GRPO通过引入参考模型在训练中持续参考过去的动作策略,防止新策略偏离任务动作空间的合理边界,有效提升训练的收敛性。

对于微调数据集中的每个输入样本q,GRPO从监督微调预热后的策略模型$\pi_{\theta_{\mathrm{old}}}$中采样一组候选的开关动作$\{o_1,o_2,\cdots,o_G\}$。计算该组样本在与环境进行交互获得的奖励,以该组的平均奖励作为参考基准衡量每个动作相对于组内平均水平的优势程度。通过最大化目标函数$J_{\mathrm{GRPO}}(\theta)$优化策略模型$\pi_\theta$:

中国知网 https://www.cnki.net

$$J_{\mathrm{GRPO}}(\theta)=\mathbb{E}_{q\sim P(Q),\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\mathrm{old}}}(O|q)}\left[\frac{1}{G}\sum_{i=1}^{G}\min\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\mathrm{old}}}(o_i|q)}A_i,\ \mathrm{clip}\left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\mathrm{old}}}(o_i|q)},1-\varepsilon,1+\varepsilon\right)A_i\right)-\beta D_{\mathrm{KL}}(\pi_\theta\|\pi_{\mathrm{ref}})\right]G \tag{22}$$

式中：θ、θ_{old}分别为策略参数和更新前的参数；ε和β为超参数；G为每组采样的数量；clip(·)为操作函数，其主要目的是限制策略更新的幅度，避免模型在训练过程中因更新过度而导致不稳定或偏离合理范围；$\pi_{\theta_{\mathrm{old}}}(o_i|q)$为未更新参数前的策略模型；$A_i$为优势函数，通过使用一组奖励$\{r_1,r_2,\cdots,r_G\}$来进行计算，这些奖励对应于每个组内的输出；$\pi_{\mathrm{ref}}$为参考模型。

$$A_i=\frac{r_i-\mathrm{mean}(\{r_1,r_2,\cdots,r_G\})}{\mathrm{std}(\{r_1,r_2,\cdots,r_G\})} \tag{23}$$

式中：mean(·)为求一组奖励平均值的函数；std(·)为求一组奖励标准差的函数。

若组内某个输出的奖励高于组内平均值，则被视为具有正优势，其在策略分布中的采样概率将提升；反之，则为负优势，其采样概率将被抑制。

GRPO通过将策略模型与参考模型之间的KL(Kullback-Leibler)散度直接嵌入损失函数进行正则化，而不是作为惩罚项加入奖励函数中，从而有效简化训练过程。KL散度$D_{\mathrm{KL}}(\pi_\theta\|\pi_{\mathrm{ref}})$计算如下：

$$D_{\mathrm{KL}}(\pi_\theta\|\pi_{\mathrm{ref}})=\frac{\pi_{\mathrm{ref}}(o_i|q)}{\pi_\theta(o_i|q)}-\log\left(\frac{\pi_{\mathrm{ref}}(o_i|q)}{\pi_\theta(o_i|q)}\right)-1 \tag{24}$$

通过基于组内相对优势评估的策略优化机制，GRPO简化了奖励估计流程，有效避免了传统强化学习方法中对全局精确价值函数建模的依赖，有助于在状态空间多样、物理约束复杂、奖励稀疏的配电网运行场景中实现更稳定的策略优化。

4　算例分析

4.1　算例数据集

为验证所提KGE-REFT-LLM模型应用于配电网动态重构的可行性及优越性，采用改进的IEEE 33节点配电系统开展算例验证，其基准电压为12.66 kV，包含33个节点和37条支路，其中，分段开关和联络开关分别为32个和5个，拓扑结构如图4所示。在16、20、33号节点分别接入容量均为600 kW的分布式光伏，在18、24、29号节点分别接入容量为600、300、500 kW的风电。

选取南方某城市两年的负荷预测数据及风光出力预测数据，数据间隔采样时间为1 h，以一天为调度周期进行配电网动态重构。通过仿真生成约17 000个时间断面的配电网动态重构数据，分别采用1 000条和15 000条训练样本进行模型监督微调和强化微调，采用1 000条样本进行模型测试。基于零均值标准化方法对数据进行标准化预处理：

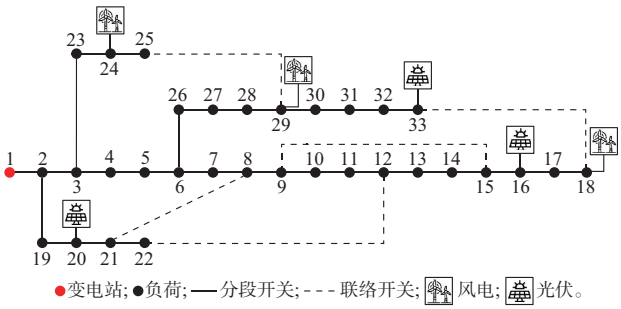


图4　改进的IEEE 33节点配电系统
Fig. 4　Modified IEEE 33-bus distribution system

$$x^*=\frac{x-\mu}{\sigma} \tag{25}$$

式中：x^*为配电网运行数据x的归一化值；μ和σ分别为配电网运行数据的平均值与标准差。

采用自顶向下、自底向上结合的方法构建面向配电网动态重构的动态知识图谱。每一个时间戳构建了与配电网动态重构任务密切关联的实体类型，如变电站、负荷、分段开关、联络开关、分布式光伏和风电等。部分面向配电网动态重构的动态知识图谱可视化展示结果如附录A图A1所示。

完整的知识图谱一共包括140.16万个实体和617 395条实体关系。通过时间戳在动态知识图谱中进行子图采样，依据LLM微调训练的输入输出格式规范，将结构化子图转化为自然语言描述的微调样本。LLM微调训练的提示词样例如附录A表A1所示。

4.2　模型性能评价指标

为量化评价所提配电网动态重构方法的有效性，本文分别采用系统网损P_{loss}、电压偏差U_{dev}、开关动作成本C_{line}和新能源消纳率η_{re}作为评价指标。功率损耗、电压偏差和开关动作成本越小，新能源消纳率越大，则表示配电网动态重构方案的效果越好，具体计算公式如下：

$$P_{\mathrm{loss}}=\sum_{t=1}^{T}\sum_{l\in\Psi_{\mathrm{L}}}I_{l,t}^2r_l\Delta t \tag{26}$$

中国知网　https://www.cnki.net

$$U_{\mathrm{dev}}=\sum_{t=1}^{T}\sum_{i=1}^{N_{\mathrm{b}}}|U_{i,t}-U_{\mathrm{ref}}|\Delta t \tag{27}$$

$$\eta_{\mathrm{re}}=\sum_{t=1}^{T}\sum_{i\in\Psi_{\mathrm{RES}}}\frac{(P_{i,t}^{\mathrm{RES,f}}-P_{i,t}^{\mathrm{RES}})\Delta t}{P_{i,t}^{\mathrm{RES,f}}}\times 100\% \tag{28}$$

4.3　模型训练过程分析

本文所有实验均基于PyTorch框架实现，在配有8张NVIDIA GeForce GTX A100 80 GB GPU的高性能计算平台上完成，确保了模型训练过程中的大规模并行计算能力与稳定的显存支撑。预训练LLM采用开源的Llama-3.1-8B模型，该模型采用优化的Transformer架构，支持128 KB超长上下文，可通过Hugging Face平台进行部署[26]。为了进一步优化模型性能和提高训练效果，在微调训练过程中采用网格搜索法选取最优的超参数配置。

第1阶段，通过1 000条高质量样本对预训练LLM进行监督微调预热训练，引入基于LoRA微调的参数高效微调方法，仅对特定模块中的低秩矩阵进行微调，确保模型能够在有限样本条件下快速掌握基础的配电网动态重构知识，大幅降低计算资源需求并避免灾难性遗忘现象。LoRA微调的配置参数见附录A表A2，包括微调目标模块、低秩矩阵的秩、低秩矩阵的缩放系数、LoRA层的丢失概率和学习率等参数。LoRA微调过程只激活约24.1 MB参数，占模型总参数的0.3%。

LLM监督微调的训练过程如图5所示，整体训练共进行了125步。在前10步内，训练损失从初始的0.13迅速下降至0.03，LLM在初始阶段表现出对任务知识的快速适应能力。随着训练的持续进行，模型进入稳定学习阶段。在第10步至第125步之间，训练损失下降速度减缓，波动逐步收敛至0.01以下，表明微调训练逐渐趋于收敛。LLM在监督微调训练过程中逐渐强化了对复杂任务指令、电网物理约束及动态重构逻辑的综合理解，能够响应任务指令并按照预定的输出格式进行决策。通过学习电网运行状态与开关动作之间的映射关系，LLM能够输出满足可行性要求的动态重构方案，从而为强化微调提供良好的初始化参数与先验策略。

第2阶段，进一步对监督微调后的LLM进行强化微调，通过GRPO算法对每步采样获得的一组候选策略进行奖励评估及策略更新。以组内平均奖励为参考基准，引导模型不断探索新的策略组合，在复杂动态环境中优化重构方案，确保模型在保持决策多样性的同时实现稳定、高效的策略学习。强化微调的配置参数如附录A表A3所示，涵盖采样温度、策略组大小、KL系数等关键参数。

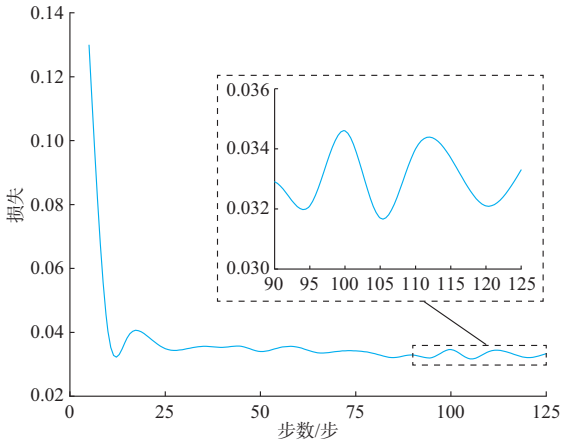


图5　监督微调训练过程

Fig. 5　Training process of supervised fine-tuning

LLM强化微调的训练过程如图6所示，整体训练共进行了300步。图中：监督微调用SFT表示。为验证监督微调预热训练在策略优化过程中的有效性，与未经过监督微调模型的奖励曲线进行对比分析。观察图7可知，监督微调预热训练有效减少了无效或不合理策略的搜索，模型强化微调训练的初始奖励更高，更快达到收敛稳定。

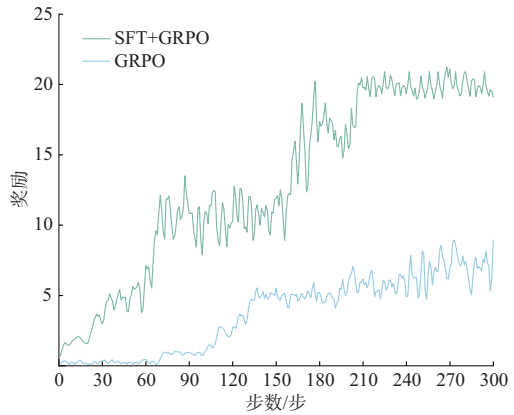


图6　强化微调训练过程

Fig. 6　Training process of reinforcement fine-tuning

得益于多维奖励函数的知识引导，强化微调模型在第210步左右即达到明显收敛，训练曲线趋于平稳，并在后续阶段保持稳定的策略表现，未出现明显的振荡或过拟合趋势。相比之下，缺乏预热训练的模型在强化微调阶段表现出收敛速度慢、奖励不稳定、策略发散等问题。

4.4　不同方法对比分析

为验证本文所提配电网动态重构方法的优越性，分别选用基于MISOCP的数学优化方法、基于近端策略优化(proximal policy optimization，PPO)算法及DDQN(double deep Q-network)算法的强化

中国知网 https://www.cnki.net

学习方法与本文方法进行对比。未经过微调的预训练LLM虽具备通用的语言理解能力，但缺乏对配电网动态重构任务的领域知识建模与指令响应能力，在测试过程中难以将输入的任务语义正确映射为满足运行约束的重构方案，无法参与性能指标的有效评价与量化分析。为验证所提KGE-REFT-LLM模型策略的有效性，将本文方法与仅经过SFT的LLM（LLM-SFT）进行对比。

表1详细列出了不同配电网动态重构方法的性能对比结果，主要评价指标包括系统网损、电压偏差、开关动作成本及新能源消纳率。其中，基于MISOCP的数学优化方法采用Gurobi求解器进行求解，在不考虑求解时效和计算复杂度的情况下，其优化结果具有全局最优性，可视为配电网动态重构优化效果的对比标准。

表1　不同方法的性能对比
Table 1　Performance comparison among various methods

方法	P_{loss}/MW	U_{dev}/p.u.	C_{line}/美元	η_{re}/%
MISOCP	0.55	10.63	280	100.00
PPO	0.64	12.21	400	99.68
DDQN	0.67	13.37	440	99.62
LLM-SFT	0.71	15.86	480	98.54
KGE-REFT-LLM	0.57	10.97	320	99.93

由表1对比分析可知，KGE-REFT-LLM方法在各个评价指标中均取得了接近最优的表现。在系统网损方面，KGE-REFT-LLM的损耗为0.57 MW，仅比理论最优的MISOCP高出0.02 MW，相较于传统强化学习方法PPO和DDQN分别下降10.94%和14.93%，显著减少了系统有功损耗。在电压偏差方面，KGE-REFT-LLM控制在10.97 p.u.，相较于PPO和DDQN分别下降11.32%和16.97%，说明所提方法能够更好地保证电压稳定性，满足配电网运行约束。在开关动作成本方面，KGE-REFT-LLM的成本为320美元，相较于PPO和DDQN分别下降20.00%和27.27%。在新能源消纳率方面，KGE-REFT-LLM达到99.93%，相较于监督微调模型LLM-SFT有效提高了1.39%。

传统强化学习方法虽具备一定的策略优化能力，但高度依赖价值函数进行策略评估与更新，在面对配电网复杂物理约束和动态变化运行状态时，易出现策略不稳定、收敛缓慢甚至失效的问题。与未经过微调的预训练LLM相比，监督微调后的LLM能够基于高质量样本积累的知识经验，显著提升对配电网重构的语义理解与指令响应能力，但仍存在2个核心问题：一是由于样本覆盖不足导致策略泛化能力弱；二是缺乏物理机理和运行约束的深度建模，导致在复杂工况下输出策略不满足潮流平衡或约束条件。强化微调阶段基于多维度奖励函数引导模型在与环境交互的过程中探索高质量的重构方案，因而在各项性能指标上表现出显著优势。

为直观展示本文所提配电网动态重构方法的性能，附录A表A4展示了所提方法的动态重构方案，图7和图8分别展示了配电网动态重构前后的系统网损对比及节点电压对比结果。

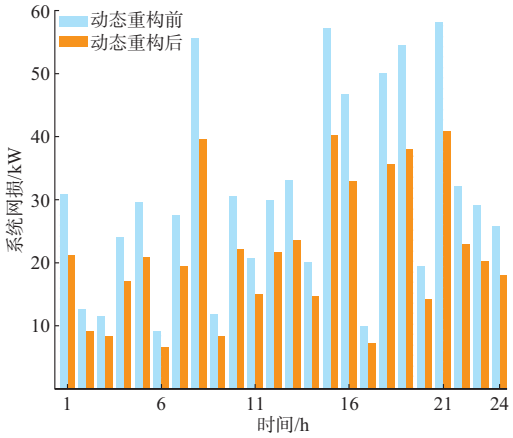


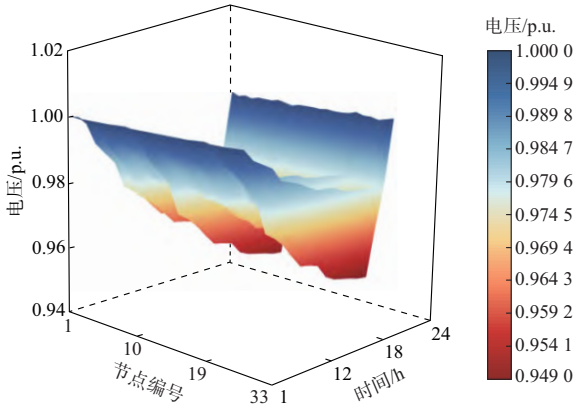
图7　重构前后系统网损对比
Fig. 7　Comparison of network loss before and after reconstruction

从图7可以明显观察到，动态重构后系统网损显著降低，表明生成的重构方案有效优化了网络潮流路径，减少了能量在传输过程中的损耗。图8进一步展示了动态重构前后节点电压的变化情况。结果表明，重构后电压整体更加接近额定值，电压偏差幅度显著收敛，说明所提方法不仅优化了供电路径，还有效控制了系统的电压质量，满足系统运行安全性要求。

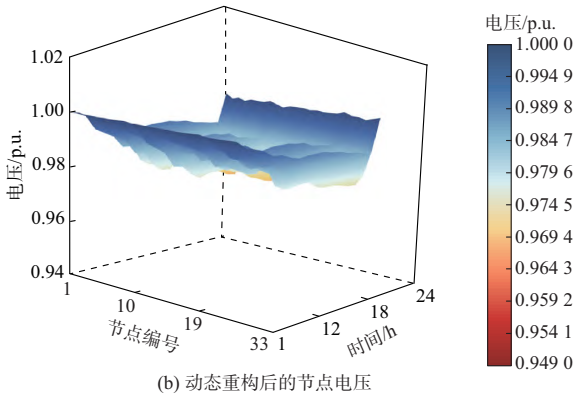
4.5　算法计算效率对比分析

表2展示了本文所提配电网动态重构方法与其他方法在训练时间以及单次决策时间的比较。结果表明，KGE-REFT-LLM在训练阶段耗时为522.3 min，远高于传统强化学习方法，这主要由于GRPO机制需对每个输入样本采样一组候选的开关动作进行相对优势评估，训练过程中的反向传播与权重更新需消耗大量计算资源。尽管训练成本较高，模型在试错中不断提升动态重构任务的推理能力，具有可接受的训练成本。在决策时间方面，所提方法仅需11.6 s即可完成一次动态重构策略生成，虽然略高于传统强化学习方法，但相较于基于MISOCP的数学优化方法，决策时间减少约75.73%，显著提升了决策效率。

中国知网　https://www.cnki.net



(a) 动态重构前的节点电压



(b) 动态重构后的节点电压

图 8　重构前后电压对比
Fig. 8　Comparison of voltage before and after reconstruction

表 2　不同方法的计算时间
Table 2　Calculation time of various methods

方法	训练时间/min	决策时间/s
MISOCP		47.8
PPO	124.3	5.7
DDQN	130.7	6.2
LLM-SFT	55.3	10.8
KGE-REFT-LLM	522.3	11.6

4.6　算法可扩展性分析

为了验证所提方法的可扩展性，采用改进的南方某区域 225 节点配电网开展算例仿真和分析，进一步评估所提方法在大规模配电网中的动态重构性能。改进的南方某区域 225 节点配电网拓扑结构如附录 A 图 A2 所示，包含 225 个节点和 225 条支路，其中，分段开关和联络开关分别为 36 个和 3 个。在 25、104、138、212 号节点分别接入容量均为 600 kW 的分布式光伏，在 53、144、179、197 号节点接入容量均为 500 kW 的风电。

表 3 展示了本文所提方法与其他方法在改进南方某区域 225 节点配电网中的性能对比结果，各评价指标中均取得了接近最优的表现。相比于效果较好的 PPO 方法，所提方法的系统网损、电压偏差和开关动作成本分别降低了 11.73%、7.57% 和 20%，新能源消纳率提高了 0.22%。

表 3　大规模配电网中不同方法的性能对比
Table 3　Performance comparison among various methods in large-scale distribution network

方法	P_{loss}/MW	U_{dev}/p.u.	C_{line}/美元	η_{re}/%	训练时间/min	决策时间/s
MISOCP	1.37	5.47	280	100.00		1 785.4
PPO	1.62	6.08	400	99.67	334.2	10.6
DDQN	1.67	6.21	440	99.51	413.5	12.7
LLM-SFT	1.71	6.28	520	99.24	113.4	21.5
KGE-REFT-LLM	1.43	5.62	320	99.89	841.6	23.1

尽管所提方法的训练时间显著高于对比方法，但其决策时间仍控制为 23.1 s。相较于基于 MISOCP 的数学优化方法，决策时间显著减少约 98.71%，表明其具备良好的在线决策效率，验证了本文方法的可扩展性与实际部署价值。

所提模型在推理服务器上部署后，无需调用复杂仿真工具或数学求解器，可实现配电网动态重构的端到端决策，能够满足实际配电网的滚动优化与实时调控需求。通过监督微调训练，模型在小样本情况下即可完成新场景适配，实现快速迁移部署。

5　结语

针对海量分布式新能源和电动汽车接入后引发的网损增加、电压越限、新能源弃电等问题，本文提出了一种基于 KGE-REFT-LLM 的配电网动态重构方法。所提方法在改进的 IEEE 33 节点配电系统及南方某区域 225 节点配电网上进行仿真验证，可得出以下结论：

1）融合海量多源异构数据构建面向配电网动态重构的动态知识图谱，通过子图采样生成兼具复杂时序演化与因果逻辑关系的高质量微调数据集，并设计多维度奖励函数引导强化微调训练，有效增强了 LLM 在复杂运行场景下的决策能力。

2）基于少量高质量微调样本进行监督微调预热训练，有效提升了 LLM 对配电网重构逻辑的语义理解与指令响应能力，有效缩减强化微调阶段的动作搜索空间。基于海量微调样本进行强化微调训练，进一步增强了模型的策略探索能力与动态环境适应性。

3）通过引入群组相对策略优化机制进行策略更新，在状态空间多样、物理约束复杂、奖励稀疏的配

中国知网 https://www.cnki.net

电网复杂决策任务中展现出更强的计算稳定性，同时具备良好的在线决策效率。

为提升模型对配电网运行场景持续演化的适应能力，未来工作将探索基于在线强化学习与持续微调的策略更新机制，使LLM在学习新任务的同时有效避免灾难性遗忘。

附录见本刊网络版，点击 http://www.aeps-info.com/aeps/article/abstract/20250719001，或扫描英文摘要后二维码，可阅读全文。

参 考 文 献

[1] 舒印彪，汤涌，张正陵，等．新型配电网构建及其关键技术[J]．中国电机工程学报，2024，44(17)：6721-6733.
SHU Yinbiao, TANG Yong, ZHANG Zhengling, et al. Construction of new distribution network and its key technologies [J]. Proceedings of the CSEE, 2024, 44(17): 6721-6733.

[2] 李金鹏，冯华，陈晓刚，等．计及多重不确定性的规模化电动汽车接入配电网调度方法[J]．电力系统自动化，2024，48(7)：138-146.
LI Jinpeng, FENG Hua, CHEN Xiaogang, et al. Dispatching method for large-scale electric vehicles connecting to distribution network considering multiple uncertainties [J]. Automation of Electric Power Systems, 2024, 48(7): 138-146.

[3] BAHRAMI S, CHEN Y C, WONG V W S. Dynamic distribution network reconfiguration with generation and load uncertainty [J]. IEEE Transactions on Smart Grid, 2024, 15(6): 5472-5484.

[4] JABR R A, SINGH R, PAL B C. Minimum loss network reconfiguration using mixed-integer convex programming [J]. IEEE Transactions on Power Systems, 2012, 27(2): 1106-1115.

[5] ZAFAR R, POTA H R. Multi-timescale coordinated control with optimal network reconfiguration using battery storage system in smart distribution grids [J]. IEEE Transactions on Sustainable Energy, 2023, 14(4): 2338-2350.

[6] LEE C, LIU C, MEHROTRA S, et al. Robust distribution network reconfiguration [J]. IEEE Transactions on Smart Grid, 2015, 6(2): 836-842.

[7] 朱红，胡子健，许洪华．模糊机会约束与图模型驱动的多目标配电网重构[J]．广东电力，2025，38(9)：119-129.
ZHU Hong, HU Zijian, XU Honghua. Multi-objective distribution network reconstruction based on fuzzy chance constraint and graph model-driven approach [J]. Guangdong Electric Power, 2025, 38(9): 119-129.

[8] XU J, GAO H J, WANG R J, et al. Real-time operation optimization in active distribution networks based on multi-agent deep reinforcement learning [J]. Journal of Modern Power Systems and Clean Energy, 2024, 12(3): 886-899.

[9] 吴文传，蔺晨晖，孙宏斌，等．基于机器学习的主动配电网能量管理与运行控制[J]．电力系统自动化，2024，48(20)：2-11.
WU Wenchuan, LIN Chenhui, SUN Hongbin, et al. Machine learning based energy management and operation control for active distribution networks [J]. Automation of Electric Power Systems, 2024, 48(20): 2-11.

[10] 董雷，吴怡，张涛，等．基于强化学习的含智能软开关主动配电网双层优化方法[J]．电力系统自动化，2023，47(6)：59-68.
DONG Lei, WU Yi, ZHANG Tao, et al. Reinforcement learning based double-layer optimization method for active distribution network with soft open point [J]. Automation of Electric Power Systems, 2023, 47(6): 59-68.

[11] GAO H J, JIANG S Y, LI Z M, et al. A two-stage multi-agent deep reinforcement learning method for urban distribution network reconfiguration considering switch contribution [J]. IEEE Transactions on Power Systems, 2024, 39(6): 7064-7076.

[12] 李鹏，黄文琦，梁凌宇，等．人机混合增强决策智能在新型电力系统调控中的应用与展望[J]．中国电机工程学报，2024，44(16)：6347-6367.
LI Peng, HUANG Wenqi, LIANG Lingyu, et al. Application and prospect of hybrid human-machine decision intelligence in the dispatch and control of next-era power systems [J]. Proceedings of the CSEE, 2024, 44(16): 6347-6367.

[13] 李鹏，余涛，李立涅，等．电力人工智能的演变与展望——从专业智能走向通用智能[J]．电力系统自动化，2024，48(16)：1-17.
LI Peng, YU Tao, LI Licheng, et al. Retrospect and prospect of artificial intelligence for electric power system—from domain intelligence to general intelligence [J]. Automation of Electric Power Systems, 2024, 48(16): 1-17.

[14] 孙秋野，张瑞霞，陈东岳．大模型技术赋能电力系统的应用及技术路线展望[J/OL]．电力系统自动化[2025-03-18]．https://kns. cnki. net/kcms/detail/32.1180. TP. 20250317.1811.006. html.
SUN Qiuye, ZHANG Ruixia, CHEN Dongyue. Applications and technical route prospects of large model technology in empowering power system [J/OL]. Automation of Electric Power Systems [2025-03-18]. https://kns. cnki. net/kcms/detail/32.1180.TP.20250317.1811.006.html.

[15] YAN Z M, XU Y. Real-time optimal power flow with linguistic stipulations: integrating GPT-agent and deep reinforcement learning [J]. IEEE Transactions on Power Systems, 2024, 39(2): 4747-4750.

[16] YANG X, LIN C H, LIU H T, et al. RL2: reinforce large language model to assist safe reinforcement learning for energy management of active distribution networks [J]. IEEE Transactions on Smart Grid, 2024, 16(4): 3419-3431.

[17] CAO Y, ZHAO H, CHENG Y, et al. Survey on large language model-enhanced reinforcement learning: concept, taxonomy, and methods [J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(6): 9737-9757.

[18] RUAN J Q, LIANG G Q, ZHAO H, et al. Applying large language models to power systems: potential security threats [J]. IEEE Transactions on Smart Grid, 2024, 15(3): 3333-3336.

[19] CHENG Y, ZHAO H, ZHOU X, et al. A large language model for advanced power dispatch [J]. Scientific Reports (Nature Portfolio), 2025, 15(1): 8925.

[20] ZHANG Y, YANG Y, SHU J, et al. OpenRFT: adapting

中国知网　https://www.cnki.net

reasoning foundation model for domain-specific tasks with reinforcement fine-tuning [EB/OL]. [2025-07-19]. https://arxiv.org/abs/2412.16849.
[21] 陈宗源,余涛,丁茂生,等.基于时空卷积动态知识图谱的新能源消纳评估方法[J].电力系统自动化,2023,47(15):46-54.
CHEN Zongyuan, YU Tao, DING Maosheng, et al. Renewable energy accommodation assessment method based on spatiotemporal convolution dynamic knowledge graph [J]. Automation of Electric Power Systems, 2023, 47(15): 46-54.
[22] PAN S R, LUO L H, WANG Y F, et al. Unifying large language models and knowledge graphs: a roadmap [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.
[23] YANG L Y, CHEN H Y, LI Z, et al. Give us the facts: enhancing large language models with knowledge graphs for fact-aware language modeling [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3091-3110.
[24] HU J E, SHEN Y L, WALLIS P, et al. LoRA: low-rank adaptation of large language models [C]// International Conference on Learning Representations, April 25-29, 2022, Appleton, USA.
[25] SHAO Z, WANG P, ZHU Q, et al. Deepseekmath: pushing the limits of mathematical reasoning in open language models [EB/OL]. [2025-07-19]. https://arxiv.org/abs/2402.03300.
[26] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The Llama 3 herd of models [R]. Menlo Park, USA: Meta AI, 2024.

陈宗源(1999—),男,博士研究生,主要研究方向:人工智能技术在电力系统中的应用、电力系统优化运行与控制。E-mail:scut_czy@qq.com

余　涛(1974—),男,通信作者,博士,教授,博士生导师,主要研究方向:复杂电力系统的非线性控制理论、优化及机器学习。E-mail:taoyu1@scut.edu.cn

卢建刚(1970—),男,硕士,教授级高级工程师,主要研究方向:智能电网、配电网、电力系统保护与控制。E-mail:jg_lu@sina.com

(编辑　代长振)

Dynamic Reconfiguration of Distribution Network Based on Knowledge Graph Enhancing Reinforcement Fine-tuning of Large Language Model

CHEN Zongyuan[1], *YU Tao*[1], *LU Jiangang*[2], *PAN Zhenning*[1], *LUO Qingquan*[1], *ZHOU Guoxun*[1]
(1. School of Electric Power Engineering, South China University of Technology, Guangzhou 510641, China;
2. Guangdong Power Grid Co., Ltd., Guangzhou 510180, China)

Abstract: Dynamic reconfiguration of distribution network enables more flexible operational regulation through topology adjustment. However, the existing decision-making technologies struggle to balance computational real-time performance and reliability. Large language models (LLMs), with their powerful semantic understanding, in-context learning, and generative decision-making capabilities, demonstrate significant potential for complex decision-making problems such as dynamic reconfiguration of distribution network. Nevertheless, their direct application to dynamic reconfiguration optimization faces challenges including the absence of structured domain knowledge, insufficient task comprehension and adaptation capabilities, and difficulties in embedding physical constraints, thereby compromising decision reliability. To address these issues, this paper proposes a dynamic reconfiguration method of distribution network based on knowledge graph enhancing reinforcement fine-tuning of LLM. First, a dynamic knowledge graph is constructed to explicitly represent the temporal evolution and causal logical relationship of distribution network operation. Second, high-quality fine-tuning datasets are generated through subgraph sampling of knowledge graph, and the supervision and fine-tuning of the pre-trained LLM is completed to enhance its task comprehension and instruction-following capabilities. Finally, a multi-dimensional reward function is designed based on the structured prior knowledge from the knowledge graph, and the group relative policy optimization is introduced for reinforcement fine-tuning of the model. Case analyses demonstrate that the proposed method significantly improves the generation efficiency and physical consistency of dynamic reconfiguration strategies of distribution network, effectively improving the operational level of distribution network.

This work is supported by Smart Grid-National Science and Technology Major Project of China (No. 2024ZD0802200).

Key words: distribution network; dynamic reconfiguration; large language model (LLM); artificial intelligence; reinforcement; fine-tuning; operational control; knowledge graph

中国知网 https://www.cnki.net